

从单次运行多样性到稳定互补性：AI 生成 HAR- NESS 群体的测量问题 (中文参考译本)

Anonymous authors

Paper under double-blind review

ABSTRACT

自动生成的 LLM harness 可以在源代码、实际执行的机制和正确性结果上有所不同，但这些差异未必意味着可重复的新增能力。我们在 BIRD 文本转 SQL 任务上研究这一问题。在发现阶段的一个种群中，尽管源代码不同，91 对 harness 中仍有 36 对在全部已评估题目上的正确性结果完全相同；轨迹检查发现了机制缺失、分支未触发和多轮路径失效。后续析因研究在六个构建器、三个种子上交叉设置策略强制与准入门控，使用 1,169 道题和官方 BIRD 评分器。自由生成已产生 8.6 个百分点的观测 oracle 提升空间。对存档实验的审后重分析估计，组合干预的效应为 -0.16 个百分点 (95% CI $[-0.83, +0.87]$)，未显示明确改善。实际门控还排除了两种原本允许的提示层策略，因此该对比无法单独识别验证的作用。重复执行显示结果不稳定，单次运行的 oracle 可以利用这种波动，而不要求稳定的机制互补。我们区分观测提升空间与稳定的题目—harness 优势，并说明将二者连接到实际选择收益所需的对照。当前证据明确了这些测量边界，尚未识别超出重复采样的稳定互补性。

1 引言

LLM harness 是包裹冻结模型的一组提示、工具与控制流程程序。自动生成大量这类程序带来一个评估问题：什么证据能够说明新程序提供了新能力？不同代码可能执行相同路径，不同路径可能给出相同答案，而一次运行中不同的答案可能来自执行随机性，并非可重复的优势。

我们在 BIRD 文本转 SQL 任务上研究这一问题 (Li et al., 2023)。在 Phase-I 发现种群中，66 对生成候选中有 21 对的正确性向量相同；加入预置的 `react` 和 `bare` 基线后，为 91 对中的 36 对。代码相似度与结果分歧没有观测到秩关联 ($\rho = -0.01$)。轨迹检查区分出三种情况：宣称的机制未进入控制流程；机制存在但在所检查题目上未触发；多轮实现失效。这些观察促使我们审核测量流程，不能证明生成的 harness 普遍坍塌。

后续预先指定的析因研究在六个构建器、三个种子上交叉设置策略强制与一致性门控。主评估使用协议开发之外的九个数据库、1,169 道题，并披露保留了一个 18 题冒烟测试例外。在这一调整后的设置中，无门控自由生成已产生 8.6 个百分点的观测 oracle 提升空间。Phase-I 模式没有再次出现，但生成方式、评分器、数据和执行均有变化，缺少受控桥接实验时不能归因于某一个协议要素。

原门控还改变了允许进入种群的策略空间：两种允许的单个调用提示变换无法通过机制检查。因此，该干预把机制筛选与一致性验证混合在一起。我们保留原实验，报告版本化的审后重分析，不将其视为修复后门控的试验。主对比仍为 -0.16 个百分点 (95% CI $[-0.83, +0.87]$)；该估计既未证明改善，也未确立等效性。

当前贡献是对三项测量边界的实证说明：

1. **代码、轨迹和结果多样性不同。**发现阶段的例子说明，未激活的分支与缺失的机制需要不同的检验。
2. **准入规则和推断方式决定比较含义。**析因研究及其数据、统计链条的明确修正，说明实际评估了哪项干预，以及估计支持什么。
3. **观测 oracle 价值不等于稳定或可用价值。**重复波动和探索性选择结果要求分别报告 oracle 准确率、最佳固定成员准确率、跨重复优势与实际选择器表现。

决定性问题是：真实 harness 种群能否超过相同预算下同一代码的独立执行种群，而且优势能否在独立重复中保留？当前研究尚未完成这一对照。因此，稳定互补性是待检验的估计目标，尚非已经发现的性质。

2 相关工作

2.1 面向 LLM 的 HARNESS 生成

一系列工作为冻结模型生成任务专用的外围程序。TTHE 通过 LLM 提议者 / 评判者循环演化文本转 SQL harness (Nie et al., 2026)；Self-Harness 展示模型改进自身 harness 的能力 (Zhang et al., 2026b)；JIT-Agent 训练模型在推理时为每道任务生成 harness (Zhang et al., 2026a)；Task-CoEvolve 联合演化任务与程序框架 (Miyai et al., 2026)。2026 年的同期研究从验证侧将行为信号纳入演化：HarnessLens 在演化过程中以行为检查分配 rollout 预算 (Xu et al., 2026)；HarnessFix 根据轨迹诊断修复 harness (Chen et al., 2026)；AHE 按每次编辑自述的行为预测进行验证 (Lin et al., 2026)；带门控的语义质量—多样性搜索按 LLM 指派的问题描述符演化种群 (Luo et al., 2026)；Harness Handbook 研究行为定位与外层搜索 (Wang et al., 2026)。

我们的分析单位与问题有所不同。表 1 比较最接近的两个系统。HarnessLens 将行为作为演化循环内部的计算分配信号；我们将整个种群的行为多样性作为结果性质，比较其在生成侧干预下的变化。HarnessBank (Luo et al., 2026) 记录搜索空间坍塌，并以门控筛选维护语义多样性库；我们的一致性门控不进行语义评分，而是借助反事实轨迹探针

	本研究	HarnessLens	HarnessBank
研究单位	种群结果矩阵	演化循环	多样性库
测量种群坍塌	是	否	仅搜索坍塌
门控定义	反事实轨迹	可归因证据	语义筛选
门控校准	正 / 负控制	—	—
门控比较	析因, 混合筛选	单因素消融	无
验证性划分	九个隔离数据库	—	—

表 1: 最接近的同期系统。演化系统内部的行为验证属于同期独立工作；本研究关注种群结果测量、仪器校准和生成策略对比。当前门控包含结构性筛选；数据库隔离存在已披露的 18 题冒烟接触例外。

机械检查声明机制是否执行，再通过析因对比比较准入策略。但实际门控也排除了允许的提示变换，因此当前实验无法单独识别验证的因果贡献。

2.2 HARNESS 的条件效用与路由

Harness 质量取决于具体实例：Gupta et al. (2026) 和 Cho (2026) 指出，单个 harness 不会在所有实例上占优。HELIX 评估同源 harness 的完整结果矩阵及超过最佳固定候选的组合互补性，并将路由器列为未来工作 (Fan & Huang, 2026)。STS 在六种固定人工程序框架之间路由 (Zhou et al., 2026)；GRASP 在开发阶段将技能编辑经门控纳入库中 (Moll et al., 2026)；Kim (2026) 在“不搜索、搜索、弃答”之间学习实例级路由；Liu et al. (2026) 在 harness 内部路由模型。经典算法选择 (Rice, 1976) 及 SATzilla 等组合求解器 (Xu et al., 2008; Kotthoff, 2014) 根据实例特征选择列举的算法。

我们的候选是完整的自动生成 harness；本研究测量选择器将继承的种群结果结构 (§5.4)，而不构建选择器。我们诊断执行路径，并通过包含结构筛选成分的析因处理比较生成策略；当前研究尚未确立稳定的可选择价值。

2.3 LLM 种群的行为多样性

LLM 输出多样性主要在样本层面（自治性、多样化解码）或智能体策略层面得到研究。语法不同的程序可能表现相同，这与程序合成和变异测试中的覆盖缺口相呼应；本研究将其具体化为 AI 生成 harness 种群的测量，并给出机制层面的分类。

3 PHASE I: 坍塌的测量与诊断（发现研究）

Phase I 是发现研究，用于描述现象、建立分类、观察题目层面的提升空间并提出后续设计。其结果均非验证性证据：151 道评估题中有 24 道与协议开发测量重叠；人工控制是在检查开发轨迹后设计的；评分器是保守代理（附录 A）。

3.1 HARNESS、结果与三项指标

Harness H 包裹冻结的目标模型 M ：接收自然语言任务 x ，调用一次或多次 M ，可选地执行中间产物（如 SQL），返回程序化评分的最终答案。以 H_0 为单次调用的 bare 基线， $Y \in \{0, 1\}$ 表示正确性，定义**边际价值** $\Delta(x, H, M) = Y(x, H, M) - Y(x, H_0, M) \in \{-1, 0, +1\}$ ，其中 $+1$ 为修复， -1 为 harness 引入的损害。

我们建议生成和路由流程在留出集报告三项前提指标，它们均可由评估结果矩阵计算：（i）**成对结果分歧**，即各 harness 对在多少比例题目上正确性不同；（ii）**联合修复率**，即 bare 错题中有多少被至少一个种群成员修复；（iii）**包含 bare 的 oracle 提升空间**

$$H(P) = \text{Acc}(x \mapsto \max_{H \in P \cup \{H_0\}} Y(x, H)) - \max_{H \in P \cup \{H_0\}} \text{Acc}(H).$$

正的观测提升空间记录了该次执行矩阵中依题目而异的成功；稳定路由信号还需要独立重复验证。只有分歧而没有修复，不增加超出 bare 的观测覆盖；有修复而没有提升空间，则没有超过最佳固定成员的观测 oracle 优势。

3.2 坍缩的量化

任务为 BIRD 文本转 SQL（SQLite，执行准确率评分），Phase I 的目标固定为 **GLM-5.3-Flash**，温度为 0。首日种群为 14 个 harness（bare、react 及 12 个演化候选）乘 60 道题，平均成对结果分歧为 **3.3%**，**91** 对中有 **36** 对在全部题目上相同。仅计 12 个生成候选时，共 66 对，原代码差异检查的归一化字符指标下平均代码相似度为 0.143；结果分歧为 3.8%，21 对完全相同。每个候选均通过了代码差异检查（“文件均不同，差异非平凡”）。bare 错题的联合修复率为 7.7%，oracle 提升空间为 3.3 个百分点；react 与 bare 在全部题目上结果一致。

图 1 量化了这一关系。91 对的 token 序列代码相似度均值为 0.190（不同于上述仅候选的字符指标 0.143），与结果分歧的 Spearman $\rho = -0.010$ 。该种群中未观测到代码相似性与行为相似性的秩关联。各对共享 harness，并非独立样本；此处 ρ 仅作描述，不作推断检验。

3.3 轨迹分类：代码多样性为何未转化为行为多样性

逐题审核 LLM 调用与产物执行序列，可区分三类失败：

- **T1：描述了机制，却未执行（6/12 个候选）**。恰好一次 LLM 调用，未执行任何产物，路径与 bare 相同。文档字符串宣称检索、自检或 token 上限，控制流程中却没有对应实现。
- **T2：机制存在，但未触发（react，所审 10/10 题）**。第一条 SQL 成功执行，错误修复未触发，最终 SQL 与 bare 相同。这不能说明发生失败时修复反馈缺少因果路径。




图 1: 语法多样性与行为坍缩 (Phase I, 发现研究)。首日 14 个 harness、60 道题, 91 对含 bare 和 react。每点为一对: 横轴是 token 序列代码相似度, 纵轴是正确性不同的题目比例; $\rho = -0.01$, 36/91 对在全部 60 题上相同。原始点见代码材料中的 `fig1_phenomenon_data.json`。

- **T3: 多轮路径失效 (1/12)**。实际实现多轮修复的候选返回自然语言说明作为最终 SQL, 将 bare 答对的题变为错误。

T1 需要执行路径准入检查, T2 需要受控故障来检验触发和反馈使用, T3 需要可执行输出验证; 这些均涉及生成协议。

3.4 人工正控制: 观测提升空间

为检查不同人工机制能否增加观测覆盖, 我们编写四种执行路径明确不同的 harness: `hpc_repair` 执行后修复, `hpc_vote3` 对三份执行结果投票, `hpc_schema` 做模式关联, `hpc_hint` 将提示前置。目标、任务、评分器与坍缩种群相同; 60 题上的 oracle 提升空间为 **6.67** 个百分点, 151 题上为 **7.28** [3.3,10.0]; `repair`、`schema`、`hint` 各有其他成员未覆盖的修复。但控制是在检查首日轨迹后设计的, 其提升空间是描述结果, 不是稳定互补性的盲估计。两次首日运行中, bare 自身也在 60 题中翻转了 3 题, 显示温度为 0 时仍有 API 非确定性。

3.5 PHASE-I 协议探查及局限

我们还探查了策略强制的自由形式协议 (指定机制, 通过导入 / 冒烟检查准入) 及编译式 Harness IR。策略强制下, 三个构建器中有两个种群的点估计超过预先指定的阈值: Qwen3.8-Flash 为 5.96、DeepSeek-V4-Flash-Vision-Exp 为 7.95 个百分点; 旧协议组为 4.64, 未达到阈值。记录工具下的各策略接纳数量随构建器不同: GLM-5.3-Flash 为 3/8、Qwen3.8-Flash 为 7/8、DeepSeek-V4-Flash-Vision-Exp 为 8/8。

这些观察促成 Phase II，但不是验证性结果：设计是两个嵌套对比，无法分开协议和构建器主效应；早期运行缺少逐尝试日志，无法审核预算相等；准入仅检查导入 / 冒烟，并非 §4 的反事实一致性门控。完整条件见附录 A。

生成空结果失败 (M0)。 以 Qwen3.8-Flash 和 DeepSeek-V4-Flash-Vision-Exp 重新运行原优化循环，得到 40 个与 `bare` 源码逐字节相同的候选。代码相同本身不意味着随机执行结果必然相同。这次运行没有形成不同代码的种群，属于更基础的生成失败；上述坍塌主张仅基于源代码确实不同的首日种群。

4 PHASE II: 验证性生成研究 (设计)

Phase II 是验证性研究。协议在观察验证性结果前冻结并提交，但存在协议偏差日志 D1 披露的例外：18 题流水线冒烟测试的聚合准确率曾被观察，题目仍被保留。偏差均记录于变更日志 (附录 B)。以下概述冻结的估计目标、划分、仪器与分析计划。

4.1 设计

实验组。 交叉设置两个因素：策略强制 ($S=1$ ：从固定八种机制中指定一种； $S=0$ ：不指定机制，由构建器自行改进) 与一致性门控 ($G=1$ ：须通过冻结的套件； $G=0$ ：仅检查中性有效性)。四组为 **II-A** (自由 / 无门控)、**II-B** (自由 / 有门控)、**II-C** (强制 / 无门控)、**II-D** (强制 / 有门控)。预先指定的次要组 **II-E** 为开放机制发现：构建器用通用轨迹原语自行声明行为合同，再按其声明门控，用于检验机制多样性是否需要作者给定词汇；它不属于析因设计。这些名称专用于 Phase II，Phase-I 条件使用描述性名称。

实际实施的处理。 原门控将 `hint_guard` 和 `format_guard` 映射到返回 `NO_MECHANISM_declared` 的普通场景，而准入要求 `PASS`。因此，八个强制策略槽位中的两个，即使中性有效也无法通过。G 应解释为非平凡机制筛选加一致性验证；存档结果无法识别纯验证作用，匹配种群规模也无法恢复被排除的类型。另外，两个强制组各 18 个 `format_guard` 槽位、54 次尝试均未通过中性有效性检查，发生在机制门控之前。代码提取审计发现一种可能的上游失败：内嵌 SQL 围栏会截断原本有效的 Python 代码 (附录 B)。

相同尝试上限，实际成本不等。 每槽位最多 $R = 3$ 次原始构建尝试，使用同一模型、温度 0.7、16,384 token 上限，首次接纳即停止。原协议的“恰好三次”不符合实际执行。A/B/C/D 的日志原始尝试数为 269/255/273/324，每组上限 432；实际 token 成本尚未完整恢复。各组的生成提示和准入策略不同：无门控组接纳首个中性有效候选 (可解析、可导入、在一道开发题上返回 SQL，不检查机制)；有门控组额外要求通过一致性套件。槽位失败后不补齐种群，生成可靠性因此也是处理的一部分。已保存提取后的代码文件与尝试日志，但生成器未存档完整构建器回复。三项生成率单独报告： R_{artifact}

Phase-II confirmatory design: database-level isolation, 2x2 factorial + open-mechanism arm, three-layer admission




图 2: **Phase-II** 验证性设计。左: 数据库级隔离, 两个开发库整体禁用; 九个评估库存在文中披露的 18 题冒烟例外。中: 策略强制乘一致性门控的 2×2 设计, 尝试上限相同、实际成本不同, 另有开放机制组 II-E。右: 中性有效性、反事实一致性及相对 bare 非空洞性的三层准入。

为有效产物率, R_{contract} 为有效且非空洞的合同率, R_{fidelity} 为在合同有效条件下声明属性得到验证的比例。

构建器与种子。 六个独立实验室的构建器为 GLM-5.3、Qwen3.8-Max、DeepSeek-V4-Pro、Kimi-K3、MiniMax-M3、ERNIE-5.0-Thinking-Preview, 各三个种子, 共 18 个配对单元。它们是项目单一 API 网关当时可用的最强模型; 无法访问 Anthropic 或 OpenAI 家族构建器, 因此尚未检验对这些模型能力的依赖。所有单元均进入主对比, 包括 $K = 0$; 排除低产出单元会以处理后的结果为条件。

数据隔离。 污染寄存器扫描项目产物中曾观察过的 BIRD 题目, 并在检查失败时拒绝继续。开发阶段接触的两个数据库整体禁用; 验证集包含九个数据库的 1,169 道题。除已披露的 18 题冒烟接触外, 九库未用于项目协议开发; 寄存器能支持的是没有项目特定的自适应使用, 不能保证训练数据隔离。分层抽取的 400 题核心集在结果出现前确定, 四组析因次要分析使用相同题目。

评分器。 主评分为官方 BIRD 执行评分器, 对原始结果行做集合相等比较, 墙钟超时 30 秒。次要评分为 Phase-I 旧评分器; 在 Phase-I 矩阵中的检查显示, 它相对官方评分器一致偏保守, 没有把官方判错的答案判对。

测量仪器。 一致性套件以脚本场景驱动 harness, 断言所记录的执行轨迹, 不依据任务成绩, 避免以结果监督进行准入。机制探针使用正确答案不同的成对反事实变体, 其中包括首条查询成功的变体, 以区分条件修复与无条件第二次调用; 输出按精确的归一化相等比较。在 Phase-II 生成前, 套件以三个人工正控制 (均须通过)、两个已知伪机制负例 (均须拒绝) 及 bare 必须违反每个条件属性的不变量进行校准; 每批生成前重跑校准。II-E 还运行 bare 检查合同非空洞性, 即 bare 必须违反该属性, 并仅验证实际声明的属性。

Metric	II-A	II-D
Candidate count	5.78	3.83
Oracle accuracy (%)	76.14	75.70
Best-fixed accuracy (%)	67.58	67.30
Headroom (pp)	8.56	8.40
D-A headroom (pp)	-0.16	
Unadjusted bootstrap 95% CI	[-0.83, +0.87]	
One-sided sign-flip p	0.647	

表 2: 原干预的修正主分析。1,169 题上 18 个构建器一种子单元的均值。oracle 与最佳固定比较均包含 bare。CI 纳入题目与生成种子变化, 以六个固定构建器及存档执行为条件; 符号翻转参考检验以观测题目为条件, 并假设单元对比对称。图表内英文标签与数值直接共用英文产物。

4.2 冻结分析计划

主估计目标为完整 1,169 题、官方评分器下, 18 个构建器乘种子单元中包含 bare 的 oracle 提升空间配对差 $H(\text{II-D}) - H(\text{II-A})$, 报告连续效应、双侧 95% CI 和配对置换检验, 不用通过 / 失败阈值。Phase-I 阈值仅保留为描述性清单。验证性次要目标在共同 core-400 上包括门控主效应 $[(B - A) + (D - C)]/2$ 、策略主效应 $[(C - A) + (D - B)]/2$ 、交互 $(D - C) - (B - A)$, 三项检验经 Holm 校正。

原计划与修正推断。原主分析代码漏掉库内题目重采样, 且各单元分别采样题目; 原析因代码仅重采样单元摘要。审后版本化分析在全部组和单元之间共用 10,000 组数据库 / 库内题目抽样, 固定构建器, 在各构建器内重采样生成种子。它未增加执行重复方差。精确符号翻转参考检验以已观察题目为条件, 并假设单元对比的符号对称; 主检验单侧, 次要检验双侧且经 Holm 校正, 均非随机化因果检验。 $H(P)$ 不随 K 单调增加: 加入全对成员会令提升空间降至零。因此跨种群比较应依据匹配 K 的分析, 不能依据单调性。K-matched 敏感性、完整定义、双评分器 / 关闭缓存 / 重复稳定性审核及偏差日志见附录 B。

5 PHASE II: 结果

5.1 原门控实验的修正重分析

以下是存档结果的审后重分析, 并非修复门控的新实验。原分析文件保留。所有修订表格使用同一 canonical 输入顺序下的全精度结果; 四组分析在相同 400 题上共用同一份 bare 记录。区间在各组和单元之间共享数据库、库内题目抽样, 并在六个固定构建器内部重采样生成种子。配对估计为 -0.16 个百分点, 未校正 95% CI 为 $[-0.83, +0.87]$, 单侧符号翻转 $p = 0.647$ 。未发现明确改善, 区间也不能确立等效性。完整集的单元对比范围为 -4.36 to +2.74 个百分点。这是实际筛选政策的估计; 该政策排除了部分允许策略, 并非纯验证干预。




图 3: 版本化修正重分析。左: 完整集 D-A 单元对比与合并的未校正 95% 区间。右: 相同 core-400、共同 bare 基线下的四组提升空间。两轴均为百分点; 不标显著性星号, 原始及校正 p 值见表 3。

Contrast	Effect (pp)	95% CI (pp)	Raw p	Holm p
Gate	-0.69	[-1.56, +0.20]	0.026	0.079
Strategy	+0.42	[-0.32, +1.51]	0.263	0.428
Interaction	-0.87	[-2.83, +0.65]	0.214	0.428

表 3: 修正的 core-400 析因重分析。门控为 $[(B - A) + (D - C)]/2$, 策略为 $[(C - A) + (D - B)]/2$, 交互为 $(D - C) - (B - A)$ 。CI 来自未校正的数据库 / 题目 / 种子 bootstrap; 原始 p 值来自双侧单元符号翻转, 三项次要检验经 Holm 校正。两类程序处理不同的变异来源。

5.2 析因效应与绝对表现

门控估计为 -0.69 个百分点, Holm 校正后 $p = 0.079$, 未达到 0.05 阈值。它无法区分有益验证与门控对提示变换的结构排除。修正的固定 K 门控敏感性为 -0.31 个百分点 (95% CI [-1.07, +0.40]): 每个 A/B、C/D 单元的两侧均匹配至较小候选数, 精确平均全部候选子集并始终保留 bare (附录 B)。子采样后的变化不能识别种群规模中介的因果比例; 加入较强固定成员还可能降低 oracle 提升空间。完整主分析集上, D-A 的 oracle 变化为 -0.44 个百分点, 最佳固定变化为 -0.28。最佳固定成员的下降抵消了部分 oracle 下降, 并没有解释掉后者。四组共同核心集的分解另见表 4。

5.3 执行波动与稳定互补性问题

存档 R3 审核报告: 三次关闭缓存重复中, 14.5% 的题目至少发生过一次 bare 正确性变化。canonical R2 重放得到同一 harness 的判定翻转 2391/28,000 (8.54%)。保留全部 18 个单元 (含两个 A 子集仅有单成员的单元) 后, 子集 D-A 从 +0.42 变为 +0.81 个百分点, 变化 +0.39 (95% CI [-0.95, +1.63])。R2 未采集匹配的 bare 重复, 因此其子集提升空间不包含 bare, 与主估计目标不同。旧 16 单元比较见附录 B。这些是不

Arm	K_{cand}	K_{total}	Bare (%)	Best (%)	Oracle (%)	H (pp)
A	5.78	6.78	63.25	66.00	74.51	8.51
B	6.11	7.11	63.25	66.12	74.39	8.26
C	5.61	6.61	63.25	65.64	75.01	9.38
D	3.83	4.83	63.25	65.65	73.90	8.25

表 4: 共同核心集的提升空间分解。各组使用相同 400 题与 bare 结果。 K_{cand} 不含 bare, $K_{\text{total}} = K_{\text{cand}} + 1$; 数量和准确率均为单元均值。提升空间为 oracle 减最佳固定准确率, 并非实际路由收益。

稳定性测量, 既非标准误, 也非平均处理效应的可检测下限; 它们不能证明所有对比均不变, 也不能识别 harness 间分歧有多少来自噪声。

作为直接的同代码诊断, 若把三次 bare 执行错误地当作三个不同的种群成员, 在相同 400 题上得到 72.25% 的单次 oracle 准确率、65.75% 的最佳固定执行准确率, 表观差距为 6.50 个百分点。这只是人为的重复采样比较: 三次执行的源码哈希相同, 因此它说明单次运行提升空间可以来自执行采样, 不能作为稳定互补性的证据。

令 $p_{h,x}$ 为 harness h 在独立执行中答对任务 x 的概率。对包含 bare 的种群, 定义

$$H_{\text{stable}} = \frac{1}{n} \sum_x \max_h p_{h,x} - \max_h \frac{1}{n} \sum_x p_{h,x}.$$

纯同代码克隆池各成员的 $p_{h,x}$ 相同, 因此稳定提升空间为零, 单次观测提升空间却可以为正。加入不同的 bare 后, 可能保留基线与 harness 的互补。独立重复估计已拟合策略相对指定比较器的价值; 发现阶段选定的固定成员可能并非最优, 仅超过它不能确立稳定互补或未见任务上的效用。当前数据缺少平衡、成本匹配的克隆对照, 稳定新增能力仍未得到估计。

5.4 路由与探索性选择

Phase-I 留一 harness 预测器未超过 DeepSeek 种群中的最佳固定成员 (−3.4 个百分点); Qwen 估计为 +0.9, CI [−5.2, +6.9]。按数据库分层的任务留出控制将平均修复 AUROC 降至 0.512, 更符合任务记忆而非可靠价值预测。这些发现仅适用于所测预测器与划分。

canonical W1 重分析仍为描述性。在 $k = 8$ 且保留 bare 时, 多样性选择相对最高开发准确率选择的提升空间变化为 +0.78 个百分点, 其中 oracle 变化 +0.35、最佳固定变化 −0.42。仅在开发数据上选定的单个固定成员变化为 −0.001 个百分点, 各已选子集采用一致的并列规则。这些是不同的估计目标, 并非已证明的路由收益。绝对数值及这一事后单次执行比较的局限见附录 C。

6 讨论与结论

证据确立了什么。源代码多样性、执行机制和单次正确性差异是不同的测量。Phase-I 模式未在调整后的 Phase-II 设置中复现，但多项协议变化使其原因无法识别。原门控的修正分析未显示明确的提升空间改善；该门控还排除了允许的提示策略，因此无法识别单独验证的效应。

尚未识别什么。同代码重跑可能发生分歧并产生 oracle 增益。结果翻转率测量不稳定性，不是处理对比的标准误，也不能定义其数值噪声地板。在将提升空间归因于稳定新增能力前，需要匹配成本的克隆对照、独立重复验证，以及经过验证的跨机制类型校准（附录 G）。

局限。主比较使用一个文本转 SQL 目标和六个固定构建器，每个构建器三个生成种子。Phase I 属于发现证据，存在已披露的任务重叠、代理评分器和查看轨迹后设计的人工控制。审后新统计分析未增加独立执行。K-matched 与 R2 已共用修正数据和重采样链条，W1/W3 也已共用 canonical 数据，但仍是描述性分析；选择不确定性与独立效用验证尚未完成。已完成的单种子 MATH-500 自由组探查（附录 H）将观测结果比较扩展至第二领域，但不提供克隆对照、修复门控的析因实验或稳定互补性的独立检验。生成代码、观测结果多样性和可重复的新增能力应分别评估。存档实验暴露了前两层的失败，第三层仍未解决。报告绝对 oracle 准确率、最佳固定准确率、准入政策、执行成本和重复波动，使这一边界可供检查。要确立实际价值，还需要独立验证超出同代码重复采样的选择收益。

AI 使用声明

本研究借助 AI 研究 AI 生成的产物，以下说明其参与范围。

必要披露。生成式 AI 工具用于：(i) 编写和修改实验代码，包括生成流程、评估采集器和统计分析脚本；(ii) 运行涉及模型 API 调用的实验流程；(iii) 分析数据并制作图表；(iv) 起草和修改论文。修订后的主分析表、析因表和结果图由共同的版本化重分析产物生成。历史探索性分析保留各自来源与局限；审后修正与原协议分开记录。验证记录分别说明各产物的自动测试、开发控制与审核范围。审后修订也使用了同模型子代理审核；这些属于机械检查，不构成跨模型独立科学验证。开发控制和本机运行测试不能证明独立门控校准或提供方层面的执行独立性。

研究构思与方向。核心问题、因果设计决策（估计目标、对比与排除规则）、解释标准及拟议的继续 / 停止准则在 AI 协助下形成。人类作者确定总体研究方向并要求按审稿意见修订；AI 工具也提出了分析与实验设计、识别反例并实施修订。最终科学决策及投稿批准仍由作者负责。本声明不表示每项 AI 提议均已得到作者逐项批准。

责任。作者对最终内容承担责任，包括 AI 辅助生成的文字、主张和产物。本声明中的事实有待作者核实，作者对其准确性负最终责任。

REFERENCES

- Mengzhuo Chen, Junjie Wang, Zhe Liu, Yawen Wang, Haiming Zheng, and Qing Wang. From failed trajectories to reliable LLM agents: Diagnosing and repairing harness flaws. *arXiv preprint arXiv:2606.06324*, 2026.
- Yong-eun Cho. It’s not the capability: Harness sensitivity is non-monotone across LLM agent tiers. *arXiv preprint arXiv:2605.26731*, 2026.
- Tianyu Fan and Chao Huang. HELIX: Model-harness co-evolution for recursive self-improvement. *arXiv preprint arXiv:2608.13951*, 2026.
- Akshat Gupta, Jermaine Lei, Alexander Lu, Gopala Anumanchipalli, and Leshem Choshen. Automated discovery has no universally superior harness. *arXiv preprint arXiv:2607.18235*, 2026.
- Minho Kim. When should LLMs search? counterfactual supervision for search routing. *arXiv preprint arXiv:2607.05752*, 2026.
- Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(2):48–60, 2014.
- Jinyang Li, Binyuan Hui, Ge Qu, Jiayi Yang, Binhua Li, Bowen Li, Bailin Wang, Bowen Qin, Ruiying Geng, Nan Huo, et al. Can LLM already serve as a database interface? a BIRD’s eye view. In *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, 2023.
- Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Lightman et al. let’s verify step by step appendix: Math-500 subset. *arXiv preprint arXiv:2305.20050*, 2023.
- Jiahang Lin, Shichun Liu, Chengjun Pan, Lizhi Lin, Shihan Dou, Zhiheng Xi, Xuanjing Huang, and Hang Yan. Agentic harness engineering: Observability-driven automatic evolution of coding-agent harnesses. *arXiv preprint arXiv:2604.25850*, 2026.
- Xinchen Liu, Hang Zhou, Yingjie Zong, Yuchuan Tian, Liuyang Song, and Shuo Zhang. Agentic routing: The harness-native data flywheel. *arXiv preprint arXiv:2607.11399*, 2026.
- Xiaotian Luo, Dizhan Xue, Fengxingyu Wang, Chuanrui Hu, and Yafeng Deng. HarnessBank: Semantic gene-bank search with gated verification for agent-harness self-evolution. *arXiv preprint arXiv:2607.13683*, 2026.
- Atsuyuki Miyai, Kiyoharu Aizawa, and Toshihiko Yamasaki. Task-CoEvolve: Efficient harness optimization via adaptive validation task selection. *arXiv preprint arXiv:2608.20169*, 2026.

- Johannes Moll, Jean-Philippe Corbeil, Jiazhen Pan, Martin Hadamitzky, Daniel Rueckert, and Lisa Adams. GRASP: Gated regression-aware skill proposer for self-improving LLM agents. *arXiv preprint arXiv:2605.29668*, 2026.
- Jun Nie, Yonggang Zhang, Jun Song, Qianshu Cai, Dahai Yu, Xinmei Tian, Bo Han, Yike Guo, et al. TTHE: Test-time harness evolution. *arXiv preprint arXiv:2607.08124*, 2026.
- John R. Rice. *The Algorithm Selection Problem*. Elsevier, 1976.
- Ruhan Wang, Yucheng Shi, Zongxia Li, Zhongzhi Li, Yue Yu, and Junyao Yang. Harness handbook: Making evolving agent harnesses readable, navigable, and editable. *arXiv preprint arXiv:2607.13285*, 2026.
- Jinghan Xu, Yikai Zhang, Aili Chen, Weiyuan Li, Jiaqing Liang, and Deqing Yang. Verify smarter, evolve further: Efficient harness evolution through behavior-aware verification. *arXiv preprint arXiv:2608.27311*, 2026.
- Lin Xu, Frank Hutter, Holger H. Hoos, and Kevin Leyton-Brown. SATzilla: Portfolio-based algorithm selection for SAT. *Journal of Artificial Intelligence Research*, 32: 565–606, 2008.
- Guibin Zhang, Leo Lu, Fangzhou Xie, Kang Zhu, Junhao Wang, and Zhifei Xie. JIT-Agent: Scaling harness intelligence via just-in-time harness evolution. *arXiv preprint arXiv:2608.25593*, 2026a.
- Hangfan Zhang, Shao Zhang, Kangcong Li, Chen Zhang, Yang Chen, and Yiqun Zhang. Self-harness: Harnesses that improve themselves. *arXiv preprint arXiv:2606.09498*, 2026b.
- Heng Zhou, Zelin Tan, Zhemeng Zhang, Yutao Fan, Yibing Lin, and Li Kang. Select-then-solve: Paradigm routing as inference-time optimization for LLM agents. *arXiv preprint arXiv:2604.06753*, 2026.

A PHASE-I 来源与条件详述

发现研究属性。 Phase I (§3、§5.4) 属于发现研究。151 道评估题中有 24 道与首日协议开发测量重叠；人工控制在检查首日轨迹后设计，其观测提升空间是描述结果，不是稳定互补性的盲估计；仓库历史为事后初始化，决策日志的变更记录是事件先后顺序的依据。Phase-I 准入阈值为联合修复率 $\geq 15\%$ 、提升空间 ≥ 5 个百分点、至少三组非空且成对不同的修复集合，在 151 题评估前已于内部决策日志冻结。v6 到 v7 的阈值调整（20% 到 15%）已披露，两种阈值均接纳同样种群。这是内部评估前冻结，不是外部预注册。

数据检查。 两次首日运行中, bare 在 60 题上翻转 3 题, 因此两列结果基于略有不同的 bare 错题集合。Phase-I 使用结果行集合相等的代理评分器; 在两份有最终 SQL 日志的 Phase-I 矩阵上, 它相对官方 BIRD 评分器一致偏保守, 没有把官方判错的答案判对, 一致率为 0.97–0.99。

Phase-I 种群。 种子基线为单次调用的 bare 和 TTHe 预置的执行反馈循环 react。旧提议者协议从 GLM-5.3-Flash 构建器的 TTHe 优化循环输出中选择六个候选; 只使用与评估集不相交的 36 道题, 按评估前冻结的规则选择行为多样性。策略强制自由形式使用 GLM-5.3-Flash、Qwen3.8-Flash、DeepSeek-V4-Flash-Vision-Exp, 各指定八种机制; GLM 种群采用有日志的重跑 ($K = 3$), 原 09-01 运行记录零接纳, 但工具未保存, 观察无法审核。Harness IR 从声明式机制规格确定性编译六个 harness: 上下文属于 {plain, schema_link, hint_guard, link+hint}, 另含候选生成温度、逐候选执行、修复轮次和选择规则, 因此声明机制按构造存在于控制流程。人工正控制为 §3.4 的四个手写 harness。

生成来源缺口。 09-01 的自由形式种群在会话中生成, 工具未保存, 逐尝试日志不存在, 因此不能审核这些运行的预算相等, 也不作此主张。准入是在评估时做导入 / 冒烟检查, 不是 Phase-II 反事实一致性门控。2026-09-03 留存的 builder_generate3.py 记录每次尝试 (重试设置、16,384 token 预算、阶段和结束原因); 完整逐策略表及 3/8、7/8、8/8 的接纳排序来自该工具, 相对冻结的准入决定属于事后记录。

B PHASE-II 协议摘要与偏差日志

权威协议为代码材料中的 PHASE2_PROTOCOL.md, 包含估计目标、划分、仪器、排除规则和历史偏差日志, 冻结提交见 PROTOCOL_FREEZE.txt。摘要如下: 2×2 析因加开放机制组; 六构建器乘三个种子; 每槽位最多三次尝试, 首次接纳即停, 不补齐; 污染登记失败则拒绝继续, 整体禁用两个开发库; 九库 1,169 题验证集与预抽取 core-400, 存在已披露的 18 题冒烟接触例外; 官方 BIRD 评分器强制 30 秒超时; 响应缓存以模型身份为键并跨进程加锁, D13 记录并修复采集中发现的缓存并发问题; 主对比为配对单元上的 D–A, 原计划使用分层 bootstrap 与置换推断; 共同核心集的析因次要检验经 Holm 校正, K-matched 仅为敏感性分析。D1–D13 记录了 18 题冒烟测试、观察验证性结果前的校准修正、凭据处理事件及补救、产物分歧隔离, 每项均有理由与日期。

审后修正另见 review-stage/REVISION_20260910.md, 不替换历史冻结。实际门控结构性拒绝两种允许的提示层策略, 实际生成成本在各组不同。修正表格共用基线记录, 并采用正文说明的数据库 / 题目重采样。

上游代码提取审计。 36 个强制 C/D 单元中, 全部 108 次 format_guard 尝试均未通过中性有效性: 71 条日志报告 Python 字符串未闭合, 36 条报告未找到 Python 围栏, 1 条报告提供方超时。归档生成器使用非贪婪正则提取 Python 围栏, 在遇到下一个三反引号时结束, 包括 Python 字符串内部的围栏。三个语法有效的合成文件分别在

Sensitivity estimand	Estimate (pp)	95% CI (pp)
K-matched B-A headroom	-0.55	[-1.53, +0.63]
K-matched D-C headroom	-0.08	[-1.26, +0.80]
K-matched gate mean	-0.31	[-1.07, +0.40]
R2 subset D-A (cached)	+0.42	[-0.61, +1.48]
R2 subset D-A (cache-off)	+0.81	[-0.35, +1.84]
R2 change in subset D-A	+0.39	[-0.95, +1.63]

表 5: core-400、18 单元的修正敏感性结果，CI 未校正。K-matched 始终保留 bare；R2 排除 bare，并以已观察采集组为条件。

普通字符串、文档字符串和正则表达式中包含 SQL 围栏，提取后均成为语法无效的前缀，截断标记仍为 false。该提取函数与审稿锁定提交一致，但历史尝试日志没有绑定运行时源码哈希，生成器也未保存完整构建器回复。因此，失败模式与提取损坏相容，不能证明全部历史失败由此造成，也不能证明修复后候选会被准入。74 份已保存提取文件均有语法错误，其中 3 份与“未找到围栏”的日志并存，作为来源冲突保留，不归属于对应尝试。这说明除门控的显式策略排除之外，还需要检查生成接口失败。

修正后的 K-matched 与 R2 重放。 两项重放与主分析共用按 manifest 顺序加载的 canonical 数据和跨单元数据库 / 库内题目抽样，在固定构建器内部重采样种子，共 10,000 次。K-matching 对每个 A/B、C/D 对使用较小候选数，精确枚举全部均匀候选子集；各子集保留 bare，每次题目抽样都在子集内部重新计算最佳固定成员。这是规模敏感性分析，不是因果中介分解。

R2 在 400 题上采集 70 个 harness，各 A/D 单元按可用情况取最前两个可调用的已接纳候选。两份关闭缓存采集文件虽均存为 repeat=0，仍保留独立采集身份，并将源码哈希与缓存运行核对。没有匹配 bare 采集，因此两种条件的提升空间都不含 bare。修正分析保留单成员单元（其子集提升空间为零），共 18 个配对单元。相对缓存结果有 2391/28,000 次判定翻转（8.54%）；D 组两次关闭缓存采集间为 1245/14,400（8.65%）。

仅为解释旧结果，若限制至两组都至少有两个成员的 16 单元，D-A 在缓存下为 -0.11 个百分点，关闭缓存后为 +0.36。这说明它与全单元估计的差别；两种分析均不能识别未来执行方差、单独缓存效应或相对克隆的稳定互补优势，采集时间与缓存条件并未分离。

记录成本与缺失账单。 相同 canonical 核心记录在 153,600 条候选一题目记录中包含 259,304 次逻辑 solver 调用（表 6）。它们包括缓存服务的请求，不等于供应商计费 API 请求。所检查记录均没有 token usage 字段，不据调用数估算 token 或货币支出。实际生成尝试数、接纳候选数和执行调用数保持为不同测量。种群成本均值对各构建器一种子单元等权，不含 bare；零候选种群贡献零次 solver 调用。

Arm	Candidate-task records	Logged solver calls	Calls/task/population
A	41,600	67,258	9.34
B	44,000	64,399	8.94
C	40,400	75,604	10.50
D	27,600	52,043	7.23

表 6: core-400 canonical 描述性成本审核，每组 18 单元。逻辑调用不是计费请求或 token 数；末列为各单元候选种群每题调用数的均值。

C 探索性指纹与选择分析

两项分析均为对存档验证性单元的事后分析：18 个构建器乘种子单元、384 个接纳候选、core-400 结果。版本化的 `experiment/revision/` 脚本共用主重分析的 canonical loader、冻结题目清单、成员关系及源码检查。这些题目已被分析过，结果仍属描述性，不能视为独立迁移验证。

丰富指纹。 为单独考察 loader 变化，W3 保留旧的有损 SQL 文本变换：删除分号，将反引号替换为引号，按单引号分段后将偶数段转为小写，再合并空白。这不是 SQL 解析或语义归一化，可能改变字面量及带引号标识符。在两份非空变换 SQL 完全相同的 364,428 个 pair-task 观察中，0 个判定不同。这是观察到的一致性，不是构造保证的性质。

pair 级 SQL 不相似度仅在判定一致、且两份 SQL 非空的题目上平均 ($1 - \text{token-Jaccard}$)。它与整体结果分歧的 Spearman 相关为：4,386 个单元内 pair 上 0.597，1,010 个组内 pair 上 0.588。各 pair 共享候选与题目，SQL 指标还以判定一致为条件，因此这些相关没有独立性假设下的显著性或因果解释。

R2 首次关闭缓存的 70-harness 采集中，调用数在 506/28000 次比较中变化，判定在 2391/28000 次中变化；变换 SQL 在 19569/27936 次中变化 (70.05%)。64 次比较缺少两份非空 SQL，仅从 SQL 分母排除。变化 SQL 对的平均 token Jaccard 为 0.619。这些通道各自的变化率不能定义效应大小的噪声地板。逻辑调用成本单列于表 6。

多样性感知选择。 每个单元合并各组全部接纳候选。重分析保留旧种子、100 次数据库半分、每划分每单元 200 次随机子集抽样和候选选择规则，但记录了新的确定顺序：历史由集合遍历生成的单元顺序未存档，仅靠种子无法恢复相同的历史划分和抽样。开发数据库用于选择，其补集用于评估；这些重叠划分不是 1,800 次独立实验。方法包括开发准确率 top- k 、均匀随机子集、贪心开发 oracle 覆盖，以及贪心平均准确率加 λ 倍 oracle 覆盖， $\lambda \in \{0.25, 0.5, 1, 2\}$ 。每次划分内的候选选择均在该次评估前固定。

表 7 在每个评估子集中保留共同 AD bare， k 只计候选；JSON 还保留 candidate-only 数值以区分历史估计目标。Oracle 和 Best 使用留出结果作描述性上界；Dev-fixed 则仅按开发准确率选一个成员，并列时按成员名升序、bare 优先。确定性方法已保留一个

k	Selection	Oracle (%)	Best (%)	H (pp)	Dev-fixed (%)
4	top-acc	73.98	66.64	7.34	65.10
4	random	73.90	66.03	7.87	64.66
4	div-only	74.22	66.18	8.04	65.13
8	top-acc	76.03	67.11	8.93	65.10
8	random	76.15	66.76	9.39	64.95
8	div-only	76.39	66.68	9.70	65.10

表 7: canonical 描述性 W1 重分析。每池含 k 个已选候选及共同 bare; 对 18 单元、100 个重叠数据库划分取均值, 无 CI。Dev-fixed 仅在开发数据上选择; Best 使用留出结果。

全局开发最优候选, 因此该比较器的差异可能来自保留了哪个并列最优, 而不是最大开发准确率提高。

在 $k = 8$ 时, div-only 相对 top-acc 的 oracle 变化为 +0.35 个百分点、best-fixed 为 -0.42、headroom 为 +0.78, dev-fixed 为 -0.001。它们是不同量, 均非独立验证的路由收益。旧的仅按单元计算的 CI 已撤回; 当前表为描述性结果, 涵盖数据库 / 题目抽样与重新选择的推断仍未完成。旧归一化提升空间比率只保留于历史产物, 不进入修订主张。

重新选择不保证区间覆盖。 一个精确反例否定了拟议正权重重选择百分位区间的普遍 95% 覆盖保证。令九个独立数据库各含一个 Bernoulli(p) 状态任务, 16 个固定候选依次为八个状态 0 专家和八个状态 1 专家, bare 恒错误。按 canonical 的 $k = 8$ 规则, 用四库开发、五库留出。保留原并列规则时, div-only 相对 top-acc 的 headroom 统计量期望为 $(1 - p^4) \mathbb{E}[\min(B, 5 - B)/5] > 0$, 其中 $B \sim \text{Binomial}(5, p)$ 。若九库状态全部相同, 任何正权重重加权下两种方法的 headroom 均为零, 百分位区间为 $[0, 0]$ 。因此覆盖率至多为 $1 - p^9 - (1 - p)^9$, 在 $p = 0.1$ 时为 61.26%。对相同单元或固定重叠划分取均值不能消除该事件。此界限针对上述构造和区间, 不是 BIRD 覆盖率估计, 也不否定其他推断方法。

D PHASE-I 补充结果

各 harness 准确率、逐折 LOHO 表、bootstrap 区间、修复集合审核、K 子采样曲线、任务留出控制及第二目标重复结果均列于匿名代码材料及对应生成脚本。第二目标固定为 Qwen3.8-Flash: 观测坍缩模式再次出现, 策略强制种群仍有提升空间, 提示侧人工控制未整体迁移。

E 模型与版本

表 8 列出模型角色及发送给 API 的精确版本字符串。全部模型通过同一商业 OpenAI 兼容聚合供应商访问, BIRD 数据采集窗口为 2026-08-30 至 2026-09-08。冻结目标始终以温度 0 调用; Phase-II 生成温度 0.7、预算 16,384 token, Phase-I 设置按工具记录。

Phase I 使用代理执行评分器；Phase II 使用官方 BIRD 评分器（30 秒超时），旧评分器用于次要审核；MATH-500 使用附录 H 的答案比较器。报告的准确率均不是 LLM 评判结果。

角色	模型精确版本字符串	阶段
冻结目标	GLM-5.3-Flash（温度 0）	I-II
第二冻结目标	Qwen3.8-Flash	I
Phase-I 构建器	GLM-5.3-Flash, Qwen3.8-Flash, DeepSeek-V4-Flash-Vision-Exp	§3.5
Phase-II 构建器	GLM-5.3, Qwen3.8-Max, DeepSeek-V4-Pro, Kimi-K3, MiniMax-M3, ERNIE-5.0-Thinking-Preview	II
评分器	代理 / 官方 BIRD 执行评分器；MATH 答案比较器	见正文

表 8: 完整模型清单。目标在各阶段内保持冻结，Phase-II 构建器来自六个独立实验室。

F PHASE-I 轨迹审核实例

以下将一项 BIRD 任务在被审 harness 中的执行过程展开，说明 §3.3 的失败分类。产物原文来自首日轨迹审核（5 个 harness 乘 10 题）；日志将 SQL 摘录限制为 120 字符，截断以 *[trunc.]* 标出。完整源码和轨迹见代码材料。

题目。 BIRD 开发集问题 352（card_games 数据库；题目按原文保留，包括拼写错误）：

```
Calculate the percentage of the cards availabe in Chinese
Simplified.
```

BIRD 提示为：

```
'Chinese Simplified' is the language; percentage = Divide(Sum(id
where language = 'Chinese Simplified'), Count(id)) *100
```

标准 SQL 如下。它与 bare SQL 在发布数据库上分别执行得 8.7734 与 8.7728，官方评分器将二者区分：

```
SELECT CAST(SUM(CASE WHEN T2.language = 'Chinese Simplified' THEN
1 ELSE 0 END) AS REAL) * 100 / COUNT(T1.id) FROM cards AS T1 INNER
JOIN foreign_data AS T2 ON T1.uuid = T2.uuid
```

bare 返回：

```
SELECT SUM(CASE WHEN language = 'Chinese Simplified' THEN 1 ELSE 0
END) * 100.0 / COUNT(id) AS percentage FROM foreign_data;
```

它被官方评分器判错。bare 查询直接在 `foreign_data` 上计数，标准查询先与 `cards` 连接再计数；提示未明确写出该连接。

react: T2, 机制存在但未触发。 控制流程确实执行 SQL，并在数据库报错时重试。但第一次调用的提示与 bare 逐字节相同，该题生成的 SQL 未报错，错误触发的重试不发生，最终 SQL 与 bare 相同。全部 10 道审核题均出现这一模式：有 SQL 执行，10/10 最终 SQL 与 bare 逐字节相同。反馈循环真实存在，但这些题上修复分支未激活；需要受控故障注入检验反馈是否改变输出。

cand_bird_g1_b0r1_g0: 代码不同、观测行为相同。 该候选确为不同程序：以守护线程监视单次 coder 调用，若超过 40 秒则发出一次对冲重问。机制存在，但审核中 API 调用停滞这一触发条件未出现；SQL 执行次数为零，10 题最终 SQL 均与 bare 相同。即使新增机制真实存在，也可能因未触发而不产生观测行为差异。

cand_bird_g1_b1r1_g1: T3, 多轮路径失效。 实际实现“执行—检查—修复”的被审候选返回自然语言说明作为最终 SQL。在 bare 答对的题目“State the alternative languages available for card named Annul numbered 29.”上，其日志最终 SQL 开头原文为：

```
with "only a single read-only SELECT is allowed". The previous
"query" was actually just prose text (the model wrote rea[trunc.]
```

修复提示要求修复“实际上只是自然语言说明”的查询，冻结目标继续输出推理说明；没有找到 SQL 块，推理文本便被提交为查询，导致该题由 bare 正确翻为 harness 错误。

G 独立构造的仪器控制集

我们用 32 例新构造的控制检验审后 Gate-v2 开发仪器，与开发探针时使用的控制集分开。仪器先固定，另一模型仅接收公开合同与调用接口，不接触仪器实现或早期控制。作者为八类机制各提供两例预期符合和两例预期不符合的实现。首次执行前，对控制源码、作者参考标签、仪器、测量程序和执行顺序记录哈希。本次没有运行 benchmark 或提供方生成，首次测量记录原样保留。

九例待审项全部保留。第三模型接收完整控制源码与轨迹，不接收作者参考标签或自动判决，对全部 32 例做源码合同审阅，并对指定四类机制做语义裁决。

独立源码审阅支持一例分解控制和两例错误分类控制符合合同，但仪器拒绝了它们。分解 stub 返回请求中首先匹配到的计划步骤的载荷；因此，下一步请求保留前一步上下文时，又取得了前一步载荷。分类检查移除了精确错误文本，但仍将普通的 **Schema** 标题计入类别，使提取的类别集合与预期错误类别不符。这些是仪器在对应控制上的失败，不是实际目标模型的失败。

三例作者预期正例存在争议：两例模式链接控制仍保留无关表，一例双视图控制批量请求候选且错误处理空结果。原标签和审阅分歧单独保留。在作者标签与源码审阅一致的

声明机制	结构通过	结构失败	待语义审阅
修复	2	2	0
执行结果投票	2	2	0
模式链接	0	4	0
Hint 约束	0	0	4
双视图	0	3	1
分解	1	3	0
错误分类	0	4	0
格式约束	0	0	4
合计	5	18	9

表 9: 固定开发仪器对 32 例独立构造控制的首次测量。没有执行失败。这些是仪器状态，不是正确性标签或生成种群错误率；作者预期正负标签须另行审核。

29 例中，仪器拒绝了 13 例符合控制中的 3 例；16 例不符合控制在指定语义审阅后均被拒绝。因此，仪器未通过本批有限控制检验。这些计数不估计生成种群的错误率。

指定 16 例的语义裁决为 7 例符合、8 例不符合、1 例待定。待定例已有结构失败，该状态保持不变，未将其语义强行改判。

该小型、人为平衡的控制集不是生成 harness 的随机样本；即使全部通过，也不能验证生产接口或替代同一 raw pool 上的准入政策比较。源码、冻结输入、完整轨迹与裁决保留在配套修订产物中。

修订仪器与新的独立控制集。 Gate-v3 修正了分解请求的步骤归属，并将类别关键词及共享请求模板作为审阅线索，不再据此自动拒绝。固定该版本后，作者与审核模型分别使用新上下文构造、审阅另一批 32 例控制，每类仍为两例预期正例与两例预期负例。审阅材料隐藏作者标签、自动判决和仪器生成的归属元数据。全部 32 例接受源码审阅；原四类提示或表述机制加上分解，共 20 例接受语义或数据流审阅。结构结果为 8 通过、10 失败、14 待审，没有执行异常。经一次留痕的证据澄清，源码审阅为 15 符合、17 不符合；语义审阅为 8 符合、11 不符合、1 待定。

待定的分类控制请求中间错误类别，合成接口却返回 SQL 文本，随后默认分支选择了语义修复动作。这证明 fixture 的响应类型不匹配，不能据此断言真实 solver 分类错误。另一例分类控制存在参考争议：其源码将给定的模式错误消息归入语义错误并采用相应动作。在 31 例无争议参考中，15 例符合控制有 14 例接受、1 例未决；16 例不符合控制全部拒绝。由于仍有未决案例，且错误分类缺少足够的双方认可正控制，预定的有限检验仍未通过。一例投票控制的符合结论仅限于执行结果仲裁，不证明其候选生成以实际任务为条件。这些有限机制检查不能验证完整 harness 运行，也不能替代计划中的共同候选池政策比较。

运行时响应合同。 随后按每类首个可用文件名选择七份归档的无 gate 强制策略候选，不依据性能挑选；没有可用的 format-guard 候选（附录B）。27 个合成场景同时暴露

了候选与仪器的限制。two-view 候选在首个结果非空时跳过第二次执行，违反原始的“execute both”声明。相比之下，schema-link 候选请求 JSON 却收到普通文本；分解请求中的完整计划使探针无法归属当前目标。保留这些观察后，我们在另 11 个开发场景中使用由源码预先指定的响应格式。专用子问题字段识别了当前目标，可执行 SQL 载荷进入最终组装；内存 SQLite 产生的四种错误触发了对应的语法或模式修复指令。schema-link 的 JSON 改变了后续 SQL 请求中的显式表列限制，尽管完整 schema 仍被保留。因此，仅凭 schema 上下文仍在场，不能认定候选忽略了关联子集。这些已曝光候选检查区分响应接口失败与可观察的候选偏差，不替代独立校准，也不提供修订后的 benchmark 结果。

统一接口与测量前参考审核。 Gate-v4 将按源码指定的响应接口与五类保持不变的 Gate-v3 机制探针整合。另一作者构造 32 项控制，在执行前接受源码盲审。作者熟悉早期控制失败；本轮源码审阅发现的 schema 响应形状与投票声明参数偏差，在保留初版后修正。修订参考在每类均有两项双方认可的符合控制与两项不符合控制。冻结源码、profile 和依赖后，一次测量覆盖 124 个场景，没有执行异常；结构结果为 4 通过、6 失败、22 待审。

新的审核上下文接收全部源码及实际轨迹，不接触参考标签、源码审核判决或自动结果。首次判为 18 符合、14 不符合。按预定混合规则保留结构失败后，16 个符合参考全部接受，但另有一个不符合的 Hint 控制被接受，因此未满足有限零错误标准。该控制正确重述已有 Hint，却在未提供 Hint 时虚构了必须排序的硬要求。一次留痕的定向证据澄清纠正了这一遗漏，以及把同一请求的两个样本视为独立构造表述的双视图判决；后者在混合结果中已被结构规则拒绝。澄清后的判决与 32 项参考全部一致，但这次跟进不替代首次盲审结果，也不构成新的独立校准通过。本次检查没有重跑仪器、调用提供方生成或进行 benchmark 评测。

声明词表的适用范围。 这些控制覆盖八种强制策略合同，不覆盖 free 臂的 repair、vote、twostage 和 plain 四类声明。原 free 提示中的 vote 要求多次采样并选择，但未规定三票多数决；twostage 要求消费早期产物，但未规定具体响应接口。plain 声明还规定不含控制流机制，而 free 提示正文要求改变控制流。因此，将八策略 gate 应用于这些声明之前，需要另行固定语义规则与未决处理政策，不能静默把 vote 当作 vote3，或在观察结果后选择兼容 profile。这个源码层适用性缺口不估计生成候选的误拒率。

H 跨领域重复：MATH-500 小型审核

为检查 Phase-II 调整协议下的观察（无门控自由生成产生不同的单次正确性向量）是否仅限文本转 SQL，我们在竞赛数学上重复自由组协议。

协议。 六构建器与 Phase II 相同，单个种子，每个八槽位，每槽位最多三次原始尝试；中性有效性门控不检查机制，只检查解析、导入、接口以及两道开发题上答案非空。冻结目标为 GLM-5.3-Flash，温度 0。MATH-500 (Lightman et al., 2023) 的 500 题在生

成前冻结为 100 开发 / 400 评估，种子 20260908。若两侧均可解析为数值，评分使用数值相等（含 a/b 、 $\frac{a}{b}$ 、小数）；否则使用归一化 LaTeX 字符串相等，去掉单位、进制下标与 °，保留 X 内容，将 pmatrix 转为元组。评分器自一致性检查中，400/400 标准答案与自身比较均判对。匹配答案格式指令下 bare 准确率为 0.938。48 槽位中接纳 35 个，各构建器 R_{artifact} 为 0.10–1.00；GLM-5.3 和 Qwen3.8-Max 在多数槽位输出代码前已将 32k token 生成预算耗于推理，按实际情况报告。本项是重复探查，不是析因实验，没有策略强制或一致性门控。

结果：35 个 harness、400 道评估题。 平均成对结果分歧为 10.6%（最大 33.0%）， $K_{\text{eff}} = 33/35$ (0.94)，结果完全相同的 pair 占 0.7%，未出现 Phase-I 式的坍塌模式。联合修复为 bare 错题的 76.0%，联合损害为 0.8%，相对 bare 的 oracle 提升空间为 4.75 个百分点。但最佳固定成员恰好是 bare 自身（0.9375，生成成员为 0.68–0.87）：观测 oracle 覆盖超过 bare，而每个生成成员单独均更差。未采集重复执行及同代码克隆控制，不能确立稳定互补性或可部署效用。

两项失败侧观察。 第一，调整协议下的观测多样性在另一输出空间的领域再次出现。第二，已隔离的试运行（PROTOCOL_CHANGELOG.md 的 G1）提供探索性比较：相同六构建器被错误地给予 GSM8K 风格任务描述，数值答案格式与 MATH-500 不匹配，种群仍有行为多样性（分歧 16.2%， $K_{\text{eff}} = 19/19$ ），但联合修复降至 18%。对灾难性成员的代码检查发现与 Phase-I 轨迹分类一致的失败：一个先生成再验证的 harness 几乎拒绝所有答案，回退却返回过时循环变量或“0”。提示侧协议错误可能留下多样性却损害效用；仅有代码差异检查无法揭示这种结果。

范围。 单种子、单目标、无析因，属于探索性研究。未在数学领域重跑造成 Phase-I 坍塌的 SQL 旧协议，因此这里只涉及调整后协议的观察，不识别坍塌的边界。