

更多程序，还是更多次采样？ 区分 LLM HARNESS 的覆盖与专长

(中文参考译本)

Anonymous authors

Paper under double-blind review

ABSTRACT

当一个 LLM harness 群体比其中最好的成员覆盖更多任务时，收益来自程序专长，还是仅仅来自更多次尝试？本文区分执行后的覆盖、跨重复保持的任务优势，以及选择器实际获得的收益。关键对照是重复运行同一个程序：在 MATH-500 上，九个相同的单次调用槽虽然没有程序专长，重复平均后的 oracle 估计仍为正，达到 2.09 %；八个生成 harness 加基线在其自身完整任务集合上为 2.38 %。通过留出重复并用克隆对照校准，在 342 个配对任务上得到平均增益 -0.10 %；覆盖不完整和低灵敏度使稳定专长仍未判清。另一个独立冻结的选择器在每道题上都选择基线，收益为 0.00 %。这些结果揭示了一个归因问题：群体覆盖为正并不确立任务专长，而覆盖机会能否转化为可用选择，还需单独检验。本文提供了将这些判断分开的受控评估。所有增益均为以 % 表示的绝对概率差。

1 引言

固定的推理预算应该用于生成更多程序，还是让同一个程序执行更多次？自动化智能体设计使前一种选择更容易实现：构建器生成一组 LLM harness，每个程序为冻结的求解模型安排提示、工具与控制流 (Hu et al., 2024; Nie et al., 2026; Zhang et al., 2026b)。其吸引力在于，不同程序可能分别擅长不同任务。但要作出这种解释，就必须把群体收益与评估群体时增加的尝试次数区分开。

困难在于，观测到不同的成功并不要求存在不同的能力。一个成功概率为 0.5 的程序独立执行两次，就能以 0.75 的概率覆盖一道题，尽管没有引入任何程序专长。Pass@ k 与自一致性已利用额外采样的价值 (Chen et al., 2021; Wang et al., 2022; Li et al., 2024)。因此，即使每个成员代码相同，一个看到全部结果后才挑选正确答案的 oracle 也能显示群体收益。对少数重复取平均并不会自动消除这种歧义：选择最大的估计成功率，也会偏向有利的采样波动。




图 1: 更多覆盖不等于更多专长。左：同一程序两次独立执行的概率计算。右：真实克隆臂在程序专长为零时仍产生正的重复平均 oracle 估计（采用完整任务估计；§5.2）。两幅面板展示不同的量，不是匹配的效应量比较。对照设计将八个生成程序加 single-call 与九个相同的 single-call 槽比较，并将重复验证与基于特征的执行前选择分开。

本文研究，什么证据能够区分覆盖机会与任务专长。全文围绕三个问题展开：已记录的执行是否包含额外正确答案？某个成员在一道题上的优势能否在新执行中保持？一个规则能否在看到答案前作出有用选择，并优于把同等资源交给固定程序？这三个问题对应不同的量，第一个问题的肯定答案不能代替后两个问题的答案。

我们先报告全部 35 个生成程序在 MATH-500 上的单次覆盖，再在所选子集上检验专长解释。核心对照固定群体规模，只改变程序是否不同：八个生成 harness 加上 single-call，对照九个逐字节相同的基线槽位。每个成员进行三次新执行，用其中两次发现逐任务选择，再用第三次验证。同代码臂测量这套过程在没有程序专长时会报告什么。随后，在同一面板上冻结于开发任务的选择器检验题目特征能否支持选择，等执行次数的 oracle 重放则比较可获得覆盖。最后，BIRD 轨迹补充检查源码差异是否真正进入执行。它提供独立诊断，不是 MATH 比较结果的因果解释。

证据带来三项认识。**第一**，同代码对照也产生正的重复平均 oracle 估计，说明这一信号本身不能识别程序专长。**第二**，留出重复与校准明确了当前数据的判断边界：克隆校正均值为 -0.10% ，但缺失与有限功效使稳定专长尚未判清。**第三**，把选择与覆盖分开，会改变实际价值的判断：所测选择器收益为 0.00% ，而完整执行预算下的重放，其观测 oracle 均值更有利于增加单次调用的执行次数。这些发现将覆盖、重复证据与实际选择分开。

2 相关工作

自动化智能体与 harness 设计。 ADAS 将智能体程序作为搜索空间 (Hu et al., 2024)。TTHE、Self-Harness、JIT-Agent 与 Task-CoEvolve 围绕冻结模型生成或调整程序结构 (Nie et al., 2026; Zhang et al., 2026b;a; Miyai et al., 2026)。HarnessLens、HarnessFix、AHE、HarnessBank、Harness Handbook 和 HarnessForge 通过运行分配、轨迹、预测检查、描述符、定位或联合策略演化研究行为 (Xu et al., 2026; Chen et al., 2026a; Lin

et al., 2026; Luo et al., 2026; Wang et al., 2026; Chen et al., 2026b)。自动设计智能体的低行为多样性也已有报道 (El et al., 2025)，程序等价与变异测试则提供了更早的概念背景 (Budd & Angluin, 1982; Papadakis et al., 2019)。本文关心所得群体的收益归因：源码差异可能不改变执行，而结果差异也可能在相同源码下出现。轨迹研究与克隆对照分别检验这两个方向。

重复采样与集成。 Pass@ k 、自一致性与相同智能体的集成利用额外尝试 (Chen et al., 2021; Wang et al., 2022; Li et al., 2024)；名义温度为 0 的调用也可能变化 (Alizadeh et al., 2023)。本文不将采样收益作为新发现，而是把它作为评估生成程序互补的显式参照。执行后的验证器 (Kwok et al., 2026) 与集成选择 (Caruana et al., 2004) 所拥有的信息，也不同于答案出现前必须作出选择的策略。本文的 oracle 重放与冻结选择器保留了这一差别。

选择与资源配置。 随实例变化的 harness 质量 (Gupta et al., 2026; Cho, 2026) 和 HELIX 结果矩阵 (Fan & Huang, 2026) 说明应超越最佳固定成员评估。STS、GRASP、反事实路由与 RouteLLM 在程序结构、技能、搜索动作或模型之间选择 (Zhou et al., 2026; Moll et al., 2026; Kim, 2026; Ong et al., 2024)，延续算法选择与组合求解中的问题 (Rice, 1976; Xu et al., 2008; Kotthoff, 2014)。定量交互与定性交互的区别 (Gail & Simon, 1985) 解释了为什么效应大小变化未必改变最佳动作。本文将任务交叉与同代码参照、留出重复相连接，再单独评估选择。这是一项诊断贡献，而非新的路由算法。

3 问题定义

一个群体可以提供额外正确答案，却不包含任务专家；任务专家也可以存在，却没有有效的选择器。下面先形式化这些区别，再介绍相应对照。设群体 P 包含基线 H_0 ， $Y(h, x, r) \in \{0, 1\}$ 表示成员 h 在任务 x 的第 r 次重复中是否答对。全文增益使用% 表示绝对概率差： $98.50\% - 93.75\% = 4.75\%$ 表示成功概率增加 0.0475。

覆盖：是否存在额外正确答案？ 单次 oracle 在看到正确性后选择成员。它相对记录矩阵中最佳固定成员的余量为

$$H(P) = \frac{1}{n} \sum_{i=1}^n \max_{h \in P} Y(h, x_i, r) - \max_{h \in P} \frac{1}{n} \sum_{i=1}^n Y(h, x_i, r). \quad (1)$$

这衡量可获得的答案，也包含重复采样带来的成功。重复平均插件估计 $\hat{H}$ 将 Y 替换为各成员一任务的均值。重复较少时，对均值取最大值仍可能选择有利的估计误差，因此 $\hat{H} > 0$ 本身不是专长证据。

稳定交互：最佳成员是否随任务改变？ 为在概念上排除执行噪声，令 $p_h(x) = \Pr\{Y(h, x, r) = 1\}$ 表示固定执行条件下的成功概率，并定义 $H_{\text{stable}} = \mathbb{E}_x \max_h p_h(x) - \max_h \mathbb{E}_x p_h(x)$ 。对两个成员，记 $\Delta(x) = p_1(x) - p_0(x)$ ，则

$$H_{\text{stable}} = \frac{1}{2} (\mathbb{E}|\Delta(x)| - |\mathbb{E}\Delta(x)|). \quad (2)$$

若一个成员处处更好，即使优势大小随任务变化，该式仍为零。正的互补要求任务优势发生交叉。同一条件下的相同程序具有相同 $p_h(x)$ ，因而稳定互补为零。这个总体恒等式说明要测什么，并不能从少量执行中直接估计未知的成功概率。

可用选择：优势能否指导决策？ 选择器 π_Z 必须在看到结果前，根据任务特征 $Z(x)$ 作出选择。即使交叉优势稳定存在，也未必能从这些特征预测。根据同一道题过去的结果学习选择，检验的是跨重复泛化，使用的信息不同。本文分别评估二者。实际资源分配还要求进一步比较：相对一次固定执行的选择收益，应与相同预算、相同答案选择规则下增加固定程序执行次数的效果比较。相同 harness 执行次数并不保证相同模型调用数或 token 消耗。

4 实验设计

4.1 HARNESS 群体与评估设置

构建器编写 Python harness，目标求解器回答程序发出的模型调用，外部评分器判定最终输出。各项研究的求解器均为 GLM-5.3-Flash。每个 harness 实现 `solve(question)`，通过 `self.llm` 调用模型；BIRD 还通过 `self.execute` 提供数据库结构与 SQL 反馈。标准答案仅对评分器可见。single-call 基线执行一次温度为 0 的调用。生成程序可以改变提示、解码、采样次数与控制流，因此固定求解器不意味着计算量相同或输出确定。表 1 说明各项研究的任务。

MATH 群体与面板抽取。 六个构建器为 GLM-5.3、Qwen3.8-Max、DeepSeek-V4-Pro、Kimi-K3、MiniMax-M3 和 ERNIE-5.0-Thinking-Preview，每个在一个种子下获得八个槽位。提示要求改进单次贪心调用，但不指定策略。每槽最多尝试三次（温度 0.7，每次最多 32,768 个输出 token），在首个程序通过解析、导入、接口及两道开发题的非空答案检查后停止。48 个槽位得到 35 个冻结程序；准入不认证质量或机制。

重复面板不按准确率排序抽取。历史平均调用次数不超过 3.05 的限制保留 21 个合格成员，再由固定加盐哈希选择每个构建器一个席位和两个自由席位。这偏向低调用程序。所选源码包含起草—检查—修订、一致性检查和采样投票；逐项清单见附录 A.2。加入 single-call 后共九个成员。该面板与九个相同基线槽均进行三次新执行，关闭缓存，解码设置由各成员源码固定。

MATH-500 (Lightman et al., 2023) 分为 100 道开发题与 400 道评估题（固定随机划分）。两项研究使用同一批 400 道评估题，因此新执行不等于全新任务验证。评分器抽取最终答案，优先使用所要求的 ##### 行；两端均可解析为数值时比较数值，否则比较规范化 LaTeX。它既不是 LLM 评分器，也不是通用符号等价检查器。比较器及其审核详见附录 A.1。

BIRD 发现与准入。 BIRD (Li et al., 2023) 要求根据问题与数据库生成 SQL。TTHE 的 proposer 使用 GLM-5.3-Flash 构建器产生 12 个发现候选，经导入与冒烟执行检查

研究	程序	评估	回答的问题
MATH 探索	35 个生成程序 + single-call	400 题; 单次运行	是否存在错误覆盖?
MATH 重复对照	8 个生成程序 + single-call, 对照 9 个克隆	同一批 400 题; 3 次新重复	选择能否跨重复迁移?
BIRD 发现	12 个生成程序 + single-call + react	60 题; 单次运行	什么机制实际执行?
BIRD 准入	6 个构建器 × 3 个种子 × 4 个臂	主比较 1,169 题; 全臂 400 题	筛选是否改变覆盖?

表 1: 每项研究支持不同的判断。单次运行指每个成员一任务对执行一次。MATH 重复面板从探索性群体中抽取。BIRD 提供独立的执行与准入证据; 不同研究的效应不合并。

准入, 与两个自带基线在 60 题上评估。独立的准入研究交叉自由 / 指定策略与无门控 / 合规门控, 使用六个构建器、三个种子、每臂八个槽位。每槽最多三次尝试 (温度 0.7, 16,384 个输出 token)。指定策略包括执行修复、三次采样投票及 schema linking。所有臂均要求接口有效、SQL 非空; 门控臂额外检查机制合规, 并排除部分结构。

准入研究保留两个数据库的 365 题用于开发, 九个数据库的 1,169 题用于评估; 四臂共用预先抽取的 400 题核心集。一次 18 题冒烟测试是已披露的开发暴露例外。预测与标准查询的结果由官方行集合评分器比较, 超时为 30 秒, 执行失败计零。发现研究则使用较早的字符串化行代理, 并限制返回行数。准入采集还使用共享响应缓存, 与 MATH 新重复不同。这些条件及门控干预的捆绑性质保留于附录 E.1 和 F。

4.2 同代码对照与重复验证

同代码槽位分离额外采样的解释。 增加成员同时增加了代码和尝试次数。因此, 我们将九个不同成员与九个逐字节相同的 single-call 槽位比较, 每个槽位在每道题上执行三次。后者保留随机结果产生的机会, 同时去掉程序专长。它是等能力参照, 并不假定所有生成程序都应表现得像 single-call。

留出重复将发现与验证分开。 若用同一批结果挑选一道题的最佳程序, 再用这些结果验证它, 就会重复利用偶然成功。我们改为三折重复交叉拟合: 每折用两次发现重复冻结任务成员映射与一个最佳固定成员, 再用第三次重复测量二者的准确率差。跨折平均得到 G_{real} 与 G_{clone} ; 固定比较对象由发现重复选出, 不一定是 single-call。随后在两臂共同完整的任务上比较:

$$D = G_{\text{real}} - G_{\text{clone}}. \quad (3)$$

这里相减的是配对任务层面的增益。它检验: 根据过去结果作出的选择, 迁移至另一次执行时, 不同程序是否比相同程序更有优势。由于过去结果来自同一批评估题, 这属于重复诊断, 不是全新任务上的路由检验。

缺失与灵敏度决定如何解释结果。 完整任务要求每个成员的每次重复均有判决，未知结果保持缺失。描述量使用各臂自身完整任务， D 使用交集。判断规则要求任一臂及交集的不完整任务均不超过 10%、至少有 30 个配对任务，并通过包括 $D > 1\%$ 在内的正效应检查。已知真值模拟检验现有重复次数能否识别交叉优势。这些检查将尚未判清与不存在的证据分开。附录 B 说明数据完整性；附录 C 给出完整规则、并列处理、不确定性及敏感性分析。采集协议在采集前固定，采集中有操作性修订；v3 分析在采集之后修订。

4.3 冻结选择与等执行次数重放

执行前的特征选择。 重复诊断使用同一任务过去的结果，实际选择器则必须在看到答案前作出选择。我们在 100 道开发题上训练 π_Z ，使用 TF-IDF 题目特征与仅在训练折内计算的成员准确率，并采用任务级五折交叉验证：问题的重复始终留在同一折。策略在评估前冻结，当前两名概率差小于 0.15 时回退至 single-call；它不能使用评估正确性或轨迹。比较对象包括开发集选出的固定成员与预先固定的随机成员。

执行后的 oracle 重放。 另一次离线比较为按开发集表现排序的成员组合与克隆臂分配相同的执行次数 $b \in \{3, 9, 15, 27\}$ 。每个入选成员贡献三次重复；克隆参照取其 27 次记录执行的子集。两臂均在执行后使用正确性作 oracle 选择，衡量可获得的覆盖。一次 harness 执行可以包含多次模型调用，因此执行次数相等不等于调用数或 token 成本相等。附录 D 给出冻结策略、重放和账目细节，并与旧档案的选择分析明确区分。

5 结果

5.1 生成群体的单次覆盖

我们先考察生成群体是否包含最佳固定成员之外的正确答案。全部 35 个获准生成成员在 400 题上各评估一次，与 single-call 的并集达到 98.50% oracle 覆盖，而最佳固定成员 single-call 为 93.75%。然而，每个生成成员单独都更差（68.25–91.50%）。由此得到的 4.75% 余量是事后可用的机会，不是观测到的路由收益。

这些结果确有差异：36 个正确性向量中有 33 个唯一向量，平均成对分歧为 10.6%（最大 33.0%），并集修复基线错误的 76.0%。但这些量均未说明执行前如何选择成员。这项单次研究没有自己的克隆对照；两个重推理构建器还在多数槽位耗尽生成预算，限制了代表性。这提出了下一个问题：若增加的只是同代码执行，是否也会得到正的 oracle 估计？重复研究在所选子集上加入这一对照。它的 D 不能校正完整群体的 4.75% 余量，新执行得到的基线均值 94.96% 也是另一个估计（附录 A.1）。

5.2 相同程序也产生正的 ORACLE 估计

同代码臂直接检验专长解释：九个槽位实现同一程序，因此稳定的程序互补按构造为零。若它的估计余量为正，该估计本身就不能区分专长与执行波动。

重复平均后的估计确实为正：克隆臂 383 个完整任务上， $\hat{H} = 2.09\%$ ；生成面板在其 350 个完整任务上为 2.38%（表 2）。二者是各臂的描述性估计，并非配对效应比较。未知保持缺失；较早的可用重复估计属于另一估计目标，说明见附录 B。该对照确立：即使平均三次重复，oracle 估计仍可在没有程序专长时为正。接下来需要检验，在部分重复中发现的选择，能否在另一次执行中保持价值。

量	生成面板 + single-call	同代码克隆
完整任务 oracle 估计 $\hat{H}$	2.38 %	2.09 %
重复诊断 G 的完整任务数	350	383
留出重复平均增益 G	0.17 %	0.55 %
配对克隆校正均值： $D = -0.10\%$ ，基于 342 个完整任务		
不完整任务：生成臂 12.5% / 克隆臂 4.2%		

表 2: 正的 oracle 估计未确立跨重复稳定的优势。各臂 $\hat{H}$ 与 G 使用本臂完整任务； D 在交集上平均配对逐题增益差，因此不能由表内两项 G 直接相减得到。生成臂未通过 10% 不完整比例门槛。

5.3 重复验证与诊断灵敏度

在评分前冻结选择，可以减少对偶然成功的重复利用。在各臂完整任务上，生成程序的留出重复均值为 $G_{\text{real}} = 0.17\%$ ，克隆为 $G_{\text{clone}} = 0.55\%$ 。在 342 题交集上，校准差异为 $D = -0.10\%$ ，95% 区间为 $[-1.55, 1.46]\%$ 。均值没有显示超越同代码参照的优势，但也未确立等价或总体负效应：生成臂 12.5% 的任务不完整，超过 10% 门槛。判断为 INSUFFICIENT EVIDENCE（证据不足）。全 0/全 1 填充情景下， G 跨越 $[-0.33, 0.33]\%$ ；完整规则及敏感性方法见附录 C，缺失记录见附录 B。

如果存在真实交叉，诊断能检出吗？ 已知真值模拟回答这个必要的后续问题。在改变成员数、任务数、重复次数与缺失条件的 100 个网格单元中，克隆校准规则最坏的观测零假设错误支持率为 2%。灵敏度则明显不足：真实 $H_{\text{stable}} = 17.5\%$ 的双专家设置在 $R = 3$ 时功效为 0%， $R = 5$ 时约为 0.7%， $R = 10, 20$ 时为 100%。更小的循环交叉即使在 $R = 20$ 时仍大多检不出（附录表 6）。这些结果属于所测模拟设置，不是通用重复次数门槛。

两项发现支持不同结论。克隆结果反驳了仅凭正插件估计识别专长的做法。重复结果尚未判清这个生成面板是否存在稳定交叉：数据不完整，而且三次重复时检验可能漏掉已知交叉。虽然部分稳定的成员平均差异可以检出，但平均更强并不等于任务专长。稳定专长是否存在尚未判清，但实际选择的效果仍可直接测量。下一节在同一 MATH 面板上，分别检验执行前的冻结选择与等执行次数下的事后覆盖。

5.4 执行前选择与 ORACLE 重放

执行前选择没有获得额外收益。 冻结的特征策略检验一种执行前实际可作出的选择。在重复面板上，它对全部 400 个评估任务选择 single-call，与开发集选定的固定成员同为 94.96% 重复平均准确率，收益为 0.00%。预先固定的随机成员比较对象差值为 -10.12%（附录 D）。该策略避开了弱成员，却没有获得任务专属收益。这个结果只涉及一个策略与特征集，既未穷尽可能的选择器，也没有把 oracle 机会变成实际准确率。

等执行次数的 oracle 重放。 即使考察 oracle 覆盖，也需要与固定程序可以获得的额外尝试比较。重放为开发集排序的面板组合与克隆臂分配相同的 harness 执行次数 b 。在 $b = 3$ 时，面板仅含 single-call，因此 +0.37% 的差异不可能来自程序多样性。增加成员后， $b = 9$ 时差值为 +0.03%， $b = 15$ 和 27 时为负（表 3）。

每题 harness 执行次数 b	3	9	15	27
面板成员数（含 single-call）	1	3	5	9
面板 oracle 覆盖（%）	98.00	98.25	98.25	98.25
克隆 oracle 覆盖（%）	97.63	98.22	98.36	98.50
面板减克隆（%）	+0.37	+0.03	-0.11	-0.25

表 3: 完整执行预算下，观测 oracle 均值并未支持更多程序。成员按开发集表现排序，每个贡献三次重复。克隆覆盖平均其 27 次记录执行的子集。两臂均使用事后 oracle 选择；执行次数匹配，token 成本未匹配。

生成臂的采集成本也更高：22,192 次逻辑调用与 54.17M 已知 token，对照克隆臂的 10,800 次调用与 14.51M token，token 比为 3.73 $\times$ 。这些是实际采集支出，不是等 token 性能比较。由于答案格式不兼容，本文不报告跨臂多数投票。因此，所测选择器没有提供收益，而等执行次数的 oracle 均值没有显示该组合持续占优。两项结果都未确立其他选择器或等 token 的实际运行比较将会如何表现。

5.5 实际执行行为的补充分析

MATH 对照表明，结果不同未必需要程序不同。补充的 BIRD 研究考察反方向的问题：不同源码是否真正产生不同且有用的执行行为？这里的机制指已实现的提示变换、工具使用或控制流操作。该研究使用独立总体、评分及执行协议，不能解释 MATH 结果的成因。

代码差异与观测结果。 所有 12 个发现候选都通过代码差异检查，但 66 个生成候选对中有 21 对的正确性向量相同；计入基线时为 36/91，源码相似度与正确性分歧的秩相关为 $\rho = -0.010$ 。这些 60 题上的一致不等于一般程序等价，但说明需要直接检查执行（附录图 2）。

轨迹定位三种不同的失败。 **T1:** 描述了但没有实现。12 个候选中的 6 个在文档中宣称检索或自检，实际只有一次模型调用且不执行产物。**T2:** 存在但未触发。全部 10 道已

审 `react` 任务的第一次 SQL 均执行成功，修复分支从未触发，最终 SQL 与 `single-call` 相同；执行成功不代表语义正确。**T3：执行了但输出失败。**一个候选执行多轮修复，却把散文作为最终 SQL，丢失了基线答对的任务。三者分别要求实现检查、能触发分支的任务和有效的输出合同；它们不确立激活机制可以提高准确率。附录 E 保留完整样例、人工控制及其开发暴露限制。

独立的 BIRD 准入研究还发现，强制策略加门控相对自由无门控的平均余量差为 -0.16% 。该门控捆绑了结构排除与合规验证，不能识别纯验证效应（附录 F）。因此，源码与准入证据需要通过实际执行来核实，其任务优势及选择价值则仍需分别测量。

6 讨论与局限

对评估的启示。 正的 oracle 增益回答是否存在额外正确答案。同代码对照说明，它不能同时回答不同程序是否具有不同的任务能力。评估应分别报告覆盖、跨重复稳定的任务优势与实际策略收益，并在资源比较中纳入重复运行固定程序的参照。若将收益归因于某个机制，则轨迹需要说明实际执行了什么，干预需要检验其贡献。这种报告方式区分有用的采样与专长，同时保留两者各自的价值。

局限。 受控 MATH 面板是在一个目标模型、已评估任务上抽取的低调用程序；v3 分析在采集后修订。缺失比例超过声明门槛，模拟也显示三次重复可能漏掉较大的交叉优势。因此，非正校准均值并不确立不存在或等价。零路由收益涉及一个选择器，重放匹配执行次数而非 token。BIRD 保持独立的单次运行协议、评分与缓存条件，其执行失败不能作为 MATH 的因果解释。

7 结论

额外覆盖、稳定任务专长和可实现的选择收益是不同的研究对象；证明其中一个不能代替另外两个的证据。在本研究中，生成群体提供了额外正确答案，同代码对照也产生正的 oracle 估计，而缺失与低灵敏度使稳定专长仍未判清。所测冻结选择器没有获得收益，等执行次数重放也未显示该组合持续占优。群体评估需要把覆盖、重复验证与实际选择连接起来，同时分别报告各自支持的结论。

伦理声明

全部实验使用公开的 BIRD 与 MATH-500 基准数据及生成的程序产物；不涉及人类被试、私人记录或个人身份信息。模型调用作为实验来源的一部分报告，论文不发布凭据或会暴露私人数据的提供方响应。主要伦理风险是夸大单次运行 oracle 增益对部署路由的含义；因此我们把未解决的选择与成本命题明确报告为 INSUFFICIENT EVIDENCE（证据不足）。

可复现性声明

本文说明所报告结果的程序群体、任务划分、执行条件、评分规则、统计过程与敏感性分析。附录补充协议细节、校准结果和具体样例。实验代码不向审稿人提供；相关方法与实证主张在论文中直接呈现。

AI 使用声明

本研究按构造就是一个借助 AI 研究 AI 生成产物的项目，以下精确披露 AI 协助的范围。

必要披露。生成式 AI 工具用于：(i) 编写和修改实验代码（生成流程、评估采集器、统计分析脚本）；(ii) 运行涉及模型 API 调用的实验流程；(iii) 分析实验数据并制作表格和图；(iv) 起草和修改论文文字。修订后的主分析表、析因表和结果图由共同的版本化重分析产物生成。历史探索性分析保留各自原始来源与所述局限。审后修正与原协议分开记录。验证记录分别说明各产物的自动测试、开发控制与审核范围。审后修订也使用了同模型子代理审核；这些属于机械检查，不构成跨模型独立科学验证。开发控制和本机运行测试不能确立独立门控校准或提供方层面的执行独立性。

研究构思与方向。核心研究问题、因果设计决策（估计目标、对比、排除规则）、解释标准及拟议的继续 / 停止准则在 AI 协助下形成。人类作者确定总体研究方向并要求按审稿意见修订；AI 工具也提出分析与实验设计、识别反例并实施修订。最终科学决策及投稿批准仍由作者负责。本声明不表示每项 AI 提议的决策均已获得作者逐项批准。

责任。作者对本研究最终内容承担责任，包括借助生成式 AI 产出的文字、主张和产物。本节中的事实陈述供作者核实；其准确性的最终责任由作者承担。

REFERENCES

- Vahid Alizadeh et al. An empirical study of the non-determinism of chatgpt in code generation. *arXiv preprint arXiv:2308.02828*, 2023.
- Timothy A. Budd and Dana Angluin. Two notions of correctness and their relation to testing. *Acta Informatica*, 18(1):31–45, 1982.
- Rich Caruana, Alexandru Niculescu-Mizil, Geoff Crew, and Alex Ksikes. Ensemble selection from libraries of models. In *Proceedings of the 21st International Conference on Machine Learning*, 2004.
- Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*, 2021.

- Mengzhuo Chen, Junjie Wang, Zhe Liu, Yawen Wang, Haiming Zheng, and Qing Wang. From failed trajectories to reliable LLM agents: Diagnosing and repairing harness flaws. *arXiv preprint arXiv:2606.06324*, 2026a.
- Mingju Chen, Can Lv, Guibin Zhang, Heng Chang, and Shiji Zhou. HarnessForge: Joint harness and policy evolution for adaptive agent systems. *arXiv preprint arXiv:2606.01779*, 2026b.
- Yong-eun Cho. It’s not the capability: Harness sensitivity is non-monotone across LLM agent tiers. *arXiv preprint arXiv:2605.26731*, 2026.
- Batu El, Mert Yuksekgonul, and James Zou. Inefficiencies of meta agents for agent design. *arXiv preprint arXiv:2510.06711*, 2025.
- Tianyu Fan and Chao Huang. HELIX: Model-harness co-evolution for recursive self-improvement. *arXiv preprint arXiv:2608.13951*, 2026.
- Mitchell H. Gail and Richard Simon. Testing for qualitative interactions between treatment effects and patient subsets. *Biometrics*, 41(2):361–372, 1985. doi: 10.2307/2530862.
- Akshat Gupta, Jermaine Lei, Alexander Lu, Gopala Anumanchipalli, and Leshem Choshen. Automated discovery has no universally superior harness. *arXiv preprint arXiv:2607.18235*, 2026.
- Shengran Hu, Cong Lu, and Jeff Clune. Automated design of agentic systems. *arXiv preprint arXiv:2408.08435*, 2024.
- Minho Kim. When should LLMs search? counterfactual supervision for search routing. *arXiv preprint arXiv:2607.05752*, 2026.
- Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(2):48–60, 2014.
- Jacky Kwok, Shulu Li, Pranav Atreya, Yuejiang Liu, Yixing Jiang, Chelsea Finn, Marco Pavone, Ion Stoica, and Azalia Mirhoseini. LLM-as-a-verifier: A general-purpose verification framework. *arXiv preprint arXiv:2607.05391*, 2026.
- Jiayi Li, Qin Zhang, Yiting Yu, Qinkai Fu, and Dawei Ye. More agents is all you need. *arXiv preprint arXiv:2402.05120*, 2024.
- Jinyang Li, Binyuan Hui, Ge Qu, Jiayi Yang, Binhua Li, Bowen Li, Bailin Wang, Bowen Qin, Ruiying Geng, Nan Huo, et al. Can LLM already serve as a database interface? a BIRD’s eye view. In *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, 2023.

- Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Lightman et al. let’s verify step by step appendix: Math-500 subset. *arXiv preprint arXiv:2305.20050*, 2023.
- Jiahang Lin, Shichun Liu, Chengjun Pan, Lizhi Lin, Shihan Dou, Zhiheng Xi, Xuanjing Huang, and Hang Yan. Agentic harness engineering: Observability-driven automatic evolution of coding-agent harnesses. *arXiv preprint arXiv:2604.25850*, 2026.
- Xiaotian Luo, Dizhan Xue, Fengxingyu Wang, Chuanrui Hu, and Yafeng Deng. HarnessBank: Semantic gene-bank search with gated verification for agent-harness self-evolution. *arXiv preprint arXiv:2607.13683*, 2026.
- Atsuyuki Miyai, Kiyoharu Aizawa, and Toshihiko Yamasaki. Task-CoEvolve: Efficient harness optimization via adaptive validation task selection. *arXiv preprint arXiv:2608.20169*, 2026.
- Johannes Moll, Jean-Philippe Corbeil, Jiazhen Pan, Martin Hadamitzky, Daniel Rueckert, and Lisa Adams. GRASP: Gated regression-aware skill proposer for self-improving LLM agents. *arXiv preprint arXiv:2605.29668*, 2026.
- Jun Nie, Yonggang Zhang, Jun Song, Qianshu Cai, Dahai Yu, Xinmei Tian, Bo Han, Yike Guo, et al. TTHE: Test-time harness evolution. *arXiv preprint arXiv:2607.08124*, 2026.
- Huai Guang Ong, Sylvain Jeremy, et al. RouteLLM: Learning to route llms with preference data. *arXiv preprint arXiv:2406.18665*, 2024.
- Mike Papadakis, Marinos Kintis, Jie Zhang, Yue Jia, Yves Le Traon, and Mark Harman. Mutation testing advances: an analysis and survey. *Advances in Computers*, 112:275–378, 2019.
- John R. Rice. *The Algorithm Selection Problem*. Elsevier, 1976.
- Ruhan Wang, Yucheng Shi, Zongxia Li, Zhongzhi Li, Yue Yu, and Junyao Yang. Harness handbook: Making evolving agent harnesses readable, navigable, and editable. *arXiv preprint arXiv:2607.13285*, 2026.
- Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc V. Le, Ed H. Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. Self-consistency improves chain of thought reasoning in language models. *arXiv preprint arXiv:2203.11171*, 2022. doi: 10.48550/arXiv.2203.11171.
- Jinghan Xu, Yikai Zhang, Aili Chen, Weiyuan Li, Jiaqing Liang, and Deqing Yang. Verify smarter, evolve further: Efficient harness evolution through behavior-aware verification. *arXiv preprint arXiv:2608.27311*, 2026.

Lin Xu, Frank Hutter, Holger H. Hoos, and Kevin Leyton-Brown. SATzilla: Portfolio-based algorithm selection for SAT. *Journal of Artificial Intelligence Research*, 32: 565–606, 2008.

Guibin Zhang, Leo Lu, Fangzhou Xie, Kang Zhu, Junhao Wang, and Zhifei Xie. JIT-Agent: Scaling harness intelligence via just-in-time harness evolution. *arXiv preprint arXiv:2608.25593*, 2026a.

Hangfan Zhang, Shao Zhang, Kangcong Li, Chen Zhang, Yang Chen, and Yiqun Zhang. Self-harness: Harnesses that improve themselves. *arXiv preprint arXiv:2606.09498*, 2026b.

Heng Zhou, Zelin Tan, Zhemeng Zhang, Yutao Fan, Yibing Lin, and Li Kang. Select-then-solve: Paradigm routing as inference-time optimization for LLM agents. *arXiv preprint arXiv:2604.06753*, 2026.

附录阅读导航

附录按正文论证顺序组织：先列主研究对象与协议，再给统计和选择细节，随后呈现 BIRD 补充证据，最后保留历史分析与偏离记录。

A Harness 生成、程序清单与数据划分.

B 同代码对照与重复执行协议.

C 统计分析、校准与灵敏度.

D 冻结选择器与等执行次数重放.

E BIRD 执行轨迹与补充分析.

F BIRD 准入策略研究.

G 来源、协议偏离与历史分析.

A HARNESS 生成、程序清单与数据划分

本附录先给出主研究的程序来源、任务划分与冻结面板，再列模型版本。BIRD 的发现与准入协议分别见附录 E 和 F。

A.1 探索性 MATH 群体、划分与覆盖

该单次研究建立了正文的起始覆盖现象，也是重复面板的程序来源。它沿用 BIRD 准入研究的无门控自由生成方案，但使用数学任务和答案比较器。

协议。 六个构建器（与 BIRD 准入研究相同模型），一个种子，各八个槽位，每槽位 $R=3$ 次原始尝试上限，中性有效性门控（机制盲：在两道开发题上检查解析、导入、接口与非空答案）。冻结目标 GLM-5.3-Flash（与 SQL 研究相同），解码设置由各冻结成员定义；基线温度为 0。MATH-500 (Lightman et al., 2023)：500 道题在生成前冻结（100 开发 / 400 评估，固定随机划分）。100 道开发题仅用于生成侧冒烟测试，从不在评估存档中执行；因此附录 G.6 的选择政策实验从评估侧切出其训练划分（80 道题），留下 320 道计分题供 D/E 命题。这是旧档案分析；新的重复研究在 100 道开发题上拟合选择器，并在全部 400 道评估题上评分（附录 D）。评分器：两侧均解析为数字时取数值相等（含 a/b 、 $\frac{a}{b}$ 、小数），否则取归一化 LaTeX 字符串相等（去除单位、进制下标、°；保留 X 内容； $\text{pmatrix} \rightarrow \text{元组}$ ）。评分器自洽性：400/400 标准答案与自身比较均判对。匹配答案格式指令下 single-call 准确率为 0.9375。产出：48 槽位接纳 35 个（ R_{artifact} 0.10–1.00；两个重推理构建器 GLM-5.3 与 Qwen3.8-Max 在多数槽位于发出代码前即耗尽 32k token 生成预算——按实际情况报告）。这一约束使被评估群体对重推理构建器风格的代表性不足；我们不在事后调整预算，该限制是所报告协议的一部分。这是重复探查，不是析因研究：无策略强制、无一致性门控。

结果（35 个 harness, 400 道评估题）。 平均成对结果分歧 10.6%（最大 33.0%）；计入 single-call 时 36 个成员中 33 个有唯一结果向量（35 个生成 harness 中为 32 个）；结果相同的对占 0.7%——没有 Phase-I 式坍缩的迹象。对 single-call 错题的联合修复为 76.0%；全部生成候选的并集在 0.8% 的 single-call 答对题上失败（这是并集全败率，不是任一候选或路由器损害）。观测 oracle 覆盖超出 single-call 4.75%，而最佳固定成员就是 single-call 自身（0.9375；生成 harness 为 0.6825–0.915）：每个生成成员单独都更差。单次小型审核最初未采集重复执行或同代码克隆控制。单独的 WP-1R 采集 (§5.2) 在同一题集上，为八个生成成员加 single-call 补充这些对照，与九个同代码槽各执行三次新重复。其采集协议在采集前冻结，v3 分析则在之后修订。非正的克隆校正均值和有限灵敏度，不能反过来识别完整群体单次 4.75% 余量的来源。对全部 14,400 条存档判定的版本化端点敏感重评分的一次哈希绑定重执行改变了其中 14 条（0.097%）：全部是单一任务上 v1 对区间端点答案的错误拒绝，因此逐成员准确率至多上升一道题，任何定性结论都不变（附录 G.6）。一个更早的、报告零翻转的已存储产物未能由修正分析复现，仅作为来源保留。

范围。 一个种子、一个目标、无析因、探索性；造成 Phase-I 坍缩的 SQL 协议未在数学领域重跑，因此本重复只说明干净协议的结果，不涉及坍缩的边界。

A.2 MATH 选中程序清单

表 4 说明重复研究中选定的九个冻结成员。H1–H8 是生成成员的中性编号，生成种子均为 0。所列操作表示各程序实现了什么，不表示每个分支均被触发或提高了正确性。平均调用数的准入上限不是单次执行硬上限，一次逻辑调用也可能请求多个样本。

冻结成员	源代码定义的执行路径
single-call	一次温度 0 的求解，按规定格式给出最终答案。
H1 (DeepSeek)	三次温度 0.4 的求解；归一化答案后投票；无答案或并列时采用贪心回退。
H2 (ERNIE)	起草解答，再让求解器验证或修正提取的答案；返回检查后答案。
H3 (GLM)	最多五种提示、温度 0 的求解；三者一致即停止；分歧未解决时裁决，并设有格式回退。
H4 (Kimi)	一次调用请求五个温度 0.7 的样本；提取答案后投票。
H5 (Kimi)	初次求解、验证与另一种求解；投票，没有多数时额外调用以解决分歧。
H6 (MiniMax)	草稿、批评；不一致时增加平局裁决调用；解析失败时使用此前可用答案。
H7 (MiniMax)	一次调用请求五个温度 0.7 的样本；归一化并投票，并列时取最先出现者。
H8 (Qwen)	草稿加独立求解与审核；比较答案，冲突时请求裁决，并设有格式修复路径。

表 4: 重复研究具体选中了哪些程序。所有调用使用同一冻结求解器；验证和裁决均为求解器提示，不能访问基准标签。六个席位按构建器分层选出，H5 (Kimi) 与 H7 (MiniMax) 为两个不分层席位。

A.3 模型与版本

表 5 列出本文使用的每个模型及其发送给 API 的确切版本字符串。所有模型均通过单一商业 OpenAI 兼容 API 聚合器访问（每个角色都用同一提供方）。冻结的是目标模型身份；解码由各 harness 定义，single-call 基线的温度为 0。Phase-II harness 生成使用温度 0.7、16,384 token 预算；Phase-I 生成条件及其证据缺口见附录 E.1。Phase I 使用代理执行评分器；Phase II 使用官方 BIRD 评分器（30s 超时），旧评分器作为次要审核。MATH-500 探查使用附录 A.1 的答案比较器；报告的准确率无一由 LLM 评分器产生。

角色	模型（确切版本字符串）	用于
冻结目标求解器	GLM-5.3-Flash（基线温度 0）	MATH / BIRD
第二冻结目标（重复）	Qwen3.8-Flash	Phase I
Phase-I 构建器	GLM-5.3-Flash, Qwen3.8-Flash, DeepSeek-V4-Flash-Vision-Exp	§G.1
Phase-II 构建器	GLM-5.3, Qwen3.8-Max, DeepSeek-V4-Pro, Kimi-K3, MiniMax-M3, ERNIE-5.0-Thinking-Preview	Phase II
门控仪器开发	GPT-6	附录 F.4
控制编写	gpt-5.5（v2/v3 集）, gpt-5.6-sol（v4 集）	附录 F.4
盲测控制审核 / 裁决	gpt-5.6-sol（v2/v3）, gpt-5.5（v4, 语义裁决）	附录 F.4
评分器	代理 / 官方 BIRD 执行评分器; MATH 答案比较器	见正文

表 5: 完整模型清单。目标在每个阶段内保持冻结；Phase-II 构建器来自六个独立实验室。

B 同代码对照与重复执行协议

本节说明采集设计、完整任务口径和缺失记录。统计判定与校准见附录 C，冻结选择器与重放见附录 D。

冻结协议。 采集设计在执行前固定。统计与操作规格在观察验证性结果之前修订；采集中尝试上限由 45,000 增至 60,000，并发由 2 增至 6。成员资格要求历史平均逻辑调用 ≤ 3.05 ，因此偏向低调用机制，并非对 35 个生成成员均匀抽样。固定加盐哈希抽取每个构建器一个成员，加两个自由席位。九成员面板与九个逐字节相同的 single-call 槽位均接受 $R = 3$ 次新重复。固定 MATH-500 划分包含 400 道评估题和 100 道开发题。评估题此前用于单次研究，因此本次验证新执行，而非全新任务。

描述性估计与配对推断。 完整任务 oracle 估计分别为生成臂 350 题上的 2.38% 与克隆臂 383 题上的 2.09%。较早的 2.54% 和 2.67% 使用全部 400 题的可用重复均值，将完全未观测的均值填零。这是不同的描述性估计目标。正文采用完整任务；配对 D 使用 342 题交集，判断仍为 INSUFFICIENT EVIDENCE。

采集中断与缺失结果。 采集使用 60,000 次全局尝试预算，并逐单元原子预留。两次提供方超时中断使生成臂分为三个续采组，克隆臂分为两个；各组求解器条件保持固定。合并时，完成观察优先于未解决请求；同一单元有多个完成记录时，保留最先完成者。生成臂 19,318 条记录中，8,418 条为迁移副本。完成观察替代未解决标记 14 次，9 个先前未解决单元随后完成。5 个单元有不一致的完成执行，主分析保留首个，敏感性分析排除这些单元。克隆臂 14,967 条记录归并为 10,800 个唯一单元，含 4,160 个副本和 0 个冲突。

72 个单元仍未解决，在结果矩阵中保持缺失。主统计量 G 仅使用完整任务，不插补。敏感性情景将未知结果分别全部填零或填一，并重算包含选择变化的完整交叉拟合。生成臂续采使用三个采集器版本，并发分别为 2/2/6。合并时核对程序身份与求解器条件；这些操作差异作为研究条件保留。

C 统计分析、校准与灵敏度

本节展开正文的留出重复诊断。旧档案上的应用及其独立数据划分保留于附录 G.6。

C.1 判定规则与采集后分析修订

主要互补性统计量是 §4.2 的交叉拟合冻结选择增益 G ：三折中的每一折，用两次重复冻结逐题成员映射与最佳固定成员，第三次重复把冻结映射对照该固定成员评分； G 是逐题均值在折上的平均。并列处理是标签对称的：由于 $R=2$ 发现分数落在 $\{0, \frac{1}{2}, 1\}$ 上且高准确率下并列占主导，确定性字典序规则会使选择偏向列表中第一个成员，因此按（折、题）抽取 iid $U(0, 10^{-9})$ 抖动并对十个冻结并列实现取平均；一个关于支配成员位置的模拟验证该统计量与顺序无关。判定统计量是两臂都完整的任务交集上的真实减克隆差 $D = G_{\text{real}} - G_{\text{clone}}$ 。其参考分布使用 10,000 次双臂随机化：在每题每重复内，每臂独立置换成员标签并重算 D （开发中否决了跨重复的单一联合置换，因为它保留真正的交叉映射、不会使其归零）。配对题目 bootstrap（固定随机种子的 2,000 次抽取）给出 95% 区间。冻结规则仅在以下条件全部满足时发出 SUPPORTED：覆盖门控通过（任一臂及其交集的不完整题目 $\leq 10\%$ ；配对任务 ≥ 30 ）、随机化 $p < 0.05$ 、bootstrap 下界为正、 $D > 1.0\%$ 、且 G_{real} 自身下界为正；REFUTED 要求 D 上界在界线内且等效 p 很小；否则 INSUFFICIENT。任一状态即终止研究、不再重跑的接纳规则保留。更早的 v2 程序——在重复 2–3 上对照 single-call 评分的发现重复 $\arg\max$ (A8.6) ——作为有标签的次要统计量保留，不是互补性检验（在 single-call 为 0.5、其他成员为 0.9 的纯全局支配下，其期望约为 $0.5(1 - 0.1^8) \cdot 0.4 \approx 0.20$ ）。两个冻结敏感性分支伴随它（题内可用重复均值插补；排除双重执行冲突单元）。

C.2 诊断对象与校准

对一个 harness 种群与一个 single-call 参考，诊断流程在显式执行矩阵 $Y[h, x, r, c]$ （成员、任务、重复、执行条件）上评估五类命题：（A）测量充分性（清单一致性、带显式已执行 / 未执行状态的评分器重放、同一性唯一性；未运行的检查被报告为未运行，且永远不能把该类渲染为 SUPPORTED）；（B）单次覆盖（oracle 减最佳固定，开发固定单独报告）；（C）稳定性，分两个分开的估计目标；（D）执行前可选择性（冻结的一次调用选择政策对照开发固定）；（E）冻结 1 次调用预算、 $\lambda=1$ 损害加权下的预算匹配政策效用（离线、一次调用；除非逐任务调用预算由逐记录证据验证或属于生成设计的一部分，否则 E 留作 INSUFFICIENT_EVIDENCE）。每类返回 SUPPORTED、REFUTED_WITHIN_SCOPE、INSUFFICIENT_EVIDENCE 或 NOT_APPLICABLE，附范围与最小缺失证据；各类绝不合并为单一分数。

两个稳定性估计目标。 *C-rank*: 成对同条件准确率差, 配共享题目重采样 bootstrap 与所有 $M(M-1)/2$ 个规范成员对上的 max-T 同时 95% 区间 (族系错误控制; v3 之前的逐对区间未对 36 个同时比较调整), 外加跨重复符号一致性; 对的方向由成员身份固定, 故种群结论对成员排序不变。种群状态意味着多重性调整后至少一对不同, 而非完整排序稳定。 *C-comp*: 一般群体的稳定互补性是 $H_{\text{stable}} = \mathbb{E} \max_h q_h(x) - \max_h \mathbb{E} q_h(x)$, 恰在某成员在每题上都是期望最佳时为零; 对两个成员它退化为式 (2) 的半绝对值形式。执行条件字段不同或成员程序身份不同的重复被拒绝作为匹配重复并强制 INSUFFICIENT_EVIDENCE; 逐字节相同的结果矩阵被拒绝, 除非两次重复都带有不同的、显式独立的执行来源 (合法的近确定性程序可以复现相同矩阵, 故同一性相等触发的是来源验证而非自动拒绝)。未知单元的对级插补界与记录成功率一并报告。

修订后的 **C-comp** 判定。 H_{stable} 的重复平均 plug-in 仅作为描述性字段保留; 它从不决定科学状态。审查中的两个已知真值反例被编码为回归测试: $M=9, T=400, R=3$ 下全部 $q = 0.9$ 给出 plug-in $\hat{H} = 8.69\%$ (300 个固定模拟数据集上的均值), 旧的可用重复口径在同代码克隆臂报告 2.67% (完整任务口径见附录 B) ——两者真实 $H_{\text{stable}} = 0$ 。校准统计量是 §4.2 所述交叉拟合冻结选择增益 G ; 判定使用真实减克隆差 D 。

什么在总体层面成立、什么是经验检查的。令 θ^* 为选择器相对于总体最佳固定成员的总体增益。每题上被选成员的概率至多为 $\max_h q_h(x)$, 故 $\theta^* \leq H_{\text{stable}}$ 。零假设 $H_{\text{stable}} = 0$ 是全局支配锥: 存在某 h_0 对所有 h 与几乎每个 x 满足 $q_{h_0}(x) \geq q_h(x)$ 。在支配下, 总体最优的冻结映射路由到支配成员, 因此整个锥上总体增益 $\theta^* \leq 0$, 不只在等能力处。这里的比较对象是总体最佳固定成员, 而有限 (R, T) 统计量 G 使用从发现数据中选出的固定成员。在后者中, 发现 argmax 是从含噪重复中选出的, 较弱成员可能在有限样本中因与含噪发现分数并列而被选中 (密封克隆臂打印的 $G_{\text{clone}} = 0.55\%$ 出现在有限样本波动之下), 所以 $\theta^* \leq 0$ 本身并不界定有限样本拒绝概率。双臂 Monte Carlo 随机化参考在等能力边界处是精确的——在该处置换标签可交换, 重算统计量 (配合 +1 校正) 是同一条件分布的一次抽样。在支配锥的其余部分, 错误支持是在下面校准网格的每个零假设 DGP 上经验验证——包括异质难度、异质支配、0.5/0.9 配置、缺失性以及两臂间匹配的黏性题内潜在状态——而不是解析地断言为有限样本结果。水平 .05 的程序在有限网格上可以以 .05 的水平错误支持; 可辩护的陈述是观测到的最差比率及其 Wilson 区间, 而非“不可能”。

并列处理。冻结 argmax 中的成员标签并列处理使用 iid $U(0, 10^{-9})$ 抖动, 在真实数据报告上对十个冻结并列实现取平均 (每个校准数据集用一次抽样: 零假设下并列偏差均值为零); 确定性字典序规则不是标签不变的, 被模拟拒绝。标签对称性由一个置换不变性回归测试直接断言: 当成员顺序在两臂中以相同方式置换时, 10 次抽样并列平均的 G 、 D 与状态在 Monte Carlo 容差内一致。

随机化机制。 标签在每个题目且每个重复内独立置换 (跨重复的单一联合置换会保留真正的交叉映射, 不会使统计量归零: 开发中已验证), 每次抽取重算两个 G 、它们的

差及两个选择；+1 Monte Carlo 校正给出精确离散水平。配对题目 bootstrap 提供抽样区间；一个 $\leq 10\%$ 不完整题目覆盖门控、极值未知单元界与正 G_{real} 符号守卫补全规则，没有克隆臂时不发出 SUPPORTED 状态。

regime	$R=3$		$R=10$		$R=20$		abst.
	plug	v3	plug	v3	plug	v3	$R=3$
equal $q=0.9^\dagger$	100	0	100	0	100	1	100
equal + difficulty [†]	100	0	100	1	100	1	100
0.5/0.9 dominance [†]	100	0	100	0	13	0	100
dominance [†]	100	0	100	0	100	0	100
cross $H \approx 0.9\%$	100	1	100	0	100	0	99
cross $H \approx 1.8\%$	100	1	100	1	100	0	99
cross $H \approx 4.2\%$	100	0	100	0	100	0	100
two strong specialists, $H=17.5\%$	100	0	100	100	100	100	100

[†]Null ($H=0$): false-support %, nominal 5%; else power %. $M=9, T=400, B=300$ at $R=3$ (150 sweeps), 300 randomizations. Wilson intervals and the full M, T, R , missingness grid in Appendix C.

表 6: 三次重复甚至会漏掉强正例。在 $M=9, T=400$ 下，零假设行报告错误支持率(%), 备择行报告功效(%); 最后一列为 $R=3$ 的弃权率。克隆校准规则 (v3) 很少支持零假设，但对所测小、中等交叉的灵敏度很低。

已知真值模拟校准。 二元张量从指定的 $M \times T$ 概率矩阵抽取：常数 q 与共享题目难度的 iid 等能力；带干净支配固定成员、审查者 0.5/0.9 配置及异质支配的全局支配；以及两类潜在任务类型上强度递增的交叉备择，外加难度相关的部分交叉。网格覆盖 $M \in \{3, 9, 20\}$ 、 $T \in \{100, 400, 1000\}$ 、 $R \in \{3, 5, 10, 20\}$ 、完整数据、5% MCAR 与 3% 难度相关缺失；论文表聚焦 (9, 400, ·) 获取设计，每格 300 个 Monte Carlo 数据集（扫描中 150 个）。每格报告四种程序（plug-in；单切分冻结增益；重复交叉拟合增益；克隆校准 v3 判定）的支持、否证、弃答与错误率，对真实参数的区间覆盖，以及平均估计。结果显示：plug-in 在所测零假设下经常错误支持；v3 最坏的观测零假设支持率为 2%。强双专家备择在 $R=10, 20$ 时功效达到 100%，但更小的循环交叉即便在 $R=20$ 时也大多检不出。这些经验比率描述所测网格，不构成一般的检验大小或功效保证。更早的八个机制派生类与四个基于重复的类（C9–C12，其中 C9/C10 现与注册的同代码克隆臂配对）继续匹配其预先固定的期望状态；不变量测试还直接断言置换不变性、支配 $\neq$ 互补性、同一性拒绝及两个审查反例。

C.3 有限重复偏差与克隆零假设校准

把 $\hat{q}_h(x)$ 记为重复平均估计，由 Jensen，对每题 $\mathbb{E} \max_h \hat{q}_h(x) \geq \max_h \mathbb{E} \hat{q}_h(x)$ ，当有限 R 噪声能改变逐题 argmax 时严格不等。plug-in 提升空间是两个此类最大值之差；Jensen 分别界定每一项，因此一般而言并不确立该差向上偏——在一个两成员两任务交叉例子中 plug-in 可能向下偏（真实 $H=0.40$ ，三次重复的期望 plug-in 约为 0.34）。被确立的是更强也更窄的命题：在同代码可交换性下，真实 H_{stable} 为零，而 plug-in 以趋近一的概率为正（逐题 argmax 上的选择噪声； $q=0.9$ 、 $M=9$ 、 $T=400$ 、 $R=3$ 的已知真值模拟中 $\hat{H}=8.69\%$ ，密封克隆臂在其 383 个完整任务上描述性为 2.09%，真实面板

在其 350 个完整任务上为 2.38%)。这些使用与各臂 G 相同的完整任务集合，但不是配对的 D 比较。因此校准程序从不凭 plug-in 判定：发现 / 验证交叉拟合在发现重复上冻结逐题成员映射，在留出重复上对照最佳固定成员评分。有限发现数据未必能识别全局支配成员；真实减克隆差将克隆臂用作观测采样参照，并非解析移除全部有限 (R, T) 选择偏差。推断使用双臂 Monte Carlo 随机化参考 (+1 校正；在等能力边界精确，在整个支配网格上经验检查而非解析断言；附录 C)。同一性门控通过要求来源验证的独立执行直接处理退化情形；没有不同来源的相同矩阵被拒绝。

C.4 已知真值控制上的验证

冻结包有两层：原八个机制派生类 $\times 2$ 实例 (16 个控制，期望不变)，加四个基于重复的类 $\times 2$ 实例，演练单次控制无法到达的稳定性路径——全局支配 (C-rank SUPPORTED, C-comp REFUTED)、等均值交叉技能 (C-rank INSUFFICIENT, C-comp 在克隆校准下 SUPPORTED, 可见层使 D/E SUPPORTED)、条件混合陷阱与克隆重复陷阱 (后两者必须弃答)；C9/C10 按 v3 判定要求携带注册的同代码克隆臂。期望状态在任何盲测运行之前固定，并由生成机制导出。不变量测试还断言置换不变性、支配 $\neq$ 互补性、同一性拒绝、两个审查反例 (iid 噪声与 0.5/0.9 支配不得支持；交叉在重复充足时必须支持)，以及判定从不在无克隆臂时支持。校准在所有状态单元上匹配；盲测集 (12 个控制加 2 个审核者挑战，在当前代码下从预提交、固定规格重新执行) 在全部 14×6 单元上匹配：零错误支持，正控制被识别，弃答上限成立。这些离散控制补充但不取代 §5.3 的 Monte Carlo 错误支持 / 功效校准——后者报告 v3 检验在所测网格上的经验错误支持率与功效。更早存储的、其 CH2 数字与自身规格矛盾的挑战结果 (生成规则强制 0.79 时最佳固定 0.94 不可达) 仅作为来源保留；忠实于规格的重新执行在每个单元上匹配审核者预提交期望。

D 冻结选择器与等执行次数重放

本节对应新的 MATH 重复研究：选择器在 100 道开发题上拟合，在 400 道评估题上评分。旧档案的 80/320 划分和 BIRD 数据库划分选择分析属于历史分析，分别见附录 G.6 和 G.4。

D.1 冻结特征选择器

π_Z 是在 TF-IDF 题目特征 (最多 300) 与仅在训练折内计算的逐成员开发准确率上的多项 logistic 回归；在 100 道开发题上作 5 折题目级 CV，问题重复绝不跨折拆分；折模型平均；并列以成员 id 打破；当 top-2 概率差距低于 0.15 时弃答至 single-call。重复聚合使用逐成员一题的可用重复均值 (问题重复留在一折)。比较器：single-call、开发固定、预先固定随机成员 (带种子)、M1b (缺失单元上带 single-call 回退的开发固定)。 E_1 (预算按构造满足) 不适用，因为面板成员发起不止一次调用； $b=3$ 次逐题调用的 E_b 作为单独命名的估计目标报告。泄漏控制：不使用答案、正确性、评估派生难度、执行后轨迹或评分器特征。

Policy	Eval acc. (%)	Δ vs dev-fixed (%) [95% CI]
single-call (fixed)	94.96	0.00 [0.00, 0.00]
dev-fixed	94.96	—
random (pre-fixed)	85.14	-10.12 [-13.27, -7.22]
M1b (dev-fixed + bare fallback)	94.96	0.00 [0.00, 0.00]
π_Z (frozen selector)	94.96	0.00 [0.00, 0.00]

表 7: 400 道 MATH-500 评估题上的 WP-2R 冻结比较器集（三次新重复的重复均值正确性；回顾性任务、前瞻性执行——不作未见任务主张）。配对差为逐题对照开发固定，配题目级 bootstrap CI。

D.2 选择与预算效用的诊断定义

D 类评估一个冻结的确定性政策 $\pi_Z : Z(x) \mapsto h$ ——执行前特征（题目文本、冻结机制标签、训练折开发准确率），仅在开发任务上拟合——按 $D(\pi_Z) = \mathbb{E}_x[Y(x, \pi_Z(x)) - Y(x, h_{\text{dev-fixed}})]$ ，并带弃答规则：当 top-2 选择概率差距低于冻结边界时回退到 single-call。E 类在均匀逐任务调用预算 b 、 $\lambda=1$ 损害加权（一次回归抵消一次修复）下评估 $U_b(\pi) = \mathbb{E}_x[\Delta(x, \pi(x))]$ ；仅当逐记录证据在每个被评估成员——任务对上验证预算时它才可受理，否则弃答。

D.3 等执行次数重放与实际采集账目

报告三种不同的比较且绝不混淆。(i) 等槽位采集：两臂都执行九个成员 / 槽位、三次重复；这是随机化设计，不意味着匹配花费。(ii) 共同逐任务执行预算 (§5.4)：在 $b \in \{3, 9, 15, 27\}$ 次逐任务执行下，离线比较开发排序面板组合与 27 次同代码执行中的 b 次，仅采用执行后 *oracle* 聚合；面板减同代码的 *oracle* 差为 +0.37, +0.03, -0.11, -0.25%。由于两臂输出格式不兼容（带框数字对自由散文）、模态答案键不公平，不报告跨臂多数投票准确率。(iii) 已实现花费：逐请求账目分层为实验运行 > harness 执行 > 逻辑调用 > 提供方尝试；迁移副本排除。真实臂作出 22,192 次逻辑调用（32,097 次提供方尝试；54.17M 已知 token；每评估题 54.5 次调用），而克隆臂为 10,800 次逻辑调用（10,804 次尝试；14.51M token；每题恰好 27 次）——由多调用面板成员驱动的 $2.05 \times$ 调用比与 $3.73 \times$ token 比；在冻结盈亏平衡价下的保守上限为 1,803.82 对 483.15 元人民币（定价不可独立验证；报告为 token 数乘以冻结的每 1M token 33.3 元，绝不作为计费金额）。全部臂的总计：38,458 逻辑调用、50,817 尝试、79.8M 已知 token、2,656.22 元上限。因此我们不作已实现成本匹配主张；共同预算重放仅匹配 harness 执行次数，不匹配 token 成本。

E BIRD 执行轨迹与补充分析

本附录展开正文的补充执行诊断。历史记录中的 Phase I 指 BIRD 发现研究，Phase II 指独立的 BIRD 准入研究；它们均不作为 MATH 结果的因果解释。

E.1 发现研究的总体与条件

发现研究状态。 Phase I (§5.5 与 §G.5) 是发现研究。其 151 个评估项中有 24 个与发现阶段协议开发测量重叠；人工控制是在检查发现阶段轨迹后设计的（其观测提升空间是描述性的，不是稳定互补性的盲估计）。Phase-I 准入阈值（联合修复率 $\geq 15\%$ 、提升空间 $\geq 5\%$ 、 ≥ 3 个成对不同的非空修复集合）在 151 题评估之前已固定；v6→v7 的阈值变更（ $20\% \rightarrow 15\%$ ）已披露，两种读数接纳相同种群。这是内部评估前冻结，不是外部预注册。

数据卫生。 single-call 基线在两次发现阶段运行之间翻转了 60 题中的 3 题（温度 0 下的 API 非确定性），因此 60 题列以略有不同的 single-call 错题集合为条件。Phase-I 评分使用行集合相等代理，我们后来测得它相对官方 BIRD 评分器一致保守（在两个记录了最终 SQL 的 Phase-I 矩阵上，它从不把官方评分器判错的答案判对；一致率 0.97–0.99）。

Phase-I 种群。 种子基线：single-call（单次调用）与 react（执行反馈循环，随 TTHE 提供）。旧提议者协议：从 TTHE 优化循环输出中选出的六个候选（GLM-5.3-Flash 构建器），仅使用与评估集不相交的 36 道题、按评估前冻结的规则为行为多样性而选择。策略强制自由形式：GLM-5.3-Flash、Qwen3.8-Flash、DeepSeek-V4-Flash-Vision-Exp 构建器，各八个指派机制；GLM 种群是有日志的重跑（ $K=3$ ；原先运行记录为零接纳，但其工具未保存，该观察无法审核）。*Harness IR*：从声明式机制规格确定性编译的六个 harness（上下文 $\in \{\text{plain, schema_link, hint_guard, link+hint}\}$ ，带温度的候选生成、逐候选执行、修复轮次、选择规则），因此声明机制按构造存在于控制流中。人工正控制：附录 E.2 的四个手写 harness。

生成日志缺口与历史协议探查见附录 G。




图 2: 源码差异未必改变观测正确性。BIRD 发现研究包含 14 个 harness、60 个任务, 每个执行一次。含基线的 91 对中, token 序列源码相似度与正确性分歧的秩相关为 $\rho = -0.010$; 36/91 对具有相同正确性向量。这是观测任务上的结果比较, 不是程序等价检验。

E.2 发现研究的结果与人工控制

每个 BIRD 发现候选都通过代码差异检查。然而, 21/66 个生成候选对具有完全相同的正确性向量 (含基线为 36/91), 91 对上源码相似度与正确性分歧几乎没有秩相关 ($\rho = -0.010$; 图 2)。整体平均分歧为 3.3% (仅生成候选为 3.8%), 对 single-call 错题的联合修复为 7.7%, 单次余量为 3.3%。在这 60 题上一致不能确立程序普遍等价, 却说明有必要检查程序实际做了什么。

E.3 轨迹区分机制缺失、未触发与执行失败

T1: 描述存在, 实现缺失。十二个候选中有六个在文档字符串中声称检索或自检, 却只调用一次模型、不执行任何产物, 所命名的机制并未实现。**T2: 机制存在, 未被触发。**全部十个经过审核的 `react` 任务中, 首个 SQL 均成功执行, 已有的执行一反馈一修复分支从未启动, 最终 SQL 与 single-call 相同。执行成功不等于语义正确, 这些运行并未检验失败条件下的修复。**T3: 执行发生, 输出损坏。**十二个候选中有一个执行多轮查询与修复, 却将自然语言作为最终 SQL 返回, 丢掉了 single-call 能答对的题。

这些观察定位不同的失败环节, 而不是赋予一个共同的多样性分数。T1 要求检查实现, T2 要求任务能够触发分支, T3 要求有效的输出契约。它们未确立机制触发会引起准确率提升。四个人工编写、执行路径不同的控制在 60 题上产生 6.67% 单次余量, 在 151 题上为 7.28%, 说明评估装置能够记录不同修复。但这些控制是在查看轨迹后编写的, 缺少匹配重复与克隆对照。附录 E.1 披露较早的代理评分器及与协议开发重叠的 24/151 题; 附录 E.4 提供具体轨迹。

E.4 轨迹审核的完整样例

为使 §5.5 的失败分类具体化，本节把一项 BIRD 任务在被审 harness 中走一遍。产物逐字取自发现阶段轨迹审核（5 个 harness $\times$ 10 道题）；其日志器把存储的 SQL 摘录上限设为 120 字符，故截断以 *[trunc.]* 标记。

任务。 BIRD 开发集问题 352 (`card_games` 数据库；题目文本逐字，拼写错误为数据集原有)：

```
Calculate the percentage of the cards available in Chinese
Simplified.
```

其 BIRD 提示：

```
'Chinese Simplified' is the language; percentage = Divide(Sum(id
where language = 'Chinese Simplified'), Count(id)) *100
```

Gold SQL（在发布数据库上执行两者分别得 8.7734 与 8.7728——官方评分器将其区分）：

```
SELECT CAST(SUM(CASE WHEN T2.language = 'Chinese Simplified' THEN
1 ELSE 0 END) AS REAL) * 100 / COUNT(T1.id) FROM cards AS T1 INNER
JOIN foreign_data AS T2 ON T1.uuid = T2.uuid
```

single-call harness 回答：

```
SELECT SUM(CASE WHEN language = 'Chinese Simplified' THEN 1 ELSE 0
END) * 100.0 / COUNT(id) AS percentage FROM foreign_data;
```

被官方评分器判错：它直接在 `foreign_data` 上计数，而 gold 查询在连接 `cards` 之后计数；提示没有写明该连接。

react (T2: 机制存在但未触发)。 `react` 的控制流确实执行 SQL 并在数据库错误时重试。但其第一次调用与 single-call 的提示逐字节相同，而此处生成的 SQL 执行无错误，因此错误触发的重试从不发生，最终 SQL 与 single-call 相同。在全部 10 道被审任务上模式都成立：有 SQL 执行，10/10 最终 SQL 与 single-call 逐字节相同——反馈循环是真实代码，但其修复分支在这些题上未激活。需要受控故障注入来检验反馈是否改变输出。

单次调用候选 (T1: 机制被描述但未执行)。 该候选的文档字符串宣称一种“保守修复”：限制求解器最大输出 token 并要求仅答案块。其行为在结构上就是 single-call：一次 LLM 调用，然后提取 SQL。token 上限仅作为环境默认值存在（2,048 对运行时的 32,000）——没有任何 harness 控制流实现它，且在这些问题上它从不生效，因为 SQL 答案比上限低几个数量级。在工作样例题上它恰好发起一次调用、什么都不执行，并

返回与 single-call 相同的错误查询（忽略空白差异；直接在 `foreign_data` 上计数而无连接）。在全部 10 道被审任务上它记录的 SQL 执行数为零，且最终 SQL 有 6 个与 single-call 逐字节相同（其余差异可追溯到改写的系统提示，而非任何机制）。因此最常见的 Phase-I 失败类不是机械损坏而是机械缺失：声明的机制只存在于散文中。

超时重试候选（代码级多样性，行为同一性）。 该候选是一个真正不同的程序：它把单次 coder 调用包在守护线程看门狗中，若调用停滞超过 40s 就发出一次对冲重复追问。机制存在于控制流中——但其触发器（停滞的 API 调用）在审核中从未出现：零次 SQL 执行，且全部 10 道被审题的最终 SQL 都等于 single-call。即使新增机制是真实的，代码不同而行为相同仍可存活：它只是从不触发。

多轮修复候选（T3：损坏的多轮路径）。 唯一一个实现了真正执行—检查—修复的被审候选把模型的散文当作最终 SQL 返回。在一道 single-call 答对的题（“State the alternative languages available for card named Annul numbered 29.”）上，其记录的最终 SQL 逐字开头为：

```
with "only a single read-only SELECT is allowed". The previous
"query" was actually just prose text (the model wrote rea[trunc.]
```

修复再提示招致了失败：被要求修复一个“实际上只是散文”的查询时，冻结目标以更多散文推理回应，找不到 SQL 块，推理文本便被当作查询提交。该题从 single-call 正确翻转为 harness 错误。

E.5 存档 BIRD 执行指纹

本指纹分析事后使用存档验证性单元（18 个构建器 × 种子单元、384 个接纳候选、core-400 结果），沿用主重分析的记录合并规则、固定任务及成员身份检查。这些任务已被分析过，因此结果是描述性的，不构成独立迁移验证。同一档案上的历史选择分析见附录 G.4。

丰富指纹。 为隔离加载器变更，W3 重分析保留旧的有损 SQL 文本变换：删除分号、替换反引号、即使在单引号分段后仍整体小写化、合并空白。这不是 SQL 解析器或语义归一化；它可能改变字面量与带引号标识符。在 364,428 个两条变换后 SQL 相同且非空的对一题观察中，有 0 个判定不同。这是观测到的一致性检查，不是按构造保证的性质。

对级 SQL 不相似度仅在判定一致且两条 SQL 非空的题目上平均 (1-token-Jaccard)。它与整体结果分歧的 Spearman 相关在 4,386 个单元内对上为 0.597，在 1,010 个组内对上为 0.588。各对共享候选与题目，且 SQL 指标以判定一致为条件；这些相关没有基于独立性的显著性或因果解释。

在 R2 的 70-harness 首次关缓存获取中，调用数在 506/28000 次比较中变化，判定在 2391/28000 次中变化。变换后 SQL 在 19569/27936 次比较中变化 (70.05%)；64 次比

较缺少两条非空 SQL，仅从 SQL 分母中排除。变化 SQL 对的平均 token Jaccard 为 0.619。这些通道特定比率不定义效应大小噪声地板。canonical 逻辑调用成本在表 12 中单独报告。

E.6 第二目标模型探查

使用 Qwen3.8-Flash 的第二目标探查重复了结果坍缩。策略强制群体仍保留提升空间，提示侧人工控制则未整体迁移。这些探索性观察不确立跨目标模型的稳定专长。

轨迹提出了什么机制假说？ BIRD 中未被触发的分支提示：在正常 SQL 任务与受控执行故障任务上，比较开启修复、关闭修复和重复 single-call。若反馈改变查询并恢复正确性，且收益在重复、预算匹配比较中保持，将支持修复机制；若重采样同样有效，则解释受到削弱。这项干预尚未运行。它检验具体的修复假说，不是 harness 多样性的普适必要条件命题。

F BIRD 准入策略研究

本研究采用 2×2 析因设计加开放机制臂，包含六个构建器与三个种子。每槽至多 $R = 3$ 次尝试，首次接纳即停止，不补足。两个开发数据库从评估池排除。评估集包含九个数据库的 1,169 题与预抽取的 400 题核心集；一次 18 题流水线冒烟测试是已披露的开发隔离例外。官方 BIRD 评分器执行 30s 超时。响应缓存按模型身份区分，并采用跨进程锁；采集中发现并修正了缓存并发缺陷。

原主对比为配对构建器一种子单元上的 D-A，使用分层 bootstrap 与置换推断；共同核心上的析因次要分析采用 Holm 校正，并进行 K 匹配敏感性分析。仪器校准修正先于验证性结果。其他偏差包括操作性访问处理，以及对不一致观察的隔离。修正分析使用共享基线记录与数据库 / 题目重采样；这些修订发生在原分析规格之后。实际门控在结构上拒绝两种允许的提示层策略，各臂实际生成成本也不同。




图 3: **Phase-II** 验证性设计（冻结协议）。左：数据库级污染隔离。中：2x2 析因与共同尝试上限，加开放机制臂 II-E。右：三层准入流程。

F.1 设计与主要比较

一项独立的确认性 BIRD 研究让六个独立构建器与三个种子在策略强制（来自固定集合的具名机制对自由发明）与合规门控两个因素下交叉，给出四个臂：II-A（自由、无门控）、II-B（自由、门控）、II-C（强制、无门控）、II-D（强制、门控）。评估覆盖开发期间从未打开过的九个数据库中的 1,169 个问题（一个已披露的 18 题冒烟测试例外），使用官方 BIRD 执行评分器，分析在结果前冻结、之后以版本化校正重分析重跑。所实现的门控把非平凡机制的结构性的剔除与合规验证捆绑在一起——八个强制提示转换槽中有两个即便中性有效也无法通过——所以该处理不能在因果上分离出“验证”本身。

Metric	II-A	II-D
Candidate count	5.78	3.83
Oracle accuracy (%)	76.14	75.70
Best-fixed accuracy (%)	67.58	67.30
Headroom (%)	8.56	8.40
D-A headroom (%)	-0.16	
Unadjusted bootstrap 95% CI	[-0.83, +0.87]	
One-sided sign-flip p	0.647	

表 8: 校正后的主分析。数值为 1,169 个问题上 18 个构建器-种子单元格的均值；single-call 同时计入 oracle 与最佳固定对照。

含 single-call 的 oracle 余量上，强制/门控（II-D）减自由/无门控（II-A）的对角均值对比为 -0.16% ，单元格对比范围为 -4.36% to $+2.74\%$ ：捆绑的筛除策略没有改善平均余量。原有不确定性分析保留在表 8；这一均值比较不确立等价。结构准入因而不能证明机制会在相关任务上触发，或增加稳定效用。




图 4: 版本化校正重分析。左: 完整集合的 D-A 单元格对比与合并 95% 区间。右: 共享核心 400 题上、以共同 single-call 为基线的四臂余量。

在共享的核心 400 题上,门控对比为 -0.69% ,策略与交互的次级效应同样未解决(表 9); 固定 K 的均值对比 -0.31% 提供群体规模的敏感性检查。开放机制臂只在开发侧运行,没有确认性估计目标。这些都是单运行对比,而附录 F.3 的 R2/R3 审核报告的执行变异性(R2 判定翻转 8.54%; 14.5% 的任务三次运行间 single-call 正确性变化; 6.50% 同代码单次缺口)把它们刻画为覆盖机会而非能力差异。

Contrast	Effect (%)	95% CI (%)	Raw p	Holm p
Gate	-0.69	$[-1.56, +0.20]$	0.026	0.079
Strategy	$+0.42$	$[-0.32, +1.51]$	0.263	0.428
Interaction	-0.87	$[-2.83, +0.65]$	0.214	0.428

表 9: 校正后的核心 400 题析因重分析。门控为 $[(B-A) + (D-C)]/2$, 策略为 $[(C-A) + (D-B)]/2$, 交互为 $(D-C) - (B-A)$; 给出原始与 Holm 调整 p 值。

F.2 同核心提升空间分解

表 10 在相同核心任务与基线记录下分解各臂的覆盖、最佳固定准确率及余量。

Arm	K_{cand}	K_{total}	Single-call (%)	Best (%)	Oracle (%)	H (%)
A	5.78	6.78	63.25	66.00	74.51	8.51
B	6.11	7.11	63.25	66.12	74.39	8.26
C	5.61	6.61	63.25	65.64	75.01	9.38
D	3.83	4.83	63.25	65.65	73.90	8.25

表 10: 同核心提升空间分解。所有臂使用相同 400 题与相同 single-call 结果。 K_{cand} 排除 single-call, $K_{\text{total}} = K_{\text{cand}} + 1$; 数量与准确率为单元均值。提升空间为 oracle 减最佳固定准确率, 不是已实现路由增益。

F.3 敏感性、重复审核与记录成本

修正的 K 匹配与 R2 重放。 两次重放都使用与修正主分析相同的确定性记录排序与共享数据库 / 库内题目抽取，在固定构建器内重采样种子（10,000 次重复）。K 匹配中，每个 A/B 与 C/D 对使用较小候选数；每个均匀候选子集被精确枚举一次。single-call 留在每个子集中，最佳固定在每次题目抽取的每个子集内部重算。这是规模敏感性分析，不是因果中介分解。保留全部 18 个单元（包括两个 A 子集为单成员的单元）使子集 D-A 从 +0.42 变为 +0.81 %（变化 +0.39 %，95% CI [-0.95, +1.63]）。R2 子集提升空间排除 single-call，因为 R2 未获得匹配的 single-call 运行，故它不同于包含 single-call 的主估计目标；旧的 16 单元比较在此对账。这些是不稳定性测量，不是标准误，也不是平均处理效应的可检出下限；它们不证明每个对比都不变，也不识别 harness 间分歧中有多大部分是噪声。

R2 在 400 题上获得 70 个 harness，在可用时为每个 A/D 单元选择前两个可调用的已接纳候选。两组关缓存采集虽然重复标签相同，仍分别保留；程序身份与缓存运行核对。未获得匹配 single-call，因此 R2 提升空间在两种条件下都排除 single-call。修正分析保留单成员单元（其子集提升空间为零），得到全部 18 个配对单元。对缓存结果有 2391/28,000 次判定翻转（8.54%），两次 D 关缓存轮次之间有 1245/14,400 次翻转（8.65%）。仅为对账，限制到两臂都至少有两个成员的 16 个单元，缓存下 D-A 为 -0.11 %、关缓存下为 +0.36 %。这解释了与全单元估计的差别；两种分析都不识别未来执行方差、单独缓存的效应、或相对克隆的稳定互补优势。获取时间与缓存条件未被分离。

R3 仅 single-call 重复审核。 R3 是一项单独的、更小的不稳定性审核：仅 *single-call* 基线（无生成 harness）在相同 core-400 题、相同冻结目标（GLM-5.3-Flash，温度 0）上的三次独立关缓存执行。400 题中 58 题（14.5%）在三次重复中至少一次改变 single-call 正确性；重复对之间的成对翻转率为 39/400、40/400、37/400（9.75%、10.0%、9.25%）。把三次 single-call 重复当作三个伪成员（各一次执行）给出单次 oracle 72.25%，相对最佳单次重复准确率 65.75%，即描述性的 6.50 % 同代码 oracle 缺口，由记录的官方评分结果计算。因此 R3 测量的是温度 0 API 非确定性下基线自身的观测不稳定性。这不是任何对比的标准误或效应大小下限，但它设定了重复控制成为解释必要项的尺度：没有它们，这个量级的 harness 对 single-call 差异不能归因于能力。

Sensitivity estimand	Estimate (%)	95% CI (%)
K-matched B–A headroom	−0.55	[−1.53, +0.63]
K-matched D–C headroom	−0.08	[−1.26, +0.80]
K-matched gate mean	−0.31	[−1.07, +0.40]
R2 subset D–A (cached)	+0.42	[−0.61, +1.48]
R2 subset D–A (cache-off)	+0.81	[−0.35, +1.84]
R2 change in subset D–A	+0.39	[−0.95, +1.63]

表 11: core-400、18 单元上的修正敏感性。CI 未校正。K 匹配比较始终保留 single-call; R2 比较排除 single-call, 并以观察到的获取组为条件。

记录成本与缺失账单数据。 相同 canonical 核心记录在 153,600 条候选一题目记录中包含 259,304 次记录的逻辑 solver 调用 (表 12)。这些调用包括缓存服务的请求, 不是提供方计费的 API 请求。所检查的记录均无 token 用量字段; 我们从不从调用数推算 token 或货币支出。因此实际生成尝试数、接纳候选数与这些执行计数保持为不同测量。种群成本均值对每个构建器—种子单元等权且排除 single-call; 零候选种群贡献零次 solver 调用。

Arm	Candidate-task records	Logged solver calls	Calls/task/population
A	41,600	67,258	9.34
B	44,000	64,399	8.94
C	40,400	75,604	10.50
D	27,600	52,043	7.23

表 12: core-400 上的描述性 canonical 成本审核, 每组 18 单元。记录的逻辑调用不是计费请求或 token 计数。末列为各单元逐题候选种群调用的平均值。

F.4 门控工具的独立控制检验

我们用 32 个新编写的控制测试审后 Gate-v2 开发仪器, 与开发其探针所用的控制分开。仪器先固定, 之后另一个模型 (gpt-5.5; 表 5) 只收到公开合同与可调用接口, 不接触其实现或早期控制。作者为八类机制各提供两个意图符合与两个意图不符合的实现。控制来源、作者参考标签、仪器、测量代码与执行顺序在首次评估前固定。未运行任何基准或提供方生成, 首次测量原样保留。

声明机制	结构通过	结构失败	需审阅
修复	2	2	0
执行结果投票	2	2	0
模式链接	0	4	0
提示守卫	0	0	4
双视图	0	3	1
分解	1	3	0
错误分类	0	4	0
格式守卫	0	0	4
合计	5	18	9

表 13: 固定开发仪器对 32 个独立编写控制的首次评估。无一例发生执行失败。这些是仪器状态，不是正确性标签或种群错误率；作者意图的正 / 负标签需另行审查。

九个需审阅案例全部保留。第三个模型（`gpt-5.6-sol`）收到完整控制来源与轨迹，但没有作者参考标签或自动判定，用于对全部 32 个控制作来源—合同审查并对四类指定机制作语义裁决。独立来源审查支持一个分解控制与两个错误分类控制符合，而仪器拒绝了它们。分解 stub 返回其文本在请求中出现的第一个计划步骤的载荷；因此在下一请求的上下文中保留较早步骤会再次取回较早载荷。分类检查移除了确切错误文本，但仍把普通 **Schema**：标题计为一个类别，使提取的类别集与预期错误类不一致。这些是仪器在这些控制上的失败，不是目标模型的观测失败。三个作者意图正控制被争议：两个模式链接控制保留了无关表，一个双视图控制批量处理其请求并错误处理空结果。其原始标签与审查分歧分别保留。在作者标签与来源审查一致的 29 个控制中，仪器拒绝了 13 个符合控制中的 3 个；全部 16 个不符合控制在指定语义审查后都被拒绝。因此仪器未通过这项有限控制检查。这些计数不估计生成种群中的错误率。指定 16 个控制的语义裁决产生 7 个符合、8 个不符合、1 个不确定。不确定案例本就有结构失败，保留该失败而不解决其语义。这个小型、刻意平衡的控制集不是生成 harness 的随机样本。通过它并不能验证生产接口或取代准入政策的共同原始池比较。

修订仪器与新的独立控制集。 Gate-v3 修正了解析请求归属，并把类别关键词与共享请求模板当作审阅线索而非自动拒绝。我们在新的模型上下文（`gpt-5.5` 编写、`gpt-5.6-sol` 审查）编写并审查新的 32 控制集之前固定此版本，仍为每机制两个意图正、两个意图负控制。审查包隐去作者标签、自动判定与仪器派生的归属元数据。全部 32 个控制接受来源审查；四个提示 / 表述组加分解中的 20 个控制还接受语义或数据流审查。结构结果为 8 通过、10 失败、14 需审阅，无执行失败。经一次记录在案的证据澄清，来源审查把 15 个控制分类为符合、17 个不符合；语义审查分类为 8 符合、11 不符合、1 不确定。

不确定的分类控制请求一个中间错误类别，但合成接口返回 SQL 文本。其回退随后选择了语义修复动作。这确立的是 fixture 中的响应类型不匹配，不是真实求解器的分类错误。第二个分类控制受到参考争议：其来源把提供的模式失败消息映射到语义动作。

在 31 个无争议参考中，15 个符合控制有 14 个被接受、1 个仍未解决；全部 16 个不符合控制被拒绝。因此预先指定的有限检查因未决案例及错误分类缺乏足够一致的正覆盖而仍未满足。一个投票控制的符合性仅适用于结果仲裁；它未确立以任务为条件的候选生成。这些有限机制检查不验证完整 harness 运行，也不取代计划中的共同池政策比较。

运行时响应合同。 我们随后测试了七个存档的无门控、策略强制候选，按固定顺序选择每种策略的首个可用候选，而非按表现；没有可用的格式守卫候选（附录 G.2）。27 个合成场景同时暴露了候选与仪器的局限。双视图候选在第一个结果非空时跳过第二次执行，与其原本“两者都执行”的声明相反。相比之下，模式链接候选请求 JSON 却收到纯文本，分解请求中的完整计划使冻结探针无法唯一归属当前目标。我们保留这些观察，并在另外 11 个开发场景中测试来源指派的响应配置。专用子问题字段识别了当前目标，可执行 SQL 载荷到达最终装配，内存 SQLite 数据库产生的四个错误引出相应的语法或模式修复指令。模式链接 JSON 改变了 SQL 编写请求中的显式表 / 列限制，但完整模式仍在场。因此仅凭保留模式上下文不能确立链接子集被忽略。这些暴露候选检查把响应接口失败与可观察的候选偏差区分开；它们不取代独立校准，也不提供修订后的基准结果。

统一接口与测量前参考审查。 Gate-v4 把来源指派的响应接口与五个未变的 Gate-v3 机制探针结合。另写的 32 控制集（gpt-5.6-sol）在执行前接受盲测来源审查。作者熟悉更早的控制失败；此来源审查中发现的模式响应与声明投票参数不匹配在保留初版的同时被修正。修订参考在每机制有两个一致符合与两个一致不符合控制。冻结其来源、配置与依赖后，一次测量覆盖 124 个场景，无执行异常。结构结果为 4 通过、6 失败、22 需审阅。

一个新的审查上下文（gpt-5.5）收到全部来源与实际轨迹，但没有参考标签、来源审查决定或自动判定。其首次判定为 18 符合、14 不符合。在预先指定的混合规则中保留结构失败会接受全部 16 个符合参考，但也接受一个不符合的提示控制，故有限零错误标准未满足。该控制正确重述已有提示，却在未提供提示时虚构了强制排序。一次记录在案的、有针对性的证据澄清纠正了这一疏漏，也纠正了一个把同一请求的两个样本当作独立表述的双视图判定。前一控制本已被结构拒绝。澄清后的判定与全部 32 个参考一致，但这次跟进不取代首次盲测结果，也不构成新的独立校准通过。此检查中未执行任何仪器重跑、提供方生成或基准评估。

声明词表的范围。 这些控制覆盖八个策略强制合同，不覆盖自由臂的四种声明（repair、vote、twostage、plain）。在原自由提示中，vote 指定多次采样与选择但未指定三票多数投票；twostage 指定产物消费但无特定响应接口。plain 声明还指定无控制流机制，而自由提示要求控制流变更。因此把八策略门控应用于这些声明需要另行固定语义规则与不确定政策，而不是静默把 vote 当作 vote3 或在观察其结果后选择兼容配置。这一来源级范围缺口不估计生成候选的错误拒绝率。

上游提取问题与未完成的提供方获取记录见附录 G。

G 来源、协议偏离与历史分析

本节集中保留历史分析、协议探查与来源缺口，不将它们作为新重复研究的确认性结果。MATH 采集中的操作修订及缺失记录仍在附录 B，分析修订仍在附录 C，BIRD 准入设计的限制仍在附录 F。

G.1 早期生成协议探查及其局限

Phase I 还探查了生成侧修复——策略强制自由形式协议（指派机制，导入 / 冒烟准入）与编译式 Harness IR。在策略强制协议下，三个构建器中有两个产生的种群点估计超过预先指定阈值（Qwen3.8-Flash 5.96、DeepSeek-V4-Flash-Vision-Exp 7.95 %；旧协议臂为 4.64 % 未达标），且逐策略接纳随构建器身份排序（在有日志工具下 GLM-5.3-Flash 3/8、Qwen3.8-Flash 7/8、DeepSeek-V4-Flash-Vision-Exp 8/8）。这些观察为 Phase II 提供动机，但不是验证性的，原因有三并已披露：设计是两个嵌套对比，无法把协议主效应与构建器主效应分开；早期运行缺少逐尝试日志，预算相等无法审核；准入是导入 / 冒烟检查，不是 §F.1 的反事实一致性门控。完整条件见附录 E.1。

生成空结果失败（M0）。 用 Qwen3.8-Flash 与 DeepSeek-V4-Flash-Vision-Exp 构建器重跑原优化循环，产生 40 个与 single-call 基线源码逐字节相同的候选。代码同一并不意味着随机执行也相同。这次运行没有提供不同代码的种群；它作为另一种更原始的失败模式报告——流水线根本没有产生不同种群。上述坍塌主张完全基于来源确实不同的发现阶段种群。

图数据。 图 2 比较所测 harness 对的源码相似度与正确性分歧。

生成来源缺口。 早期自由形式种群在会话中产出；其生成工具未保存，也不存在逐尝试日志——因此这些运行的预算相等无法审核，我们也不作此主张。它们的准入是评估时的导入 / 冒烟检查，不是 Phase-II 的反事实一致性门控。后续生成过程记录每次尝试（3 次重试、16,384 token 预算、逐尝试阶段与结束原因）；完整的逐策略网格与构建器接纳排序（3/8、7/8、8/8）来自该有日志工具，相对冻结的准入决定属于事后。

G.2 上游代码提取审计

在 36 个强制 C/D 单元中，全部 108 次 `format_guard` 尝试均未通过中性有效性：71 条日志报告 Python 字符串未终止，36 条报告无 Python 围栏，1 条报告提供方超时。存档生成器的非贪婪 Python 围栏提取器在随后第一个三反引号处终止，包括 Python 字符串内部的三反引号。三个合成的、语法有效、在普通字符串、文档字符串或正则中包含 SQL 围栏的程序变成了无效前缀；而提取器仍把其截断标志设为 false。审核的提取器与保留实现一致，但历史尝试记录无法验证当时实际执行的版本。完整构建器消息未被该生成器保存。因此失败模式与提取损坏相容，但不证明所有历史失败都由此造成，也不证明修复后的候选会通过准入。我们找到 74 个保留的提取程序，全部语法无

效；其中三个与无围栏日志并存，作为来源冲突保留，不归属于那些尝试。这些发现把一个生成接口失败置于门控显式策略排除之旁。

G.3 审后提供方获取状态

审后的提供方获取尝试未形成完整共同池：传输中断把已完成响应、未闭合请求与未启动尝试留在不同的可审计状态中。这些记录为来源与缺失性核算保留，但被排除于关于种群表现、成本或稳定互补性的主张之外。因此，稿件不把提供方可用性或部分获取用作未解决的克隆控制问题的证据。

G.4 历史 BIRD 选择分析

选择分析与附录 E.5 的指纹分析都是对存档验证性单元（18 个构建器 $\times$ 种子单元、384 个接纳候选、core-400 结果）的事后分析。两者使用与主重分析相同的记录合并规则、固定任务与成员身份检查。它们仍是描述性的：这些题目此前已被分析过，这不是独立迁移验证。

多样性感知选择。 每个单元合并跨臂的全部接纳候选。重分析保留旧种子、100 次随机数据库对半划分、每划分每单元 200 次随机子集抽取及候选选择规则。它记录一个新的确定性调度：历史的集合派生单元顺序未存档，因此仅凭种子无法恢复相同的历史划分与抽取。选择使用开发数据库；评估使用互补数据库。重叠划分不是 1,800 个独立实验。方法为开发准确率 top- k 、均匀随机子集、贪心开发 oracle 覆盖、以及贪心平均准确率加 λ 倍 oracle 覆盖（ $\lambda \in \{0.25, 0.5, 1, 2\}$ ）。所有候选选择都在划分的评估之前于划分内冻结。

表 14 在每个被评估子集中保留共同的 AD single-call； k 只计候选。仅候选估计与包含基线的估计分开记录，以区分历史估计目标。Oracle 与最佳固定使用留出结果作为描述性上界。开发固定改为用开发准确率选一个成员，成员名并列时升序、single-call 优先。确定性方法本就保留一个全局开发最佳候选；该比较器的差异可能来自哪些并列最大值存活，而非开发最大准确率提高。

在 $k = 8$ 时，仅多样性相对 top-acc 使 oracle 变化 +0.35 %、最佳固定变化 -0.42 %、提升空间变化 +0.78 %。开发固定变化 -0.001 %。这些是不同的量，没有一个是独立验证的路由增益。我们撤回旧的仅单元置信区间；当前表是描述性的，涵盖数据库 / 题目采样与重选择的推断仍待完成。更早的归一化提升空间比率不纳入所报告的分析。

k	Selection	Oracle (%)	Best (%)	H (%)	Dev-fixed (%)
4	top-acc	73.98	66.64	7.34	65.10
4	random	73.90	66.03	7.87	64.66
4	div-only	74.22	66.18	8.04	65.13
8	top-acc	76.03	67.11	8.93	65.10
8	random	76.15	66.76	9.39	64.95
8	div-only	76.39	66.68	9.70	65.10

表 14: canonical 描述性 W1 重分析。每个池含 k 个选定候选加共同 single-call。18 单元与 100 个重叠数据库划分上的均值；无置信区间。开发固定仅在开发数据上选择；最佳固定使用留出结果。

重选择不确立区间覆盖。 一个精确反例排除了我们提出的正权重重选择百分位区间的普遍 95% 覆盖保证。令九个独立数据库各含一个 $\text{Bernoulli}(p)$ 任务状态。16 个固定候选由八个状态 0 专家后接八个状态 1 专家组成；single-call 恒错。把 canonical $k = 8$ 规则应用于四个开发库与五个留出库。在记录的并列规则下，仅多样性减 top-acc 提升空间统计量的期望为 $(1 - p^4) \mathbb{E}[\min(B, 5 - B)/5] > 0$ ，其中 $B \sim \text{Binomial}(5, p)$ 。在全部九个状态恰好相同的事件上，每种正加权都给两种方法产生零提升空间，故百分位区间为 $[0, 0]$ 。因此覆盖率至多为 $1 - p^9 - (1 - p)^9$ ，在 $p = 0.1$ 时为 61.26%。对相同单元或重叠固定划分取平均不能移除该事件。此界限针对所述构造与区间，不涉及 BIRD 特定覆盖率，也不涉及其他推断方法的不可能性。

G.5 路由与探索性选择

Phase-I 留一 harness 预测器未在所测 DeepSeek 种群中超过最佳固定 harness (-3.4%)；Qwen 估计为 $+0.9\%$ (CI $[-5.2, +6.9]$)，题目留出的修复 AUROC 为 0.512。这些预测器与划分特定结果不确立价值预测。canonical W1 分析同样是描述性的：在 $k = 8$ 时，多样性相对 top-准确率选择使 oracle 变化 $+0.35\%$ 、最佳固定变化 -0.42% 、提升空间变化 $+0.78\%$ ；开发选定固定成员变化 -0.001% 。没有一个是经验证的路由增益（附录 G.4）。

G.6 历史档案诊断与重评分

应用于 MATH-500 存档（36 成员 $\times$ 400 题）与 18 单元 BIRD Phase-II 存档。在 BIRD 上，完整性类（A）对每个单元为 REFUTED_WITHIN_SCOPE：冻结输入清单包含重叠的采集记录，其行在 canonical 键上重复（由存档的先写先得策略解决，并记录判定冲突计数），因此下述覆盖数字在该去重视图上计算，而非在无冲突存档上；评分器重放在此路径上不执行，被报告为未运行而非通过。在此范围内，所有单元显示单次覆盖（B SUPPORTED）；稳定性、可选择性与可部署性按冻结规则为 INSUFFICIENT_EVIDENCE，因为存档不含匹配重复也没有供政策训练的开发 / 评估划分——不是因为成本缺失：逐记录逻辑调用已存档，并在与其余重分析相同的规范化去重

视图上读取 (153,600 条候选-题核心子集记录上共 259,304 次调用, 表 12), 但 token / 美元成本仍不可恢复。在 MATH 上, 冻结选择政策在 400 道评估题的前 80 道上训练 (这 80 道从所有 D/E 命题中留出; 存档不含开发集执行: 附录 A.1 的 100 题开发划分仅用于生成冒烟测试, 故政策划分从评估侧切出, 留下 320 道计分题), 在每道评估题上与开发固定 (single-call) 持平, 因此可选择性与可部署性为 INSUFFICIENT_EVIDENCE 而非被否定。三个已发表数字被修正 (结果向量计数的成员口径, 现为计入 single-call 的 33/36 成员与 32/35 生成 harness; 生成 harness 准确率范围 0.6825–0.915, 此前印为 0.68–0.87; 最佳固定 = single-call 的提升空间分解明确写出), 两个过载的指标名被消歧 (并集全败对任一候选失败), 一个保留判定控制在显式定义下确认了报告的一对数字 (联合修复 76.0% / 并集全败 0.8%)。对全部 14,400 条 MATH 判定的版本化端点敏感评分器的一次重执行改变了其中 14 条——全是单一任务上 v1 对区间端点答案的错误拒绝; v1 重放本身内部一致, 而更早存储的零翻转产物未能由修正分析复现, 已被取代。因此新评分器旨在捕获的括号合并缺陷确实在此存档中触发, 且恰在一个任务上。

G.7 隔离的 MATH 提示协议试运行

第一, 干净协议的多样性结果在第二个领域、不同输出空间上得到重复。第二, 一个被隔离的试运行轮次提供了一项探索性比较: 当相同六个构建器 (被错误地) 收到数值答案格式与 MATH-500 不匹配的 GSM8K 风格任务描述时, 生成种群仍保持行为多样 (16.2% 分歧, 19 个唯一结果向量), 但其联合修复坍缩至 18%——对灾难性成员的代码级检查逐字复现了 Phase-I 轨迹分类 (一个先生成后验证的 harness, 其验证器拒绝几乎所有答案, 其回退返回过时的循环变量或 “0”)。有多样性而无效用, 由代码级检查不可见的提示侧协议错误诱发: 检测到它的是测量任务本身, 而非任何代码级审核。

G.8 测量边界的平行领域证据

表 15 把两个领域就同一诊断问题并列呈现, 但不合并。MATH-500 复现了该边界: 单次分歧与 4.75% 提升空间与 single-call 作为最佳固定成员 (93.75%) 并存。单次探查本身没有修复门控控制; 克隆、重复与选择器控制来自单独的新 WP-1R 采集 (§5.2)。

领域 / 分析	n_H	n_{eval}	分歧	Oracle	最佳固定	H (%)
BIRD, A / D	18 单元	1,169	—	76.14 / 75.70%	67.58 / 67.30%	8.56 / 8.40
BIRD, D–A	18 配对	1,169	—	—	—	–0.16
MATH-500, 自由	35	400	10.6%	98.50%	93.75% (single-call)	4.75

表 15: 同一测量问题的平行领域证据。BIRD 是存档析因分析; MATH-500 是单种子探索性自由臂探查。两种设计不合并。提升空间是单次诊断量, 不是选择器准确率或稳定互补性。