

更多程序，还是更多次采样？ 区分 LLM HARNESS 的覆盖与专长

(中文参考译本)

Anonymous authors

Paper under double-blind review

ABSTRACT

推理预算应当用于更多程序，还是同一程序的更多次执行？本文通过区分答案覆盖、表现可重复性与可用选择，研究生成式 LLM harness 中的这一选择。在 MATH-500 的 386 道题上，我们将八个生成程序加一个基线，与九个逐字节相同的基线槽位比较，每个成员执行三次。相同程序已经产生 2.16 个百分点的重复平均 oracle 余量。生成程序的评分模式残差相关性更强 (0.789 对 0.006)，但这一结构主要由涉及 100 道题的持续损失构成，持续获胜仅出现在一道题上。冻结选择器获得 0.00 个百分点的收益，两臂在 27 次执行时均达到 98.70% 的 oracle 覆盖。留出重复尚未判清稳定互补性。补充的 BIRD 轨迹展示了实现、触发与输出有效性如何塑造执行行为。在所测面板上，可重复差异主要揭示程序在哪里失分，而额外执行基线能够达到相同的完整预算覆盖。

1 引言

固定的推理预算应当用于更多程序，还是同一程序的更多次执行？自动化 agent 设计让第一种选择越来越容易实现：构建模型围绕固定求解器编写 LLM harness，安排提示、工具与控制流 (Hu et al., 2024; Nie et al., 2026; Zhang et al., 2026b)。这样的程序群体承载着一种分工设想：不同成员擅长不同任务。这一设想的实际价值，取决于程序优势能否持续，以及能否据此作出选择。

这种优势最先呈现的信号通常是额外覆盖：一个程序答对了另一个程序答错的题。然而，同一程序也会产生这种现象。两个成功概率均为 0.5 的独立执行，可以以 0.75 的概率覆盖一道题。Pass@k 刻画这种机会；self-consistency 和采样投票集成则将多次尝试聚合为一个答案 (Chen et al., 2021; Wang et al., 2022; Li et al., 2024)。因此，即使每个成员的代码完全相同，看到全部结果的 oracle 也能从群体中获得增益。重复次数较少时，选择最大的成功率估计，仍可能选中幸运的结果。

本文研究这一初始覆盖信号如何进一步体现为有用的任务专长。分析围绕三个问题展开：群体是否提供额外的正确答案？任务上的优势能否在新一次执行中重现？能否在执

1. 覆盖 重复平均 oracle 余量 生成程序: 2.33 pp 同代码: 2.16 pp 相同程序也产生正的覆盖余量。	2. 可重复性 评分模式残差相关性 生成程序: 0.789 同代码: 0.006 持续损失: 100 题 持续获胜: 1 题	3. 选择与重放 冻结选择器收益 0.00 pp 27 次执行的 oracle 覆盖 生成程序: 98.70% 同代码: 98.70%
--	--	---

图 1: 正余量与强可重复性, 同时伴随零选择收益和相同的完整预算 oracle 覆盖。三栏均使用相同的 386 道 MATH 题、八个生成程序加 single-call, 以及九个相同的 single-call 槽位, 每个成员进行三次新执行。持续输赢指三次均相对 single-call 失分或获胜。选择器收益相对开发集选出的固定基线计算; 重放在相同 harness 执行次数下, 使用执行后正确性比较生成面板与同代码执行。

行前选出有帮助的程序, 其覆盖又如何与固定程序的额外尝试比较? 每个问题都将分析推进一步, 接近如何分配推理预算这一实际决策。

核心实验在固定成员数和重复次数的同时改变程序身份。八个生成 harness 加上 single-call, 与九个逐字节相同的基线槽位在相同的 386 道 MATH-500 题上分别执行三次。两次重复用于确定逐题选择, 第三次检验选择能否迁移。随后, 在开发数据上冻结的选择器根据题目特征作出选择, 等执行次数重放则比较不同预算下可获得的答案。完整的 35 个生成程序提供初始的单次覆盖图景。补充的 BIRD 轨迹将程序差异追踪到执行过程, 展示实现与触发如何塑造评分背后的行为。

结果形成了一条连贯的证据链。相同程序产生正的 oracle 余量; 生成程序确实具有更强的评分模式可重复性, 但持续损失涉及 100 道题, 持续获胜仅出现在一道题上。这种结构更清楚地描绘了弱点, 而非有用的任务优势: 克隆校准后的留出收益为 -0.26 个百分点, 冻结选择器收益为 0.00 个百分点, 两臂在 27 次执行时均达到 98.70% 的 oracle 覆盖。

本文提供了用于解释 oracle 余量的同代码参照、区分持续损失与获胜的重复执行分析, 以及冻结选择与等执行次数覆盖的联合视角。它们共同将程序群体的价值具体化: 增加了哪些答案, 哪些差异能够持续, 以及哪些优势能够帮助作出实际选择。

2 相关工作

自动化智能体与 harness 设计。 可执行程序为调整 LLM 行为提供了灵活空间。ADAS 直接搜索这一空间 (Hu et al., 2024); Self-Harness 利用失败轨迹提出修改, 经回归测试后保留修改 (Zhang et al., 2026b); TTHe 在评估期间依据无标签轨迹调整 harness (Nie et al., 2026)。相关系统改进任务适配与验证资源分配 (Zhang et al., 2026a; Miyai et al., 2026), 或通过验证、诊断、定位和策略演化呈现 harness 行为 (Xu et al., 2026; Chen et al., 2026a; Lin et al., 2026; Luo et al., 2026; Wang et al., 2026; Chen et al.,

2026b)。El et al. (2025) 报告，所研究的自动设计智能体在逐题评分模式上的多样性较低。本文从执行轨迹和重复结果两个角度观察程序群体：轨迹揭示实际执行的机制，同代码重复衡量采样带来的覆盖。这一视角将程序等价与变异测试 (Budd & Angluin, 1982; Papadakis et al., 2019) 连接到生成 harness 群体的性能归因。

重复采样与集成。 即使程序固定，多次执行也能提高答案覆盖。Pass@ k 衡量 k 次采样中至少一次成功的概率；自一致性与相同智能体的集成聚合多次尝试 (Chen et al., 2021; Wang et al., 2022; Li et al., 2024)，名义温度为 0 的调用也可能变化 (Ouyang et al., 2023)。这些收益构成本文执行预算匹配比较中的采样参照。另一个区别是选择发生在何时。执行后的验证器对候选解排序 (Kwok et al., 2026)；集成选择在验证集上选定模型组合，在推理时平均预测 (Caruana et al., 2004)。本文的冻结选择器在执行前选择程序，oracle 重放则衡量记录输出中的覆盖。

选择与资源配置。 将程序群体转化为有用的选择，使 harness 设计与算法选择及组合求解相联系 (Rice, 1976; Xu et al., 2008; Kotthoff, 2014)。HELIX 利用群体内互补的轨迹扩展经验证的覆盖，并为模型改进提供数据 (Fan & Huang, 2026)。STS 比较六种推理范式，训练基于嵌入的路由器，实现部分 oracle 收益 (Zhou et al., 2026)。模型-问题组合间 (Gupta et al., 2026) 及所评估模型间 (Cho, 2026) 的 harness 敏感性、搜索路由 (Kim, 2026) 和基于偏好训练的模型路由 (Ong et al., 2024)，进一步说明按任务选择的意义。GRASP 在新增错误约束下选择对有界技能库的编辑 (Moll et al., 2026)。本文固定目标模型，在同一程序群体中测量 oracle 覆盖、跨重复稳定的逐题优势与实际选择收益。定量交互与定性交互的区别 (Gail & Simon, 1985) 则说明，效应大小可以变化，而最佳动作仍然相同。

3 问题定义

我们区分程序群体提供的答案、跨执行持续的任务优势，以及选择器实现的收益。设 P 包含基线 H_0 ， $Y(h, x, r) \in \{0, 1\}$ 表示成员 h 在任务 x 的第 r 次重复中是否答对。准确率使用%，收益与余量使用百分点 (pp)。

覆盖：有哪些额外答案可用？ 单次运行 oracle 在看到正确性后选择成员，其相对于记录矩阵中最佳固定成员的余量为

$$H(P) = \frac{1}{n} \sum_{i=1}^n \max_{h \in P} Y(h, x_i, r) - \max_{h \in P} \frac{1}{n} \sum_{i=1}^n Y(h, x_i, r). \quad (1)$$

这一量刻画可获得正确答案，包括重复采样带来的答案。重复平均代入估计 (plug-in estimate) $\hat{H}$ 将 Y 替换为成员-任务均值。重复次数较少时，对这些均值取最大值可能选中有利的估计误差，这正是引入同代码对照的动机。

稳定互补性：每道题上哪个成员最好？ 记固定执行条件下 $p_h(x) = \Pr\{Y(h, x, r) = 1\}$ ，相应的总体余量为 $H_{\text{stable}} = \mathbb{E}_x \max_h p_h(x) - \max_h \mathbb{E}_x p_h(x)$ 。对于两个成员，令

$\Delta(x) = p_1(x) - p_0(x)$, 则

$$H_{\text{stable}} = \frac{1}{2}(\mathbb{E}|\Delta(x)| - |\mathbb{E}\Delta(x)|). \quad (2)$$

正互补性要求任务上的优势交叉：较好的成员随任务改变。若一个成员处处更好，即使优势大小不同，余量仍为零。相同条件下的相同程序具有相等的 $p_h(x)$ ，由此构成零互补性参照。该定义针对总体概率；下文的重复诊断检验从有限执行中学到的选择。

可用选择：哪些优势能够指导决策？ 选择器 π_Z 在执行前根据任务特征 $Z(x)$ 作出选择，其效用取决于这些特征能否预测相关优势。我们将这一决策与根据问题既往结果学习的选择分别评估，后者检验跨重复泛化。随后，等执行次数 oracle 重放比较程序组合与固定程序额外执行所提供的覆盖。其预算单位为 harness 执行，每次执行可以包含多次模型调用和相应 token。

4 实验设计

4.1 HARNESS 群体与评估设置

本文固定目标求解器 GLM-5.3-Flash，改变调用它的 Python 程序。构建器编写 harness，求解器回答程序发出的模型调用，外部评分器判定最终输出；标准答案仅对评分器可见。每个 harness 实现 `solve(question)`，通过 `self.llm` 调用模型；BIRD 还通过 `self.execute` 提供数据库结构与 SQL 反馈。single-call 基线执行一次温度为 0 的调用。生成程序可以改变提示、解码、采样次数与控制流。表 1 将各程序群体与其回答的问题对应起来；模型细节见附录 A.3。

MATH 群体与面板抽取。 六个构建器为 GLM-5.3、Qwen3.8-Max、DeepSeek-V4-Pro、Kimi-K3、MiniMax-M3 和 ERNIE-5.0-Thinking-Preview，每个在一个种子下获得八个槽位。每个槽位都是一次独立改进单次贪心调用的机会：策略由构建器选择，不施加跨槽位多样性约束。每槽最多尝试三次，温度为 0.7，每次最多 32,768 个输出 token，复用相同提示且不反馈前次尝试的结果。首个程序通过解析、导入、接口及两道开发题的非空答案检查后即停止生成。48 个槽位得到 35 个冻结程序；构建器指令见附录 A.1。

重复面板从中抽取八个程序。历史平均调用次数不超过 3.05 的条件保留 21 个合格成员，再由固定加盐哈希选出每个构建器一个席位和两个自由席位。所得低调用面板包含起草—检查—修订、一致性检查和采样投票（附录 A.2）。加入 single-call 后共九个成员。该面板与九个相同基线槽分别进行三次关闭缓存的新执行，解码设置由源码固定。

MATH-500 (Lightman et al., 2023) 提供 100 道开发题及共同分析集中的 386 道评估题。分析集在采集后确定，要求两臂全部重复和单次评估群体均有完整观测，由此排除 14 道重复观测不完整的题（附录 B）。所有 MATH 主比较因此使用相同题目身份和完整观测的评分单元。评分器抽取最终答案，优先使用要求的 ##### 行；两端均可解析为数值时比较数值，否则比较规范化 LaTeX（附录 A.1）。

研究	程序	评估	回答的问题
MATH 探索	35 个生成程序 + single-call	386 题; 单次运行	是否存在错误覆盖?
MATH 重复对照	8 个生成程序 + single-call, 对照 9 个克隆	同一批 386 题; 3 次新重复	选择能否跨重复迁移?
BIRD 发现	12 个生成程序 + single-call + react	60 题; 单次运行	什么机制实际执行?
BIRD 准入	6 个构建器 × 3 个种子 × 4 个臂	主比较 1,169 题; 全臂 400 题	筛选是否改变覆盖?

表 1: 四项研究连接覆盖、可重复性与实际执行。单次运行指每个成员一任务对执行一次。MATH 重复面板从探索性群体中抽取。BIRD 提供独立的执行与准入证据, 各项研究分别报告效应。

BIRD 发现与准入。 BIRD (Li et al., 2023) 要求根据问题与数据库生成 SQL。发现研究中, TTHE 的 proposer 使用 GLM-5.3-Flash 构建器产生 12 个通过导入与冒烟执行检查的候选, 与两个自带基线在 60 题上评估。准入研究交叉自由 / 指定 (forced) 策略与无门控 / 合规门控, 使用六个构建器、三个种子、每臂八个槽位; 每槽最多三次尝试, 温度为 0.7, 输出上限为 16,384 个 token。指定策略包括执行修复、三次采样投票及 schema linking。所有臂均要求接口有效、SQL 非空; 门控臂额外检查机制合规, 并排除部分结构。

准入研究使用两个数据库的 365 题进行开发, 九个数据库的 1,169 题进行评估, 四臂共用预先抽取的 400 题核心集。一次 18 题冒烟测试构成开发暴露例外。官方行集评分器比较预测与标准查询的结果, 超时为 30 秒, 执行失败计零。发现研究使用较早的字符串化行代理, 并限制返回行数。准入采集使用共享响应缓存, MATH 重复执行则关闭缓存。完整的数据划分、评分与捆绑门控规格见附录 E.1 和 F。

4.2 同代码对照与重复验证

同代码参照。 受控面板包含九个不同成员, 参照臂包含九个逐字节相同的 single-call 槽位。每个成员或槽位在每道题上执行三次。该设计在改变程序身份的同时保留群体规模与采样机会。

两次重复确定选择, 第三次检验。 每一折用两次发现重复确定逐题成员和一个最佳固定成员, 第三次重复测量二者的准确率差。对三折取平均得到 G_{real} 与 G_{clone} 。在共同完整题集上, 以配对的逐题收益计算

$$D = G_{\text{real}} - G_{\text{clone}}. \quad (3)$$

正差值表示根据既往结果学到的选择, 在不同程序间比在相同程序间具有更好的迁移表现。逐题选择与固定参照均完全由发现重复确定。

分析题集与可重复性。 全部主估计使用同一批 386 道题, 每臂包含 10,422 个已评分单元。原始不完整题目占比为 3.50%, 低于采集门槛的 10% 上限。采集协议先于数据采

集制定，重复诊断与共同完整题集分析在采集后形成。补采集快照保留程序、求解器、任务及三次重复设计（附录 B）。

我们还在移除成员与任务的加性效应后，测量跨重复的评分模式残差相关性。这一探索性测量描述可重复性， G 则描述留出选择收益。已知真值模拟刻画诊断的灵敏度。附录 B.1 与 C 给出计算、并列处理、不确定性估计及判定规则。

4.3 冻结选择与等执行次数重放

根据题目选择程序。 我们使用 100 题开发集拟合 π_Z ，预测每题可用重复平均正确率最高的成员；训练标签并列时按成员 ID 顺序处理。五个任务折将问题重复保留在同一折。各拟合模型共享从开发题文本学习的 TF-IDF 词表，并将训练折内的成员准确率作为附加输入。推断时平均已拟合折模型的概率向量，选择概率最高的成员；前两名概率差小于 0.15 时回退到 single-call，最高概率并列也因此触发回退。策略在评估前冻结，拟合与回退细节见附录 D。参照包括开发集选出的固定成员，以及随机抽取后固定的一个成员。

向程序组合分配执行次数。 离线 oracle 重放在预算 $b \in \{3, 9, 15, 27\}$ 下，比较按开发集排名组成的程序组合与同代码执行。每个纳入成员贡献三次重复；克隆覆盖是从其 27 次记录执行中全部大小为 b 的子集均匀抽取时的精确期望。两臂均使用执行后的正确性衡量可用答案。补采集分析保持已记录的选择器决策与程序组合顺序不变。重放使用两臂均完整的题目，预算单位为 harness 执行，模型调用与 token 用量由程序决定。附录 D 给出策略、重放公式与记账细节。

5 结果

5.1 群体覆盖超过任一固定成员

生成群体覆盖的任务多于其最佳固定成员。在 386 道分析题上，35 个获准生成成员与 single-call 的并集达到 99.22% oracle 覆盖，而 single-call 为 95.08%。每个生成成员单独都更差（69.69–92.49%）。全部 13,896/13,896 个单次执行单元均已观测，得到执行后 oracle 可获得的 4.15 pp 额外覆盖。

这一覆盖伴随着明显的评分结果差异：36 个正确性向量中有 29 个唯一向量，平均成对分歧为 10.94%（最大 33.16%），并集修复基线错误的 84.21%。接下来的问题是，这些差异有多少能在重复执行中保持。我们在同一批 386 题上，将选定程序面板与同代码对照比较，新执行的基线均值为 95.85%。重复诊断 D 衡量面板相对克隆的留出选择增益；完整群体的覆盖与面板估计分别对应各自的程序群体和执行（附录 A.1）。

5.2 相同程序也产生正的 ORACLE 估计

相同程序的重复平均 oracle 估计达到 2.16 pp，生成面板为 2.33 pp（表 2）。九个克隆槽位实现相同程序，其总体层面的稳定互补构造为零。两项估计均使用同一批 386 道

题及完整观测。因此，即使平均三次重复，正的 oracle 估计本身仍不足以识别程序专长。

量	生成面板 + single-call	同代码克隆
完整任务 oracle 估计 $\hat{H}$	2.33 pp	2.16 pp
重复诊断 G 的完整任务数	386	386
留出重复平均增益 G	0.10 pp	0.35 pp
评分模式残差相关性	0.789	0.006
配对克隆校正均值: $D = -0.26$ pp, 基于 386 题		
分析集完整率: 两臂均 100%, 每臂 10,422 个单元		

表 2: 覆盖、可重复性和选择收益相互分离。所有量均使用同一批 386 题，两臂在该分析集上均完整观测。 D 是未舍入交叉拟合增益的配对差，显示值的舍入可能影响直接相减。

5.3 可重复评分差异主要体现为持续失分

生成程序的评分结果模式比克隆更可重复。生成程序的平均残差相关性为 0.789，克隆为 0.006；配对 bootstrap 差异为 0.783，95% 区间为 [0.69, 0.87]。这一探索性分析从评分优势矩阵中去除成员与任务的加性效应，再计算每个留出重复与其余两次重复均值的相关性。

持续差异明显偏向 single-call。三次重复均输给基线的情况涉及 100 道题（570 个成员—任务对）；三次均获胜只出现在一道题上，由八个生成成员共同实现。这一表面修复对答案格式提取敏感（附录 B.1）。这种方向上的不对称性解释了强评分可重复性为何可以与少量观测获胜并存。

留出选择没有提供明确的超越克隆的正向证据。在完整观测的分析任务上，克隆校正均值为 $D = -0.26$ pp，95% 区间为 $[-1.45, 0.95]$ pp，随机化 $p = 0.8127$ 。区间包含零，未满足正向支持条件，因而判断为 INSUFFICIENT EVIDENCE（证据不足），并非等效结论。排除包含冲突评分的三道题后，在 383 个配对任务上得到 $D = -0.61$ pp，判断不变（附录 B）。

三次重复对交叉优势的检出能力有限。已知真值校准表明，三次重复可能漏检幅度可观的任务交叉优势。真实 $H_{\text{stable}} = 17.5$ pp 的双专家设置在 $R = 3$ 时功效为 0%， $R = 5$ 时约为 0.7%， $R = 10, 20$ 时为 100%。在所测 100 单元网格上，最坏的观测零假设错误支持率为 2%；更小的循环交叉即使在 $R = 20$ 时仍大多检不出（附录表 7）。这些具体设置下的结果解释了为何当前重复次数仍无法判清有用交叉优势。接下来，我们直接评估所测执行前决策规则。

5.4 所测选择器无增益，完整预算下覆盖持平

冻结选择器与开发集选出的基线持平。所测特征策略的增益为 0.00 pp。冻结分类器在全部 386 道评估题上直接选择 single-call，未触发置信度回退。这些选择在三次重复上的准确率为 95.85%，与开发集选出的固定成员相同。因此，在该分析集上保留基线的是学习到的策略本身。附录 D 给出其构造和同一分析集上的比较器结果。

完整执行预算下，两臂 oracle 覆盖持平。在 $b = 27$ 次执行时，按开发集排序的程序组合与同代码对照都达到 98.70% oracle 覆盖（表 3）。比较使用两臂均完整的 386 道题，克隆覆盖对均匀抽取的执行取平均。在 $b = 9$ 和 15 时，程序组合减去克隆的差异分别为 +0.08 pp 与 +0.02 pp。在 $b = 3$ 时，组合只包含 single-call，因此 +0.20 pp 的差异反映相同程序之间的执行变动。

Harness executions per task b	3	9	15	27
Panel members, including single-call	1	3	5	9
Panel oracle coverage (%)	98.45	98.70	98.70	98.70
Clone oracle coverage (%)	98.24	98.63	98.69	98.70
Panel minus clones (pp)	+0.20	+0.08	+0.02	+0.00

Differences are computed before rounding the displayed coverage values.

表 3: 在记录的执行中，完整预算下 oracle 覆盖持平。每个入选成员贡献三次重复；克隆覆盖是从记录的 27 次执行中均匀抽取子集的精确均值，并在共同完整任务上配对。两臂在相同 harness 执行次数下使用执行后正确性。

选择器与重放结果分别回答两个应用问题：所测执行前策略的增益为零，执行后 oracle 覆盖则在完整记录预算下持平。这里匹配的是 harness 执行次数，模型调用数和 token 成本随程序而异。

5.5 BIRD 轨迹定位代码到执行之间的中断

源码差异可能在产生有效最终答案之前消失。补充的 BIRD 研究在独立程序群体上，使用任务对应的评分与执行协议，直接追踪这一过程。这里的机制指已实现的提示变换、工具使用或控制流操作。对实际程序行为的检查，从执行层面补充了 MATH 对照。

不同源码常产生相同的评分结果。全部 12 个发现候选都通过代码差异检查，但 21/66 个生成候选对的正确性向量相同，计入基线时为 36/91。源码相似度与正确性分歧几乎没有秩相关 ($\rho = -0.010$)。这些 60 题上的一致促使我们检查轨迹（附录图 2）。

轨迹区分未实现、未触发和输出失败的机制。T1：描述了但没有实现。12 个候选中的 6 个描述了检索或自检，实际只有一次模型调用，未实现所描述的检索或自检步骤。这一分类覆盖全部十二个候选，五个 harness 的轨迹审核提供具体样例。

T2: 存在但未触发。全部 10 道已审 `react` 任务的第一次 SQL 均执行成功，修复分支从未触发，最终 SQL 与 `single-call` 相同。因此，执行成功仍可能让语义错误的答案保持不变。

T3: 执行了但输出失败。一个候选执行多轮修复，却把自然语言说明作为最终 SQL，丢失了基线答对的任务。三类情况分别定位实现、分支触发和有效输出的检查。附录 E 提供具体轨迹与人工控制，并说明其开发暴露限制。

独立的 BIRD 准入研究检验，指定策略并筛选程序能否增加余量。实际门控组合了结构排除与合规验证；指定策略加门控减去自由无门控的差为 -0.16 pp，观测平均余量没有增加（附录 F）。准入比较衡量筛选改变了什么，轨迹则定位所提操作在哪些环节未能产生有用答案。MATH 的重复与选择器分析进一步回答：任务优势能否持续，以及能否据此作出选择。

6 讨论与局限

从程序群体到有用的选择。 同代码参照将采样机会与程序身份区分开，重复执行则揭示持续差异的方向。在所测面板中，持续结构集中于失分，因此较强的可重复性更清楚地描述了程序在哪里失败，而非选择器在哪里能够利用优势。这解释了为什么评分模式可以高度可重复，同时选择收益为零、完整预算下覆盖持平。设计应追求执行前可以识别的、能够持续的任务优势。BIRD 则定位通向这种优势的三个中断：所提操作可能没有实现、保持闲置，或已经执行却返回无效答案。

适用范围。 MATH 研究使用低调用程序面板、一个求解器和三次重复。重复诊断与完整案例重分析在采集后形成；补采集保持程序、任务、求解器和重复次数不变。排除的 14 道题比纳入的 386 道题更难（附录 B）。三次重复的留出比较尚未判清稳定互补性，记录的评分模式包含答案格式效应。选择器结果对应冻结策略；重放匹配 harness 执行次数，模型调用与 token 随程序变化。BIRD 使用自身的程序群体与评分条件。

7 结论

对于所测 MATH 面板，基线的额外执行在 27 次执行时达到与生成程序组合相同的 98.70% oracle 覆盖，冻结选择器的收益为 0.00 个百分点。生成程序的差异可重复，但集中体现为持续失分。结合相同程序也有正余量这一结果，本文区分了找到更多答案与拥有可用的任务专长。更多程序值得占用推理预算的条件，是其任务优势能够持续、指导选择，并超过固定程序的额外执行。

伦理声明

全部实验使用公开的 BIRD 与 MATH-500 基准数据及生成的程序产物；不涉及人类被试、私人记录或个人身份信息。模型调用作为实验来源的一部分报告，论文不发布凭据或会暴露私人数据的提供方响应。结果区分已记录的答案覆盖与执行前选择器的表现。

可复现性声明

本文说明所报告结果的程序群体、任务划分、执行条件、评分规则、统计过程与敏感性分析。附录补充协议细节、校准结果和具体样例。

AI 使用声明

生成式 AI 工具协助了研究问题、实验与统计设计、反例分析、代码开发、模型 API 工作流、数据分析、图表和文稿准备。版本化产物记录分析与修订；自动测试、本机运行检查和同模型子代理用于辅助机械核验。人类作者确定研究方向，并对科学决策、核实、最终内容及投稿承担责任。

REFERENCES

- Timothy A. Budd and Dana Angluin. Two notions of correctness and their relation to testing. *Acta Informatica*, 18(1):31–45, 1982. doi: 10.1007/bf00625279.
- Rich Caruana, Alexandru Niculescu-Mizil, Geoff Crew, and Alex Ksikes. Ensemble selection from libraries of models. In *Proceedings of the 21st International Conference on Machine Learning*, 2004. doi: 10.1145/1015330.1015432.
- Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*, 2021. doi: 10.48550/arXiv.2107.03374. URL <https://arxiv.org/abs/2107.03374>.
- Mengzhuo Chen, Junjie Wang, Zhe Liu, Yawen Wang, Haiming Zheng, and Qing Wang. From failed trajectories to reliable LLM agents: Diagnosing and repairing harness flaws. *arXiv preprint arXiv:2606.06324*, 2026a. doi: 10.48550/arXiv.2606.06324. URL <https://arxiv.org/abs/2606.06324>.
- Mingju Chen, Can Lv, Guibin Zhang, Heng Chang, and Shiji Zhou. HarnessForge: Joint harness and policy evolution for adaptive agent systems. *arXiv preprint arXiv:2606.01779*, 2026b. doi: 10.48550/arXiv.2606.01779. URL <https://arxiv.org/abs/2606.01779>.
- Yong-eun Cho. It’s not the capability: Harness sensitivity is non-monotone across LLM agent tiers. *arXiv preprint arXiv:2605.26731*, 2026. doi: 10.48550/arXiv.2605.26731. URL <https://arxiv.org/abs/2605.26731>.
- Batu El, Mert Yuksekgonul, and James Zou. Inefficiencies of meta agents for agent design. *arXiv preprint arXiv:2510.06711*, 2025. doi: 10.48550/arXiv.2510.06711. URL <https://arxiv.org/abs/2510.06711>.

- Tianyu Fan and Chao Huang. HELIX: Model-harness co-evolution for recursive self-improvement. *arXiv preprint arXiv:2608.13951*, 2026. doi: 10.48550/arXiv.2608.13951. URL <https://arxiv.org/abs/2608.13951>.
- Mitchell H. Gail and Richard Simon. Testing for qualitative interactions between treatment effects and patient subsets. *Biometrics*, 41(2):361–372, 1985. doi: 10.2307/2530862.
- Akshat Gupta, Jermaine Lei, Alexander Lu, Gopala Anumanchipalli, and Leshem Choshen. Automated discovery has no universally superior harness. *arXiv preprint arXiv:2607.18235*, 2026. doi: 10.48550/arXiv.2607.18235. URL <https://arxiv.org/abs/2607.18235>.
- Shengran Hu, Cong Lu, and Jeff Clune. Automated design of agentic systems. *arXiv preprint arXiv:2408.08435*, 2024. doi: 10.48550/arXiv.2408.08435. URL <https://arxiv.org/abs/2408.08435>.
- Minho Kim. When should LLMs search? counterfactual supervision for search routing. *arXiv preprint arXiv:2607.05752*, 2026. doi: 10.48550/arXiv.2607.05752. URL <https://arxiv.org/abs/2607.05752>.
- Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(3):48–60, 2014. doi: 10.1609/aimag.v35i3.2460.
- Jacky Kwok, Shulu Li, Pranav Atreya, Yuejiang Liu, Yixing Jiang, Chelsea Finn, Marco Pavone, Ion Stoica, and Azalia Mirhoseini. LLM-as-a-verifier: A general-purpose verification framework. *arXiv preprint arXiv:2607.05391*, 2026. doi: 10.48550/arXiv.2607.05391. URL <https://arxiv.org/abs/2607.05391>.
- Jinyang Li, Binyuan Hui, Ge Qu, Jiayi Yang, Binhua Li, Bowen Li, Bailin Wang, Bowen Qin, Ruiying Geng, Nan Huo, Xuanhe Zhou, Chenhao Ma, Guoliang Li, Kevin Chang, Fei Huang, Reynold Cheng, and Yongbin Li. Can LLM already serve as a database interface? a BIG bench for large-scale database grounded text-to-SQLs. In *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, volume 36, pp. 42330–42357, 2023. doi: 10.52202/075280-1835. URL https://proceedings.neurips.cc/paper_files/paper/2023/hash/83fc8fab1710363050bbd1d4b8cc0021-Abstract-Datasets_and_Benchmarks.html.
- Junyou Li, Qin Zhang, Yangbin Yu, Qiang Fu, and Deheng Ye. More agents is all you need. *arXiv preprint arXiv:2402.05120*, 2024. doi: 10.48550/arXiv.2402.05120. URL <https://arxiv.org/abs/2402.05120>.
- Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by

- step. *arXiv preprint arXiv:2305.20050*, 2023. doi: 10.48550/arXiv.2305.20050. URL <https://arxiv.org/abs/2305.20050>.
- Jiahang Lin, Shichun Liu, Chengjun Pan, Lizhi Lin, Shihan Dou, Zhiheng Xi, Xuanjing Huang, Hang Yan, Zhenhua Han, Tao Gui, and Yu-Gang Jiang. Agentic harness engineering: Observability-driven automatic evolution of coding-agent harnesses. *arXiv preprint arXiv:2604.25850*, 2026. doi: 10.48550/arXiv.2604.25850. URL <https://arxiv.org/abs/2604.25850>.
- Xiaotian Luo, Dizhan Xue, Fengxingyu Wang, Chuanrui Hu, and Yafeng Deng. HarnessBank: Semantic gene-bank search with gated verification for agent-harness self-evolution. *arXiv preprint arXiv:2607.13683*, 2026. doi: 10.48550/arXiv.2607.13683. URL <https://arxiv.org/abs/2607.13683>.
- Atsuyuki Miyai, Kiyoharu Aizawa, and Toshihiko Yamasaki. Task-CoEvolve: Efficient harness optimization via adaptive validation task selection. *arXiv preprint arXiv:2608.20169*, 2026. doi: 10.48550/arXiv.2608.20169. URL <https://arxiv.org/abs/2608.20169>.
- Johannes Moll, Jean-Philippe Corbeil, Jiazhen Pan, Martin Hadamitzky, Daniel Rueckert, Lisa Adams, and Keno Bressem. GRASP: Gated regression-aware skill proposer for self-improving LLM agents. *arXiv preprint arXiv:2605.29668*, 2026. doi: 10.48550/arXiv.2605.29668. URL <https://arxiv.org/abs/2605.29668>.
- Jun Nie, Yonggang Zhang, Jun Song, Qianshu Cai, Dahai Yu, Yike Guo, Xinmei Tian, and Bo Han. TTTE: Test-time harness evolution. *arXiv preprint arXiv:2607.08124*, 2026. doi: 10.48550/arXiv.2607.08124. URL <https://arxiv.org/abs/2607.08124>.
- Isaac Ong, Amjad Almahairi, Vincent Wu, Wei-Lin Chiang, Tianhao Wu, Joseph E. Gonzalez, M Waleed Kadous, and Ion Stoica. RouteLLM: Learning to route llms with preference data. *arXiv preprint arXiv:2406.18665*, 2024. doi: 10.48550/arXiv.2406.18665. URL <https://arxiv.org/abs/2406.18665>.
- Shuyin Ouyang, Jie M. Zhang, Mark Harman, and Meng Wang. An empirical study of the non-determinism of ChatGPT in code generation. *arXiv preprint arXiv:2308.02828*, 2023. doi: 10.48550/arXiv.2308.02828. URL <https://arxiv.org/abs/2308.02828>.
- Mike Papadakis, Marinos Kintis, Jie Zhang, Yue Jia, Yves Le Traon, and Mark Harman. Mutation testing advances: an analysis and survey. In *Advances in Computers*, volume 112, pp. 275–378. Elsevier, 2019. doi: 10.1016/bs.adcom.2018.03.015.
- John R. Rice. The algorithm selection problem. In *Advances in Computers*, volume 15, pp. 65–118. Elsevier, 1976. doi: 10.1016/s0065-2458(08)60520-3.

- Ruhan Wang, Yucheng Shi, Zongxia Li, Zhongzhi Li, Yue Yu, Junyao Yang, Kishan Panaganti, Haitao Mi, Dongruo Zhou, and Leoweiliang. Harness handbook: Making evolving agent harnesses readable, navigable, and editable. *arXiv preprint arXiv:2607.13285*, 2026. doi: 10.48550/arXiv.2607.13285. URL <https://arxiv.org/abs/2607.13285>.
- Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc V. Le, Ed H. Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. Self-consistency improves chain of thought reasoning in language models. *arXiv preprint arXiv:2203.11171*, 2022. doi: 10.48550/arXiv.2203.11171. URL <https://arxiv.org/abs/2203.11171>.
- Jinghan Xu, Yikai Zhang, Aili Chen, Weiyuan Li, Jiaqing Liang, and Deqing Yang. Verify smarter, evolve further: Efficient harness evolution through behavior-aware verification. *arXiv preprint arXiv:2608.27311*, 2026. doi: 10.48550/arXiv.2608.27311. URL <https://arxiv.org/abs/2608.27311>.
- Lin Xu, Frank Hutter, Holger H. Hoos, and Kevin Leyton-Brown. SATzilla: Portfolio-based algorithm selection for SAT. *Journal of Artificial Intelligence Research*, 32: 565–606, 2008. doi: 10.1613/jair.2490.
- Guibin Zhang, Leo Lu, Fangzhou Xie, Kang Zhu, Junhao Wang, Zhifei Xie, Zhaochen Yu, Zihang Liu, Zhongxiang Sun, Qiankun Li, Yue Liao, Heng Chang, Xiaobin Hu, Qibing Ren, Wangchunshu Zhou, Chuanrui Hu, Yafeng Deng, and Shuicheng Yan. JIT-Agent: Scaling harness intelligence via just-in-time harness evolution. *arXiv preprint arXiv:2608.25593*, 2026a. doi: 10.48550/arXiv.2608.25593. URL <https://arxiv.org/abs/2608.25593>.
- Hangfan Zhang, Shao Zhang, Kangcong Li, Chen Zhang, Yang Chen, Yiqun Zhang, Lei Bai, and Shuyue Hu. Self-harness: Harnesses that improve themselves. *arXiv preprint arXiv:2606.09498*, 2026b. doi: 10.48550/arXiv.2606.09498. URL <https://arxiv.org/abs/2606.09498>.
- Heng Zhou, Zelin Tan, Zhemeng Zhang, Yutao Fan, Yibing Lin, Li Kang, Xiufeng Song, Rui Li, Songtao Huang, Ao Yu, Yuchen Fan, Yanxu Chen, Kaixin Xu, Xiaohong Liu, Yiran Qin, Philip Torr, Chen Zhang, and Zhenfei Yin. Select-then-solve: Paradigm routing as inference-time optimization for LLM agents. *arXiv preprint arXiv:2604.06753*, 2026. doi: 10.48550/arXiv.2604.06753. URL <https://arxiv.org/abs/2604.06753>.

附录阅读导航

附录给出程序生成、重复执行、选择方法、校准及 BIRD 补充研究。

A Harness 生成、程序清单与数据划分.

B 同代码对照与重复执行协议.

C 统计分析、校准与灵敏度.

D 冻结选择器与等执行次数重放.

E BIRD 执行轨迹与补充分析.

F BIRD 准入策略研究.

A HARNESS 生成、程序清单与数据划分

本附录给出 MATH 群体、任务划分、冻结面板与模型版本。BIRD 协议见附录 E 和 F。

A.1 MATH 群体、共同分析集与覆盖

单次研究提供覆盖测量与重复面板的程序来源，将 BIRD 的无门控自由生成方案用于竞赛数学，并采用领域特定比较器。

协议与分析集。 构建器指令可概括为（非逐字引用）：编写 Python `solve(question)` harness，通过 `self.llm` 改进单次贪心调用，自选提示、解码、采样与控制流，以 ##### 返回最终答案。标准答案保留在外部评分器中。槽位不分配机制或多样性目标；尝试沿用相同指令，不提供先前代码或性能反馈。准入要求接口有效且输出非空。

六个构建器在一个种子下各获八个槽位，每槽至多三次尝试，在两道开发题上检查解析、导入、接口及非空答案。目标为 GLM-5.3-Flash，解码由成员定义，single-call 温度为 0。生成前划分保留 100 道开发题。单次、重复与选择策略分析共用 386 道完整观测题；采集后的完整性规则排除 14 道题（附录 B）。开发题与选择器保持固定。

评分器优先比较可解析的数值（含分数与小数），否则比较规范化 LaTeX。归一化去除单位、进制下标和度数符号，保留文本命令内容，并将矩阵转为元组。加上 ##### 标记的标准答案通过 386/386 次自比较。该集单次基线准确率为 95.08%。

门控接纳 35/48 个槽位。GLM-5.3 与 Qwen3.8-Max 在多数槽位发出代码前耗尽 32k token 预算，使其风格在这一固定预算群体中代表性不足。

共同完整集上的结果。 包含 single-call 的 36 个成员在 386 题上各有一次评分，共 13,896/13,896 个单元。平均成对分歧为 10.94%（最大 33.16%），唯一结果向量为 29/36（生成为 28/35），2.22% 的成员对结果相同。生成并集修复 84.21% 的基线错题；在

0.82% 的基线正确题上，所有生成成员均失败。Oracle 覆盖 99.22%，比最佳固定成员 single-call (95.08%) 高 4.15 pp。生成成员准确率为 69.69%–92.49%。

重复面板在相同题目上比较八个生成成员加 single-call 与九个同代码槽位。留出诊断对应此面板，单次余量对应完整群体。存档评分器与版本化端点敏感评分器均复现全部 13,896 个纳入评分。

范围。 这些测量对应一个种子、一个目标与按完整性筛选的 MATH 题集；BIRD 使用下文的独立协议。

A.2 MATH 选中程序清单

表 4 说明重复研究中选定的九个冻结成员。H1–H8 是生成成员的中性编号，生成种子均为 0。所列操作表示各程序实现了什么，不表示每个分支均被触发或提高了正确性。平均调用数的准入上限不是单次执行硬上限，一次逻辑调用也可能请求多个样本。

冻结成员	源代码定义的执行路径
single-call	一次温度 0 的求解，按规定格式给出最终答案。
H1 (DeepSeek)	三次温度 0.4 的求解；归一化答案后投票；无答案或并列时采用贪心回退。
H2 (ERNIE)	起草解答，再让求解器验证或修正提取的答案；返回检查后答案。
H3 (GLM)	最多五种提示、温度 0 的求解；三者一致即停止；分歧未解决时裁决，并设有格式回退。
H4 (Kimi)	一次调用请求五个温度 0.7 的样本；提取答案后投票。
H5 (Kimi)	初次求解、验证与另一种求解；投票，没有多数时额外调用以解决分歧。
H6 (MiniMax)	草稿、批评；不一致时增加平局裁决调用；解析失败时使用此前可用答案。
H7 (MiniMax)	一次调用请求五个温度 0.7 的样本；归一化并投票，并列时取最先出现者。
H8 (Qwen)	草稿加独立求解与审核；比较答案，冲突时请求裁决，并设有格式修复路径。

表 4: 重复研究具体选中了哪些程序。所有调用使用同一冻结求解器；验证和裁决均为求解器提示，不能访问基准标签。六个席位按构建器分层选出，H5 (Kimi) 与 H7 (MiniMax) 为两个不分层席位。

A.3 模型与版本

表 5 给出确切 API 模型标识。所有角色均通过同一商业 OpenAI 兼容聚合器访问。目标身份固定，解码由各 harness 定义，single-call 基线温度为 0。Phase-II 生成使用温度 0.7、16,384 token 预算；Phase-I 条件见附录 E.1。Phase I 使用代理执行评分器，Phase II 使用官方 BIRD 评分器 (30s 超时) 并保留旧评分器的次要审核，MATH-500 使用附录 A.1 的答案比较器。报告准确率均不使用 LLM 评分器。

角色	模型（确切版本字符串）	用于
冻结目标求解器	GLM-5.3-Flash（基线温度 0）	MATH / BIRD
BIRD 发现构建器	GLM-5.3-Flash	附录 E.1
MATH / BIRD 准入构建器	GLM-5.3, Qwen3.8-Max, DeepSeek-V4-Pro, Kimi-K3, MiniMax-M3, ERNIE-5.0-Thinking-Preview	MATH / BIRD
评分器	代理 / 官方 BIRD 执行评分器；MATH 答案比较器	见正文

表 5: 所报告基准研究的模型清单。目标在每个阶段内保持冻结；Phase-II 构建器来自六个独立实验室。

B 同代码对照与重复执行协议

全部 MATH 主估计共用 386 道完整观测题。下文给出面板、纳入规则与重复分析。

面板与纳入规则。 程序、求解器、评分器、开发划分及三次重复身份固定。加盐哈希选出每个构建器的一个低调用成员，另加两个自由席位与 single-call；对照含九个相同基线槽位。2026 年 9 月 26 日 UTC 05:15 快照合并生成臂续采 10 与克隆臂续采 20。查看结果后，保留单次与重复研究每个必需单元均有记录二元评分的任务，以这 386 个题目身份定义共同重分析集。

完整性与排除。 单次矩阵包含 $36 \times 386 = 13,896$ 个观测单元，每个重复臂包含 $9 \times 3 \times 386 = 10,422$ 个，三个矩阵均为 100% 完整。选择策略评估与 oracle 重放使用相同题目身份。

排除的 14 道题包含 61 个生成臂未评分单元，分布为 DeepSeek 5、ERNIE 4、GLM 9、Kimi 30、MiniMax 9、Qwen 4；基线与克隆记录完整。取子集前的排除比例 3.50% 低于冻结的 10% 门槛。排除题更难、更长，基线准确率更低（表 6）。未知评分与全部已发生采集成本仍保留在来源记录中。

观测特征	纳入（386）	排除（14）
基线重复平均准确率（%）	95.85	71.43
基准难度等级均值	3.47	4.29
Level-5 题目比例（%）	26.42	64.29
题干平均长度（字符）	198.75	284.71

表 6: 纳入题与排除题的观测特征。排除题的基准难度更高、题干更长、基线准确率更低。

来源与冲突。 Manifest 核验涵盖执行条件、程序、任务 / 划分哈希、面板抽样及调度的 13 项字段；快照、矩阵与题目名单绑定哈希。完成评分替代未知，冲突时保留最先

完成者。生成臂有五个冲突单元，其中三个位于三道纳入题；克隆无冲突。采集器与并发变更保留记录。

估计与敏感性。 记录二元评分给出生成臂代入估计余量 2.33 pp、克隆臂 2.16 pp，以及 $D = -0.26$ pp (95% 区间 $[-1.45, 0.95]$ pp; INSUFFICIENT EVIDENCE)。从两臂删除三道冲突题，并在剩余 383 题上重新选择，得到 $D = -0.61$ pp (区间 $[-1.96, 0.64]$ pp)，判断不变。

B.1 探索性可重复性与评分敏感性

对非参照成员定义 $A_r(h, x) = Y(h, x, r) - Y(h_0, x, r)$ ，其中 h_0 为 single-call 或 clone-cl。各重复内减去行、列均值并加回总体均值，将每次留出的残差矩阵与其余两次均值的残差相关，再平均三项相关性。配对任务 bootstrap 使用 2,000 次共享抽样。生成臂相关性为 0.789 ($[0.75, 0.83]$)，克隆为 0.006 ($[-0.07, 0.08]$)，差异为 0.783 ($[0.69, 0.87]$)。这一采集后诊断衡量去除加性效应后的重复评分模式。

三次均输的记录涉及 570 个成员—任务对、100 道题。三次均赢的八个对全部来自同一题，由八个生成程序共享。该题对格式敏感：标准答案为 12，基线输出以 ##### 12th grade 结尾，一个生成成员返回 12th grade。提取器保留前者的完整 ##### 内容并计零，却对后者回退至数值提取并计一。保留记录评分；此处的重复修复来自答案格式。

C 统计分析、校准与灵敏度

实证诊断使用 386 道完整 MATH 题，合成校准使用下文指定的样本量。

C.1 留出重复统计量与判定规则

三折中的每一折，用两次发现重复为每题选择一个成员，并按平均发现准确率选择一个最佳固定成员；第三次重复将逐题映射对照该固定成员评分。逐题增益在折上平均得到 G ，两臂的配对差为 $D = G_{\text{real}} - G_{\text{clone}}$ (§4.2)。重复平均 oracle 代入估计量 $\hat{H}$ 仅作描述，不决定判定结果。

发现分数落在 $\{0, \frac{1}{2}, 1\}$ 上，因此并列很常见。选择使用 iid $U(0, 10^{-9})$ 抖动对称地打破成员并列；实证报告对十个冻结的并列实现取平均，每个校准数据集使用一个并列实现。实证随机化参考在每臂的每题、每次重复内独立置换成员标签。每次抽取都重算两个选择、两个增益及 D ，共 10,000 次，并使用 +1 Monte Carlo 校正。配对题目 bootstrap 使用固定随机种子的 2,000 次抽取，两臂共享重采样题目身份，以获得 95% 区间。

正向支持要求：取子集前任一臂及其交集的不完整题比例不超过 10%；配对题至少 30 道；随机化 $p < 0.05$ ； D 与 G_{real} 的 bootstrap 下界均为正；且 $D > 1.0$ pp。重复须条件匹配并核实独立执行来源。当前判断为 INSUFFICIENT EVIDENCE，并非等效性结论。

分析规格。采集协议与初始停止规则先于采集；v3 诊断、补采集及完整性重分析属于采集后修订。估计使用 9 月 26 日快照，纳入、排除与冲突敏感性见附录 B。

C.2 总体目标与诊断边界

对于成员成功概率 $p_h(x)$ ，稳定互补性为

$$H_{\text{stable}} = \mathbb{E}_x \max_h p_h(x) - \max_h \mathbb{E}_x p_h(x).$$

当某个固定成员在几乎每道题上都是期望最佳时，该量为零。选择器相对于总体最佳固定成员的总体增益 θ^* 满足 $\theta^* \leq H_{\text{stable}}$ ，因为其逐题成功概率不超过 $\max_h p_h(x)$ 。

实证 G 使用有限发现数据选出的固定成员。克隆相减提供采样参照，但 D 及其区间与 H_{stable} 不同：接近零的 D 不将总体目标界定在零附近。

随机化参照在等能力、成员标签可交换时精确；更广全局支配零假设的错误控制由校准网格作经验检查。

有限重复的 oracle 估计。 对重复均值 $\hat{p}_h(x)$ ，Jensen 不等式逐题给出 $\mathbb{E} \max_h \hat{p}_h(x) \geq \max_h \mathbb{E} \hat{p}_h(x)$ 。余量还减去第二个最大值，因此该不等式一般并不意味着二者之差向上偏。在 $p_h(x) = 0.9$ 、 $M = 9$ 、 $T = 400$ 、 $R = 3$ 的已知真值等能力模拟中，300 个数据集的平均代入估计量为 8.69 pp，而 $H_{\text{stable}} = 0$ 。实证同代码臂同样给出 2.16 pp。这些例子表明，正的代入余量估计不足以证明专长。

C.3 已知真值校准与统计功效

二元张量从指定的成员—任务概率矩阵抽取。零假设设置包括等能力、共享题目难度、全局支配、0.5/0.9 支配配置及异质支配。备择包括潜在任务类型间的交叉与难度相关的部分交叉。网格覆盖 $M \in \{3, 9, 20\}$ 、 $T \in \{100, 400, 1000\}$ 、 $R \in \{3, 5, 10, 20\}$ 、完整数据、5% MCAR 与 3% 难度相关缺失。

对每个重复数 R ，校准统计量都使用 R 折：每折用其余 $R - 1$ 次重复学习逐题选择和固定成员，再在唯一留出的重复上评分。表中 *plug* 比较器在其百分位法 95% 题目 bootstrap 区间下界大于零时判为正向结果（1,000 次抽取）；逐题最大值与样本最佳成员均在重采样前固定。标为 v3* 的模拟版本使用上述正向支持条件、300 次 bootstrap 与 300 次随机化，但只对真实臂检查完整性门槛；实证规则还检查克隆臂与配对交集。模拟中的弃权表示未获得正向支持。

双专家设置将 400 道题分成等大的两半。两名专家各自在所属半区的成功概率为 0.95，另一半为 0.60；其余七名成员在全部题目上的成功概率均为 0.60。结果由独立 Bernoulli 抽样产生。oracle 均值为 0.95，最佳固定均值为 0.775，因此 $H_{\text{stable}} = 17.5$ pp。九个克隆槽位共享第一名专家的成功概率分布，并各自独立抽样。

表 7 报告 $M = 9$ 、 $T = 400$ 的设置，每格使用 300 个 Monte Carlo 数据集（扫描为 150 个），每集执行 300 次随机化。100 格网格中，最大观测零假设错误支持率为 2%。真实

$H_{\text{stable}} = 17.5$ pp 的双专家备择在 $R = 3$ 时功效为 0%， $R = 5$ 时约 0.7%， $R = 10, 20$ 时为 100%；较小循环交叉在 $R = 20$ 时仍大多无法检出。这些设置特定的结果说明，三次重复仍未判清稳定互补性。

regime	$R=3$		$R=10$		$R=20$		abst.
	plug	v3*	plug	v3*	plug	v3*	$R=3$
equal $p=0.9^\dagger$	100	0	100	0	100	1	100
equal + difficulty [†]	100	0	100	1	100	1	100
0.5/0.9 dominance [†]	100	0	100	0	13	0	100
dominance [†]	100	0	100	0	100	0	100
cross $H \approx 0.9$ pp	100	1	100	0	100	0	99
cross $H \approx 1.8$ pp	100	1	100	1	100	0	99
cross $H \approx 4.2$ pp	100	0	100	0	100	0	100
two strong specialists, $H=17.5$ pp	100	0	100	100	100	100	100

[†] Null ($H=0$): false-support %; otherwise power %. $M=9, T=400$, 300 datasets at $R=3$ (150 in sweeps). *plug*: positive 95% bootstrap lower bound. *v3 simulation variant: real-arm completeness gate, 300 bootstrap draws and 300 randomizations. The empirical rule additionally gates clones and their paired intersection; details are given above.

表 7: 三次重复甚至会漏掉强正例。在 $M = 9, T = 400$ 下，零假设行报告错误支持率 (%), 备择行报告功效 (%); 最后一列为 $R = 3$ 的弃权率。模拟版克隆校准规则 (v3*) 在稳定互补性为零时很少误判为正向支持，但对所测小、中等交叉的灵敏度很低。

D 冻结选择器与等执行次数重放

选择器在 100 道开发题上拟合，记录的选择与开发集排序在共同 386 题上评估。

D.1 冻结特征选择器

所报告的选择器 π_Z 在 100 道开发题上采用五折题目划分，拟合多项 logistic 回归。成员 h 在开发题 x 上的评分摘要为可用重复均值：

$$\bar{Y}_h(x) = \frac{1}{|\mathcal{R}_{hx}|} \sum_{r \in \mathcal{R}_{hx}} Y(h, x, r),$$

其中 $\mathcal{R}_{hx}$ 为该成员在该开发题上已有评分的重复集合。仅当每个成员都有至少一次已观测重复时，该题才纳入拟合。训练标签为 $y(x) = \arg \max_h \bar{Y}_h(x)$ ，并列按成员 ID 升序取首。合格题按题目 ID 排序后连续划为五折，不打乱顺序；题目的所有重复始终留在同一折。

TF-IDF 词表与逆文档频率在全部合格开发题文本上统一拟合，去除英文停用词，最多保留 300 维特征。每个折模型将其四个训练折上的逐成员准确率向量附加到每道题的特征中。该向量在同一模型内对所有题目相同，只有文本特征随题目变化。logistic 回归使用 $C = 1$ ，迭代上限为 1,000；若某个训练折只有一种标签，则跳过该模型，模型未见的成员类别赋零概率。若共拟合 $1 \leq K \leq 5$ 个模型，以 $q_k(h | x)$ 表示第 k 个模型的类别预测概率，则推断使用 $\bar{q}(h | x) = K^{-1} \sum_{k=1}^K q_k(h | x)$ 。令 $h_{(1)}$ 、 $h_{(2)}$ 为平均概率

最高的两个成员，最终冻结选择为

$$\pi_Z(x) = \begin{cases} \text{single-call}, & \bar{q}(h_{(1)} | x) - \bar{q}(h_{(2)} | x) < 0.15, \\ h_{(1)}, & \text{其他情况.} \end{cases}$$

阈值在平均之后应用，因此最高预测概率并列时会回退至基线。策略表评估包含基线回退在内的最终选择，报告以 harness 执行为单位的重复平均准确率；所选 harness 可以发起多次模型调用。

比较对象为 single-call、开发集固定成员、用种子 20260915 抽取一次后固定的成员，以及缺失单元上回退至基线的开发集固定成员。

Policy	Eval acc. (%)	S vs dev-fixed (pp) [95% CI]
single-call (fixed)	95.85	0.00 [0.00, 0.00]
dev-fixed	95.85	—
One randomly drawn fixed member	86.01	-9.84 [-13.04, -6.91]
Dev-fixed + baseline fallback	95.85	0.00 [0.00, 0.00]
π_Z (frozen selector)	95.85	0.00 [0.00, 0.00]

表 8: 共同 386 题 MATH 分析集上的冻结比较器。每个选定成员在每题上都有三次评分。准确率为重复均值；对开发固定的逐题配对差使用 2,000 次任务 bootstrap。特征策略、开发固定及回退策略均保留原记录的 single-call 选择，随机抽取后固定的成员为 gsm_kimi_s0_g3。记录中的策略在这些任务的新执行上评估。

D.2 选择收益与预算效用的范围

实际选择器的 $Z(x)$ 仅包含题目特征与训练折成员准确率。相对开发集固定成员收益为

$$S(\pi_Z) = \mathbb{E}_x [\bar{Y}_{\pi_Z(x)}(x) - \bar{Y}_{h_{\text{dev-fixed}}}(x)],$$

此处 $\bar{Y}_h(x)$ 对三次评估重复取平均。我们用 S 表示策略收益，将 D 留给真实臂减克隆臂的重复诊断。机制标签不属于该特征选择器的输入。

重放预算 b 表示 harness 执行次数，每次可包含多个模型调用；覆盖由执行后的 oracle 计算。

D.3 等执行次数重放与采集账目

每臂含九个成员 / 槽位、每槽三次重复。重放使用共同 386 题与冻结开发排序 (§5.4)，在 $b \in \{3, 9, 15, 27\}$ 下取前 $b/3$ 个成员的全部三次重复。若 27 次克隆执行中有 f 次错误，从全部大小为 b 的子集中均匀抽取时的期望覆盖为 $1 - \binom{f}{b} / \binom{27}{b}$ ，其中 $b > f$ 时 $\binom{f}{b} = 0$ 。表 3 将此精确期望与相同执行次数下的生成面板覆盖比较。

采集台账保留全部尝试与已知用量，包括排除题和补采集；结果表使用共同完整集。调用与 token 用量按程序和采集记录记账。

E BIRD 执行轨迹与补充分析

Phase I 对应 BIRD 发现研究，Phase II 对应准入研究。本附录展开前者的程序与执行路径。

E.1 发现研究的程序群体与条件

程序群体与评分。 发现研究在 60 题上评估 GLM-5.3-Flash 经 TTHe 提议者生成的十二个候选，以及 single-call 和 `react` (§5.5)。准入检查导入与冒烟执行。基线在两次发现运行间翻转 60 题中的三题。在两个保留 SQL 的矩阵上，行集合代理评分器与官方 BIRD 评分器一致率为 0.97–0.99，没有代理判对而官方判错的案例。

开发暴露。 人工控制在查看轨迹后设计，24/151 个评估项与协议开发重叠，其余量作描述性报告。早期记录缺少生成工具与逐尝试日志，无法重建等生成预算。




图 2: 源码差异未必改变观测正确性。BIRD 发现研究包含 14 个 harness、60 个任务，每个执行一次。含基线的 91 对中，token 序列源码相似度与正确性分歧的秩相关为 $\rho = -0.010$ ；36/91 对具有相同正确性向量。这是观测任务上的结果比较，不是程序等价检验。

E.2 发现研究的结果与人工控制

全部候选通过代码差异检查，但 21/66 个生成对的正确性向量相同（含基线为 36/91）。91 对上的源码相似度与正确性分歧相关为 $\rho = -0.010$ （图 2）。这 60 题的平均分歧为 3.3%，仅生成候选为 3.8%，联合修复率为 7.7%，单次余量为 3.3 pp。轨迹展示不同程序产生相近结果的具体路径。

E.3 轨迹区分机制缺失、未触发与执行失败

T1: 描述存在, 实现缺失。十二个候选中六个声称检索或自检, 却只有一次模型调用, 未实现所描述的检索或自检步骤。**T2: 机制存在, 未被触发。**全部十个被审 `react` 任务的首个 SQL 均无错误执行, 修复分支未启动, 最终 SQL 与 `single-call` 相同; 执行成功仍可伴随语义错误。**T3: 执行发生, 输出损坏。**十二个候选中一个执行多轮修复, 却将自然语言作为 SQL 返回, 丢掉基线答对的题。

三个案例分别定位实现、分支触发与输出有效性。四个人工编写、路径不同的控制在 60 题上产生 6.67 pp 余量, 在 151 题上为 7.28 pp。这些轨迹检查后的控制缺少匹配重复与克隆; 24/151 的开发重叠见附录 E.1, 具体轨迹见附录 E.4。

E.4 轨迹审核的完整样例

T1 的六 / 十二计数覆盖完整发现群体。独立轨迹审核在十道题上跟踪五个 harness: `single-call` 基线、`react`、生成的单次调用候选、超时重试候选及多轮修复候选 (5 × 10)。下文以一题展示路径。日志中的 SQL 摘录上限为 120 字符, 截断标为 `[trunc.]`。

任务。 BIRD 开发集问题 352 (`card_games` 数据库; 题目文本逐字, 拼写错误为数据集原有):

```
Calculate the percentage of the cards availabe in Chinese
Simplified.
```

其 BIRD 提示:

```
'Chinese Simplified' is the language; percentage = Divide(Sum(id
where language = 'Chinese Simplified'), Count(id)) *100
```

标准 SQL:

```
SELECT CAST(SUM(CASE WHEN T2.language = 'Chinese Simplified' THEN
1 ELSE 0 END) AS REAL) * 100 / COUNT(T1.id) FROM cards AS T1 INNER
JOIN foreign_data AS T2 ON T1.uuid = T2.uuid
```

`single-call` harness 回答:

```
SELECT SUM(CASE WHEN language = 'Chinese Simplified' THEN 1 ELSE 0
END) * 100.0 / COUNT(id) AS percentage FROM foreign_data;
```

在发布数据库上, 标准查询得到 8.7734, 基线查询得到 8.7728。官方评分器将基线查询判错: 它直接在 `foreign_data` 上计数, 而标准查询在连接 `cards` 之后计数; 提示没有写明该连接。

react (T2: 修复未触发)。 首个提示与 single-call 逐字节相同。SQL 执行成功，因此数据库错误重试未触发。全部 10 道被审题沿此路径运行：执行 SQL，但 10/10 最终查询与 single-call 逐字节相同。

单次调用候选 (T1: 修复缺失)。 文档字符串的“保守修复”要求输出 token 上限与仅答案块，实际仅调用一次模型再提取 SQL。上限只是环境默认值 (2,048，对比运行时 32,000)，没有 harness 控制流实现，也未在短答案上生效。样例题用一次调用、零次 SQL 执行返回同一错误的 `foreign_data` 查询，仅空白不同。全部 10 题的 SQL 执行数均为零，6 个最终查询与 single-call 逐字节相同，其余差异来自提示改写，未实现检索、自检或修复。

超时重试候选 (看门狗未触发)。 守护线程看门狗包裹 coder 调用，停滞超过 40s 时发出一次对冲重复请求。审核中未出现停滞：SQL 执行数为零，全部 10 题的最终 SQL 与 single-call 相同。

多轮修复候选 (T3: 多轮路径执行失败)。 唯一一个实现了真正执行—检查—修复的被审候选把模型的自然语言说明当作最终 SQL 返回。在一道 single-call 答对的题 (“State the alternative languages available for card named Annul numbered 29.”) 上，其记录的最终 SQL 逐字开头为：

```
with "only a single read-only SELECT is allowed". The previous
"query" was actually just prose text (the model wrote rea[trunc.]
```

该修复提示下，输出契约再次失败：被要求修复一个“实际上只是自然语言说明”的查询时，冻结目标继续返回自然语言推理；由于找不到 SQL 块，推理文本便被当作查询提交。该题从基线正确翻转为 harness 错误。

F BIRD 准入策略研究

2×2 研究交叉六个构建器与三个种子，II-E 仅用于开发。每槽至多 $R = 3$ 次尝试，首次接纳即停，不补足。两个开发数据库被排除。评估包含九个数据库的 1,169 题与预抽取的 400 题核心集，其中一次 18 题冒烟测试是已披露的开发暴露。官方 BIRD 评分器超时为 30s。模型身份区分的响应缓存在修正并发缺陷后使用跨进程锁。

主 D-A 对比配对构建器一种子单元，采用分层 bootstrap 与置换推断；核心分析使用 Holm 校正析因对比及 K 匹配敏感性。仪器修正先于确认性结果，后续分析修正统一基线记录与数据库 / 题目重采样。规范记录按先写先得去重，冲突与操作偏离保留在来源审核中。各臂生成成本不同。




图 3: **BIRD 准入设计**。左：数据划分及已披露的开发暴露。中：采用共同尝试上限的 2×2 四臂比较。右：中性有效性检查及门控臂实际采用的结构筛选与合规验证组合。额外的开放机制臂 II-E 仅用于开发。

F.1 设计与主要比较

六构建器、三种子研究交叉策略强制与门控：II-A（自由、无门控）、II-B（自由、门控）、II-C（强制、无门控）、II-D（强制、门控）。强制策略来自固定集合，自由构建器在附录 F.4 的词汇中选择声明。评估使用九个数据库的 1,169 题、官方 BIRD 评分器，并包含已披露的 18 题冒烟例外。下文报告按照查看结果前制定的分析方案开展的校正重分析。

Metric	II-A	II-D
Candidate count	5.78	3.83
Oracle accuracy (%)	76.14	75.70
Best-fixed accuracy (%)	67.58	67.30
Headroom (pp)	8.56	8.40
D-A headroom (pp)	-0.16	
Unadjusted bootstrap 95% CI	[-0.83, +0.87]	
One-sided sign-flip p	0.647	

表 9: 校正后的主分析。数值为 1,169 个问题上 18 个构建器-种子单元格的均值；single-call 同时计入 oracle 与最佳固定对照。

强制 / 门控减自由 / 无门控的含基线 oracle 余量对比为 -0.16 pp, 单元对比范围 -4.36 to $+2.74$ pp。实际的策略强制与门控组合未提高观测平均余量; 不确定性见表 9。




图 4: **BIRD 准入对比**。左: 完整集合的 D-A 单元格对比与合并 95% 区间。右: 共享核心 400 题上、以共同 single-call 为基线的四臂余量。图中余量和差值坐标均表示百分点。

核心 400 题的门控对比为 -0.69 pp, 策略与交互效应尚无定论 (表 10); 固定 K 对比为 -0.31 pp。II-E 仍仅用于开发。R2/R3 审核 (附录 F.3) 为这些单次覆盖测量提供参照: R2 翻转 8.54%, 三次运行间 14.5% 的基线题目改变正确性, 同代码 oracle 缺口为 6.50 pp。

Contrast	Effect (pp)	95% CI (pp)	Raw p	Holm p
Gate	-0.69	$[-1.56, +0.20]$	0.026	0.079
Strategy	+0.42	$[-0.32, +1.51]$	0.263	0.428
Interaction	-0.87	$[-2.83, +0.65]$	0.214	0.428

表 10: 校正后的核心 400 题析因重分析。门控为 $[(B-A)+(D-C)]/2$, 策略为 $[(C-A)+(D-B)]/2$, 交互为 $(D-C)-(B-A)$; 给出原始与 Holm 调整 p 值。

F.2 同一核心集上的余量分解

表 11 在相同核心任务与基线记录下分解各臂的覆盖、最佳固定准确率及余量。

Arm	K_{cand}	K_{total}	Single-call (%)	Best (%)	Oracle (%)	H (pp)
A	5.78	6.78	63.25	66.00	74.51	8.51
B	6.11	7.11	63.25	66.12	74.39	8.26
C	5.61	6.61	63.25	65.64	75.01	9.38
D	3.83	4.83	63.25	65.65	73.90	8.25

表 11: 同一核心集上的余量分解。所有臂使用相同 400 题与相同 single-call 结果。 K_{cand} 排除 single-call, $K_{\text{total}} = K_{\text{cand}} + 1$; 数量与准确率为单元均值。余量为 oracle 减最佳固定准确率, 不是已实现路由增益。

F.3 敏感性、重复审核与记录成本

K 匹配与 R2 重放。 重放使用确定性记录排序、共享数据库 / 库内题目抽样, 以及固定构建器内的种子重采样 (10,000 次)。K 匹配取 A/B、C/D 对中的较小候选数, 精确枚举均匀子集, 保留 single-call, 并在每个子集和题目抽样中重选最佳固定成员, 衡量群体规模敏感性。下述 R2 保留全部 18 个单元, 包括两个 A 子集为单成员的单元; D-A 从 +0.42 变为 +0.81 pp (变化 +0.39 pp, 95% CI [-0.95, +1.63])。

R2 在 400 题上覆盖 70 个 harness, 在可用时取 A/D 每单元前两个可调用的已接纳候选。两个关缓存组虽有重复标签, 仍分别保留, 程序身份与缓存运行核对。因缺少匹配 single-call, 两种 R2 条件均排除该基线; 18 个保留配对中的单成员余量为零。相对缓存结果翻转 2391/28,000 次 (8.54%), 两个 D 关缓存轮次间翻转 1245/14,400 次 (8.65%)。这些数值描述观测不稳定性: 获取时间与缓存混杂, 翻转率并非标准误差或效应大小下限。

R3 仅 single-call 重复审核。 在 core-400 上用 GLM-5.3-Flash、温度 0, 对 single-call 基线作三次独立关缓存运行。58/400 题 (14.5%) 正确性改变; 成对翻转为 39/400、40/400、37/400 (9.75%、10.0%、9.25%)。将运行视为三个伪成员、各一次执行, 官方评分给出 oracle 覆盖 72.25%、最佳单次准确率 65.75%, 形成 6.50 pp 同代码缺口。这记录了温度 0 下的基线执行变异, 也是主研究设置重复对照的依据。

Sensitivity estimand	Estimate (pp)	95% CI (pp)
K-matched B-A headroom	-0.55	[-1.53, +0.63]
K-matched D-C headroom	-0.08	[-1.26, +0.80]
K-matched gate mean	-0.31	[-1.07, +0.40]
R2 subset D-A (cached)	+0.42	[-0.61, +1.48]
R2 subset D-A (cache-off)	+0.81	[-0.35, +1.84]
R2 change in subset D-A	+0.39	[-0.95, +1.63]

表 12: core-400、18 单元上的修正敏感性。CI 未校正。K 匹配比较始终保留 single-call; R2 比较排除 single-call, 并以观察到的获取组为条件。

记录成本。 核心记录的 153,600 条候选一题目记录包含 259,304 次逻辑 solver 调用 (表 13), 包括缓存服务的请求, 计数对应逻辑请求而非计费请求; token 用量缺失。生成尝试、接纳数与执行调用分别报告。群体成本按构建器一种子单元等权平均, 排除 single-call, 零候选群体记零调用。

Arm	Candidate-task records	Logged solver calls	Calls/task/population
A	41,600	67,258	9.34
B	44,000	64,399	8.94
C	40,400	75,604	10.50
D	27,600	52,043	7.23

表 13: core-400 上的描述性 canonical 成本审核, 每组 18 单元。记录的逻辑调用不是计费请求或 token 计数。末列为各单元逐题候选种群调用的平均值。

F.4 准入范围与实现

自由臂构建器在 repair、vote、twostage、plain 中选择。vote 要求多样本与选择, 包含但不限于三路多数投票; twostage 消费产物, 不规定响应接口; plain 不声明控制流机制, 尽管提示要求改变。因此, 策略选择在这四类声明内进行。

所评估门控组合结构筛选与合规验证, 有效的纯提示变换也可能被结构筛查拒绝。开发检验发现误拒、请求归属与响应接口缺陷, 以及未决判断。后续修订未产生替代基准结果, 故报告对应实际实现的门控组合。

生成接口。 格式守卫 (format-guard) 是八个固定策略之一; C、D 两个强制臂的每个构建器一种子单元为每种策略分配一个槽位。该策略要求遵守数据库结构约束, 并以 SQL 代码块给出最终答案, 不附加其他文字。其 36 个槽位的 108 次尝试均未通过中性有效性: 71 条日志为字符串未终止, 36 条为无 Python 围栏, 一条为提供方超时。合成示例复现存档非贪婪围栏提取器的截断。完整构建器消息与确切历史提取器版本缺失, 限制了这些上游有效性失败的归因。