

更多程序，还是更多次采样？ 区分 LLM HARNESS 的覆盖与专长

(中文参考译本)

Anonymous authors

Paper under double-blind review

ABSTRACT

生成的 LLM harness 究竟增加了任务特异能力，还是仅增加了获得正确答案的机会？本文在 MATH-500 的同一批 386 道完整观测分析题上，通过同代码对照区分覆盖、可重复性与可用选择。八个生成程序加一个基线，与九个逐字节相同的基线槽位比较，每个成员执行三次。尽管程序专长按构造为零，克隆仍产生 2.16 个百分点的重复平均 oracle 余量。生成程序的评分模式残差相关性远高于克隆 (0.789 对 0.006)，但持续输给基线的情况涉及 100 道题，持续获胜却仅出现在一道题上。冻结特征选择器收益为零；执行 27 次时，两臂 oracle 覆盖均为 98.70%。留出重复证据尚未判清稳定互补性。补充的 BIRD 轨迹区分了缺失、未触发以及执行后破坏输出的机制。因此，在所测面板上，强可重复性既没有为冻结选择器带来收益，也没有使完整预算下的 oracle 覆盖超过同一程序的额外执行。

1 引言

固定的推理预算应该用于生成更多程序，还是让同一个程序执行更多次？自动化智能体设计使前一种选择更容易实现：构建器生成一组 LLM harness，每个程序为冻结的求解模型安排提示、工具与控制流 (Hu et al., 2024; Nie et al., 2026; Zhang et al., 2026b)。其吸引力在于，不同程序可能分别擅长不同任务。但要作出这种解释，就必须把群体收益与评估群体时增加的尝试次数区分开。

困难在于，观测到不同的成功并不要求存在不同的能力。一个成功概率为 0.5 的程序独立执行两次，就能以 0.75 的概率覆盖一道题，尽管没有引入任何程序专长。Pass@k 衡量多次采样的覆盖率；自一致性与采样投票集成则将多次尝试聚合为一个答案 (Chen et al., 2021; Wang et al., 2022; Li et al., 2024)。因此，即使每个成员代码相同，一个看到全部结果后才挑选正确答案的 oracle 也能显示群体收益。对少数重复取平均并不会自动消除这种歧义：选择最大的估计成功率，也会偏向有利的采样波动。

1. 覆盖 重复平均 oracle 余量 生成程序: 2.33 pp 同代码: 2.16 pp 相同程序也产生正的覆盖余量。	2. 可重复性 评分模式残差相关性 生成程序: 0.789 同代码: 0.006 持续损失: 100 题 持续获胜: 1 题	3. 选择与重放 冻结选择器收益 0.00 pp 27 次执行的 oracle 覆盖 生成程序: 98.70% 同代码: 98.70%
---	---	--

图 1: 正余量与强可重复性, 同时伴随零选择收益和相同的完整预算 oracle 覆盖。三栏均使用相同的 386 道 MATH 题、八个生成程序加 single-call, 以及九个相同的 single-call 槽位, 每个成员进行三次新执行。持续输赢指三次均相对 single-call 失分或获胜。选择器收益相对开发集选出的固定基线计算; 重放在相同 harness 执行次数下, 使用执行后正确性比较生成面板与同代码执行。

本文研究, 什么证据能够区分覆盖机会与任务专长。全文围绕三个问题展开: 已记录的执行是否包含额外正确答案? 某个成员在一道题上的优势能否在新执行中保持? 一个规则能否在看到答案前作出有用选择, 并优于把同等资源交给固定程序? 这三个问题对应不同的量, 第一个问题的肯定答案不能代替后两个问题的答案。

我们先报告全部 35 个生成程序在 MATH-500 上的单次覆盖, 再在所选子集上检验专长解释。核心对照固定群体规模, 只改变程序是否不同: 八个生成 harness 加上 single-call, 对照九个逐字节相同的基线槽位。每个成员进行三次新执行, 用其中两次发现逐任务选择, 再用第三次验证。同代码臂测量这套过程在没有程序专长时会报告什么。随后, 在同一面板上冻结于开发任务的选择器检验题目特征能否支持选择, 等执行次数的 oracle 重放则比较可获得覆盖。最后, BIRD 轨迹检查源码差异是否真正进入执行, 提供 SQL 场景中的补充诊断。

证据带来三项认识。**第一**, 相同程序也产生正的重复平均 oracle 余量, 因此这一信号本身不能识别程序专长。**第二**, 生成程序的评分结果模式比克隆明显更可重复, 但持续差异以损失为主: 持续输给基线的情况涉及 100 道题 (570 个成员—任务对), 持续获胜仅出现在一道题上。稳定差异因而未必提供有用的任务优势; 克隆校正留出增益为 -0.26 个百分点。**第三**, 冻结选择器收益为 0.00 个百分点, 执行 27 次时两臂 oracle 重放均为 98.70%。在这一面板上, 更多程序既没有为所测选择器带来收益, 也没有使完整预算下的 oracle 覆盖超过基线的更多次执行。

2 相关工作

自动化智能体与 harness 设计。 ADAS 将智能体程序作为搜索空间 (Hu et al., 2024)。Self-Harness 从轨迹中挖掘失败, 提出针对性修改, 并在回归测试后保留修改 (Zhang et al., 2026b); TTHe 则在评估期间利用无标签轨迹调整可执行 harness (Nie et al., 2026)。其他系统改进任务适配与验证资源分配 (Zhang et al., 2026a; Miyai et al., 2026),

或通过验证、诊断、定位和策略演化使 harness 行为可观测、可编辑 (Xu et al., 2026; Chen et al., 2026a; Lin et al., 2026; Luo et al., 2026; Wang et al., 2026; Chen et al., 2026b)。El et al. (2025) 发现，所研究的自动设计智能体在逐题评分模式上的多样性较低。本文区分程序群体结果的两种解释：不同程序可能执行相同行为，相同程序也可能产生不同结果。轨迹检查判断所提机制是否实际执行；同代码重复对照则隔离不改变程序即可获得的覆盖。这把程序等价与变异测试 (Budd & Angluin, 1982; Papadakis et al., 2019) 连接到生成 harness 群体的性能归因。

重复采样与集成。 Pass@ k 衡量 k 次采样中至少一次成功的概率；自一致性与相同智能体的集成则聚合多次尝试 (Chen et al., 2021; Wang et al., 2022; Li et al., 2024)；名义温度为 0 的调用也可能变化 (Ouyang et al., 2023)。本文将这些采样收益作为执行预算匹配时评估生成程序互补的显式参照。执行后的验证器对候选解排序 (Kwok et al., 2026)，集成选择则在验证集上选定模型组合，并在推理时平均其预测 (Caruana et al., 2004)。两者都评估或组合已生成的输出，而本文的选择器在程序执行前作出选择。本文的 oracle 重放与冻结选择器保留了这一差别。

选择与资源配置。 HELIX 利用同一群体中不同 harness 的互补轨迹扩展经验证的覆盖，并为后续模型改进提供数据 (Fan & Huang, 2026)。STS 比较六种推理范式，训练基于嵌入的路由器，以实现部分 oracle 收益 (Zhou et al., 2026)。本文固定目标模型，评估生成程序，并区分 oracle 覆盖、跨重复稳定的逐题优势与实际选择收益；同代码群体为这一区分提供采样参照。模型-问题组合间的 harness 敏感性 (Gupta et al., 2026)、所评估模型间的 harness 敏感性 (Cho, 2026)、搜索路由 (Kim, 2026) 和基于偏好训练的模型路由 (Ong et al., 2024)，将该问题连接到算法选择与组合求解 (Rice, 1976; Xu et al., 2008; Kotthoff, 2014)。GRASP 则在新增错误约束下选择对有界技能库的编辑 (Moll et al., 2026)。定量交互与定性交互的区别 (Gail & Simon, 1985) 解释了为什么效应大小变化未必改变最佳动作。本文的贡献是在同一程序群体中测量上述三种量，并揭示它们在何处出现分离。

3 问题定义

一个群体可以提供额外正确答案，却不包含任务专家；任务专家也可以存在，却没有有效的选择器。下面先形式化这些区别，再介绍相应对照。设群体 P 包含基线 H_0 ， $Y(h, x, r) \in \{0, 1\}$ 表示成员 h 在任务 x 的第 r 次重复中是否答对。准确率和频率使用%，增益与余量使用百分点 (pp)：成功概率差 0.04145 经舍入报告为 4.15 个百分点。

覆盖：是否存在额外正确答案？ 单次 oracle 在看到正确性后选择成员。它相对记录矩阵中最佳固定成员的余量为

$$H(P) = \frac{1}{n} \sum_{i=1}^n \max_{h \in P} Y(h, x_i, r) - \max_{h \in P} \frac{1}{n} \sum_{i=1}^n Y(h, x_i, r). \quad (1)$$

这衡量可获得的答案，也包含重复采样带来的成功。重复平均插件估计 $\hat{H}$ 将 Y 替换为各成员一任务的均值。重复较少时，对均值取最大值仍可能选择有利的估计误差，因此 $\hat{H} > 0$ 本身不是专长证据。

稳定互补：最佳成员是否随任务改变？ 为在概念上排除执行噪声，令 $p_h(x) = \Pr\{Y(h, x, r) = 1\}$ 表示固定执行条件下的成功概率，并定义 $H_{\text{stable}} = \mathbb{E}_x \max_h p_h(x) - \max_h \mathbb{E}_x p_h(x)$ 。对两个成员，记 $\Delta(x) = p_1(x) - p_0(x)$ ，则

$$H_{\text{stable}} = \frac{1}{2}(\mathbb{E}|\Delta(x)| - |\mathbb{E}\Delta(x)|). \quad (2)$$

若一个成员处处更好，即使优势大小随任务变化，该式仍为零。正的互补要求任务优势发生交叉。同一条件下的相同程序具有相同 $p_h(x)$ ，因而稳定互补为零。这个总体恒等式说明要测什么，并不能从少量执行中直接估计未知的成功概率。

可用选择：优势能否指导决策？ 选择器 π_Z 必须在看到结果前，根据任务特征 $Z(x)$ 作出选择。即使交叉优势稳定存在，也未必能从这些特征预测。根据同一道题过去的结果学习选择，检验的是跨重复泛化，使用的信息不同。本文分别评估二者。实际资源分配还要求进一步比较：相对一次固定执行的选择收益，应与相同预算、相同答案选择规则下增加固定程序执行次数的效果比较。相同 harness 执行次数并不保证相同模型调用数或 token 消耗。

4 实验设计

4.1 HARNESS 群体与评估设置

构建器编写 Python harness，目标求解器回答程序发出的模型调用，外部评分器判定最终输出。所报告的比较使用 GLM-5.3-Flash（附录 A.3）。每个 harness 实现 `solve(question)`，通过 `self.llm` 调用模型；BIRD 还通过 `self.execute` 提供数据库结构与 SQL 反馈。标准答案仅对评分器可见。single-call 基线执行一次温度为 0 的调用。生成程序可以改变提示、解码、采样次数与控制流；这些设置决定各成员的计算过程与采样行为。表 1 说明各项研究的任务。

MATH 群体与面板抽取。 六个构建器为 GLM-5.3、Qwen3.8-Max、DeepSeek-V4-Pro、Kimi-K3、MiniMax-M3 和 ERNIE-5.0-Thinking-Preview，每个在一个种子下获得八个槽位。每个槽位是独立的生成机会，并非指定策略。提示要求改进单次贪心调用，程序结构由构建器自行设计，不施加跨槽位多样性约束。重试复用相同提示，不反馈前次代码或评估结果。每槽最多尝试三次（温度 0.7，每次最多 32,768 个输出 token），在首个程序通过解析、导入、接口及两道开发题的非空答案检查后停止。48 个槽位得到 35 个冻结程序，用于后续评估。附录 A.1 概述构建器指令和接口约束。

重复面板按历史平均调用次数不超过 3.05 的条件保留 21 个合格成员，再由固定加盐哈希选择每个构建器一个席位和两个自由席位。这偏向低调用程序。所选源码包含起草—检查—修订、一致性检查和采样投票；逐项清单见附录 A.2。加入 single-call 后共九

研究	程序	评估	回答的问题
MATH 探索	35 个生成程序 + single-call	386 题; 单次运行	是否存在错误覆盖?
MATH 重复对照	8 个生成程序 + single-call, 对照 9 个克隆	同一批 386 题; 3 次新重复	选择能否跨重复迁移?
BIRD 发现	12 个生成程序 + single-call + react	60 题; 单次运行	什么机制实际执行?
BIRD 准入	6 个构建器 $\times$ 3 个种子 $\times$ 4 个臂	主比较 1,169 题; 全臂 400 题	筛选是否改变覆盖?

表 1: 每项研究支持不同的判断。单次运行指每个成员一任务对执行一次。MATH 重复面板从探索性群体中抽取。BIRD 提供独立的执行与准入证据, 各项研究分别报告效应。

个成员。该面板与九个相同基线槽均进行三次新执行, 关闭缓存, 解码设置由各成员源码固定。

本文使用 MATH-500 (Lightman et al., 2023) 中的 100 道开发题与同一批 386 道评估分析题。该分析集在采集后按完整观测条件确定: 两臂全部重复和单次评估群体均有评分; 14 道重复观测不完整的题被排除。本文所有 MATH 主比较使用相同题目身份, 分析集内评分单元观测完整率为 100%。重复研究在这些任务上进行新执行。排除情况见附录 B。评分器抽取最终答案, 优先使用所要求的 ##### 行; 两端均可解析为数值时比较数值, 否则比较规范化 LaTeX。比较器及其审核详见附录 A.1。

BIRD 发现与准入。 BIRD (Li et al., 2023) 要求根据问题与数据库生成 SQL。TTHE 的 proposer 使用 GLM-5.3-Flash 构建器产生 12 个发现候选, 经导入与冒烟执行检查准入, 与两个自带基线在 60 题上评估。独立的准入研究交叉自由 / 指定策略与无门控 / 合规门控, 使用六个构建器、三个种子、每臂八个槽位。每槽最多三次尝试 (温度 0.7, 16,384 个输出 token)。指定策略包括执行修复、三次采样投票及 schema linking。所有臂均要求接口有效、SQL 非空; 门控臂额外检查机制合规, 并排除部分结构。

准入研究保留两个数据库的 365 题用于开发, 九个数据库的 1,169 题用于评估; 四臂共用预先抽取的 400 题核心集。一次 18 题冒烟测试是已披露的开发暴露例外。预测与标准查询的结果由官方行集评分器比较, 超时为 30 秒, 执行失败计零。发现研究则使用较早的字符串化行代理, 并限制返回行数。准入采集使用共享响应缓存, MATH 重复执行则关闭缓存。这些条件及门控干预的捆绑性质保留于附录 E.1 和 F。

4.2 同代码对照与重复验证

同代码槽位分离额外采样的解释。 增加成员同时增加了代码和尝试次数。因此, 我们将九个不同成员与九个逐字节相同的 single-call 槽位比较, 每个槽位在每道题上执行三次。后者保留随机结果产生的机会, 同时去掉程序专长, 构成等能力参照。

留出重复将发现与验证分开。若用同一批结果挑选一道题的最佳程序，再用这些结果验证它，就会重复利用偶然成功。我们改为三折重复交叉拟合：每折用两次发现重复冻结任务成员映射与一个最佳固定成员，再用第三次重复测量二者的准确率差。跨折平均得到 G_{real} 与 G_{clone} ；固定比较对象按发现重复的准确率选出。随后在两臂共同完整的任务上比较：

$$D = G_{\text{real}} - G_{\text{clone}}. \quad (3)$$

这里相减的是配对任务层面的增益。它检验：根据过去结果作出的选择，迁移至另一次执行时，不同程序是否比相同程序更有优势。该诊断衡量同一批评估题上的跨重复迁移。

完整观测与灵敏度决定如何解释结果。 全部主分析量，包括两臂描述性插件量和交叉拟合增益，均使用同一批 386 个完整任务。每臂观测到 10,422/10,422 个成员—任务—重复评分单元，完整率为 100%；所有估计均使用记录中的二元评分。原始采集覆盖门槛在取子集前检查并通过：不完整题目占 3.50%，低于 10% 上限。包括 $D > 1$ pp 在内的正效应检查和至少 30 个配对任务的要求均不变。已知真值模拟检验重复次数的灵敏度。附录 B 说明分析集纳入条件；附录 C 给出规则、并列处理、不确定性和敏感性分析。采集协议在采集前固定，v3 程序及共同完整集分析在之后确定。

补采集快照与探索性可重复性。 本文分析附录 B 所记录时间点的补采集快照，程序、求解器、任务与重复次数保持固定。另检验去除成员与任务加性效应后的跨重复相关性。这一探索性相关量衡量残差评分模式的可重复性， G 则衡量留出选择增益；构造与评分细节见附录 B.1。

4.3 冻结选择与等执行次数重放

执行前的特征选择。 重复诊断使用同一任务过去的结果，实际选择器则必须在看到答案前作出选择。我们在 100 道开发题上训练 π_Z ，使用 TF-IDF 题目特征与仅在训练折内计算的成员准确率，并采用任务级五折交叉验证：问题的重复始终留在同一折。策略在评估前冻结；选择前对五个折模型的概率向量取平均，并列按固定成员 ID 顺序处理，前两名概率差小于 0.15 时回退至 single-call。其输入由题目特征与开发集导出的成员统计量组成。比较对象包括开发集选出的固定成员与预先随机抽取后固定使用的成员。

执行后的 oracle 重放。 另一次离线比较为按开发集表现排序的成员组合与克隆臂分配相同的执行次数 $b \in \{3, 9, 15, 27\}$ 。每个入选成员贡献三次重复；克隆参照取其 27 次记录执行的子集。两臂均在执行后使用正确性作 oracle 选择，衡量可获得的覆盖。一次 harness 执行可以包含多次模型调用，模型调用数与 token 成本随程序而异。附录 D 给出冻结策略、重放和账目细节。

补采集分析保持此前记录的选择器决策与组合排序不变。重放只使用两臂均完整的任务，对克隆子集的均匀平均作精确计算，组合成员沿用记录中的开发集排序。

5 结果

5.1 生成群体的单次覆盖

我们先考察生成群体是否包含最佳固定成员之外的正确答案。全部 35 个获准生成成员与 single-call 在同一批 386 道分析题上均有一次完整评分，共观测到 13,896/13,896 个单元。其并集达到 99.22% oracle 覆盖，而最佳固定成员 single-call 为 95.08%。每个生成成员单独都更差 (69.69–92.49%)。由此得到的 4.15 pp 余量量化了执行后 oracle 可获得的额外正确答案。

这些结果确有差异：36 个正确性向量中有 29 个唯一向量，平均成对分歧为 10.94% (最大 33.16%)，并集修复基线错误的 84.21%。这些量描述群体中可获得的正确答案。重复研究在同一批 386 题上将选定程序面板与同代码对照比较； D 衡量面板相对克隆的留出选择增益，新执行的基线均值为 95.85%。完整群体余量与面板估计分别描述各自的程序群体和执行 (附录 A.1)。

5.2 相同程序也产生正的 ORACLE 估计

九个克隆槽位实现相同程序，其总体层面的稳定互补按构造为零。在同一批 386 个任务上，克隆的重复平均 oracle 估计为 2.16 pp，生成面板为 2.33 pp (表 2)。两者使用完全相同的题目身份及完整观测。这一对照确立：平均三次重复，仍不足以让正的 oracle 估计识别程序专长。

量	生成面板 + single-call	同代码克隆
完整任务 oracle 估计 $\hat{H}$	2.33 pp	2.16 pp
重复诊断 G 的完整任务数	386	386
留出重复平均增益 G	0.10 pp	0.35 pp
评分模式残差相关性	0.789	0.006
配对克隆校正均值： $D = -0.26$ pp，基于 386 题		
分析集完整率：两臂均 100%，每臂 10,422 个单元		

表 2: 覆盖、可重复性和选择收益相互分离。所有量均使用同一批 386 题，两臂在该分析集上均完整观测。 D 是未舍入交叉拟合增益的配对差，显示值的舍入可能影响直接相减。

5.3 可重复评分模式与留出选择增益

生成程序确实呈现可重复的差异。探索性分析从评分优势矩阵中去除成员与任务的加性效应，再计算每个留出重复与其余两次重复均值的相关性。生成程序的平均残差相关性为 0.789，克隆为 0.006；配对 bootstrap 差异为 0.783，95% 区间为 [0.69, 0.87]。这些相关性描述可重复的评分结果模式。为考察其方向，我们统计持续输赢：三次重复均输给 single-call 的情况涉及 100 道题 (570 个成员—任务对)；三次均获胜则只出现在

一道题上，由八个生成成员共同实现。这一表面修复对答案格式提取敏感（附录 B.1）。这种观测不对称性解释了强评分可重复性与有限的观测获胜如何并存。

留出选择诊断检验更强的问题：过去的结果能否为下一次执行识别有用的成员？克隆校正均值为 $D = -0.26$ pp，95% 区间为 $[-1.45, 0.95]$ pp，随机化 $p = 0.8127$ 。主分析任务均完整观测，但判断仍为 INSUFFICIENT EVIDENCE（证据不足）：区间包含零，未满足正向支持条件，也未建立等效结论。排除包含冲突评分的三道纳入题后，在 383 个配对任务上得到 $D = -0.61$ pp，判断不变（附录 B）。

如果存在真实交叉，诊断能检出吗？ 已知真值校准量化诊断的灵敏度。在所测 100 单元网格上，最坏的观测零假设错误支持率为 2%；但真实 $H_{\text{stable}} = 17.5$ pp 的双专家设置在 $R = 3$ 时功效为 0%， $R = 5$ 时约为 0.7%， $R = 10, 20$ 时为 100%。更小的循环交叉即使在 $R = 20$ 时仍大多检不出（附录表 7）。这些都是具体设置下的经验结果。因此，数据识别出了可重复评分模式，有用的任务交叉优势仍未判清。实际执行前选择的效果则仍可直接评估。

5.4 执行前选择与 ORACLE 重放

冻结选择器与开发集选出的基线持平。 特征策略在应用置信度回退规则后，最终在全部 386 道评估题上选择 single-call。这里评估完整决策规则；报告的最终选择不区分分类器初始偏好和回退决定。保持选择不变、仅更新记录结果后，三次重复的准确率为 95.85%，与开发集选出的固定成员完全相同：所测策略与特征的增益为 0.00 个百分点。附录 D 给出其构造与同一分析集上的比较器结果。

完整执行预算下，两臂 oracle 覆盖持平。 在两臂均完整的 386 个任务上，比较按开发集排序的程序组合与均匀抽取的同代码执行。在 $b = 3$ 时，组合只包含 single-call，其 +0.20 pp 差异反映相同程序之间的执行变动。在 $b = 9$ 和 15 时，差异分别为 +0.08 pp 与 +0.02 pp。在 $b = 27$ 时，两臂的 oracle 覆盖均为 98.70%（表 3）。

Harness executions per task b	3	9	15	27
Panel members, including single-call	1	3	5	9
Panel oracle coverage (%)	98.45	98.70	98.70	98.70
Clone oracle coverage (%)	98.24	98.63	98.69	98.70
Panel minus clones (pp)	+0.20	+0.08	+0.02	+0.00

Differences are computed before rounding the displayed coverage values.

表 3: 在观测到的补采集快照中，完整预算下的 oracle 覆盖相同。每个入选成员贡献三次重复；克隆覆盖是从记录的 27 次执行中均匀抽取子集的精确均值，并在共同完整任务上配对。两臂在相同 harness 执行次数下使用执行后正确性。

这些重放均值描述相同 harness 执行次数下的执行后 oracle 覆盖。模型调用数和 token 成本随程序而异。所测执行前选择器的增益为零，完整的记录执行预算则为两臂提供了相同的 oracle 覆盖。

5.5 实际执行行为的补充分析

MATH 对照表明，结果不同未必需要程序不同。补充的 BIRD 研究考察反方向的问题：不同源码是否真正产生不同且有用的执行行为？这里的机制指已实现的提示变换、工具使用或控制流操作。BIRD 研究在独立程序群体上，使用任务对应的评分与执行协议，直接检查执行行为。

代码差异与观测结果。 所有 12 个发现候选都通过代码差异检查，但 66 个生成候选对中有 21 对的正确性向量相同；计入基线时为 36/91，源码相似度与正确性分歧的秩相关为 $\rho = -0.010$ 。这些 60 题上的一致促使我们直接检查执行（附录图 2）。

轨迹定位三种不同的失败。 **T1：描述了但没有实现。** 12 个候选中的 6 个在文档中宣称检索或自检，实际只有一次模型调用且不执行产物。这是对全部十二个候选的分类；五个 harness 的轨迹审核提供具体样例。**T2：存在但未触发。** 全部 10 道已审 `react` 任务的第一次 SQL 均执行成功，修复分支从未触发，最终 SQL 与 `single-call` 相同；执行成功不代表语义正确。**T3：执行了但输出失败。** 一个候选执行多轮修复，却把自然语言说明作为最终 SQL，丢失了基线答对的任务。三者分别要求实现检查、能触发分支的任务和有效的输出契约。附录 E 保留完整样例、人工控制及其开发暴露限制。

独立的 BIRD 准入研究还发现，强制策略加门控相对自由无门控的平均余量差为 -0.16 pp。该门控捆绑了结构排除与合规验证（附录 F）。这些结果共同定位了从源码变化到机制实现、触发与有效输出之间的失败环节；可重复的任务优势与选择价值则测量证据链的后续环节。

6 讨论与局限

对评估的启示。 本文区分了三种容易被当作同类证据的观察：相同程序产生正的 oracle 余量；生成程序产生可重复的评分模式；冻结选择器却没有获得收益，完整预算下 oracle 覆盖也持平。因此，有用专长的主张需要将可重复的优势、任务交叉与可用选择规则连接起来，生成面板的持续损失涉及 100 道题，持续获胜仅出现在一道题上；可重复结构主要刻画程序在哪里失分，而非选择器在哪里获益。若将优势归因于某种机制，则轨迹需要说明实际执行了什么，干预需要检验其贡献。

局限。 受控 MATH 面板是在一个求解模型、已评估任务上抽取的低调用程序。修订的留出重复过程和新增可重复性分析均在采集后形成。初始研究按其停止规则结束；另行记录的补采集阶段发生在查看早期结果之后，并保持程序、任务、求解器和重复次数不变。386 题分析集按完整性筛选，集内观测完整。被排除的 14 道题观测难度更高、基线准确率更低（附录 B），因此性能估计描述所选题集。三次重复的诊断功效较低，稳定评分模式还可能包含固定评分器的格式效应。校准结果保持 INSUFFICIENT EVIDENCE（证据不足）。零路由收益对应所测选择器与特征。重放统一 harness 执行次数，模型调用数和 token 成本随程序而异。BIRD 发现适用于其自身的评分与采集条件。

7 结论

对所测 MATH 面板，完整执行预算下更多程序没有超过更多次采样：执行 27 次后，两臂 oracle 覆盖均为 98.70%，冻结特征选择器的收益为 0.00 个百分点。生成程序仍表现出很强的评分模式可重复性，但持续损失涉及的任务远多于持续获胜。同代码对照、重复执行和冻结选择器区分了三个不同的量：可获得正确答案、可重复差异以及可用任务优势。有用专长要求最后一项，即能够指导选择、并优于增加固定程序执行次数的优势。

伦理声明

全部实验使用公开的 BIRD 与 MATH-500 基准数据及生成的程序产物；不涉及人类被试、私人记录或个人身份信息。模型调用作为实验来源的一部分报告，论文不发布凭据或会暴露私人数据的提供方响应。主要伦理风险是夸大单次运行 oracle 增益对部署路由的含义；因此我们把未解决的选择与成本命题明确报告为 INSUFFICIENT EVIDENCE（证据不足）。

可复现性声明

本文说明所报告结果的程序群体、任务划分、执行条件、评分规则、统计过程与敏感性分析。附录补充协议细节、校准结果和具体样例。审稿材料通过这些方法描述、表格与样例呈现方法和实证证据。

AI 使用声明

本研究按构造就是一个借助 AI 研究 AI 生成产物的项目，以下精确披露 AI 协助的范围。

必要披露。生成式 AI 工具用于：(i) 编写和修改实验代码（生成流程、评估采集器、统计分析脚本）；(ii) 运行涉及模型 API 调用的实验流程；(iii) 分析实验数据并制作表格和图；(iv) 起草和修改论文文字。修订后的主分析表、析因表和结果图由共同的版本化重分析产物生成。历史探索性分析保留各自原始来源与所述局限。审后修正与原协议分开记录。验证记录分别说明各产物的自动测试、开发控制与审核范围。审后修订也使用同模型子代理进行机械检查，并辅以开发控制和本机运行测试。

研究构思与方向。核心研究问题、因果设计决策（估计目标、对比、排除规则）、解释标准及拟议的继续 / 停止准则在 AI 协助下形成。人类作者确定总体研究方向并要求按审稿意见修订；AI 工具也提出分析与实验设计、识别反例并实施修订。最终科学决策及投稿批准仍由作者负责。

责任。作者对本研究最终内容承担责任，包括借助生成式 AI 产出的文字、主张和产物。作者已复核上述披露及最终文稿，并对其准确性负责。

REFERENCES

- Timothy A. Budd and Dana Angluin. Two notions of correctness and their relation to testing. *Acta Informatica*, 18(1):31–45, 1982. doi: 10.1007/bf00625279.
- Rich Caruana, Alexandru Niculescu-Mizil, Geoff Crew, and Alex Ksikes. Ensemble selection from libraries of models. In *Proceedings of the 21st International Conference on Machine Learning*, 2004. doi: 10.1145/1015330.1015432.
- Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*, 2021. doi: 10.48550/arXiv.2107.03374. URL <https://arxiv.org/abs/2107.03374>.
- Mengzhuo Chen, Junjie Wang, Zhe Liu, Yawen Wang, Haiming Zheng, and Qing Wang. From failed trajectories to reliable LLM agents: Diagnosing and repairing harness flaws. *arXiv preprint arXiv:2606.06324*, 2026a. doi: 10.48550/arXiv.2606.06324. URL <https://arxiv.org/abs/2606.06324>.
- Mingju Chen, Can Lv, Guibin Zhang, Heng Chang, and Shiji Zhou. HarnessForge: Joint harness and policy evolution for adaptive agent systems. *arXiv preprint arXiv:2606.01779*, 2026b. doi: 10.48550/arXiv.2606.01779. URL <https://arxiv.org/abs/2606.01779>.
- Yong-eun Cho. It’s not the capability: Harness sensitivity is non-monotone across LLM agent tiers. *arXiv preprint arXiv:2605.26731*, 2026. doi: 10.48550/arXiv.2605.26731. URL <https://arxiv.org/abs/2605.26731>.
- Batu El, Mert Yuksekgonul, and James Zou. Inefficiencies of meta agents for agent design. *arXiv preprint arXiv:2510.06711*, 2025. doi: 10.48550/arXiv.2510.06711. URL <https://arxiv.org/abs/2510.06711>.
- Tianyu Fan and Chao Huang. HELIX: Model-harness co-evolution for recursive self-improvement. *arXiv preprint arXiv:2608.13951*, 2026. doi: 10.48550/arXiv.2608.13951. URL <https://arxiv.org/abs/2608.13951>.
- Mitchell H. Gail and Richard Simon. Testing for qualitative interactions between treatment effects and patient subsets. *Biometrics*, 41(2):361–372, 1985. doi: 10.2307/2530862.
- Akshat Gupta, Jermaine Lei, Alexander Lu, Gopala Anumanchipalli, and Leshem Choshen. Automated discovery has no universally superior harness. *arXiv preprint arXiv:2607.18235*, 2026. doi: 10.48550/arXiv.2607.18235. URL <https://arxiv.org/abs/2607.18235>.

- Shengran Hu, Cong Lu, and Jeff Clune. Automated design of agentic systems. *arXiv preprint arXiv:2408.08435*, 2024. doi: 10.48550/arXiv.2408.08435. URL <https://arxiv.org/abs/2408.08435>.
- Minho Kim. When should LLMs search? counterfactual supervision for search routing. *arXiv preprint arXiv:2607.05752*, 2026. doi: 10.48550/arXiv.2607.05752. URL <https://arxiv.org/abs/2607.05752>.
- Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(3):48–60, 2014. doi: 10.1609/aimag.v35i3.2460.
- Jacky Kwok, Shulu Li, Pranav Atreya, Yuejiang Liu, Yixing Jiang, Chelsea Finn, Marco Pavone, Ion Stoica, and Azalia Mirhoseini. LLM-as-a-verifier: A general-purpose verification framework. *arXiv preprint arXiv:2607.05391*, 2026. doi: 10.48550/arXiv.2607.05391. URL <https://arxiv.org/abs/2607.05391>.
- Jinyang Li, Binyuan Hui, Ge Qu, Jiaxi Yang, Binhua Li, Bowen Li, Bailin Wang, Bowen Qin, Ruiying Geng, Nan Huo, Xuanhe Zhou, Chenhao Ma, Guoliang Li, Kevin Chang, Fei Huang, Reynold Cheng, and Yongbin Li. Can LLM already serve as a database interface? a BIG bench for large-scale database grounded text-to-SQLs. In *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, volume 36, pp. 42330–42357, 2023. doi: 10.52202/075280-1835. URL https://proceedings.neurips.cc/paper_files/paper/2023/hash/83fc8fab1710363050bbd1d4b8cc0021-Abstract-Datasets_and_Benchmarks.html.
- Junyou Li, Qin Zhang, Yangbin Yu, Qiang Fu, and Deheng Ye. More agents is all you need. *arXiv preprint arXiv:2402.05120*, 2024. doi: 10.48550/arXiv.2402.05120. URL <https://arxiv.org/abs/2402.05120>.
- Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by step. *arXiv preprint arXiv:2305.20050*, 2023. doi: 10.48550/arXiv.2305.20050. URL <https://arxiv.org/abs/2305.20050>.
- Jiahang Lin, Shichun Liu, Chengjun Pan, Lizhi Lin, Shihan Dou, Zhiheng Xi, Xuanjing Huang, Hang Yan, Zhenhua Han, Tao Gui, and Yu-Gang Jiang. Agentic harness engineering: Observability-driven automatic evolution of coding-agent harnesses. *arXiv preprint arXiv:2604.25850*, 2026. doi: 10.48550/arXiv.2604.25850. URL <https://arxiv.org/abs/2604.25850>.
- Xiaotian Luo, Dizhan Xue, Fengxingyu Wang, Chuanrui Hu, and Yafeng Deng. HarnessBank: Semantic gene-bank search with gated verification for agent-harness self-evolution. *arXiv preprint arXiv:2607.13683*, 2026. doi: 10.48550/arXiv.2607.13683. URL <https://arxiv.org/abs/2607.13683>.

- Atsuyuki Miyai, Kiyoharu Aizawa, and Toshihiko Yamasaki. Task-CoEvolve: Efficient harness optimization via adaptive validation task selection. *arXiv preprint arXiv:2608.20169*, 2026. doi: 10.48550/arXiv.2608.20169. URL <https://arxiv.org/abs/2608.20169>.
- Johannes Moll, Jean-Philippe Corbeil, Jiazhen Pan, Martin Hadamitzky, Daniel Rueckert, Lisa Adams, and Keno Bressem. GRASP: Gated regression-aware skill proposer for self-improving LLM agents. *arXiv preprint arXiv:2605.29668*, 2026. doi: 10.48550/arXiv.2605.29668. URL <https://arxiv.org/abs/2605.29668>.
- Jun Nie, Yonggang Zhang, Jun Song, Qianshu Cai, Dahai Yu, Yike Guo, Xinmei Tian, and Bo Han. TTHE: Test-time harness evolution. *arXiv preprint arXiv:2607.08124*, 2026. doi: 10.48550/arXiv.2607.08124. URL <https://arxiv.org/abs/2607.08124>.
- Isaac Ong, Amjad Almahairi, Vincent Wu, Wei-Lin Chiang, Tianhao Wu, Joseph E. Gonzalez, M Waleed Kadous, and Ion Stoica. RouteLLM: Learning to route llms with preference data. *arXiv preprint arXiv:2406.18665*, 2024. doi: 10.48550/arXiv.2406.18665. URL <https://arxiv.org/abs/2406.18665>.
- Shuyin Ouyang, Jie M. Zhang, Mark Harman, and Meng Wang. An empirical study of the non-determinism of ChatGPT in code generation. *arXiv preprint arXiv:2308.02828*, 2023. doi: 10.48550/arXiv.2308.02828. URL <https://arxiv.org/abs/2308.02828>.
- Mike Papadakis, Marinos Kintis, Jie Zhang, Yue Jia, Yves Le Traon, and Mark Harman. Mutation testing advances: an analysis and survey. In *Advances in Computers*, volume 112, pp. 275–378. Elsevier, 2019. doi: 10.1016/bs.adcom.2018.03.015.
- John R. Rice. The algorithm selection problem. In *Advances in Computers*, volume 15, pp. 65–118. Elsevier, 1976. doi: 10.1016/s0065-2458(08)60520-3.
- Ruhan Wang, Yucheng Shi, Zongxia Li, Zhongzhi Li, Yue Yu, Junyao Yang, Kishan Panaganti, Haitao Mi, Dongruo Zhou, and Leoweiliang. Harness handbook: Making evolving agent harnesses readable, navigable, and editable. *arXiv preprint arXiv:2607.13285*, 2026. doi: 10.48550/arXiv.2607.13285. URL <https://arxiv.org/abs/2607.13285>.
- Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc V. Le, Ed H. Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. Self-consistency improves chain of thought reasoning in language models. *arXiv preprint arXiv:2203.11171*, 2022. doi: 10.48550/arXiv.2203.11171. URL <https://arxiv.org/abs/2203.11171>.
- Jinghan Xu, Yikai Zhang, Aili Chen, Weiyuan Li, Jiaqing Liang, and Deqing Yang. Verify smarter, evolve further: Efficient harness evolution through behavior-aware

verification. *arXiv preprint arXiv:2608.27311*, 2026. doi: 10.48550/arXiv.2608.27311. URL <https://arxiv.org/abs/2608.27311>.

Lin Xu, Frank Hutter, Holger H. Hoos, and Kevin Leyton-Brown. SATzilla: Portfolio-based algorithm selection for SAT. *Journal of Artificial Intelligence Research*, 32: 565–606, 2008. doi: 10.1613/jair.2490.

Guibin Zhang, Leo Lu, Fangzhou Xie, Kang Zhu, Junhao Wang, Zhifei Xie, Zhaochen Yu, Zihang Liu, Zhongxiang Sun, Qiankun Li, Yue Liao, Heng Chang, Xiaobin Hu, Qibing Ren, Wangchunshu Zhou, Chuanrui Hu, Yafeng Deng, and Shuicheng Yan. JIT-Agent: Scaling harness intelligence via just-in-time harness evolution. *arXiv preprint arXiv:2608.25593*, 2026a. doi: 10.48550/arXiv.2608.25593. URL <https://arxiv.org/abs/2608.25593>.

Hangfan Zhang, Shao Zhang, Kangcong Li, Chen Zhang, Yang Chen, Yiqun Zhang, Lei Bai, and Shuyue Hu. Self-harness: Harnesses that improve themselves. *arXiv preprint arXiv:2606.09498*, 2026b. doi: 10.48550/arXiv.2606.09498. URL <https://arxiv.org/abs/2606.09498>.

Heng Zhou, Zelin Tan, Zhemeng Zhang, Yutao Fan, Yibing Lin, Li Kang, Xiufeng Song, Rui Li, Songtao Huang, Ao Yu, Yuchen Fan, Yanxu Chen, Kaixin Xu, Xiaohong Liu, Yiran Qin, Philip Torr, Chen Zhang, and Zhenfei Yin. Select-then-solve: Paradigm routing as inference-time optimization for LLM agents. *arXiv preprint arXiv:2604.06753*, 2026. doi: 10.48550/arXiv.2604.06753. URL <https://arxiv.org/abs/2604.06753>.

附录阅读导航

附录记录支撑当前主张的研究对象、重复与选择方法、校准及 BIRD 证据。早期生成试验、被替代的统计程序、门控开发迭代和历史 BIRD 子集选择分析不属于本稿范围，其记录继续保留在项目档案中。当前分析的修订与局限随相应研究保留。

A Harness 生成、程序清单与数据划分。

B 同代码对照与重复执行协议。

C 统计分析、校准与灵敏度。

D 冻结选择器与等执行次数重放。

E BIRD 执行轨迹与补充分析。

F BIRD 准入策略研究。

A HARNESS 生成、程序清单与数据划分

本附录先给出主研究的程序来源、任务划分与冻结面板，再列模型版本。BIRD 的发现与准入协议分别见附录 E 和 F。

A.1 MATH 群体、共同分析集与覆盖

单次研究提供初始覆盖证据以及重复面板的程序来源。它把 BIRD 准入研究的无门控自由生成方案用于竞赛数学，并采用领域特定答案比较器。

协议与分析集。 构建器任务可概括为以下结构化指令（并非原提示逐字引用）：编写实现 `solve(question)` 的 Python harness；通过 `self.llm` 改进单次贪心调用；自行选择提示、解码、采样与控制流；使用要求的 `####` 标记返回数学最终答案。标准答案仅属于外部评分器。槽位不指定机制，也不施加跨程序多样性目标。多次尝试使用相同指令，不输入前次候选代码或性能反馈。准入检查接口有效性和输出非空，不要求准确率提升。

六个构建器在一个种子下各有八个槽位，每槽至多三次原始尝试。中性有效性门控在两道开发题上检查解析、导入、接口及非空答案。冻结目标为 GLM-5.3-Flash，解码由各成员定义，single-call 温度为 0。原始任务划分在生成前确定，保留 100 道开发题。最终评估分析在单次群体、两臂重复与冻结政策评分中统一使用同一批 386 道完整观测题。该集合在采集后按完整性确定，排除 14 道不完整题（附录 B）。开发题及冻结选择器保持不变。

评分器在两端均可解析为数值时比较数值（含分数与小数），否则比较规范化 LaTeX。归一化去除单位、进制下标和度数符号，保留文本命令内容，并将矩阵转换为元组。所要求的最终答案标记为 `####`。给每个标准答案加上该标记后，386/386 次自比较均判对；这验证了这些标准答案的格式一致性。分析集上的单次基线准确率为 95.08%。

有效性门控接纳 35/48 个槽位。两个重推理构建器 GLM-5.3 与 Qwen3.8-Max 在多数槽位发出代码前即耗尽 32k token 生成预算，使这些构建器风格在固定生成预算下的代表性不足。本探索性研究在一个种子下评估自由生成与中性有效性准入。

共同完整集上的结果。 包含 single-call 在内的全部 36 个成员在 386 题上各有一次记录评分，共 13,896/13,896 个单元。平均成对分歧为 10.94%（最大 33.16%）。唯一成员结果向量为 29/36（生成向量为 28/35），2.22% 的成员对结果相同。生成候选并集修复基线错误的 84.21%，并在 0.82% 的基线正确题上全部失败。后者衡量全部生成成员均失败的题目占基线正确题的比例。Oracle 覆盖为 99.22%，最佳固定成员 single-call 为 95.08%，余量为 4.15 个百分点。生成成员准确率介于 69.69% 与 92.49%。

新重复面板使用八个生成成员加 single-call，对照九个同代码槽位，题目身份完全相同。其克隆校正诊断衡量该面板的留出选择增益，单次余量则描述完整生成群体。存档评分器重放复现全部 13,896 个纳入评分；版本化端点敏感评分器在该子集上产生相同评分。

范围。 MATH 发现描述单种子、单目标下的探索性生成，评估范围为按完整性筛选的题集。BIRD 研究则在各自协议下描述 SQL 执行与准入。

A.2 MATH 选中程序清单

表 4 说明重复研究中选定的九个冻结成员。H1-H8 是生成成员的中性编号，生成种子均为 0。所列操作表示各程序实现了什么，不表示每个分支均被触发或提高了正确性。平均调用数的准入上限不是单次执行硬上限，一次逻辑调用也可能请求多个样本。

冻结成员	源代码定义的执行路径
single-call	一次温度 0 的求解，按规定格式给出最终答案。
H1 (DeepSeek)	三次温度 0.4 的求解；归一化答案后投票；无答案或并列时采用贪心回退。
H2 (ERNIE)	起草解答，再让求解器验证或修正提取的答案；返回检查后答案。
H3 (GLM)	最多五种提示、温度 0 的求解；三者一致即停止；分歧未解决时裁决，并设有格式回退。
H4 (Kimi)	一次调用请求五个温度 0.7 的样本；提取答案后投票。
H5 (Kimi)	初次求解、验证与另一种求解；投票，没有多数时额外调用以解决分歧。
H6 (MiniMax)	草稿、批评；不一致时增加平局裁决调用；解析失败时使用此前可用答案。
H7 (MiniMax)	一次调用请求五个温度 0.7 的样本；归一化并投票，并列时取最先出现者。
H8 (Qwen)	草稿加独立求解与审核；比较答案，冲突时请求裁决，并设有格式修复路径。

表 4: 重复研究具体选中了哪些程序。所有调用使用同一冻结求解器；验证和裁决均为求解器提示，不能访问基准标签。六个席位按构建器分层选出，H5 (Kimi) 与 H7 (MiniMax) 为两个不分层席位。

A.3 模型与版本

表 5 列出所报告基准研究使用的模型及其发送给 API 的确切版本字符串。所有模型均通过单一商业 OpenAI 兼容 API 聚合器访问（每个角色都用同一提供方）。冻结的是目标模型身份；解码由各 harness 定义，single-call 基线的温度为 0。Phase-II harness 生成使用温度 0.7、16,384 token 预算；Phase-I 生成条件及其证据缺口见附录 E.1。Phase I 使用代理执行评分器；Phase II 使用官方 BIRD 评分器（30s 超时），旧评分器作为次要审核。MATH-500 探查使用附录 A.1 的答案比较器；报告的准确率无一由 LLM 评分器产生。

角色	模型（确切版本字符串）	用于
冻结目标求解器	GLM-5.3-Flash（基线温度 0）	MATH / BIRD
BIRD 发现构建器	GLM-5.3-Flash	附录 E.1
MATH / BIRD 准入构建器	GLM-5.3, Qwen3.8-Max, DeepSeek-V4-Pro, Kimi-K3, MiniMax-M3, ERNIE-5.0-Thinking-Preview	MATH / BIRD
评分器	代理 / 官方 BIRD 执行评分器; MATH 答案比较器	见正文

表 5: 所报告基准研究的模型清单。目标在每个阶段内保持冻结; Phase-II 构建器来自六个独立实验室。

B 同代码对照与重复执行协议

当前全部 MATH 主估计统一使用一个 386 题的完整观测分析集。本节说明其形成方式, 记录评分完整性、来源与样本筛选。

研究对象、快照与纳入规则。 程序面板、求解器、评分器、开发划分及三次重复身份保持固定。加盐哈希为每个构建器选出一个低调用成员, 再增加两个自由席位和 single-call; 对照有九个相同基线槽位。2026 年 9 月 26 日 UTC 05:15 捕获的评分快照合并生成臂截至续采 10、克隆臂截至续采 20 的账本, 并以该快照固定分析输入。仅保留两臂所有成员与重复均有评分、且单次研究中全部成员均有评分的任务。每个必需单元均接受记录中的任一二元评分。所得 386 个题目身份固定用于全部主比较。这一纳入规则在查看结果后应用, 作为重分析披露。

完整分析集与排除的观测。 单次矩阵有 $36 \times 386 = 13,896$ 个已观测单元, 每个重复臂有 $9 \times 3 \times 386 = 10,422$ 个已观测单元。因此三个矩阵在分析集内的评分观测完整率均为 100%。政策准确率及 oracle 重放使用相同题目身份。评分完整性与采集账目分别记录。

固定纳入规则排除 14 道题, 涉及生成臂 61 个未评分单元; 这些排除题的克隆记录均完整。这些题已从当前分析中排除, 保留的来源记录中未知评分保持未知。原始排除题比例为 3.50%, 低于冻结的 10% 门槛, 门槛按取子集前的采集记录检查。按构建器计, 未评分单元为 DeepSeek 5、ERNIE 4、GLM 9、Kimi 30、MiniMax 9、Qwen 4; 基线完整。原始记录和已发生的采集成本均保留, 包括分析集之外的记录。

观测特征	纳入 (386)	排除 (14)
基线重复平均准确率 (%)	95.85	71.43
基准难度等级均值	3.47	4.29
Level-5 题目比例 (%)	26.42	64.29
题干平均长度 (字符)	198.75	284.71

表 6: 纳入题与排除题的观测特征。排除题的基准难度更高、题干更长、基线准确率更低。

身份、保留规则与冲突。 对续采 manifest 的 13 项条件字段作核验，包括求解器、缓存、评分器、协议、重复、程序身份、任务 / 划分哈希、面板抽样及调度。核实原快照哈希，并将新评分矩阵和题目名单绑定至哈希。对于每个成员—任务—重复身份，完成评分替代未知；后续记录不同仍以最先完成评分为准。生成臂有五个评分冲突单元身份，其中三个位于分析集中的三道题；克隆无冲突。采集器与并发变更保留为操作偏离记录。

当前估计与敏感性。 共同集上的插件量为生成臂 2.33 pp、克隆臂 2.16 pp。配对诊断为 $D = -0.26$ pp，95% 区间 $[-1.45, 0.95]$ pp，判断为 INSUFFICIENT EVIDENCE。冲突排除敏感性从两臂删除分析集中受影响的三道题，在剩余 383 道完整观测题上重新计算选择，得到 $D = -0.61$ pp，区间 $[-1.96, 0.64]$ pp，状态不变。这个明确标注的敏感性子集与 386 题主分析分开；两者均直接使用记录中的二元评分计算。版本化产物保留早期估计及采集快照。

B.1 探索性可重复性与评分敏感性

对每个臂，以 $A_r(h, x) = Y(h, x, r) - Y(h_0, x, r)$ 表示非参照成员的优势， h_0 为 single-call 或 clone-c1。在共同完整任务上，对每次重复分别减去行均值和列均值，再加回总体均值。每次留出一个重复，计算展平后的残差矩阵与其余两次重复均值的残差之间的相关性，再对三项相关性取平均。配对任务 bootstrap 使用 2,000 次抽样，两臂共享抽到的任务。生成臂相关性为 0.789 $([0.75, 0.83])$ ，克隆为 0.006 $([-0.07, 0.08])$ ，差异为 0.783 $([0.69, 0.87])$ 。这一采集后诊断衡量去除加性效应后的残差评分模式可重复性。

记录评分呈现明显不对称：生成成员在 570 个成员—任务对上三次重复均输给 single-call，涉及 100 个不同任务；三次均赢的有八个成员—任务对，却全部来自同一个任务，由八个生成程序共享。这些计数汇总了三次重复中实际观测到的评分模式。在该唯一任务中，标准答案为 12，基线所有输出均以 ##### 12th grade 结尾，一个生成成员则返回 12th grade。固定提取器保留完整的 ##### 内容并将前者计为零，却对后者回退到数字提取并计为一。评分差异来自提取器对不同格式采用的分支。我们保留记录评分，并将该案例解释为对格式敏感的重复修复。

C 统计分析、校准与灵敏度

本节给出正文使用的留出重复诊断。实证估计使用共同的 386 道完整 MATH 题；合成校准采用单独指定的样本量。

C.1 留出重复统计量与判定规则

三折中的每一折，用两次发现重复为每题选择一个成员，并按平均发现准确率选择一个最佳固定成员；第三次重复将逐题映射对照该固定成员评分。逐题增益在折上平均得到 G ，两臂的配对差为 $D = G_{\text{real}} - G_{\text{clone}}$ (§4.2)。重复平均 oracle 插件量 $\hat{H}$ 仅作描述，不决定判定结果。

发现分数落在 $\{0, \frac{1}{2}, 1\}$ 上，因此并列很常见。选择使用 iid $U(0, 10^{-9})$ 抖动对称地打破成员并列；实证报告对十个冻结的并列实现取平均，每个校准数据集使用一个并列实现。实证随机化参考在每臂的每题、每次重复内独立置换成员标签。每次抽取都重算两个选择、两个增益及 D ，共 10,000 次，并使用 +1 Monte Carlo 校正。配对题目 bootstrap 使用固定随机种子的 2,000 次抽取，两臂共享重采样题目身份，以获得 95% 区间。

正向支持要求同时满足：在完整案例筛选之前，任一臂及两臂交集的不完整题目比例不超过 10%；配对题目至少 30 道；随机化 $p < 0.05$ ； D 的 bootstrap 下界为正； $D > 1.0$ pp；且 G_{real} 的下界为正。当前比较为 INSUFFICIENT EVIDENCE，不确立等效性。执行条件与程序身份检查要求匹配且独立获取的重复。仅凭结果矩阵相同不能认定重复采集，仍需核实不同的执行来源。

分析修订。 采集协议先于采集制定；当前 v3 诊断与按完整性筛选的分析在采集后确定。原停止规则适用于初始采集阶段。补采集与共同集重分析作为独立修订记录，当前估计绑定 9 月 26 日快照。附录 B 给出纳入规则、排除题特征、评分冲突与冲突排除敏感性。更早的诊断版本已被替代，不用于当前估计。

C.2 总体目标与诊断边界

对于成员成功概率 $q_h(x)$ ，稳定互补性为

$$H_{\text{stable}} = \mathbb{E}_x \max_h q_h(x) - \max_h \mathbb{E}_x q_h(x).$$

当某个固定成员在几乎每题上都是期望最佳时，该量为零。选择器相对于总体最佳固定成员的总体增益 θ^* 满足 $\theta^* \leq H_{\text{stable}}$ ，因为其逐题成功概率不超过 $\max_h q_h(x)$ 。

实证 G 的比较对象由有限发现数据选出，未必是总体最佳固定成员。克隆相减提供观测采样参照，并不解析消除全部有限样本选择偏差。因此，所报告的 D 区间不是 H_{stable} 的区间；接近零的 D 不能把稳定互补性界定在零附近。

在成员标签可交换的等能力边界处，随机化参考是精确的。对于更广的全局支配零假设，错误控制仅在校准网格上经验检查，没有一般有限样本定理保证。

有限重复的 **oracle** 估计。对重复均值 $\hat{q}_h(x)$, Jensen 不等式逐题给出 $\mathbb{E} \max_h \hat{q}_h(x) \geq \max_h \mathbb{E} \hat{q}_h(x)$ 。余量还减去第二个最大值, 因此该不等式一般并不意味着二者之差向上偏。在 $q = 0.9$ 、 $M = 9$ 、 $T = 400$ 、 $R = 3$ 的已知真值等能力模拟中, 300 个数据集的平均插件量为 8.69 pp, 而 $H_{\text{stable}} = 0$ 。实证同代码臂同样给出 2.16 pp。这些例子表明, 正插件余量不足以证明专长。

C.3 已知真值校准与统计功效

二元张量从指定的成员一任务概率矩阵抽取。零假设设置包括等能力、共享题目难度、全局支配、0.5/0.9 支配配置、异质支配, 以及匹配的黏性题内潜在状态。备择包括潜在任务类型间的交叉与难度相关的部分交叉。网格覆盖 $M \in \{3, 9, 20\}$ 、 $T \in \{100, 400, 1000\}$ 、 $R \in \{3, 5, 10, 20\}$ 、完整数据、5% MCAR 与 3% 难度相关缺失。

表 7 保留 $M = 9, T = 400$ 的设置, 每格使用 300 个 Monte Carlo 数据集 (扫描中为 150 个), 每个数据集执行 300 次随机化, 比较插件量与当前克隆校准规则的支持率。在所测 100 格格上, 该规则最坏的观测零假设错误支持率为 2%。真实 $H_{\text{stable}} = 17.5$ pp 的双专家备择在 $R = 3$ 时功效为 0%, 在 $R = 5$ 时约为 0.7%, 在 $R = 10, 20$ 时为 100%。更小的循环交叉即使在 $R = 20$ 时仍大多无法检出。这些设置特定的比率不构成一般检验大小或功效保证; 当前研究的三次重复仍未判清稳定互补性。

regime	$R=3$		$R=10$		$R=20$		abst.
	plug	v3	plug	v3	plug	v3	$R=3$
equal $q=0.9^\dagger$	100	0	100	0	100	1	100
equal + difficulty [†]	100	0	100	1	100	1	100
0.5/0.9 dominance [†]	100	0	100	0	13	0	100
dominance [†]	100	0	100	0	100	0	100
cross $H \approx 0.9$ pp	100	1	100	0	100	0	99
cross $H \approx 1.8$ pp	100	1	100	1	100	0	99
cross $H \approx 4.2$ pp	100	0	100	0	100	0	100
two strong specialists, $H=17.5$ pp	100	0	100	100	100	100	100

[†]Null ($H=0$): false-support %, nominal 5%; else power %. $M=9, T=400, B=300$ at $R=3$ (150 sweeps), 300 randomizations. Appendix C describes the M, T, R and missingness settings and summarizes the wider calibration grid.

表 7: 三次重复甚至会漏掉强正例。在 $M = 9, T = 400$ 下, 零假设行报告错误支持率 (%), 备择行报告功效 (%); 最后一列为 $R = 3$ 的弃权率。克隆校准规则 (v3) 很少支持零假设, 但对所测小、中等交叉的灵敏度很低。

D 冻结选择器与等执行次数重放

选择器在 100 道开发题上拟合, 并在与当前其他 MATH 比较完全相同的 386 道完整观测分析题上评估。将记录中的选择器决策与开发集排序应用于这一共同题集。

D.1 冻结特征选择器

所报告的选择器 π_Z 组合了在 100 道开发题上拟合的五个多项 logistic 折模型。输入为 TF-IDF 题目特征（最多 300 维）与仅在相应训练折内计算的逐成员开发准确率。五折划分以题目为单位，同题的所有重复始终留在同一折。成员 h 在开发题 x 上的评分摘要为可用重复均值：

$$\bar{Y}_h(x) = \frac{1}{|\mathcal{R}_{hx}|} \sum_{r \in \mathcal{R}_{hx}} Y(h, x, r),$$

其中 $\mathcal{R}_{hx}$ 为该成员在该开发题上已有评分的重复集合。五个拟合模型通过折模型平均组合。以 $p_k(h | x)$ 表示第 k 个折模型的预测概率，推断使用 $\bar{p}(h | x) = \frac{1}{5} \sum_{k=1}^5 p_k(h | x)$ 。令 $h_{(1)}$ 、 $h_{(2)}$ 为平均概率最高的两个成员，并列按成员 ID 处理，则最终冻结选择为

$$\pi_Z(x) = \begin{cases} \text{single-call}, & \bar{p}(h_{(1)} | x) - \bar{p}(h_{(2)} | x) < 0.15, \\ h_{(1)}, & \text{其他情况.} \end{cases}$$

因此，五折步骤提供推断时使用的平均预测，阈值在平均之后应用。政策表评估包含基线回退在内的最终选择，报告以 harness 执行为单位的重复平均准确率；所选 harness 可以发起多次模型调用。

比较对象为 single-call、开发集选定的固定成员、随机抽取后固定的一个成员（用固定种子只抽取一次），以及缺失单元上回退至基线的开发集固定成员。随机比较器在所有任务上使用同一个成员。

Policy	Eval acc. (%)	S vs dev-fixed (pp) [95% CI]
single-call (fixed)	95.85	0.00 [0.00, 0.00]
dev-fixed	95.85	—
One randomly drawn fixed member	86.01	-9.84 [-13.04, -6.91]
Dev-fixed + baseline fallback	95.85	0.00 [0.00, 0.00]
π_Z (frozen selector)	95.85	0.00 [0.00, 0.00]

表 8: 共同 386 题 MATH 分析集上的冻结比较器。每个选定成员在每题上都有三次评分。准确率为重复均值；对开发固定的逐题配对差使用 2,000 次任务 bootstrap。特征政策、开发固定及回退政策均保留原记录的 single-call 选择，随机抽取后固定的成员为 gsm_kimi_s0_g3。记录中的政策在这些任务的新执行上评估。

D.2 选择收益与预算效用的范围

实际选择器的 $Z(x)$ 仅包含题目特征与训练折成员准确率。相对开发集固定成员收益为

$$S(\pi_Z) = \mathbb{E}_x [\bar{Y}_{\pi_Z(x)}(x) - \bar{Y}_{h_{\text{dev-fixed}}}(x)],$$

此处 $\bar{Y}_h(x)$ 对三次评估重复取平均。我们用 S 表示政策收益，将 D 留给真实臂减克隆臂的重复诊断。机制标签不属于该特征选择器的输入。

下述重放比较衡量相同 *harness* 执行次数下的 oracle 覆盖率；预算 b 表示 *harness* 执行次数，每次执行可以包含多次模型调用。

D.3 等执行次数重放与采集账目

等槽位采集在每臂执行九个成员 / 槽位、每槽三次重复，调用数与 token 用量由各程序决定。当前等执行次数重放 (§5.4) 使用两臂共同完整的 386 道题以及不变的开发集排序。在预算 $b \in \{3, 9, 15, 27\}$ 下，面板取排序前 $b/3$ 个成员的全部三次重复。若某题的 27 次克隆执行中有 f 次错误，则均匀选取大小为 b 的子集的期望覆盖率为 $1 - \binom{f}{b} / \binom{27}{b}$ ，其中 $b > f$ 时令 $\binom{f}{b} = 0$ 。我们精确计算均匀子集的期望。表 3 给出配对均值。两臂均使用执行后 oracle 正确性，得到相同 *harness* 执行次数下的描述性覆盖估计。

采集账目与这些结果表分开保留。原始台账记录所有已有尝试和已知用量，包括被排除题和补采集。这些台账覆盖其范围内已发生的采集成本，结果表则描述共同完整题集。生成成员可以发起多次调用，资源使用按程序和采集记录记账。

E BIRD 执行轨迹与补充分析

本附录展开正文的补充执行诊断。历史记录中的 Phase I 指 BIRD 发现研究，Phase II 指独立的 BIRD 准入研究；它们均不作为 MATH 结果的因果解释。

E.1 发现研究的程序群体与条件

程序群体与评分。 §5.5 的发现比较在 60 道题上评估由 GLM-5.3-Flash 构建器通过 TTTE 提议者生成的十二个候选，以及 *single-call* 和 *react*。准入检查导入与冒烟执行，不验证所声称的机制。基线在发现阶段的两次运行之间翻转了 60 题中的三题，因此两次运行的基线错题集略有不同。发现研究使用行集合代理评分器；在两个保留了最终 SQL 的矩阵上，它与官方 BIRD 评分器的一致率为 0.97–0.99，没有代理判对而官方判错的案例。

开发暴露与记录边界。 人工控制是在查看发现轨迹后设计的，其 151 个评估项中有 24 个与协议开发测量重叠。因此，其余量是描述性的，不是稳定互补性的盲估计。早期会话内生成记录没有保留审核等生成预算所需的生成工具与逐尝试日志。这些限制适用于此处保留的发现证据。




图 2: 源码差异未必改变观测正确性。BIRD 发现研究包含 14 个 harness、60 个任务, 每个执行一次。含基线的 91 对中, token 序列源码相似度与正确性分歧的秩相关为 $\rho = -0.010$; 36/91 对具有相同正确性向量。这是观测任务上的结果比较, 不是程序等价检验。

E.2 发现研究的结果与人工控制

每个 BIRD 发现候选都通过代码差异检查。然而, 21/66 个生成候选对具有完全相同的正确性向量 (含基线为 36/91), 91 对上源码相似度与正确性分歧几乎没有秩相关 ($\rho = -0.010$; 图 2)。整体平均分歧为 3.3% (仅生成候选为 3.8%), 对 single-call 错题的联合修复为 7.7%, 单次余量为 3.3pp。在这 60 题上一致不能确立程序普遍等价, 却说明有必要检查程序实际做了什么。

E.3 轨迹区分机制缺失、未触发与执行失败

T1: 描述存在, 实现缺失。十二个候选中有六个在文档字符串中声称检索或自检, 却只调用一次模型、不执行任何产物, 所命名的机制并未实现。**T2: 机制存在, 未被触发。**全部十个经过审核的 `react` 任务中, 首个 SQL 均成功执行, 已有的执行一反馈一修复分支从未启动, 最终 SQL 与 single-call 相同。执行成功不等于语义正确, 这些运行并未检验失败条件下的修复。**T3: 执行发生, 输出损坏。**十二个候选中有一个执行多轮查询与修复, 却将自然语言作为最终 SQL 返回, 丢掉了 single-call 能答对的题。

这些观察定位不同的失败环节, 而不是赋予一个共同的多样性分数。T1 要求检查实现, T2 要求任务能够触发分支, T3 要求有效的输出契约。它们未确立机制触发会引起准确率提升。四个人工编写、执行路径不同的控制在 60 题上产生 6.67pp 单次余量, 在 151 题上为 7.28pp, 说明评估装置能够记录不同修复。但这些控制是在查看轨迹后编写的, 缺少匹配重复与克隆对照。附录 E.1 披露较早的代理评分器及与协议开发重叠的 24/151 题; 附录 E.4 提供具体轨迹。

E.4 轨迹审核的完整样例

前述 T1 计数来自对全部十二个发现候选的分类。独立的轨迹审核覆盖五个 harness: single-call、react、单次调用候选、超时重试候选和多轮修复候选。它展示具体执行路径,不是“十二个中有六个属于 T1”的计数分母。本节将一项任务沿这些路径展开。产物逐字取自该审核 (5 个 harness $\times$ 10 道题);其日志器把存储的 SQL 摘录上限设为 120 字符,故截断以 *[trunc.]* 标记。

任务。 BIRD 开发集问题 352 (card_games 数据库;题目文本逐字,拼写错误为数据集原有):

```
Calculate the percentage of the cards availabe in Chinese
Simplified.
```

其 BIRD 提示:

```
'Chinese Simplified' is the language; percentage = Divide(Sum(id
where language = 'Chinese Simplified'), Count(id)) *100
```

Gold SQL (在发布数据库上执行两者分别得 8.7734 与 8.7728——官方评分器将其区分):

```
SELECT CAST(SUM(CASE WHEN T2.language = 'Chinese Simplified' THEN
1 ELSE 0 END) AS REAL) * 100 / COUNT(T1.id) FROM cards AS T1 INNER
JOIN foreign_data AS T2 ON T1.uuid = T2.uuid
```

single-call harness 回答:

```
SELECT SUM(CASE WHEN language = 'Chinese Simplified' THEN 1 ELSE 0
END) * 100.0 / COUNT(id) AS percentage FROM foreign_data;
```

被官方评分器判错:它直接在 foreign_data 上计数,而 gold 查询在连接 cards 之后计数;提示没有写明该连接。

react (T2: 机制存在但未触发)。 react 的控制流确实执行 SQL 并在数据库错误时重试。但其第一次调用与 single-call 的提示逐字节相同,而此处生成的 SQL 执行无错误,因此错误触发的重试从不发生,最终 SQL 与 single-call 相同。在全部 10 道被审任务上模式都成立:有 SQL 执行,10/10 最终 SQL 与 single-call 逐字节相同——反馈循环是真实代码,但其修复分支在这些题上未激活。需要受控故障注入来检验反馈是否改变输出。

单次调用候选 (T1: 机制被描述但未执行)。 该候选的文档字符串宣称一种“保守修复”:限制求解器最大输出 token 并要求仅答案块。其行为在结构上就是 single-call:一次 LLM 调用,然后提取 SQL。token 上限仅作为环境默认值存在 (2,048 对运行时的

32,000)——没有任何 harness 控制流实现它,且在这些题上它从不生效,因为 SQL 答案比上限低几个数量级。在该样例题上它恰好发起一次调用、不执行 SQL,并返回与 single-call 相同的错误查询(忽略空白差异;直接在 `foreign_data` 上计数而无连接)。在全部 10 道被审任务上它记录的 SQL 执行数为零,且最终 SQL 有 6 个与 single-call 逐字节相同;其余差异来自改写的系统提示,没有实现检索、自检或修复操作。提示改写本身是一种已实现的变换,但没有实现文档宣称的额外机制。因此最常见的 Phase-I 失败是:声明的操作没有进入实际执行的程序。

超时重试候选(代码级多样性,行为同一性)。 该候选是一个真正不同的程序:它把单次 coder 调用包在守护线程看门狗中,若调用停滞超过 40s 就发出一次对冲重复追问。机制存在于控制流中——但其触发器(停滞的 API 调用)在审核中从未出现:零次 SQL 执行,且全部 10 道被审题的最终 SQL 都等于 single-call。即使新增机制是真实的,代码不同而行为相同仍可存活:它只是从不触发。

多轮修复候选(T3:多轮路径执行失败)。 唯一一个实现了真正执行一检查一修复的被审候选把模型的自然语言说明当作最终 SQL 返回。在一道 single-call 答对的题(“State the alternative languages available for card named Annul numbered 29.”)上,其记录的最终 SQL 逐字开头为:


```
with "only a single read-only SELECT is allowed". The previous
"query" was actually just prose text (the model wrote rea[trunc.]
```

修复提示导致输出契约失败:被要求修复一个“实际上只是自然语言说明”的查询时,冻结目标继续返回自然语言推理;由于找不到 SQL 块,推理文本便被当作查询提交。该题从 single-call 正确翻转为 harness 错误。

F BIRD 准入策略研究

确认性研究采用包含六个构建器与三个种子的 2×2 析因设计;开放机制臂 II-E 仅用于开发。每槽至多 $R = 3$ 次尝试,首次接纳即停止,不补足。两个开发数据库从评估池排除。评估集包含九个数据库的 1,169 题与预抽取的 400 题核心集;一次 18 题流水线冒烟测试是已披露的开发隔离例外。官方 BIRD 评分器执行 30s 超时。响应缓存按模型身份区分,并采用跨进程锁;采集中发现并修正了缓存并发缺陷。

原主对比为配对构建器一种子单元上的 D-A,使用分层 bootstrap 与置换推断;共同核心上的析因次要分析采用 Holm 校正,并进行 K 匹配敏感性分析。仪器校准修正先于验证性结果。其他偏差包括操作性访问处理,以及对不一致观察的隔离。修正分析使用共享基线记录与数据库/题目重采样;这些修订发生在原分析规格之后。重叠采集记录按规范身份去重,采用记录在案的先写先得规则;判定冲突保留在来源审核中,当前表格使用该去重视图。实际门控可能在结构上拒绝已通过中性有效性检查的纯提示变换,各臂实际生成成本也不同。



II-E: 仅用于开发，不纳入确认性比较。

图 3: BIRD 准入设计。左: 数据库级污染隔离。中: 2x2 确认性析因与共同尝试上限; 额外的开放机制臂 II-E 仅用于开发。右: 三层准入流程。

F.1 设计与主要比较

一项独立的确认性 BIRD 研究让六个独立构建器与三个种子在策略强制（来自固定集合的具名机制对构建器自选策略）与合规门控两个因素下交叉，给出四个臂：II-A（自由、无门控）、II-B（自由、门控）、II-C（强制、无门控）、II-D（强制、门控）。“自由”表示不指派具体策略；构建器仍须声明 `repair`、`vote`、`twostage` 或 `plain`，详见附录 F.4。评估覆盖开发期间从未打开过的九个数据库中的 1,169 个问题（一个已披露的 18 题冒烟测试例外），使用官方 BIRD 执行评分器，分析在结果前冻结、之后以版本化校正重分析重跑。所实现的门控把非平凡机制的结构筛查与合规验证捆绑在一起——允许的纯提示变换即便通过中性有效性检查，也可能被结构筛查排除——所以该处理不能在因果上分离出“验证”本身。

Metric	II-A	II-D
Candidate count	5.78	3.83
Oracle accuracy (%)	76.14	75.70
Best-fixed accuracy (%)	67.58	67.30
Headroom (pp)	8.56	8.40
D—A headroom (pp)	−0.16	
Unadjusted bootstrap 95% CI	[−0.83, +0.87]	
One-sided sign-flip p	0.647	

表 9: 校正后的主分析。数值为 1,169 个问题上 18 个构建器-种子单元格的均值；single-call 同时计入 oracle 与最佳固定对照。

含 single-call 的 oracle 余量上，强制/门控（II-D）减自由/无门控（II-A）的对角均值对比为 -0.16 pp，单元格对比范围为 -4.36 to $+2.74$ pp：捆绑的筛除策略没有改善平均余量。校正分析的不确定性估计见表 9；这一均值比较不确立等价。结构准入因而不能证明机制会在相关任务上触发，或增加稳定效用。




图 4: 版本化校正重分析。左：完整集合的 D-A 单元格对比与合并 95% 区间。右：共享核心 400 题上、以共同 single-call 为基线的四臂余量。

图中余量和差值坐标均表示百分点。

在共享的核心 400 题上，门控对比为 -0.69 pp，策略与交互的次级效应同样未解决（表 10）；固定 K 的均值对比 -0.31 pp 提供群体规模的敏感性检查。开放机制臂只在开发侧运行，没有确认性估计目标。这些都是单运行对比，而附录 F.3 的 R2/R3 审核报告的执行变异性（R2 判定翻转 8.54%；14.5% 的任务三次运行间 single-call 正确性变化；6.50 pp 同代码单次缺口）把它们刻画为覆盖机会而非能力差异。

Contrast	Effect (pp)	95% CI (pp)	Raw p	Holm p
Gate	-0.69	$[-1.56, +0.20]$	0.026	0.079
Strategy	$+0.42$	$[-0.32, +1.51]$	0.263	0.428
Interaction	-0.87	$[-2.83, +0.65]$	0.214	0.428

表 10: 校正后的核心 400 题析因重分析。门控为 $[(B-A)+(D-C)]/2$ ，策略为 $[(C-A)+(D-B)]/2$ ，交互为 $(D-C) - (B-A)$ ；给出原始与 Holm 调整 p 值。

F.2 同核心提升空间分解

表 11 在相同核心任务与基线记录下分解各臂的覆盖、最佳固定准确率及余量。

Arm	K_{cand}	K_{total}	Single-call (%)	Best (%)	Oracle (%)	H (%)
A	5.78	6.78	63.25	66.00	74.51	8.51
B	6.11	7.11	63.25	66.12	74.39	8.26
C	5.61	6.61	63.25	65.64	75.01	9.38
D	3.83	4.83	63.25	65.65	73.90	8.25

表 11: 同核心提升空间分解。所有臂使用相同 400 题与相同 single-call 结果。 K_{cand} 排除 single-call, $K_{\text{total}} = K_{\text{cand}} + 1$; 数量与准确率为单元均值。提升空间为 oracle 减最佳固定准确率, 不是已实现路由增益。

F.3 敏感性、重复审核与记录成本

修正的 K 匹配与 R2 重放。 两次重放都使用与修正主分析相同的确定性记录排序与共享数据库 / 库内题目抽取, 在固定构建器内重采样种子 (10,000 次重复)。K 匹配中, 每个 A/B 与 C/D 对使用较小候选数; 每个均匀候选子集被精确枚举一次。single-call 留在每个子集中, 最佳固定在每次题目抽取的每个子集内部重算。这是规模敏感性分析, 不是因果中介分解。保留全部 18 个单元 (包括两个 A 子集为单成员的单元) 使子集 D-A 从 +0.42 变为 +0.81 pp (变化 +0.39 pp, 95% CI [-0.95, +1.63])。R2 子集提升空间排除 single-call, 因为 R2 未获得匹配的 single-call 运行, 故它不同于包含 single-call 的主估计目标; 全部 18 个单元均保留。这些是不稳定性测量, 不是标准误, 也不是平均处理效应的可检出下限; 它们不证明每个对比都不变, 也不识别 harness 间分歧中有多大部分是噪声。

R2 在 400 题上获得 70 个 harness, 在可用时为每个 A/D 单元选择前两个可调用的已接纳候选。两组关缓存采集虽然重复标签相同, 仍分别保留; 程序身份与缓存运行核对。未获得匹配 single-call, 因此 R2 提升空间在两种条件下都排除 single-call。修正分析保留单成员单元 (其子集提升空间为零), 得到全部 18 个配对单元。对缓存结果有 2391/28,000 次判定翻转 (8.54%), 两次 D 关缓存轮次之间有 1245/14,400 次翻转 (8.65%)。这些观测重放不识别未来执行方差、单独缓存的效应或相对克隆的稳定互补性。获取时间与缓存条件未被分离。

R3 仅 single-call 重复审核。 R3 是一项单独的、更小的不稳定性审核: 仅 *single-call* 基线 (无生成 harness) 在相同 core-400 题、相同冻结目标 (GLM-5.3-Flash, 温度 0) 上的三次独立关缓存执行。400 题中 58 题 (14.5%) 在三次重复中至少一次改变 single-call 正确性; 重复对之间的成对翻转率为 39/400、40/400、37/400 (9.75%、10.0%、9.25%)。把三次 single-call 重复当作三个伪成员 (各一次执行) 给出单次 oracle 72.25%, 相对最佳单次重复准确率 65.75%, 即描述性的 6.50 pp 同代码 oracle 缺口, 由记录的官方评分结果计算。因此 R3 测量的是温度 0 API 非确定性下基线自身的观测不稳定性。这

不是任何对比的标准误差或效应大小下限，但它设定了重复控制成为解释必要项的尺度：没有它们，这个量级的 harness 对 single-call 差异不能归因于能力。

Sensitivity estimand	Estimate (%)	95% CI (%)
K-matched B–A headroom	−0.55	[−1.53, +0.63]
K-matched D–C headroom	−0.08	[−1.26, +0.80]
K-matched gate mean	−0.31	[−1.07, +0.40]
R2 subset D–A (cached)	+0.42	[−0.61, +1.48]
R2 subset D–A (cache-off)	+0.81	[−0.35, +1.84]
R2 change in subset D–A	+0.39	[−0.95, +1.63]

表 12: core-400、18 单元上的修正敏感性。CI 未校正。K 匹配比较始终保留 single-call；R2 比较排除 single-call，并以观察到的获取组为条件。

记录成本与缺失账单数据。 相同 canonical 核心记录在 153,600 条候选一题目记录中包含 259,304 次记录的逻辑 solver 调用（表 13）。这些调用包括缓存服务的请求，不是提供方计费的 API 请求。所检查的记录均无 token 用量字段；我们不从调用数推算 token 或货币支出。因此实际生成尝试数、接纳候选数与这些执行计数保持为不同测量。种群成本均值对每个构建器一种子单元等权且排除 single-call；零候选种群贡献零次 solver 调用。

Arm	Candidate-task records	Logged solver calls	Calls/task/population
A	41,600	67,258	9.34
B	44,000	64,399	8.94
C	40,400	75,604	10.50
D	27,600	52,043	7.23

表 13: core-400 上的描述性 canonical 成本审核，每组 18 单元。记录的逻辑调用不是计费请求或 token 计数。末列为各单元逐题候选种群调用的平均值。

F.4 准入范围与工具局限

自由臂中，构建器从 repair、vote、twostage 和 plain 四类声明中选择。vote 要求多个样本与选择，不一定是三路多数投票；twostage 要求消费产物，但不指定响应接口。plain 不声明控制流机制，尽管提示要求改变控制流。因此，“自由”指在指定词汇内由构建器选择，而非不受约束的接口。

门控同时包含结构筛选与符合性验证。独立开发检验发现误拒、请求归属和响应接口缺陷，以及未决的符合性判断。后续接口修订与裁决没有产生修订后的基准结果。因此，所报告处理仍是实际实现的组合筛选政策；这些开发检验不确立准入工具的一般语义有效性。

1566 生成接口局限。 36 个强制臂单元的全部 108 次格式守卫尝试均未通过中性有效性检
1567 查：71 条日志报告字符串未终止，36 条报告没有 Python 围栏，一条报告提供方超时。
1568 合成示例复现了存档非贪婪代码围栏提取器的截断行为，但完整构建器消息与各历史
1569 尝试实际执行的确切版本未被保留。这些观察记录上游有效性失败，不证明预期机制不
1570 符合声明，也不把每次拒绝都归因于门控。
1571
1572

1573
1574
1575
1576
1577
1578
1579
1580
1581
1582
1583
1584
1585
1586
1587
1588
1589
1590
1591
1592
1593
1594
1595
1596
1597
1598
1599
1600
1601
1602
1603
1604
1605
1606
1607
1608
1609
1610
1611
1612
1613
1614
1615
1616
1617
1618
1619