

AI 生成 HARNESS 群体中的行为坍缩

(中文参考译本)

Anonymous authors

Paper under double-blind review

ABSTRACT

自动生成的 LLM harness (脚手架) 群体支撑着路由与价值预测, 而这两类应用的前提是群体成员在结果上彼此分歧。我们在 BIRD text-to-SQL 上审计了这一前提。Phase-I 发现性研究发现, 一个标准 harness 演化群体在语法上多样、在行为上却已坍缩——91 对 harness 中有 36 对在每个任务上完全相同, 代码相似度与结果分歧之间无关联——并通过执行轨迹审计把失败溯源到“机制有描述、从未执行”。一个手写的正控制表明路由所需的 headroom 是存在的 (7.3 pp); 失败出在生成侧。一项预先指定的确证性因子研究 (策略强制 $\times$ 一致性门控; 六构建器、三种子; 来自从未打开过的数据库的 1,169 道题; 官方 BIRD 评分器) 随后两次改写了这一叙事。第一, 坍缩被证明对协议敏感: 在干净且预算相等的协议下, 自由的无门控生成本身就已产出 headroom 丰富的群体 (8.6 pp oracle headroom、31% 联合修复率)。第二, 干预没有明确改善 (-0.16 pp, CI $[-0.90, +0.82]$); 表面上为负的门控效应在很大程度上受规模混淆 (K 匹配后为 -0.30 pp, CI 跨越零), 且 bare 结果的噪声底 (温度 0 下 14.5% 的翻转率) 超过了所讨论的效应量。稳定的结论是一条测量准则: 在生成群体之上做路由之前, 先报告结果分歧、修复、伤害与 headroom——并且要审计生成协议本身, 因为我们发现的坍缩对管线曾通过的所有代码级检查都不可见。

1 引言

在冻结的 LLM 上增长最快的杠杆已不再是权重, 而是 *harness* (脚手架)——即为任务包裹模型的那段由提示、工具与控制流组成的程序。一系列不断增长的“AI4AI”系统自动生成这类脚手架: LLM 构建器提出、编辑并演化 harness 代码。其隐含前提是: 当代码不同时, 行为也不同——三十个 harness 组成的群体应当是三十种作答方式, 而不是同一种方式被写了三十遍。在此类群体上做路由与价值预测, 预设的正是这一点。

Phase I (发现性研究): 前提不成立, 且原因可辨识。在冻结中端目标模型的 BIRD text-to-SQL (Li et al., 2023) 上, 我们测量的是一个标准 harness 演化循环产出的候选实际做了什么, 而非其源文件声称什么 (图 1)。每个候选都通过了代码差异检查, 然

而在 12 个生成候选（66 个候选对）中，两两结果分歧平均仅为 **3.8%**，且 **21 对** 在行为上完全相同；若把随系统交付的 `react harness` 和 `bare` 基线也计入（91 对），则有 36 对在每个任务上返回完全相同的正确性，且两两代码相似度与结果分歧之间没有观测到的秩关联（Spearman $\rho = -0.01$ ）。交付的 `react` 变体在每个被审计的任务上都与 `bare` 逐字节复现相同的最终 SQL。执行轨迹审计把“不同的代码”分解为三类失败：机制被描述却不在控制流中执行、反馈对输出没有因果通路、以及真正意义上的多轮路径被损坏（§3）。我们称之为**行为坍缩**（behavioral collapse）。

坍缩并不是任务本身的属性：四个手写的、执行路径被强制区分的 `harness` 在同一目标与判分器上给出 7.3 pp 的 `oracle headroom`——路由所需要的提升空间是真实存在的；是生成侧未能把它填充起来。我们还在一条已部署的管线中记录到第二种更原始的失败模式：一个被广泛使用的优化循环产出了与基线源码逐字节相同的候选。这并非行为坍缩——根本没有生成出任何不同的群体——我们将其报告为生成空（generation-null, M0）失败，并将其与坍缩论断严格区分开；坍缩论断只建立在源码确实不同的群体之上。

Phase II（确证性研究）：一个预先指定的因子设计。Phase I 表明行为坍缩或许可以通过生成侧干预修复，但其设计——两个嵌套对比、三个构建器、早期运行未留日志——无法把协议效应与构建器效应分开，其评估集与开发条目重叠，且其判分器是一个保守的代理。因此，在任何确证性结果被观测之前，我们先冻结了一份确证性协议：一个 2×2 因子设计，交叉策略强制（指定机制 vs. 自由发明）与机制一致性门控（反事实轨迹验证 vs. 仅中立有效性检查），再与六个构建器模型和三个种子交叉，在开发期间从未打开过的九个数据库中抽取的 1,169 道题上评估，由官方 BIRD 判分器打分，主对比（forced+gated vs. free+ungated 群体）作为成对连续效应分析并给出分层 bootstrap 置信区间（§4）。一致性测量工具在任何候选被评分之前，先在手写正控制与已知负样本（冒名顶替的 `harness`）上校准。

确证性答案两次改写了叙事：Phase-I 的坍缩在干净协议下没有复现（自由生成本身就 `headroom` 丰富），而干预本身在测量精度之内为零结果——表面上的负门控效应在很大程度上受规模混淆且未过 Holm 显著性，且 API 非确定性噪声底超过了所讨论的亚 pp 级效应（第 5 节）。

把两个阶段合起来读，本文回答三个嵌套问题：多样性是否存在（代码层面存在，行为层面大幅缩水）；它是否有用（仅在群体层面有用，从不足以胜过 `bare` 基线）；它能否被逐实例预测（在所测的预测器下不能，§efsec:boundary）。

我们的贡献：

1. 对 AI 生成 `harness` 群体行为坍缩的结果矩阵测量，并附一套解释代码多样性为何未能转化为行为多样性的执行轨迹分类法，以及对真坍缩与生成空失败的干净区分。
2. 经过校准的生成侧测量工具与一项预先指定的因子研究：一套反事实一致性测试套件与自指定行为契约，二者均在正负控制上校准；一个各臂原始生成预算

相等的 2×2 设计，在无污染数据上、以官方评分器分离联合干预及其各组分的效应。

3. 一个关于路由的边界结果：在 Phase-I 群体上，开集 harness 价值预测无法胜过最优固定 harness，其表面上的逐任务信号与任务记忆一致；我们将其精确限定在所测的预测器与划分上 (§5.3)。

在 harness 之外，我们所分离出的这一失败模式——LLM 构建器产出貌似合理、文档完善、却在行为上惰性的变体——是一种生成可靠性现象，我们预期凡是要模型修改自身程序之处，它都会再次出现。

2 相关工作

2.1 面向 LLM 的 HARNESS 生成

一系列不断增长的工作在冻结模型周围生成任务专属脚手架。TTHE 用一个 LLM 提议者/评判者循环演化 text-to-SQL harness (Nie et al., 2026)；Self-Harness (Zhang et al., 2026b) 证明一个模型可以改进自己的 harness；JIT-Agent (Zhang et al., 2026a) 训练模型在推理时逐任务生成 harness；Task-CoEvolve (Miyai et al., 2026) 让任务与脚手架共同演化。2026 年的一个并行工作簇让 harness 演化从验证侧开始感知行为：HarnessLens (Xu et al., 2026) 在演化过程中用行为级检查分配 rollout 预算；HarnessFix (Chen et al., 2026) 从轨迹落地的诊断出发修复 harness；AHE (Lin et al., 2026) 对照自我声明的行为预测来验证每次提议的编辑；门控语义质量-多样性搜索 (Luo et al., 2026) 在 LLM 赋予的病理描述符之上演化群体；Harness Handbook (Wang et al., 2026) 攻克行为定位与外循环搜索。

我们的工作与其互补，但在分析单元与问题取向上不同。表 1 对比了两个最邻近的系统。HarnessLens 把行为当作演化循环内部的信号来分配算力；我们问的是所得群体作为结果属性是否在行为上多样，以及哪些生成侧因素导致或修复其坍缩。HarnessBank (Luo et al., 2026) 记录了搜索空间坍缩，并用门控筛查维护一个语义多样性库；我们的一致性门控完全不评语义——它通过反事实轨迹探针在机械层面验证所声明的机制确实执行——并且我们的设计通过因子对比分离门控的因果贡献，而不是报告端到端的系统收益。

2.2 HARNESS 的条件效用与路由

近期多篇论文确立了 harness 质量以实例为条件：Gupta et al. (2026) 与 Cho (2026) 的非单调性分析记录了没有任何单一 harness 在所有实例上占优。HELIX (Fan & Huang, 2026) 表明一个兄弟 harness 组合能胜过最优固定 harness，并将 harness 路由器列为未来工作；STS (Zhou et al., 2026) 在封闭集合内的六个人工设计脚手架之间路由；GRASP (Moll et al., 2026) 在开发期把技能编辑门控进库；Kim (2026) 在 {不搜索、搜索、弃答} 之上学习反事实的实例级路由；Liu et al. (2026) 在一个 harness 内部路由模型。这些工作都消费一个成员确实存在分歧的群体；Fan & Huang (2026) 与我们最接近，它评

	本工作	HarnessLens	HarnessBank
研究单元	群体结果矩阵	演化循环	多样性库
是否测量群体坍塌	是	否	仅搜索坍塌
门控定义	反事实轨迹	可归因证据	语义筛查
门控校准	正/负控制	—	—
门控的因果隔离	2×2 因子	门控消融（单因子）	无
确证性划分	9 个未触碰数据库	—	—

表 1: 最邻近的并行系统。演化系统内部的行为感知验证属于并行的独立工作；我们的贡献是群体级的结果测量、测量工具校准，以及受控的生成侧对比。

估了完整的候选结果矩阵并测量组合相对最优固定候选的互补性。以实例为条件的选择本身是经典问题：算法选择 (Rice, 1976) 与 SATzilla 等组合求解器 (Xu et al., 2008; Kotthoff, 2014) 依据逐实例特征在已枚举的算法中挑选。我们与之在单元与问题上都不同：候选是完整的生成 harness，而我们并不构建选择器——我们测量此类群体是否携带可供选择的多样性，即任何选择器将要继承的结果结构 (§efsec:boundary)。我们的贡献更窄也更高不同：我们测量自动生成的群体是否作为结果现象发生坍塌，在轨迹层面诊断原因，并用受控因子实验分离生成侧成因。

2.3 LLM 群体中的行为多样性

LLM 输出的多样性研究大多停留在样本层面（自一致性、多样解码）或智能体策略层面。语法上不同的程序可以表现出相同行为，这一观察呼应了程序合成与变异测试实践中记录的覆盖缺口；我们的贡献是针对 AI 生成的 harness 群体把这一点实例化并量化，并给出机制层面的分类法。

3 PHASE I: 测量与诊断坍塌（发现性研究）

Phase I 是一项发现性研究：其作用是确立现象、确立分类法、确立任务侧提升空间的存在，并为确证性设计提供动机。它的任何结果都不是确证性的：151 个评估条目中有 24 个与协议开发期的测量重叠，人类对照是在检视开发期轨迹之后设计的，且其判分器是一个保守代理（附录 ??）。我们在陈述这些限制的前提下报告它。

3.1 HARNESS、结果与三个指标

一个 harness H 包裹一个冻结的目标模型 M ：它接收自然语言任务 x ，向 M 发出一次或多次调用，可选地执行中间产物（例如 SQL），并返回一个由程序判分的最终答案。以 H_0 为 bare 单次调用基线、 $Y \in \{0, 1\}$ 为正确性，harness 边际价值定义为 $\Delta(x, H, M) = Y(x, H, M) - Y(x, H_0, M) \in \{-1, 0, +1\}$ （+1 修复，-1 harness 造成的伤害）。

我们提议，harness 生成与 harness 路由管线在一个留存集上报告三个前提指标，三者均可由任何评估本来就产出的结果矩阵计算：(i) 两两结果分歧——在所有 harness 对上，正确性不同的任务占比；(ii) 联合修复率——bare 错误中被某个群体成员修复的比例；(iii) 含 bare 的 oracle headroom

$$H(P) = \text{Acc}(x \mapsto \max_{H \in P \cup \{H_0\}} Y(x, H)) - \max_{H \in P \cup \{H_0\}} \text{Acc}(H).$$

正的 headroom 意味着群体价值以条目为条件——这正是路由器需要的信号。这三个指标须组合解读：高分歧而无修复是噪声；有修复而无 headroom 则意味着某个 harness 占优。

3.2 坍缩的量化

领域为 BIRD text-to-SQL (SQLite; 执行准确率判分)，Phase I 全程目标模型冻结在 **GLM-5.3-Flash** (温度 0)。在第 1 天群体上——14 个 harness (bare、react 及 12 个演化候选) × 60 个任务——两两结果分歧平均为 **3.3%**，且 **91 对**中有 **36 对**在每个任务上完全相同；仅看 12 个生成候选 (66 个候选对；在原代码差异检查所用的归一化字符度量下，两两平均代码相似度 0.143)，分歧为 3.8%，完全相同的对为 21 对。每个候选都曾通过代码差异检查 (“所有文件互不相同、差异非平凡”)。对 bare 错误的联合修复率为 7.7%，oracle headroom 为 3.3pp；react 与 bare 在零个任务上不同。

图 1 将核心关系定量化：在全部 91 对上，图中所用词元序列度量下的两两源代码相似度 (均值 0.190；与上文仅限候选的归一化字符度量 0.143 不同) 与结果分歧的 Spearman $\rho = -0.010$ ——在该群体中，代码相似度与行为相似度之间没有观测到的秩关联。(各对共享 harness，并非独立样本；我们将 ρ 作为描述性摘要报告，而非推断性检验。)

3.3 轨迹分类法：代码多样性为何未能变成行为多样性

审计执行轨迹 (每个任务的 LLM 调用与产物执行序列) 将 “不同的代码” 分解为三类失败：

- **T1** ——机制有描述、未执行 (6/12 个候选)。harness 恰好发出一次 LLM 调用且从不执行任何产物——与 bare 的执行路径完全相同。文档字符串声称有检索、自检或 token 上限；控制流中一样都不存在。
- **T2** ——没有因果通路的反馈 (react, 10/10 个被审计任务)。SQL 被执行、错误被反馈，然而最终 SQL 在每个被审计任务上都与 bare 逐字节相同。
- **T3** ——损坏的多轮路径 (1/12)。唯一实现真正多轮修复的候选把散文当作最终 SQL 返回，把 bare 本来做对的条目变成 harness 做错。

该分类法是可行的：T1 要求执行路径验收门，T2 要求经验证的反馈因果通路，T3 要求可执行输出的校验——全部是生成协议层面的要求。




图 1: 语法多样性 vs. 行为坍缩 (Phase I, 发现性研究; 第 1 天群体: 14 个 harness $\times$ 60 个任务, 含 bare 与 react 基线共 91 对)。每个点是一个 harness 对; x = 词元序列代码相似度, y = 正确性不同的任务占比。代码相似度不能预测结果分歧 ($\rho = -0.01$); 36/91 对在全部 60 个任务上相同。原始数据: 代码发布中的 `fig1_phenomenon_data.json`。

3.4 人类正控制: HEADROOM 是存在的

为了排除“该领域本来就没有实例条件信号”这一替代解释, 我们手写了四个执行路径被强制不同的 harness (`hpc_repair`: 执行后修复; `hpc_vote3`: 对执行结果做 3 票投票; `hpc_schema`: 模式链接; `hpc_hint`: 提示优先重排)。与坍缩群体相同的冻结目标、任务与判分器: 在 60 个任务上 oracle headroom 为 **6.67 pp**, 在 151 条集合上为 **7.28 pp** [3.3, 10.0], 且 repair/schema/hint 各自修复了其他成员漏掉的条目。一个已披露的注意事项: 该对照是在检视第 1 天轨迹之后设计的, 因此其 headroom 是一个存在性证明, 而非盲估。bare 基线本身在第 1 天两次运行之间翻转了 60 个条目中的 3 个 (温度 0 下的 API 非确定性)。

3.5 PHASE-I 协议探针及其局限

Phase I 还试探了生成侧修复——一个策略强制的自由格式协议 (指定机制、导入/冒烟验收) 和一个编译型 Harness IR。在策略强制协议下, 三个构建器中有两个产出的群体的点估计超过了预指定阈值 (Qwen3.8-Flash 5.96、DeepSeek-V4-Flash-Vision-Exp 7.95 pp; 旧协议臂未达标, 4.64 pp), 且按策略的验收率随构建器身份有序排列 (在留有日志的工具下: GLM-5.3-Flash 3/8、Qwen3.8-Flash 7/8、DeepSeek-V4-Flash-Vision-Exp 8/8)。这些观察为 Phase II 提供了动机, 但不具确证性, 原因有三 (均已披露): 设计是两个嵌套对比, 无法把协议主效应与构建器主效应分开; 早期运行缺少逐次尝试

日志，因此预算相等性无法审计；验收是导入/冒烟检查，而非 §4 的反事实一致性门控。完整条件细节见附录 ??。

生成空失败 (M0)。 用 Qwen3.8-Flash 和 DeepSeek-V4-Flash-Vision-Exp 构建器重跑原始优化循环，产出了 40 个与 bare 基线源码逐字节相同的候选。相同的代码平凡地导出相同的结果，因此该次运行对行为坍缩不提供任何证据；我们将其作为一种不同且更原始的失败模式报告——管线根本没有产出任何不同的群体。上文的坍缩论断仅建立在源码确实不同的第 1 天群体之上。

4 PHASE II: 确证性生成研究 (设计)

Phase II 是确证性研究。其协议在任何确证性结果被观测之前即已冻结并提交（一个例外，作为偏离 D1 在协议变更日志中披露：一次 18 条的管线冒烟测试，其总体准确率曾被观测，其条目被保留）；偏离记录于协议变更日志（附录 ??）。冻结的估计量、划分、测量工具与分析计划在此概述。

4.1 设计

实验臂。 两个交叉因子：策略强制 ($S=1$: 构建器被分配一个来自固定八元集合的具名机制; $S=0$: 构建器自由发明一个改进, 不指定任何机制) 与一致性门控 ($G=1$: harness 必须通过冻结的一致性测试套件; $G=0$: 仅做中立有效性检查)。由此得到四个因子臂, 分别记为 **II-A** (free/ungated)、**II-B** (free/gated)、**II-C** (forced/ungated)、**II-D** (forced/gated)。另有第五个、预先指定的次级臂 **II-E** (开放机制发现: 构建器在通用轨迹原语之上输出一份自指定的行为契约, 并依据自身声明门控), 用于检验机制多样性是否根本需要作者提供词汇表; 它被有意置于因子设计之外。这些臂名为 Phase II 专用; §3.5 中的 Phase-I 条件始终用其描述性名称指称。

原始生成预算相等。 每个臂的每个槽位恰好获得 $R=3$ 次原始构建器尝试 (相同模型、温度 0.7、16,384 token 上限)。各臂仅在接纳哪个原始候选上不同: 无门控臂接纳第一个通过中立有效性的候选 (可解析、可导入、在开发问题上返回 SQL——对机制盲); 门控臂接纳第一个额外通过一致性测试套件的候选。槽位失败即最终失败; 群体从不补足, 因此生成可靠性本身是处理的一部分。所有原始候选均被保留, 生成可靠性与群体质量通过三个比率分别报告: R_{artifact} (有效产物)、 R_{contract} (有效且非空洞的契约)、 R_{fidelity} (在契约有效的前提下, 所声称的性质被验证)。

构建器与种子。 六个来自相互独立厂商的构建器 (GLM-5.3、Qwen3.8-Max、DeepSeek-V4-Pro、Kimi-K3、MiniMax-M3、ERNIE-5.0-Thinking-Preview), 各三个种子: 共 18 个成对的 (构建器 $\times$ 种子) 单元。这些是本项目单一 API 网关上可用的最强模型; 无法接入任何 Anthropic 或 OpenAI 系构建器, 因此前沿能力依赖性未经检验。每个单元不论接纳的群体规模如何 (包括 $K=0$) 都进入主对比——剔除低产出单元会以处理后结果为条件。




图 2: **Phase-II 确证性设计（冻结协议）**。左：数据库级污染隔离（两个开发数据库被整库封禁；评估使用开发期间从未打开过的九个数据库）。中：原始预算相等的 2x2 因子设计（策略强制 × 一致性门控），外加开放机制臂 II-E。右：三层接纳管线（中立有效性 → 反事实一致性 → 相对 bare 的非空洞性）。

数据隔离。 一个失效即封闭（fail-closed）的污染登记表扫描所有项目制品以寻找被观测过的 BIRD 题目。开发期间接触过的两个数据库被整库封禁；确证性评估使用开发期间从未打开过的九个数据库中的 1,169 道题（登记表可辩护的主张是不存在项目特定的自适应使用，而非预训练期隔离；18 条冒烟接触是已披露的例外），并在任何结果出现之前抽取一个分层的 400 条核心集。因子次级分析在相同的 400 条核心条目上对全部四臂进行。

判分器。 主判分器：官方 BIRD 执行评分器（对原始结果行做集合相等判定，30 秒墙钟超时）。次判分器：Phase-I 遗留判分器，经测量一致偏保守（在 Phase-I 矩阵上，它从不把官方评分器拒绝的答案判对）。

测量工具。 一致性测试套件让每个 harness 在脚本化场景下运行，并对记录的执行轨迹做断言，从不针对任务性能断言，因此门控不可能泄露结果监督。每个机制都用成对的反事实变体探测，其正确答案互不相同——包括一个让首次查询成功的变体，用以把条件修复与无条件的第二次调用区分开——答案以精确的归一化相等比较。在任何 Phase-II 生成之前，该套件先针对三个手写正控制（必须全部通过）和两个已知负样本冒名 harness（必须全部被拒绝）校准，外加“bare 基线必须违反每一条条件性质”这一不变量；该校准是一个可执行的门，在每个生成批次前重跑。臂 II-E 额外强制非空洞性（契约必须被 bare 基线违反，通过实际运行 bare 检查），并且只验证实际声明的性质。

	臂 II-A (free/ungated)	臂 II-D (forced/gated)
Oracle headroom $H(P)$, 官方判分器	8.6 pp (单元均值)	8.4 pp (单元均值)
联合修复率	31.3%	30.0%
联合伤害率	19.8%	24.6%
两两分歧	10.4%	12.6%
独特结果向量占比 K_{eff}/K	1.00	1.00
成对对比 $H(\text{II-D}) - H(\text{II-A})$, 18 个单元:		
点估计		-0.16 pp
双侧 95% CI (分层 bootstrap)		[-0.90, +0.82] pp
成对置换 p (单侧)		0.65

表 2: **主结果**。各臂含 bare 的 oracle headroom 及成对 D-A 对比, 在 1,169 题确证性集合 (开发期间从未打开的九个数据库) 上按 6 构建器 $\times$ 3 种子汇总, 官方 BIRD 判分器。CI 跨越零: **联合干预没有明确改善**。逐单元数值见图 3 (左)。

4.2 冻结的分析计划

主估计量是含 bare 的 oracle headroom 的成对差 $H(\text{II-D}) - H(\text{II-A})$ (按构建器 $\times$ 种子单元配对), 在完整 1,169 题集合上、以官方判分器评估——一个带双侧 95% CI 与成对置换检验的连续效应, 绝不是一个通过/不通过的阈值。Phase-I 的阈值仅作为一个描述性核对清单存续。**确证性次级分析** (Holm 校正, 四臂在相同的 400 条核心条目上): 门控主效应 $[(B-A) + (D-C)]/2$ 、策略主效应 $[(C-A) + (D-B)]/2$, 以及二者交互 $(D-C) - (B-A)$ ——即策略分化是否需要执行保真才能实现。**推断**: 分层成对 bootstrap (10,000 次重采样; 先重采样数据库、再在其内重采样任务, 单元配对)。 $H(P)$ 对 K 不单调——一个全对的 harness 会把 headroom 压到零——因此许可跨群体论断的是 K 匹配比较, 而非单调性。 K 匹配敏感性分析、完整的估计量定义, 以及稳健性审计 (双判分器、关缓存复跑、重复稳定性) 与协议偏离日志一并在附录 ?? 中指定。

5 PHASE II: 结果

5.1 主对比: FORCED+GATED VS. FREE+UNGATED

对主问题的确证性答案是否定的: 相对自由、无门控的生成, 策略强制加一致性门控的协议没有提高群体 headroom。点估计很小 (-0.16 pp), 分层 bootstrap CI 舒适地跨越零, 置换检验也未提供反对零假设的证据。按照预先指定的条件性结论, 我们将其报告为没有明确改善——一个未决的估计, 而非无效应的证据。

两个次级观察限定了这个零结果。第一, 两臂都带有可观的 headroom (A: 各单元 3.1–11.7 pp; D: 4.5–11.9 pp): Phase-I 的坍塌状态离 “干净协议” 状态很远, 在当前构建器强度下, 仅自由生成就已产出 headroom 丰富的群体。第二, 逐单元差值是异质的 (-2.5 到 +2.8 pp): 在门控接纳了自由臂所缺 harness 的小 K 单元上呈正趋势 (deepseek/s1 +2.0、glm/s0 +2.7), 而在自由臂本已很大的单元上呈负趋势——不过在当前量级下,




图 3: 确证性结果。左: 逐单元的 D-A headroom 差值 (已排序; 绿色 = D 更好, 红色 = A 更好) 及汇总 95% CI 带。右: 在完全相同的 400 条核心条目上的因子臂均值; 一致性门控的负主效应已加星标 (CI 排除零)。两图均来自冻结的分析脚本。

对比	对 headroom 的效应, 95% CI
门控主效应 $[(B-A) + (D-C)]/2$	-0.67 pp [-1.17, -0.13]
策略主效应 $[(C-A) + (D-B)]/2$	+0.41 pp [-0.22, +1.11]
策略 × 门控交互 $(D-C) - (B-A)$	-0.87 pp [-2.22, +0.31]

表 3: 确证性次级结果, 18 个四臂单元, 四臂均在完全相同的 400 条核心集上。门控主效应是唯一 CI 排除零的对比——且在负侧。

下文的噪声底分析提醒我们不要从结构上解读逐单元的离散度。臂 D 修复的 bare 错误略少 (30.0% vs. 31.3%), 而造成的伤害更多 (24.6% vs. 19.8%)。

5.2 因子分解 (相同的 400 条核心条目)

对因子分解的解读必须带上两项修正——冻结的分析计划已预见到它们, 而数据现在把它们补齐了。

规模混淆。门控接纳的候选少约 30% (69 vs. C 臂的 101 个槽位), 而 oracle headroom 随群体规模增长, 因此未匹配的 -0.67 pp 中有一部分是机械性的。在匹配群体规模下 (把每个无门控群体子采样到其门控臂的 K , 200 次抽样), 门控主效应缩小到 -0.30 pp, 95% CI [-0.73, +0.11]——与零不可区分。未匹配效应的一半以上来自群体规模。

多重性。三个因子对比构成一个预先指定的 Holm 族。门控主效应的原始置换 p 为 0.028, 但 **Holm** 校正后的 p 为 0.084——即便不考虑 K 匹配, 也不具确证性。未匹配 CI 排除零从来就不是预先指定的显著性。

噪声底。bare 的三次独立关缓存重复 (R3, 温度 0) 中, 14.5% 的任务结果至少翻转一次 (两两 ~9.7-10.0%; bare 准确率在各次重复间波动 63.8-65.8%)。所讨论的亚百分点级效应比这一噪声底低一个数量级。

Headroom 分解。门控并没有让群体变差：oracle 准确率基本不变（A .761 vs. D .757；表 4），未匹配的 headroom 差值来自最优固定准确率的移动，而不是联合正确性的损失。这里的“headroom 更小”意味着路由回旋余地更小，而不是群体更差。

诚实的总结是：在该基准上，无论哪个方向，任何一个组分都没有把群体 headroom 推出噪声之外。我们把未匹配、 K 匹配、校正后与分解后的视角并排报告，拒绝解读其余量。

5.3 多样性不蕴含可学习的路由

开集价值预测无法胜过最优固定 harness。在 Phase-I 接纳群体上的逐 harness 留一（leave-one-harness-out）预测器未能胜过最优固定 harness（DeepSeek-V4-Flash-Vision-Exp 臂 -3.4 pp, Qwen3.8-Flash $+0.9$ pp, CI $[-5.2, +6.9]$ ；跨协议池 -0.9 pp）。表面上的逐折修复 AUROC 0.82–0.98 在按数据库分层、按任务留出的控制下坍塌（均值 0.512）——在该被测配置内，信号是任务记忆，而非 harness 价值估计。一个狭义的正结果幸存：在 24 个 harness 的跨协议池上，同一预测器作为弃答门相对 bare 获得了 $+6.9$ pp，且观测到的诱发伤害为零——但这是在与门控调参相同的任务上测得的，因此不构成部署论断。选择性弃答可能比完全路由更容易；那个开放问题——仅凭代码与任务文本估计一个未见 harness 的逐条目价值——仍然开放。

5.4 探索性：该测量什么，该为什么而选择

两项针对已归档确证性单元的事后分析（细节见英文版附录 app:rich）回答了一篇测量论文自然会引出的两个问题。**(i) 输出空间相似度携带代码空间相似度所缺失的信号：**在判决一致的单元上计算的平均最终 SQL 不相似度，与结果分歧率的 Spearman 相关为 $\rho=0.59$ （臂内 0.57），而代码相似度则为 $\rho=-0.01$ ——但更丰富的通道也是更嘈杂的通道（同一 harness 重跑时，调用计数在 1.8% 的单元上变化，判决在 8.5% 上，SQL 文本在 70% 上），且强制机制臂产生 39–42% 的多调用轨迹（自由臂 25–30%）却得分更低（.62 vs. .64）。**(ii) 多样性感知的群体选择可迁移：**在 dev 半库上以最大化 oracle 覆盖选取 $k=8$ 个 harness，比按准确率选优多出 $+0.82$ pp 的留出 headroom（95% CI

臂	K	bare	mean H_i	best-fixed	oracle	headroom
A free/ungated	6.8	.653	.658	.676	.761	.086
B free/gated	7.1	.632	.642	.661	.744	.083
C forced/ung.	6.6	.632	.624	.656	.750	.094
D forced/gated	4.8	.653	.646	.673	.757	.084

表 4: **Headroom 分解**（18 个四臂单元，core-400，官方判分器）。各臂的 oracle 准确率基本不变；未匹配的 headroom 差异由最优固定准确率承载，而非群体效用。各臂生成可靠性（来自逐次尝试日志）： $K/144$ 个槽位——A 104、B 110、C 101、D 69；门控拒绝约 30% 的中立有效候选，构建器层面的 R_{artifact} 跨度从 0.13（GLM）到 0.80（ERNIE）。

[0.43, 1.31]), 比随机选择多 +0.40 pp ([0.18, 0.66]); 按准确率选择本身还不如随机——它买到的是最优成员, 多样性买到的是互补性。归一化地看, 多样性选取的 8-子集保留了全池 oracle headroom (相对最优固定 harness) 的 76% (按准确率选取: 73%; 成对差 +2.9 pp, CI [-0.02, +6.08])。群体级统计量可在数据库切分间迁移; 逐条目价值估计则不可 (§5.3)。

6 讨论

协议敏感性本身就是发现。Phase-I 的坍塌在干净、预算相等的协议下没有复现: 自由的无门控生成本身就产出了 8.6 pp oracle headroom、31% 联合修复率的群体。坍塌是特定生成管线的失败模式——而且它对这些管线曾通过的每一项代码级检查都不可见。在这里加入机制验证并没有增加路由价值, 其表面上的代价在很大程度上是群体规模造成的假象。是结果层面的审计、而非更强的代码级门控, 才能检出坍塌。亚 pp 级的生成侧效应位于重复运行的噪声底 (14.5% 的 bare 任一翻转率) 之下, 而该噪声底应当伴随每一个 CI 报告。另外, 产出量分解与 headroom 分解表明, 门控改变的是哪些候选存活, 而非群体能否作答: 可靠性与互补性需要分开报告。

局限性。单一领域族 (text-to-SQL); Phase-I 来自发现性设计 (已披露任务重叠、代理判分器、检视轨迹后设计的人类对照); 因子推断以六个被抽样的构建器为条件; Phase-I 早期生成缺少逐次尝试日志; §5.4 的指纹与选择分析为探索性 (对确证性结果的事后分析)。一项单种子的 MATH-500 自由臂复刻 (英文版附录 app:crossdomain) 在第二领域复现了干净协议的多样性结果——包括群体级互补性 (76% 联合修复率) 与成员级效用 (无生成 harness 胜过 bare) 的尖锐分离——但该复刻为探索性, 且未测试坍塌诱导协议。

7 结论

AI 生成的 harness 群体可以恰恰是其源文件所显示的样子, 却与路由所需的相去甚远——反过来也可能成立。Phase-I 在一个发现性群体中测量了语法-行为鸿沟, 在轨迹层面追溯其机制, 并证明任务上确实存在缺失的 headroom。一项预先指定的确证性因子研究 (六构建器、三种子、2×2 强制 × 门控、1,169 道未见题目) 随后两次改写了叙事。**坍塌被证明对协议敏感:** 在干净、预算相等的协议下, 自由的无门控生成本身就已产出 headroom 丰富的群体——坍塌是特定管线的失败模式, 且对这些管线通过的所有代码级检查都不可见。**干预在测量精度之内为零结果,** 其亚 pp 级效应位于噪声底之下。

实践结论依然成立——在生成群体之上做路由之前, 先测量分歧、修复、伤害与 headroom, 按互补性而非准确率选择群体, 并且审计生成协议本身。

AI 使用声明

本研究在构造上即是一个研究 AI 生成制品的 AI 辅助科研项目, 我们在此精确披露辅助的程度。

要求的披露。我们使用生成式 AI 工具完成了：(i) 编写与修改实验代码（生成管线、评估采集器、统计分析脚本），这些代码通过自动化测试、与手写正控制及已知负突变体的校准比对、以及跨模型对抗性审查加以验证；(ii) 执行实验，包括本文报告的所有模型 API 调用；(iii) 分析实验数据并制作表格与图；以及 (iv) 起草与编辑稿件文本。本文中的每一个定量论断都由已提交、受版本控制的分析脚本从归档的原始输出中生成，且对预冻结协议的每一次偏离都在协议变更日志中披露。

研究想法与方向。核心研究问题、因果设计决策（估计量、对比、剔除规则）、解释标准以及全部 go/no-go 决策均由人类作者作出，AI 工具担任执行者以及一名对抗性审稿人（按我们的跨模型审查纪律，与执行者分属不同模型家族）。

责任。我们对本工作的最终内容负责，包括在生成式 AI 协助下产生的文本、论断与制品。本节中的事实陈述供作者核验；其准确性由作者承担最终责任。

REFERENCES

- Mengzhuo Chen, Junjie Wang, Zhe Liu, Yawen Wang, Haiming Zheng, and Qing Wang. From failed trajectories to reliable LLM agents: Diagnosing and repairing harness flaws. *arXiv preprint arXiv:2606.06324*, 2026.
- Yong-eun Cho. It’s not the capability: Harness sensitivity is non-monotone across LLM agent tiers. *arXiv preprint arXiv:2605.26731*, 2026.
- Tianyu Fan and Chao Huang. HELIX: Model-harness co-evolution for recursive self-improvement. *arXiv preprint arXiv:2608.13951*, 2026.
- Akshat Gupta, Jermaine Lei, Alexander Lu, Gopala Anumanchipalli, and Leshem Choshen. Automated discovery has no universally superior harness. *arXiv preprint arXiv:2607.18235*, 2026.
- Minho Kim. When should LLMs search? counterfactual supervision for search routing. *arXiv preprint arXiv:2607.05752*, 2026.
- Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(2):48–60, 2014.
- Jinyang Li, Binyuan Hui, Ge Qu, Jiayi Yang, Binhua Li, Bowen Li, Bailin Wang, Bowen Qin, Ruiying Geng, Nan Huo, et al. Can LLM already serve as a database interface? a BIRD’s eye view. In *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, 2023.
- Jiahang Lin, Shichun Liu, Chengjun Pan, Lizhi Lin, Shihan Dou, Zhiheng Xi, Xuanjing Huang, and Hang Yan. Agentic harness engineering: Observability-driven automatic evolution of coding-agent harnesses. *arXiv preprint arXiv:2604.25850*, 2026.

- Xinchen Liu, Hang Zhou, Yingjie Zong, Yuchuan Tian, Liuyang Song, and Shuo Zhang. Agentic routing: The harness-native data flywheel. *arXiv preprint arXiv:2607.11399*, 2026.
- Xiaotian Luo, Dizhan Xue, Fengxingyu Wang, Chuanrui Hu, and Yafeng Deng. HarnessBank: Semantic gene-bank search with gated verification for agent-harness self-evolution. *arXiv preprint arXiv:2607.13683*, 2026.
- Atsuyuki Miyai, Kiyoharu Aizawa, and Toshihiko Yamasaki. Task-CoEvolve: Efficient harness optimization via adaptive validation task selection. *arXiv preprint arXiv:2608.20169*, 2026.
- Johannes Moll, Jean-Philippe Corbeil, Jiazhen Pan, Martin Hadamitzky, Daniel Rueckert, and Lisa Adams. GRASP: Gated regression-aware skill proposer for self-improving LLM agents. *arXiv preprint arXiv:2605.29668*, 2026.
- Jun Nie, Yonggang Zhang, Jun Song, Qianshu Cai, Dahai Yu, Xinmei Tian, Bo Han, Yike Guo, et al. TTHE: Test-time harness evolution. *arXiv preprint arXiv:2607.08124*, 2026.
- John R. Rice. *The Algorithm Selection Problem*. Elsevier, 1976.
- Ruhan Wang, Yucheng Shi, Zongxia Li, Zhongzhi Li, Yue Yu, and Junyao Yang. Harness handbook: Making evolving agent harnesses readable, navigable, and editable. *arXiv preprint arXiv:2607.13285*, 2026.
- Jinghan Xu, Yikai Zhang, Aili Chen, Weiyuan Li, Jiaqing Liang, and Deqing Yang. Verify smarter, evolve further: Efficient harness evolution through behavior-aware verification. *arXiv preprint arXiv:2608.27311*, 2026.
- Lin Xu, Frank Hutter, Holger H. Hoos, and Kevin Leyton-Brown. SATzilla: Portfolio-based algorithm selection for SAT. *Journal of Artificial Intelligence Research*, 32: 565–606, 2008.
- Guibin Zhang, Leo Lu, Fangzhou Xie, Kang Zhu, Junhao Wang, and Zhifei Xie. JIT-Agent: Scaling harness intelligence via just-in-time harness evolution. *arXiv preprint arXiv:2608.25593*, 2026a.
- Hangfan Zhang, Shao Zhang, Kangcong Li, Chen Zhang, Yang Chen, and Yiqun Zhang. Self-harness: Harnesses that improve themselves. *arXiv preprint arXiv:2606.09498*, 2026b.
- Heng Zhou, Zelin Tan, Zhemeng Zhang, Yutao Fan, Yibing Lin, and Li Kang. Select-then-solve: Paradigm routing as inference-time optimization for LLM agents. *arXiv preprint arXiv:2604.06753*, 2026.