

更多次掷骰，还是更多个程序？

区分生成 HARNESS 群体中的执行抽样与任务专长

(中文参考译本)

Anonymous authors

Paper under double-blind review

ABSTRACT

自动生成的 LLM harness 可能在源代码和观测结果上不同，却并不带来稳定的任务专长。我们研究如何区分依赖程序的专长与重复执行的收益，把源代码、执行与结果多样性作为三个不同的量分别报告。在 BIRD 文本转 SQL 的案例研究中，轨迹检查发现了三条执行层面的路径，说明表面不同的 harness 为何没有实现不同的策略：声称的机制在控制流中缺失（12 个生成候选中的 6 个）、机制存在却从未被触发（react, 10/10）、多轮路径损坏（1/12）；代码相似度与结果不一致之间没有秩相关（ $\rho = -0.01$ ；尽管全部通过代码差异检查，仍有 21/66 个生成对具有完全相同的正确性向量）。在 MATH-500 上一项独立的探索性研究（35 个生成 harness、400 个任务、各运行一次）显示，相对于最佳固定成员（即 bare 本身）有 4.75 pp 的单次 oracle 余量。随后一项新的预注册采集把八个生成 harness 与九个逐字节相同的 bare 克隆槽配对，各三次独立重复：尽管克隆群体按构造没有专长，重复平均的描述性插件量在两臂上都为正（真实面板的 350 个完整任务上 2.54 pp，克隆臂的 383 个完整任务上 2.67 pp）。交叉拟合的冻结选择增益为 $G_{\text{real}} = 0.17 \text{ pp}$ （95% CI $[-0.82, 1.31]$ ），而 $G_{\text{clone}} = 0.55 \text{ pp}$ ，故克隆校准差为 -0.10 pp （95% CI $[-1.55, 1.46]$ ，随机化 $p = .7742$ ），基于 342 个配对完整任务；覆盖门控未通过（12.5% 的真实臂任务被排除，高于冻结的 10% 阈值），因此面板报告 INSUFFICIENT EVIDENCE（证据不足）——既非存在增益，也非 1 pp 等效。综合而言，这些研究表明生成 harness 群体中观测到的 oracle 覆盖增益混合了程序专长与对同一固定随机程序额外执行的收益；harness 群体评估应把单次覆盖机会、重复稳定交互与执行前选择价值作为不同的量报告。

1 引言

LLM harness 是包裹在冻结模型外的提示、工具与控制流程序。当一个自动生成的程序群体相对于最佳固定参照表现出更高覆盖时，存在两种可能解释：其成员实现了不同的任务专长，或者群体只是对同一个固定随机程序进行了更多次独立执行。这两者并不是同一个主张。两个相同的程序若各自以概率 0.5 答对（错误相互独立），各运行一次即可得到 0.75 的覆盖率——相比只运行一个高出 25 pp，却没有任何专长。因此，群体 oracle 缺口可能是关于执行噪声、而非程序多样性的观测。

我们在 BIRD 文本转 SQL (Li et al., 2023) 与 MATH-500 (Lightman et al., 2023) 上研究这一问题，使用三类证据。第一，在一个 BIRD 发现群体中，轨迹审计发现 66 个生成候选对中有 21 对的正确性向量完全相同（计入 react 与 bare 后 91 对中有 36 对），尽管代码相似度与结果不一致之间没有秩相关 ($\rho = -0.01$)。三条执行层面的路径解释了这种坍缩：代码中声称、但控制流中缺失的机制（12 个候选中的 6 个）；存在却从未被触发的机制（react, 10/10）；以及损坏的多轮路径（1/12）。第二，在 MATH-500 上一项独立的探索性研究（35 个生成 harness、400 个任务、各运行一次）显示，相对于最佳固定成员（即 bare 本身）有 4.75 pp 的单次 oracle 余量。第三，一项新的预注册采集把八个生成 harness（连同 bare）与九个逐字节相同的 bare 克隆槽配对，各三次独立重复：重复平均的描述性插件量在两臂上都为正（真实面板的 350 个完整任务上 2.54 pp，克隆臂的 383 个完整任务上 2.67 pp），然而交叉拟合的冻结选择增益与同代码臂相当 ($D = -0.10$ pp, 95% CI $[-1.55, 1.46]$ ，随机化 $p = .7742$ ，基于 342 个配对完整任务)，且预声明的覆盖门控在 12.5% 的真实臂任务上未满足。独立地，对单一 bare harness 在 BIRD 400 个核心任务上的三次运行审计发现 14.5% 的判定在重复间发生变化；把三次 bare 执行当作三个“成员”会得到描述性的 6.50 pp 单次缺口，而没有任何对应的程序专长。

这些观察促使我们把表观互补性作为三个不同的量评估——源代码多样性、执行层面多样性与结果多样性——而不是单一标量。我们的贡献是：

1. 对生成 harness 群体中代码层、执行层与结果层多样性的实证分离，并给出一个轨迹分类法，确切说明语法上不同的程序在何处未能实现不同的策略。
2. 克隆对照、基于重复的评估。一项预注册采集配合显式的交叉拟合冻结选择统计量与同代码随机化参照，度量有多少表观互补性可归因于额外执行，并在已知真值模拟网络上把该判定规则作为测量仪表加以验证。
3. 一套面向 harness 群体的报告协议：把单次覆盖机会、重复稳定的任务交互与执行前选择价值作为不同的数、在分别声明的预算（槽数、执行数、token 数）下报告，每项研究只声明一次作用域。

决定性问题是：不同的生成程序能否在把相同执行花在一个固定程序之上，带来能在独立重复中存活的冻结选择增益。在新的预注册面板上，校准差与克隆臂不可区分、覆盖门控未满足，因此判定为 INSUFFICIENT EVIDENCE（证据不足），既非存在增益也非 1 pp 等效：在三次重复下，表观互补性与执行抽样相符，而不是该面板被发现的属

性。这为群体构建重新确立了更清晰的目标——有用的路由取决于执行噪声被分离之后的稳定任务-harness 交互，这正是受控研究所要检验的估计目标。

2 表观互补性度量的是什么？

LLM harness H 是包裹在冻结目标模型 M 外的提示、工具与控制程序：它接收自然语言任务 x ，对 M 发起一次或多次调用，可选地执行中间产物（例如 **SQL**），并返回一个以程序化方式评分的最终答案。令 H_0 表示单次调用的 **bare** 基线， $Y(h, x, r) \in \{0, 1\}$ 为成员 h 在任务 x 的第 r 次独立重复上的正确性。我们评估的群体 P 始终包含 H_0 。

问题 1：单次覆盖机会。 给定单个执行矩阵，最佳固定准确率为 $\max_h \mathbb{E}_x Y(h, x, \cdot)$ ，单次 *oracle* 准确率为 $\mathbb{E}_x \max_h Y(h, x, \cdot)$ 。二者之差为含 **bare** 的 *oracle* 余量

$$H(P) = \frac{1}{n} \sum_i \max_{h \in P \cup \{H_0\}} Y(x_i, h) - \max_{h \in P \cup \{H_0\}} \frac{1}{n} \sum_i Y(x_i, h). \quad (1)$$

$H(P)$ 只记录那张执行矩阵中存在的、依赖于具体题目的成功；它无法确立可重复的优势或任何执行前决策，因为它是在事后知道谁答对的情况下计算的。与之并列的两个简单指标是：成对结果不一致（两个成员在多少比例的任务上结果不同），以及联合修复率（**bare** 错误中被某成员纠正的比例）；没有修复的不一致不增加覆盖，而不能超过最佳固定成员的修复不增加余量。

执行噪声大到足以让这一区分变得关键。 在 **BIRD** 核心 400 题存档上，一次规范化回放发现 2,391/28,000 个同 harness 判定相对于缓存结果翻转（8.54%）；一次专门的三次运行、仅含 **bare** 的审计发现 14.5% 的任务至少有一次 **bare** 正确性发生变化；把三次独立的 **bare** 执行当作三个“成员”会得到描述性的 6.50 pp 单次 *oracle* 缺口，尽管它们是同一个程序。因此单次运行的 $H(P)$ 同时计入了专长与额外的抽样机会，这引出问题 2。

问题 2：重复稳定的、依任务条件变化的优势。 对两个成员，记 $\Delta(x) = p_1(x) - p_0(x)$ 为其逐题成功概率差， $(u)_+ = \max(u, 0)$ 。在总体层面，

$$H_{\text{stable}} = \mathbb{E} \Delta(x)_+ - (\mathbb{E} \Delta(x))_+ = \frac{1}{2} (\mathbb{E} |\Delta(x)| - |\mathbb{E} \Delta(x)|), \quad (2)$$

因此一个在每个任务上都更好的成员会产生 $H_{\text{stable}} = 0$ 的稳定排序差：全局支配不是互补性，互补性要求优势在任务之间发生交叉。这是一个两成员的总体恒等式和概念锚点，而不是有限样本界：在有限次含噪重复上选出的映射和最佳固定成员带有选择噪声，同代码对照在 §4.3 中对其加以测量。因此稳定排序与稳定互补性并不是一个嵌套的阶梯。

问题 3：执行前选择价值。 *oracle* 在执行后读取谁答对了；而路由器必须事先选定一个成员，这是一个严格更小的信息集。因此实际可部署的量是执行前冻结的选择器相对于最佳固定成员的留出增益——而非执行后的 *oracle* 覆盖。本文余下部分分别测量这三个问题，并报告每一个被回答时所处的预算（槽数、执行数、token 数）。

3 评估协议

实证研究使用四类证据来源，按 §4 的顺序呈现：一个 BIRD 文本转 SQL 发现群体，用于代码到执行的轨迹审计 (§4.1)；一项独立的 MATH-500 探索性单次探针 (§4.2)；一项新的预注册 MATH-500 采集，带有匹配重复与同代码对照 (§4.3)；以及一项预声明的 BIRD 准入策略实验，配有版本化的校正重分析 (§4.4)。每项研究固定各自的估计目标、重复数、缺失规则与预算单位，结果绝不跨研究排成“前 / 后”的线。

同代码克隆对照。 这一决定性设计把“对一个固定程序做更多次独立执行”变成一个被测量的臂，而不是一个假设。预注册采集运行一个由八个生成 harness 加 bare 组成的面板，并平行运行九个等槽、逐字节相同的 bare 克隆槽，在相同的 400 个 MATH-500 任务上各三次独立重复。等槽既不等于等执行，也不等于等 token；三种预算单位分别报告。

交叉拟合的冻结选择统计量。 重复平均插件 $\hat{H}$ 会最大化含噪的逐题估计，仅作为描述量保留。科学统计量采用交叉拟合的冻结选择：在三个折的每一折中，两次发现重复同时冻结逐题成员映射 $h^*(x) = \arg \max_h \bar{q}_h(x)$ 与唯一的最佳固定成员 h_{fix} ；留出重复则把冻结映射对照该固定成员（绝不对照 bare）评分。由此得到 G_{real} 与 G_{clone} ，判定统计量是它们在两臂均完整的任务上的配对差 $D = G_{\text{real}} - G_{\text{clone}}$ ，参照一个两臂、题内的 Monte Carlo 随机化分布（成员标签在两臂内按题目和按重复独立置换）以及一个配对题目 bootstrap。该随机化参照在臂标签可交换的等能力零假设处是精确的；在支配锥的其余部分，有限样本错误支持是在已知真值 DGP 上经验地核查，而非解析地断言。冻结的保护包括：任一臂的不完整任务覆盖率门控 $\leq 10\%$ 、配对任务至少 30 个、以及不插补未知单元（改为报告全 0 / 全 1 填充情景）。没有克隆臂时，该统计量只是描述性的，不发出任何“互补性成立”的判定。

已知真值上的测量仪表验证。 我们在具有指定成员×题目概率的模拟二元张量上验证该判定规则，跨度为成员数 $M \in \{3, 9, 20\}$ 、题目数 $T \in \{100, 400, 1000\}$ 、重复数 $R \in \{3, 5, 10, 20\}$ 、完整数据、5% MCAR 与 3% 难度相关缺失；零假设族包括等能力（含异质难度变体）与全局支配（含 0.5/0.9 配置），以及强度递增的交叉备择。100 个单元全部完成，零过程错误。表 1 报告 $M=9, T=400$ 的切片：插件在每个零假设上都以接近一的比率错误支持（包括全 $q=0.9$ 与密封的克隆臂），而克隆校准规则观测到的最差零假设错误支持率为 2%（等能力， $M=9, T=100, R=3$ ；Wilson [0.68, 5.71]%）。功效随重复数如实报告：在 $R=3$ 时，一个 $H=17.5$ pp 的干净双专家交叉以 0% 功效被检出（ $R=5$ 时 0.7%， $R=10, 20$ 时 100%），而现实的 1–4 pp 循环交互在 $R=3$ 时仍无法分辨。这些都是经测试 DGP 的陈述，不是跨越支配锥的解析有限样本规模保证。

缺失与题目来源。 若一个任务在某臂的每个成员、每次重复上都有记录的判定，则称该任务对该臂完整；存在未解析远程调用或携带未知标记的任务从该臂排除，而不插补。点估计为完整案例、在纳入任务上是精确的；两臂有不同的完整任务集，因此臂级描述数在各自的任务集上报告，只有 D 在交集上配对。评估任务此前曾在单次探

regime	$R=3$		$R=10$		$R=20$		abst.
	plug	v3	plug	v3	plug	v3	$R=3$
equal $q=0.9^\dagger$	100	0	100	0	100	1	100
equal + difficulty [†]	100	0	100	1	100	1	100
0.5/0.9 dominance [†]	100	0	100	0	13	0	100
dominance [†]	100	0	100	0	100	0	100
cross $H \approx 0.9$ pp	100	1	100	0	100	0	99
cross $H \approx 1.8$ pp	100	1	100	1	100	0	99
cross $H \approx 4.2$ pp	100	0	100	0	100	0	100
two strong specialists, $H=17.5$ pp	100	0	100	100	100	100	100

[†]Null ($H=0$): false-support %, nominal 5%; else power %. $M=9$, $T=400$, $B=300$ at $R=3$ (150 sweeps), 300 randomizations. Wilson intervals and the full M , T , R , missingness grid in Appendix H.

表 1: 已知真值测量仪表验证, $M=9$, $T=400$ 。零假设行报告错误支持 % (名义 5%), 备择行报告功效 %; 最后一列是 $R=3$ 的弃权率。完整 M, T, R 与缺失网格见附录 H。

针中执行过, 因此本采集在执行上是前瞻的、在任务是回顾的——是一项独立重复研究, 而非未见过任务的验证。

4 实证诊断

4.1 代码多样性却无行为多样性: BIRD

该发现群体包含 14 个 harness——12 个演化生成的候选加上 bare 与 react 基线——在 60 个 BIRD 任务上各有一次记录执行 (单运行矩阵; 此处未采集匹配重复), 目标模型冻结为 GLM-5.3-Flash。成员配对给出 $\binom{12}{2} = 66$ 个生成候选对, 计入两个基线后为 91 对。每个候选此前都通过了代码差异检查, 断言所有文件互异且差异非平凡。然而, 66 个生成对中有 21 对在每个任务上的正确性向量完全相同 (计入基线后 91 对中有 36 对); 在全部 91 对上, 源代码相似度与结果不一致之间基本没有秩相关 (Spearman $\rho = -0.010$; 图 1)。总体平均成对结果不一致为 3.3% (生成候选间 3.8%), 对 bare 错误的联合修复率为 7.7%, 单次 oracle 余量为 3.3 pp; react 与 bare 在零个任务上不同。

审计执行轨迹分离出三条路径, 说明不同的源代码为何没有产生不同的被执行策略。**T1**——声称却未执行的机制 (6/12 个生成候选): 程序只发起一次模型调用、不执行任何产物, 与 bare 是同一条执行路径, 而其 docstring 却声称控制流中并不存在的检索或自检机制。**T2**——存在却从未被触发的机制 (react 在审计的 10/10 个任务上): 错误修复分支是真实代码, 但首个 SQL 在每个审计任务上都成功, 分支从不触发, 最终 SQL 与 bare 相同; 这并不表明修复路径在失败时缺乏因果作用力。**T3**——损坏的多轮路径 (1/12): 一个执行-检查-修复程序把模型的散文当作最终 SQL 返回, 使 bare-正确的题目变成 harness-错误。三类分别要求不同的检验——执行路径准入、受控故障注入、可执行输出验证。




图 1: 代码多样性与行为坍缩 (BIRD 发现群体: 14 个 harness $\times$ 60 个任务, 计入 bare 与 react 共 91 对)。每个点是一对 harness; x 为 token 序列代码相似度, y 为正确性不同的任务比例。代码相似度不能预测结果不一致 ($\rho = -0.010$), 且 36/91 对在全部 60 个任务上完全相同。

一个人工正控表明该测量装置能够检出真正的专长。四个在同一冻结目标与评分器下、强制具有不同执行路径的手写 harness (执行并修复、三票、schema 链接、提示优先重排), 在 60 个任务上给出 6.67 pp 的 oracle 余量, 在完整的 151 题集合上为 7.28 pp (95% 区间 [3.3, 10.0]), 每个机制都修复了其他机制漏掉的题。由于该控制是在检查发现轨迹之后才编写的, 其余量是描述性的而非盲测; 发现群体的来源 (含 24/151 个题目与协议开发重叠、以及保守的代理评分器) 在附录 A 报告。

4.2 探索性 MATH-500 群体中的单次余量

在 MATH-500 上一项独立的探索性研究使用六个构建器、一个种子、一个机制无关的有效性门控, 目标冻结为温度 0 的 GLM-5.3-Flash, 每个被纳入的 harness 在相同的 400 个评估任务上执行一次。48 个生成槽中纳入 35 个; 两个推理密集型构建器在多数槽上耗尽了 32k 生成 token 预算, 因此该群体对推理密集风格的代表性不足。这是一个复制探针而非析因实验, 既未采集重复也没有同代码对照。

该群体表面上行为多样: 平均成对结果不一致为 10.6% (最大 33.0%), 36 个成员 (计入 bare) 中有 33 个具有唯一正确性向量, 成员修复了 76.0% 的 bare 错误。但单次 oracle 覆盖率为 98.50%, 而最佳固定成员是 bare 本身, 仅 93.75%; 每个生成成员单独看都更差 (0.6825–0.915)。因此含 bare 的单次 oracle 余量为 4.75 pp: 这是一个无法通过执行前承诺于任何单一程序来实现的覆盖机会。这一探索性观察促成了 §4.3 中独立的预注册重复加克隆研究: 两项研究使用不同的群体、估计目标与预算, 4.75 pp 不与受控结果作为前后校正来比较。第二域复制详见附录 J。

量	真实臂	克隆臂
完整任务数	350	383
重复平均插件 $\hat{H}$	2.54 pp	2.67 pp
交叉拟合增益 G	0.17 pp	0.55 pp
校准 $D = -0.10$ pp, CI $[-1.55, 1.46]$, $p = .7742$		
配对完整任务: 342; 排除率 12.5%/4.2%		

表 2: 克隆对照的 **MATH-500** 结果。插件与 G 使用两臂各自不同的完整任务集, 因此其数值不是配对对照; D 在两臂均完整的 342 个任务上计算。

4.3 同代码克隆呈现正的表现互补性

预注册采集 (2026-09-15 冻结) 在相同的 400 个 **MATH-500** 任务上, 对一个由八个生成 harness 加 bare 组成的面板与九个等槽、逐字节相同的 bare 克隆槽各执行三次独立重复。该面板是从 35 个探索成员中以加盐哈希抽取、资格限定为低调用机制的样本; 评估任务此前曾在单次探针中使用, 因此这是前瞻执行、回顾任务的研究, 而非未见过任务的验证。协议与执行记录见附录 I。

重复平均的描述性插件在两臂上都为正——真实面板的 350 个完整任务上 2.54 pp, 克隆臂的 383 个上 2.67 pp——尽管克隆群体按构造有 $H_{\text{stable}} = 0$ 。这是本文最锐利的测量事实: 相同源代码、相同重复计划、正的表现互补性, 与已知真值零假设对最大化型插件的预测完全一致。

交叉拟合的冻结选择增益在两臂各自完整任务集上为 $G_{\text{real}} = 0.17$ pp (CI $[-0.82, 1.31]$) 与 $G_{\text{clone}} = 0.55$ pp, 因此克隆臂上的有限 (R, T) 选择噪声与面板增益同量级。判定统计量 D 并非这些臂级数值的算术差: 两个增益都在两臂均完整的 342 个任务上通过交叉拟合重算, 得到 $D = -0.10$ pp (CI $[-1.55, 1.46]$, 随机化 $p = .7742$)。稳定成员排序 (C-rank) 为 SUPPORTED (成立), 但互补性判定弃权: 12.5% 的真实臂任务不完整, 高于冻结的 10% 覆盖门控, 故 C-comp 为 INSUFFICIENT EVIDENCE (证据不足), 区间上端不能确立 1 pp 等效, 被排除任务的全 0 / 全 1 填充情景把 G 框在 $[-0.33, 0.33]$ pp。该弃权既由功效、也由覆盖率驱动: 在 $R = 3$ 时, 该仪器即便对一个强的 $H = 17.5$ pp 双专家交叉也只有 0% 功效 ($R = 5$ 时 0.7%, $R = 10, 20$ 时 100%; §3)。

槽数不决定花费。离线的等执行预算回放把 dev 排序后面板的执行后 oracle 覆盖与 27 次同代码执行中的 b 次对照, $b \in \{3, 9, 15, 27\}$: 面板减同代码的差为 $+0.37, +0.03, -0.11, -0.25$ pp, 即在每个预算上都持平 (范围 -0.25 至 $+0.37$ pp)。该面板使用了克隆臂 3.73× 的 token (54.17M 对 14.51M, 22,192 对 10,800 个逻辑调用), 因此不做任何已实现成本匹配的主张; 由于两臂输出格式不兼容 (带框数字对自由散文), 也不报告跨臂多数投票准确率。冻结的执行前选择器 π_Z 在每个评估任务上都弃权为 bare, 与 dev 固定在三次重复上的 94.96% 持平 (探索性研究中 bare 的单次准确率为 93.75%; 此处更高的值是同一任务集上的重复均值, 是不同的统计量, 并非予

Metric	II-A	II-D
Candidate count	5.78	3.83
Oracle accuracy (%)	76.14	75.70
Best-fixed accuracy (%)	67.58	67.30
Headroom (pp)	8.56	8.40
D–A headroom (pp)	−0.16	
Unadjusted bootstrap 95% CI	[−0.83, +0.87]	
One-sided sign-flip p	0.647	

表 3: 校正后的主分析。数值为 1,169 个问题上 18 个构建器–种子单元格的均值；bare 同时计入 oracle 与最佳固定对照。




图 2: 版本化校正重分析。左: 完整集合的 D–A 单元格对比与合并 95% 区间。右: 共享核心 400 题上、以共同 bare 为基线的四臂余量。

盾)，而预先固定一个随机成员则显著更差 (−10.12 pp, CI [−13.27, −7.22])：观测到的 oracle 价值并不是已实现的路由价值。

4.4 BIRD 上的准入策略研究

一项独立的确认性 BIRD 研究让六个独立构建器与三个种子在策略强制（来自固定集合的具名机制对自由发明）与合规门控两个因素下交叉，给出四个臂：II-A（自由、无门控）、II-B（自由、门控）、II-C（强制、无门控）、II-D（强制、门控）。评估覆盖开发期间从未打开过的九个数据库中的 1,169 个问题（一个已披露的 18 题冒烟测试例外），使用官方 BIRD 执行评分器，分析在结果前冻结、之后以版本化校正重分析重跑。所实现的门控把非平凡机制的结构性筛除与合规验证捆绑在一起——八个强制提示转换槽中有两个即便中性有效也无法通过——所以该处理不能在因果上分离出“验证”本身。

含 bare 的 oracle 余量上，强制/门控（II-D）减自由/无门控（II-A）的对角对比为 −0.16 pp（未调整 95% CI [−0.83, +0.87]，单侧符号翻转 $p = 0.647$ ），单元格对比范围为 −4.36 to +2.74 pp：捆绑的筛除策略没有可检出的余量红利，区间也不能确立等效。

Contrast	Effect (pp)	95% CI (pp)	Raw p	Holm p
Gate	-0.69	[-1.56, +0.20]	0.026	0.079
Strategy	+0.42	[-0.32, +1.51]	0.263	0.428
Interaction	-0.87	[-2.83, +0.65]	0.214	0.428

表 4: 校正后的核心 400 题析因重分析。门控为 $[(B-A)+(D-C)]/2$ ，策略为 $[(C-A)+(D-B)]/2$ ，交互为 $(D-C) - (B-A)$ ；给出原始与 Holm 调整 p 值。

在共享的核心 400 题上，门控对比为 -0.69 pp (Holm 调整 $p = 0.079$)，策略与交互的次级效应同样不显著 (表 4)；固定 K 敏感性 -0.31 pp (CI [-1.07, +0.40]) 确认余量对群体规模并非单调。开放机制臂只在开发侧运行，没有确认性估计目标。这些都是单运行对比，而 §2 报告的执行变异性 (R2 判定翻转 8.54%；14.5% 的任务三次运行间 bare 正确性变化；6.50 pp 同代码单次缺口) 把它们刻画为覆盖机会而非能力差异。

5 相关工作

5.1 面向 LLM 的 HARNESS 生成

一条不断增长的研究线围绕冻结模型生成任务专属的脚手架。TTHE 用 LLM 提议/评判循环演化文本转 SQL harness (Nie et al., 2026)；Self-Harness (Zhang et al., 2026b) 展示模型可以改进自己的 harness；JIT-Agent (Zhang et al., 2026a) 学会在推理时为每个任务生成 harness；Task-CoEvolve (Miyai et al., 2026) 共同演化任务与脚手架。自动智能体程序搜索 (Hu et al., 2024) 最早把这类生成程序框定为搜索空间。2026 年的一个并行集群从验证侧让 harness 演化具备行为感知：HarnessLens (Xu et al., 2026) 在演化过程中用行为级检查分配推演预算，HarnessFix (Chen et al., 2026a) 从有轨迹依据的诊断修复 harness，AHE (Lin et al., 2026) 对照自声明的行为预测验证每次编辑，门控质量多样性 / HarnessBank (Luo et al., 2026) 在 LLM 标注的病理描述符上演化群体，Harness Handbook (Wang et al., 2026) 针对行为定位与外环搜索，HarnessForge (Chen et al., 2026b) 共同演化 harness 与内部策略。

我们的分析单位与问题互补但不同。表 5 对比了两个最接近的系统。HarnessLens 把行为当作演化循环内部的信号来分配算力；我们追问所得群体作为一种结果属性是否行为多样。HarnessBank (Luo et al., 2026) 记录搜索空间坍塌并按 LLM 给出的语义描述符筛选；我们的准入工具完全不给语义打分，而是驱动反事实轨迹探针，机械地验证一个声称的机制确实执行，并通过析因对比比较准入策略。由于所实现的门控也在结构上排除了两个被允许的提示转换，该处理不能在因果上分离验证本身。

5.2 条件效用、路由与重复抽样

Harness 质量是依实例条件变化的：Gupta et al. (2026) 与 Cho (2026) 记录了没有任何单一 harness 在所有实例上占优。HELIX 评估完整的兄弟 harness 结果矩阵以及超过最佳固定候选的群体互补性，但把路由器列为未来工作 (Fan & Huang, 2026)。STS 在六个

	本文	HarnessLens	HarnessBank
分析单位	群体结果矩阵	演化循环	多样性库
是否测量行为坍塌	是	否	仅搜索坍塌
同代码克隆对照	是	否	否
准入检查	反事实轨迹	预算分配	语义筛除
策略比较	析因	单循环	无
确认性划分	9 个隔离 DB	—	—

表 5: 最接近的并行系统。当前门控包含结构性筛除，确认性划分有一个已披露的 18 题冒烟测试例外。

固定的人工设计脚手架上路由 (Zhou et al., 2026)，GRASP 把技能编辑门控进开发期库 (Moll et al., 2026)，Kim (2026) 学习在 {不搜索、搜索、弃权} 上路由，RouteLLM (Ong et al., 2024) 在模型层面路由。底层决策边界是经典的定量与定性（交叉）交互之分：仅效应量改变并不一定改变应选的动作 (Gail & Simon, 1985)。算法选择 (Rice, 1976) 与 SATzilla 这类组合求解器 (Xu et al., 2008; Kotthoff, 2014) 根据实例特征在枚举的算法间选择，随机重启长期以来捕获的是对单个求解器多做尝试、而非来自组合的收益。集成选择在模型库上优化一个验证目标 (Caruana et al., 2004)，与执行前选择一个成员是不同的信息集；自一致 (Wang et al., 2022) 在事后聚合多条采样轨迹，其成本与信息集同样不同于执行前的单成员路由。

我们的候选是完整的、自动生成的 harness；我们测量一个选择器将继承的群体结果结构，而不是构建选择器。执行后验证器 (Kwok et al., 2026) 给已完成的轨迹打分，而我们的执行前估计目标在 harness 运行之前就做出选择，是不同的信息集；我们通篇把 oracle 覆盖明确标注为执行后、验证器可实现的上界，而非路由效用。

5.3 生成群体中的行为多样性

LLM 输出的多样性主要在样本层 (pass@k (Chen et al., 2021)、自一致、多样化解码) 或智能体策略层被研究。对固定生成器重复抽样、以及由独立实例化的相同智能体组成多智能体集成 (Li et al., 2024)，都已表明同代码额外执行能带来性能收益；名义温度 0 的调用在重复间也会变化 (Alizadeh et al., 2023)。我们的同代码克隆臂把这一执行层基线变成 harness 群体的显式被测量零假设。语法不同的程序行为相同，与经典的程序等价 (Budd & Angluin, 1982) 和变异体等价 (Papadakis et al., 2019) 结果相邻。最接近的是 El et al. (2025)，他们在聚合层面报告自动设计智能体行为多样性偏低；我们在两个方向上扩展该观察：一个轨迹层分类法（声称却未执行、存在却未触发、多轮损坏），确切说明语法差异在何处没有变成被执行的策略；以及反向发现——相同代码在重复执行下产生正的表现互补信号——并针对 harness 群体以匹配重复、同代码对照和显式的槽数/执行数/token 记账加以测量。

6 意义与局限

研究表明了什么。群体效用是执行噪声被分离之后的稳定任务-harness 交互：oracle 在执行后问谁答对了，而路由器必须事先承诺。三项研究分离了此前单次报告混为一谈的量。在 BIRD 上，源代码多样性对行为差异没有信息量 ($\rho = -0.01$ ，尽管通过代码差异检查仍有 21/66 个相同向量)，三条具名执行路径显示了不同程序在何处未能实现不同策略。在探索性 MATH-500 群体上，单次 oracle 覆盖比最佳固定成员高 4.75 pp，而该成员就是 bare 本身。在预注册面板上，逐字节相同的程序复现了正的重复平均插件（克隆臂上 2.67 pp），而校准差为 $D = -0.10$ pp (CI $[-1.55, 1.46]$, $p = .7742$)、等执行覆盖持平：在三次重复下，表观增益与对一个固定程序额外执行不可区分，预声明规则弃权而非称之为等效；冻结选择器没有捕获到预先固定随机成员所损失的任何差距 (-10.12 pp)。

一套报告协议。结果引出四条低成本做法：(i) 纳入同代码克隆臂，使额外执行成为被测量的基线；(ii) 采集留出的独立重复并做发现/验证切分，报告重复数与各臂缺失情况；(iii) 把单次覆盖机会、重复稳定交互与执行前选择价值作为三个信息集不同的量分别报告；(iv) 分别报告槽数、执行数与 token 数，任何预算匹配比较都在所声称的单位上执行。

作用域。BIRD 证据覆盖一个 SQL 目标、六个构建器、三个种子 (W1/W3 分析为描述性)；MATH 面板是在既往见过的任务上的低调用筛选抽取，不是未见过任务的检验。在 $R = 3$ 时该判定只对强交叉有效 (对 $H = 17.5$ pp 交互功效为 0%)，覆盖门控又独立地在 12.5% 的真实臂任务上失败，因此弃权是测量边界而非不存在的证据——更多重复是解决它的直接途径。该面板花费克隆臂 $3.73\times$ 的 token，因此成本受控的比较是等执行回放 (而非已实现成本)，校准是跨越 100 个单元的经验性、经测试 DGP 的结果，而非解析的支配锥保证。可迁移的主张是这一测量区分及其在两个域上展示的控制；其他面板、目标与重复数是开放的扩展。

致谢

占位：经费、算力与基础设施致谢由作者在 camera-ready 前定稿 (投稿阶段匿名)。

伦理声明

全部实验使用公开的 BIRD 与 MATH-500 基准数据及生成的程序产物；不涉及人类被试、私人记录或个人身份信息。模型调用作为实验来源的一部分报告，论文不发布凭据或会暴露私人数据的提供方响应。主要伦理风险是夸大单次运行 oracle 增益对部署路由的含义；因此我们把未解决的选择与成本命题明确报告为 INSUFFICIENT EVIDENCE (证据不足)。

可复现性声明

补充材料包含冻结的诊断实现、控制清单与哈希绑定的结果记录。REPRODUCE.md 给出单元测试、校准、盲测控制、存档诊断与 LaTeX 构建的确切离线命令。所报告的依赖提供方的存档连同其来源与哈希保留；任何命题都不需要访问在线模型 API 即可重跑诊断本身。

AI 使用声明

本研究按构造就是一个借助 AI 研究 AI 生成产物的项目，以下精确披露 AI 协助的范围。

必要披露。生成式 AI 工具用于：(i) 编写和修改实验代码（生成流程、评估采集器、统计分析脚本）；(ii) 运行涉及模型 API 调用的实验流程；(iii) 分析实验数据并制作表格和图；(iv) 起草和修改论文文字。修订后的主分析表、析因表和结果图由共同的版本化重分析产物生成。历史探索性分析保留各自原始来源与所述局限。审后修正与原协议分开记录。验证记录分别说明各产物的自动测试、开发控制与审核范围。审后修订也使用了同模型子代理审核；这些属于机械检查，不构成跨模型独立科学验证。开发控制和本机运行测试不能确立独立门控校准或提供方层面的执行独立性。

研究构思与方向。核心研究问题、因果设计决策（估计目标、对比、排除规则）、解释标准及拟议的继续 / 停止准则在 AI 协助下形成。人类作者确定总体研究方向并要求按审稿意见修订；AI 工具也提出分析与实验设计、识别反例并实施修订。最终科学决策及投稿批准仍由作者负责。本声明不表示每项 AI 提议的决策均已获得作者逐项批准。

责任。作者对本研究最终内容承担责任，包括借助生成式 AI 产出的文字、主张和产物。本节中的事实陈述供作者核实；其准确性的最终责任由作者承担。

REFERENCES

- Vahid Alizadeh et al. An empirical study of the non-determinism of chatgpt in code generation. *arXiv preprint arXiv:2308.02828*, 2023.
- Timothy A. Budd and Dana Angluin. Two notions of correctness and their relation to testing. *Acta Informatica*, 18(1):31–45, 1982.
- Rich Caruana, Alexandru Niculescu-Mizil, Geoff Crew, and Alex Ksikes. Ensemble selection from libraries of models. In *Proceedings of the 21st International Conference on Machine Learning*, 2004.
- Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*, 2021.

- Mengzhuo Chen, Junjie Wang, Zhe Liu, Yawen Wang, Haiming Zheng, and Qing Wang. From failed trajectories to reliable LLM agents: Diagnosing and repairing harness flaws. *arXiv preprint arXiv:2606.06324*, 2026a.
- Mingju Chen, Can Lv, Guibin Zhang, Heng Chang, and Shiji Zhou. HarnessForge: Joint harness and policy evolution for adaptive agent systems. *arXiv preprint arXiv:2606.01779*, 2026b.
- Yong-eun Cho. It’s not the capability: Harness sensitivity is non-monotone across LLM agent tiers. *arXiv preprint arXiv:2605.26731*, 2026.
- Batu El, Mert Yuksekogonul, and James Zou. Inefficiencies of meta agents for agent design. *arXiv preprint arXiv:2510.06711*, 2025.
- Tianyu Fan and Chao Huang. HELIX: Model-harness co-evolution for recursive self-improvement. *arXiv preprint arXiv:2608.13951*, 2026.
- Mitchell H. Gail and Richard Simon. Testing for qualitative interactions between treatment effects and patient subsets. *Biometrics*, 41(2):361–372, 1985. doi: 10.2307/2530862.
- Akshat Gupta, Jermaine Lei, Alexander Lu, Gopala Anumanchipalli, and Leshem Choshen. Automated discovery has no universally superior harness. *arXiv preprint arXiv:2607.18235*, 2026.
- Shengran Hu, Cong Lu, and Jeff Clune. Automated design of agentic systems. *arXiv preprint arXiv:2408.08435*, 2024.
- Minho Kim. When should LLMs search? counterfactual supervision for search routing. *arXiv preprint arXiv:2607.05752*, 2026.
- Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(2):48–60, 2014.
- Jacky Kwok, Shulu Li, Pranav Atreya, Yuejiang Liu, Yixing Jiang, Chelsea Finn, Marco Pavone, Ion Stoica, and Azalia Mirhoseini. LLM-as-a-verifier: A general-purpose verification framework. *arXiv preprint arXiv:2607.05391*, 2026.
- Jiayi Li, Qin Zhang, Yiting Yu, Qinkai Fu, and Dawei Ye. More agents is all you need. *arXiv preprint arXiv:2402.05120*, 2024.
- Jinyang Li, Binyuan Hui, Ge Qu, Jiayi Yang, Binhua Li, Bowen Li, Bailin Wang, Bowen Qin, Ruiying Geng, Nan Huo, et al. Can LLM already serve as a database interface? a BIRD’s eye view. In *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, 2023.

- Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Lightman et al. let’s verify step by step appendix: Math-500 subset. *arXiv preprint arXiv:2305.20050*, 2023.
- Jiahang Lin, Shichun Liu, Chengjun Pan, Lizhi Lin, Shihan Dou, Zhiheng Xi, Xuanjing Huang, and Hang Yan. Agentic harness engineering: Observability-driven automatic evolution of coding-agent harnesses. *arXiv preprint arXiv:2604.25850*, 2026.
- Xiaotian Luo, Dizhan Xue, Fengxingyu Wang, Chuanrui Hu, and Yafeng Deng. HarnessBank: Semantic gene-bank search with gated verification for agent-harness self-evolution. *arXiv preprint arXiv:2607.13683*, 2026.
- Atsuyuki Miyai, Kiyoharu Aizawa, and Toshihiko Yamasaki. Task-CoEvolve: Efficient harness optimization via adaptive validation task selection. *arXiv preprint arXiv:2608.20169*, 2026.
- Johannes Moll, Jean-Philippe Corbeil, Jiazhen Pan, Martin Hadamitzky, Daniel Rueckert, and Lisa Adams. GRASP: Gated regression-aware skill proposer for self-improving LLM agents. *arXiv preprint arXiv:2605.29668*, 2026.
- Jun Nie, Yonggang Zhang, Jun Song, Qianshu Cai, Dahai Yu, Xinmei Tian, Bo Han, Yike Guo, et al. TTHE: Test-time harness evolution. *arXiv preprint arXiv:2607.08124*, 2026.
- Huai Guang Ong, Sylvain Jeremy, et al. RouteLLM: Learning to route llms with preference data. *arXiv preprint arXiv:2406.18665*, 2024.
- Mike Papadakis, Marinos Kintis, Jie Zhang, Yue Jia, Yves Le Traon, and Mark Harman. Mutation testing advances: an analysis and survey. *Advances in Computers*, 112:275–378, 2019.
- John R. Rice. *The Algorithm Selection Problem*. Elsevier, 1976.
- Ruhan Wang, Yucheng Shi, Zongxia Li, Zhongzhi Li, Yue Yu, and Junyao Yang. Harness handbook: Making evolving agent harnesses readable, navigable, and editable. *arXiv preprint arXiv:2607.13285*, 2026.
- Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc V. Le, Ed H. Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. Self-consistency improves chain of thought reasoning in language models. *arXiv preprint arXiv:2203.11171*, 2022. doi: 10.48550/arXiv.2203.11171.
- Jinghan Xu, Yikai Zhang, Aili Chen, Weiyuan Li, Jiaqing Liang, and Deqing Yang. Verify smarter, evolve further: Efficient harness evolution through behavior-aware verification. *arXiv preprint arXiv:2608.27311*, 2026.
- Lin Xu, Frank Hutter, Holger H. Hoos, and Kevin Leyton-Brown. SATzilla: Portfolio-based algorithm selection for SAT. *Journal of Artificial Intelligence Research*, 32:565–606, 2008.

Guibin Zhang, Leo Lu, Fangzhou Xie, Kang Zhu, Junhao Wang, and Zhifei Xie. JIT-Agent: Scaling harness intelligence via just-in-time harness evolution. *arXiv preprint arXiv:2608.25593*, 2026a.

Hangfan Zhang, Shao Zhang, Kangcong Li, Chen Zhang, Yang Chen, and Yiqun Zhang. Self-harness: Harnesses that improve themselves. *arXiv preprint arXiv:2606.09498*, 2026b.

Heng Zhou, Zelin Tan, Zhemeng Zhang, Yutao Fan, Yibing Lin, and Li Kang. Select-then-solve: Paradigm routing as inference-time optimization for LLM agents. *arXiv preprint arXiv:2604.06753*, 2026.

A PHASE-I 来源与条件详述

发现研究状态。 Phase I (§4.1 与 §C.1) 是发现研究。其 151 个评估项中有 24 个与首日协议开发测量重叠；人工控制是在检查首日轨迹后设计的（其观测提升空间是描述性的，不是稳定互补性的盲估计）；仓库历史为事后初始化，决策日志变更记录是权威的排序记录。Phase-I 准入阈值（联合修复率 $\geq 15\%$ 、提升空间 ≥ 5 pp、 ≥ 3 个成对不同的非空修复集合）在 151 题评估之前已于内部决策日志冻结；v6→v7 的阈值变更（20%→15%）已披露，两种读数接纳相同种群。这是内部评估前冻结，不是外部预注册。

数据卫生。 bare 基线在两次首日运行之间翻转了 60 题中的 3 题（温度 0 下的 API 非确定性），因此 60 题列以略有不同的 bare 错题集合为条件。Phase-I 评分使用行集合相等代理，我们后来测得它相对官方 BIRD 评分器一致保守（在两个记录了最终 SQL 的 Phase-I 矩阵上，它从不把官方评分器判错的答案判对；一致率 0.97–0.99）。

Phase-I 种群。 种子基线：bare（单次调用）与 react（执行反馈循环，随 TTHE 提供）。旧提议者协议：从 TTHE 优化循环输出中选出的六个候选（GLM-5.3-Flash 构建器），仅使用与评估集不相交的 36 道题、按评估前冻结的规则为行为多样性而选择。策略强制自由形式：GLM-5.3-Flash、Qwen3.8-Flash、DeepSeek-V4-Flash-Vision-Exp 构建器，各八个指派机制；GLM 种群是有日志的重跑（K=3；原 09-01 运行记录为零接纳，但其工具未保存，该观察无法审核）。Harness IR：从声明式机制规格确定性编译的六个 harness（上下文 $\in \{\text{plain, schema.link, hint.guard, link+hint}\}$ ，带温度的候选生成、逐候选执行、修复轮次、选择规则），因此声明机制按构造存在于控制流中。人工正控制：§4.1 的四个手写 harness。

生成来源缺口。 09-01 自由形式种群在会话中产出；其生成工具未保存，也不存在逐尝试日志——因此这些运行的预算相等无法审核，我们也不作此主张。它们的准入是评估时的导入 / 冒烟检查，不是 Phase-II 的反事实一致性门控。自 2026-09-03 起的在案工具（builder_generate3.py）记录每次尝试（3 次重试、16,384 token 预算、逐

尝试阶段与结束原因)；完整的逐策略网格与构建器接纳排序 (3/8、7/8、8/8) 来自该有日志工具，相对冻结的准入决定属于事后。

A.1 PHASE-I 协议探查及其局限

Phase I 还探查了生成侧修复——策略强制自由形式协议 (指派机制，导入 / 冒烟准入) 与编译式 Harness IR。在策略强制协议下，三个构建器中有两个产生的种群点估计超过预先指定阈值 (Qwen3.8-Flash 5.96、DeepSeek-V4-Flash-Vision-Exp 7.95 pp；旧协议臂为 4.64 pp 未达标)，且逐策略接纳随构建器身份排序 (在有日志工具下 GLM-5.3-Flash 3/8、Qwen3.8-Flash 7/8、DeepSeek-V4-Flash-Vision-Exp 8/8)。这些观察为 Phase II 提供动机，但不是验证性的，原因有三并已披露：设计是两个嵌套对比，无法把协议主效应与构建器主效应分开；早期运行缺少逐尝试日志，预算相等无法审核；准入是导入 / 冒烟检查，不是 §3 的反事实一致性门控。完整条件见附录 A。

生成空结果失败 (M0)。 用 Qwen3.8-Flash 与 DeepSeek-V4-Flash-Vision-Exp 构建器重跑原优化循环，产生 40 个与 bare 基线源码逐字节相同的候选。代码同一并不意味着随机执行也相同。这次运行没有提供不同代码的种群；它作为另一种更原始的失败模式报告——流水线根本没有产生不同种群。上述坍塌主张完全基于来源确实不同的首日种群。

图数据。 图 1 (正文) 背后的原始点对是代码材料中的 `fig1_phenomenon_data.json`。

B PHASE-II 协议摘要与偏差日志

权威协议 (估计目标、划分、仪器、排除规则与历史偏差变更日志) 是代码材料中的 PHASE2_PROTOCOL.md，冻结于 PROTOCOL_FREEZE.txt 记录的提交。摘要：2×2 析因加开放机制臂；六构建器 × 三种子；每槽位至多 $R=3$ 次尝试，首次接纳即停，不补足；污染寄存器 (失败即关闭，两个开发数据库整体禁用)；来自九个开发期间从未打开数据库的 1,169 题验证集加预抽取 400 题核心；官方 BIRD 评分器强制 30s 超时；以模型身份为键、跨进程加锁的响应缓存 (偏差 D13 记录并修复了采集中发现的一个缓存并发缺陷)；主对比为配对 (构建器 × 种子) 单元上的 D-A，配分层 bootstrap 与置换推断；共同核心上 Holm 校正的析因次要项；仅 K 匹配敏感性。偏差 D1-D13 包括已披露的 18 题流水线冒烟测试、在观察任何验证性结果之前所作的仪器校准修复、凭据处理事件及其补救、以及产物分歧隔离——每项在变更日志中均有理由与日期。审后修正记录于 review-stage/REVISION_20260910.md；修订结果不替代历史冻结。特别地，实际门控在结构上拒绝两种允许的提示层策略，且各组实际生成成本不同。如正文所述，修正表格使用共享基线记录与数据库 / 题目重采样。

上游代码提取审计。 在 36 个强制 C/D 单元中，全部 108 次 format_guard 尝试均未通过中性有效性：71 条日志报告 Python 字符串未终止，36 条报告无 Python 围栏，1




图 3: **Phase-II** 验证性设计（冻结协议）。左：数据库级污染隔离。中：2x2 析因与共同尝试上限，加开放机制臂 II-E。右：三层准入流程。

条报告提供方超时。存档生成器的非贪婪 Python 围栏提取器在随后第一个三反引号处终止，包括 Python 字符串内部的三反引号。三个合成的、语法有效、在普通字符串、文档字符串或正则中包含 SQL 围栏的文件变成了无效前缀；而提取器仍把其截断标志设为 false。该提取器与审稿锁定提交相比未变，但历史尝试日志未绑定其执行时来源哈希。完整构建器消息未被该生成器保存。因此失败模式与提取损坏相容，但不证明所有历史失败都由此造成，也不证明修复后的候选会通过准入。我们找到 74 个已保存的提取文件，全部语法无效；其中三个与无围栏日志并存，作为来源冲突保留，不归属于那些尝试。这些发现把一个生成接口失败置于门控显式策略排除之旁。

修正的 K 匹配与 R2 重放。 两次重放都使用与修正主分析相同的 manifest 排序 canonical 加载器与共享数据库 / 库内题目抽取，在固定构建器内重采样种子（10,000 次重复）。K 匹配中，每个 A/B 与 C/D 对使用较小候选数；每个均匀候选子集被精确枚举一次。bare 留在每个子集中，最佳固定在每次题目抽取的每个子集内部重算。这是规模敏感性分析，不是因果中介分解。保留全部 18 个单元（包括两个 A 子集为单成员的单元）使子集 D-A 从 +0.42 变为 +0.81 pp（变化 +0.39 pp，95% CI [-0.95, +1.63]）。R2 子集提升空间排除 bare，因为 R2 未获得匹配的 bare 运行，故它不同于包含 bare 的主估计目标；旧的 16 单元比较在此对账。这些是不稳定性测量，不是标准误，也不是平均处理效应的可检出下限；它们不证明每个对比都不变，也不识别 harness 间分歧中有多大部分是噪声。

R2 在 400 题上获得 70 个 harness，在可用时为每个 A/D 单元选择前两个可调用的已接纳候选。两个关缓存获取文件即使都存储 repeat=0 也保留各自身份；来源哈希与缓存运行核对。未获得匹配 bare，因此 R2 提升空间在两种条件下都排除 bare。修正分析保留单成员单元（其子集提升空间为零），得到全部 18 个配对单元。对缓存结果有 2391/28,000 次判定翻转（8.54%），两次 D 关缓存轮次之间有 1245/14,400 次翻转（8.65%）。仅为对账，限制到两臂都至少有两个成员的 16 个单元，缓存下 D-A 为

Sensitivity estimand	Estimate (pp)	95% CI (pp)
K-matched B-A headroom	-0.55	[-1.53, +0.63]
K-matched D-C headroom	-0.08	[-1.26, +0.80]
K-matched gate mean	-0.31	[-1.07, +0.40]
R2 subset D-A (cached)	+0.42	[-0.61, +1.48]
R2 subset D-A (cache-off)	+0.81	[-0.35, +1.84]
R2 change in subset D-A	+0.39	[-0.95, +1.63]

表 6: core-400、18 单元上的修正敏感性。CI 未校正。K 匹配比较始终保留 bare；R2 比较排除 bare，并以观察到的获取组为条件。

-0.11 pp、关缓存下为 +0.36 pp。这解释了与全单元估计的差别；两种分析都不识别未来执行方差、单独缓存的效应、或相对克隆的稳定互补优势。获取时间与缓存条件未被分离。

R3 仅 bare 重复审核。 R3 是一项单独的、更小的不稳定性审核：仅 bare 基线（无生成 harness）在相同 core-400 题、相同冻结目标（GLM-5.3-Flash，温度 0）上的三次独立关缓存执行。400 题中 58 题（14.5%）在三次重复中至少一次改变 bare 正确性；重复对之间的成对翻转率为 39/400、40/400、37/400（9.75%、10.0%、9.25%）。把三次 bare 重复当作三个伪成员（各一次执行）给出单次 oracle 72.25%，相对最佳单次重复准确率 65.75%，即描述性的 6.50 pp 同代码 oracle 缺口，由原始 artifacts/phase2/r3_rep{0,1,2}.jsonl 的官方评分列计算。因此 R3 测量的是温度 0 API 非确定性下基线自身的观测不稳定性。这不是任何对比的标准误差或效应大小下限，但它设定了重复控制成为解释必要项的尺度：没有它们，这个量级的 harness 对 bare 差异不能归因于能力。存档记录为 artifacts/phase2/r3_flip_rate.json，生成脚本为 experiment/phase2/run_r2r3.py。

记录成本与缺失账单数据。 相同 canonical 核心记录在 153,600 条候选一题目记录中包含 259,304 次记录的逻辑 solver 调用（表 7）。这些调用包括缓存服务的请求，不是提供方计费的 API 请求。所检查的记录均无 token 用量字段；我们不从调用数推算 token 或货币支出。因此实际生成尝试数、接纳候选数与这些执行计数保持为不同测量。种群成本均值对每个构建器一种子单元等权且排除 bare；零候选种群贡献零次 solver 调用。

B.1 审后提供方获取状态

审后的提供方获取尝试未形成完整共同池：传输中断把已完成响应、未闭合请求与未启动尝试留在不同的可审计状态中。这些记录为来源与缺失性核算保留，但被排除于关于种群表现、成本或稳定互补性的主张之外。因此，稿件不把提供方可用性或部分获取用作未解决的克隆控制问题的证据。

Arm	Candidate-task records	Logged solver calls	Calls/task/population
A	41,600	67,258	9.34
B	44,000	64,399	8.94
C	40,400	75,604	10.50
D	27,600	52,043	7.23

表 7: core-400 上的描述性 canonical 成本审核，每组 18 单元。记录的逻辑调用不是计费请求或 token 计数。末列为各单元逐题候选种群调用的平均值。

C 探索性指纹与选择分析

两项分析都是对存档验证性单元（18 个构建器×种子单元、384 个接纳候选、core-400 结果）的事后分析。版本化的 experiment/revision/ 脚本现在使用与主重分析相同的 canonical 加载器、冻结题目列表、成员关系与来源检查。它们仍是描述性的：这些题目此前已被分析过，这不是独立迁移验证。

丰富指纹。 为隔离加载器变更，W3 重分析保留旧的有损 SQL 文本变换：删除分号、替换反引号、即使在单引号分段后仍整体小写化、合并空白。这不是 SQL 解析器或语义归一化；它可能改变字面量与带引号标识符。在 364,428 个两条变换后 SQL 相同且非空的对一题观察中，有 0 个判定不同。这是观测到的一致性检查，不是按构造保证的性质。

对级 SQL 不相似度仅在判定一致且两条 SQL 非空的题目上平均 (1-token-Jaccard)。它与整体结果分歧的 Spearman 相关在 4,386 个单元内对上为 0.597，在 1,010 个组内对上为 0.588。各对共享候选与题目，且 SQL 指标以判定一致为条件；这些相关没有基于独立性的显著性或因果解释。

在 R2 的 70-harness 首次关缓存获取中，调用数在 506/28000 次比较中变化，判定在 2391/28000 次中变化。变换后 SQL 在 19569/27936 次比较中变化 (70.05%)；64 次比较缺少两条非空 SQL，仅从 SQL 分母中排除。变化 SQL 对的平均 token Jaccard 为 0.619。这些通道特定比率不定义效应大小噪声地板。canonical 逻辑调用成本在表 7 中单独报告。

多样性感知选择。 每个单元合并跨臂的全部接纳候选。重分析保留旧种子、100 次随机数据库对半划分、每划分每单元 200 次随机子集抽取及候选选择规则。它记录一个新的确定性调度：历史的集合派生单元顺序未存档，因此仅凭种子无法恢复相同的历史划分与抽取。选择使用开发数据库；评估使用互补数据库。重叠划分不是 1,800 个独立实验。方法为开发准确率 top- k 、均匀随机子集、贪心开发 oracle 覆盖、以及贪心平均准确率加 λ 倍 oracle 覆盖 ($\lambda \in \{0.25, 0.5, 1, 2\}$)。所有候选选择都在划分的评估之前于划分内冻结。

表 8 在每个被评估子集中保留共同的 AD bare； k 只计候选。JSON 还记录仅候选值以区分历史估计目标。Oracle 与最佳固定使用留出结果作为描述性上界。开发固定改为

k	Selection	Oracle (%)	Best (%)	H (pp)	Dev-fixed (%)
4	top-acc	73.98	66.64	7.34	65.10
4	random	73.90	66.03	7.87	64.66
4	div-only	74.22	66.18	8.04	65.13
8	top-acc	76.03	67.11	8.93	65.10
8	random	76.15	66.76	9.39	64.95
8	div-only	76.39	66.68	9.70	65.10

表 8: canonical 描述性 W1 重分析。每个池含 k 个选定候选加共同 bare。18 单元与 100 个重叠数据库划分上的均值；无置信区间。开发固定仅在开发数据上选择；最佳固定使用留出结果。

用开发准确率选一个成员，成员名并列时升序、bare 优先。确定性方法本就保留一个全局开发最佳候选；该比较器的差异可能来自哪些并列最大值存活，而非开发最大准确率提高。

在 $k = 8$ 时，仅多样性相对 top-acc 使 oracle 变化 +0.35 pp、最佳固定变化 -0.42 pp、提升空间变化 +0.78 pp。开发固定变化 -0.001 pp。这些是不同的量，没有一个是独立验证的路由增益。我们撤回旧的仅单元置信区间；当前表是描述性的，涵盖数据库 / 题目采样与重选择的推断仍待完成。更早的归一化提升空间比率仅保留在历史产物中，不进入修订主张。

重选择不确立区间覆盖。 一个精确反例排除了我们提出的正权重重选择百分位区间的普遍 95% 覆盖保证。令九个独立数据库各含一个 Bernoulli(p) 任务状态。16 个固定候选由八个状态 0 专家后接八个状态 1 专家组成；bare 恒错。把 canonical $k = 8$ 规则应用于四个开发库与五个留出库。在记录的并列规则下，仅多样性减 top-acc 提升空间统计量的期望为 $(1 - p^4) \mathbb{E}[\min(B, 5 - B)/5] > 0$ ，其中 $B \sim \text{Binomial}(5, p)$ 。在全部九个状态恰好相同的事件上，每种正加权都给两种方法产生零提升空间，故百分位区间为 $[0, 0]$ 。因此覆盖率至多为 $1 - p^9 - (1 - p)^9$ ，在 $p = 0.1$ 时为 61.26%。对相同单元或重叠固定划分取平均不能移除该事件。此界限针对所述构造与区间，不涉及 BIRD 特定覆盖率，也不涉及其他推断方法的不可能性。

C.1 路由与探索性选择

Phase-I 留一 harness 预测器未在所测 DeepSeek 种群中超过最佳固定 harness (-3.4 pp)；Qwen 估计为 +0.9 pp (CI [-5.2, +6.9])，题目留出的修复 AUROC 为 0.512。这些预测器与划分特定结果不确立价值预测。canonical W1 分析同样是描述性的：在 $k = 8$ 时，多样性相对 top-准确率选择使 oracle 变化 +0.35 pp、最佳固定变化 -0.42 pp、提升空间变化 +0.78 pp；开发选定固定成员变化 -0.001 pp。没有一个是经验证的路由增益（附录 C）。

D PHASE-I 补充结果

逐 harness 准确率、逐折 LOHO 表、bootstrap 区间、修复集审核、 K 子采样曲线、题目留出控制与第二目标重复（Qwen3.8-Flash 作冻结目标：坍塌重复；策略强制种群保留提升空间；提示侧人工控制未整体迁移）均连同其生成脚本包含在匿名代码材料中。

E 模型与版本

表 9 列出本文使用的每个模型及其发送给 API 的确切版本字符串。所有模型均通过单一商业 OpenAI 兼容 API 聚合器访问（每个角色都用同一提供方）；BIRD 数据采集窗口为 2026-08-30 至 2026-09-08。冻结目标始终在温度 0 调用。Phase-II harness 生成使用温度 0.7、16,384 token 预算；Phase-I 生成设置按工具记录于代码材料。Phase I 使用代理执行评分器；Phase II 使用官方 BIRD 评分器（30s 超时），旧评分器作为次要审核。MATH-500 探查使用附录 J 的答案比较器；报告的准确率无一由 LLM 评分器产生。

角色	模型（确切版本字符串）	用于
冻结目标求解器	GLM-5.3-Flash（温度 0）	Phase I-II
第二冻结目标（重复）	Qwen3.8-Flash	Phase I
Phase-I 构建器	GLM-5.3-Flash, Qwen3.8-Flash, DeepSeek-V4-Flash-Vision-Exp	§A.1
Phase-II 构建器	GLM-5.3, Qwen3.8-Max, DeepSeek-V4-Pro, Kimi-K3, MiniMax-M3, ERNIE-5.0-Thinking-Preview	Phase II
门控仪器开发	GPT-6	附录 G
控制编写	gpt-5.5 (v2/v3 集), gpt-5.6-sol (v4 集)	附录 G
盲测控制审核 / 裁决	gpt-5.6-sol (v2/v3), gpt-5.5 (v4, 语义裁决)	附录 G
评分器	代理 / 官方 BIRD 执行评分器; MATH 答案比较器	见正文

表 9: 完整模型清单。目标在每个阶段内保持冻结；Phase-II 构建器来自六个独立实验室。

F PHASE-I 轨迹审核的工作样例

为使 §4.1 的失败分类具体化，本节把一项 BIRD 任务在被告 harness 中走一遍。产物逐字取自首日轨迹审核（5 个 harness $\times$ 10 道题）；其日志器把存储的 SQL 摘录上限设为 120 字符，故截断以 *[trunc.]* 标记。完整 harness 来源与轨迹在代码材料中。

任务。 BIRD 开发集问题 352 (card_games 数据库；题目文本逐字，拼写错误为数据集原有)：

Calculate the percentage of the cards availabe in Chinese Simplified.

其 BIRD 提示:

```
'Chinese Simplified' is the language; percentage =
Divide(Sum(id where language = 'Chinese Simplified'),
Count(id)) *100
```

Gold SQL (在发布数据库上执行两者分别得 8.7734 与 8.7728——官方评分器将其区分):

```
SELECT CAST(SUM(CASE WHEN T2.language = 'Chinese Simplified'
THEN 1 ELSE 0 END) AS REAL) * 100 / COUNT(T1.id) FROM cards
AS T1 INNER JOIN foreign_data AS T2 ON T1.uuid = T2.uuid
```

bare harness 回答:

```
SELECT SUM(CASE WHEN language = 'Chinese Simplified'
THEN 1 ELSE 0 END) * 100.0 / COUNT(id) AS percentage FROM
foreign_data;
```

被官方评分器判错: 它直接在 `foreign_data` 上计数, 而 `gold` 查询在连接 `cards` 之后计数; 提示没有写明该连接。

react (T2: 机制存在但未触发)。 `react` 的控制流确实执行 SQL 并在数据库错误时重试。但其第一次调用与 `bare` 的提示逐字节相同, 而此处生成的 SQL 执行无错误, 因此错误触发的重试从不发生, 最终 SQL 与 `bare` 相同。在全部 10 道被审任务上模式都成立: 有 SQL 执行, 10/10 最终 SQL 与 `bare` 逐字节相同——反馈循环是真实代码, 但其修复分支在这些题上未激活。需要受控故障注入来检验反馈是否改变输出。

cand.bird.g1.b0r0.g0 (T1: 机制被描述但未执行)。 该候选的文档字符串宣称一种“保守修复”: 限制求解器最大输出 token 并要求仅答案块。其 `solve()` 在结构上就是 `bare`: 一次 LLM 调用, 然后 `extract_sql`。token 上限仅作为 `os.environ.setdefault` 默认值存在 (2,048 对运行时的 32,000)——没有任何 `harness` 控制流实现它, 且在这些问题上它从不生效, 因为 SQL 答案比上限低几个数量级。在工作样例题上它恰好发起一次调用、什么都不执行, 并返回与 `bare` 相同的错误查询 (忽略空白差异; 直接在 `foreign_data` 上计数而无连接)。在全部 10 道被审任务上它记录的 SQL 执行数为零, 且最终 SQL 有 6 个与 `bare` 逐字节相同 (其余差异可追溯到改写的系统提示, 而非任何机制)。因此最常见的 Phase-I 失败类不是机械损坏而是机械缺失: 声明的机制只存在于散文中。

cand.bird.g1.b0r1.g0 (代码级多样性, 行为同一性)。 该候选是一个真正不同的程序: 它把单次 `coder` 调用包在守护线程看门狗中, 若调用停滞超过 40s 就发出一次对冲重复追问。机制存在于控制流中——但其触发器 (停滞的 API 调用) 在审核中从未出现: 零次 SQL 执行, 且全部 10 道被审题的最终 SQL 都等于 `bare`。即使新增机制是真实的, 代码不同而行为相同仍可存活: 它只是从不触发。

cand.bird.g1.blr1.g1 (T3: 损坏的多轮路径)。唯一一个实现了真正执行一检查一修复的二审候选把模型的散文当作最终 SQL 返回。在一道 bare 答对的题 (“State the alternative languages available for card named Annul numbered 29.”) 上, 其记录的最终 SQL 逐字开头为:

```
with "only a single read-only SELECT is allowed". The
previous "query" was actually just prose text (the model
wrote rea[trunc.]
```

修复再提示招致了失败: 被要求修复一个 “实际上只是散文” 的查询时, 冻结目标以更多散文推理回应, 找不到 SQL 块, 推理文本便被当作查询提交。该题从 bare 正确翻转为 harness 错误。

G 仪器控制的独立构造

我们用 32 个新编写的控制测试审后 Gate-v2 开发仪器, 与开发其探针所用的控制分开。仪器先固定, 之后另一个模型 (gpt-5.5; 表 9) 只收到公开合同与可调用接口, 不接触其实现或早期控制。作者为八类机制各提供两个意图符合与两个意图不符合的实现。控制来源、作者参考标签、仪器、测量代码与执行顺序在首次评估前哈希。未运行任何基准或提供方生成, 首次测量原样保留。

声明机制	结构通过	结构失败	需审阅
修复	2	2	0
执行结果投票	2	2	0
模式链接	0	4	0
提示守卫	0	0	4
双视图	0	3	1
分解	1	3	0
错误分类	0	4	0
格式守卫	0	0	4
合计	5	18	9

表 10: 固定开发仪器对 32 个独立编写控制的首次评估。无一例发生执行失败。这些是仪器状态, 不是正确性标签或种群错误率; 作者意图的正 / 负标签需另行审查。

九个需审阅案例全部保留。第三个模型 (gpt-5.6-sol) 收到完整控制来源与轨迹, 但没有作者参考标签或自动判定, 用于对全部 32 个控制作来源一合同审查并对四类指定机制作语义裁决。独立来源审查支持一个分解控制与两个错误分类控制符合, 而仪器拒绝了它们。分解 stub 返回其文本在请求中出现的第一个计划步骤的载荷; 因此在下一请求的上下文中保留较早步骤会再次取回较早载荷。分类检查移除了确切错误文本, 但仍把普通 Schema: 标题计为一个类别, 使提取的类别集与预期错误类不一致。这些是仪器在这些控制上的失败, 不是目标模型的观测失败。三个作者意图正控制被

争议：两个模式链接控制保留了无关表，一个双视图控制批量处理其请求并错误处理空结果。其原始标签与审查分歧分别保留。在作者标签与来源审查一致的 29 个控制中，仪器拒绝了 13 个符合控制中的 3 个；全部 16 个不符合控制在指定语义审查后都被拒绝。因此仪器未通过这项有限控制检查。这些计数不估计生成种群中的错误率。指定 16 个控制的语义裁决产生 7 个符合、8 个不符合、1 个不确定。不确定案例本就有结构失败，保留该失败而不解决其语义。这个小型、刻意平衡的控制集不是生成 harness 的随机样本。通过它并不能验证生产接口或取代准入政策的共同原始池比较。来源、冻结输入、完整轨迹与裁决保留在配套修订产物中。

修订仪器与新的独立控制集。 Gate-v3 修正了分解请求归属，并把类别关键词与共享请求模板当作审阅线索而非自动拒绝。我们在新的模型上下文（gpt-5.5 编写、gpt-5.6-sol 审查）编写并审查新的 32 控制集之前固定此版本，仍为每机制两个意图正、两个意图负控制。审查包隐去作者标签、自动判定与仪器派生的归属元数据。全部 32 个控制接受来源审查；四个提示 / 表述组加分解中的 20 个控制还接受语义或数据流审查。结构结果为 8 通过、10 失败、14 需审阅，无执行失败。经一次记录在案的证据澄清，来源审查把 15 个控制分类为符合、17 个不符合；语义审查分类为 8 符合、11 不符合、1 不确定。

不确定的分类控制请求一个中间错误类别，但合成接口返回 SQL 文本。其回退随后选择了语义修复动作。这确立的是 fixture 中的响应类型不匹配，不是真实求解器的分类错误。第二个分类控制受到参考争议：其来源把提供的模式失败消息映射到语义动作。在 31 个无争议参考中，15 个符合控制有 14 个被接受、1 个仍未解决；全部 16 个不符合控制被拒绝。因此预先指定的有限检查因未决案例及错误分类缺乏足够一致的正覆盖而仍未满足。一个投票控制的符合性仅适用于结果仲裁；它未确立以任务为条件的候选生成。这些有限机制检查不验证完整 harness 运行，也不取代计划中的共同池政策比较。

运行时响应合同。 我们随后测试了七个存档的无门控、策略强制候选，按策略选择第一个可用文件名而非按表现；没有可用的格式守卫候选（附录 B）。27 个合成场景同时暴露了候选与仪器的局限。双视图候选在第一个结果非空时跳过第二次执行，与其原本“两者都执行”的声明相反。相比之下，模式链接候选请求 JSON 却收到纯文本，分解请求中的完整计划使冻结探针无法唯一归属当前目标。我们保留这些观察，并在另外 11 个开发场景中测试来源指派的响应配置。专用子问题字段识别了当前目标，可执行 SQL 载荷到达最终装配，内存 SQLite 数据库产生的四个错误引出相应的语法或模式修复指令。模式链接 JSON 改变了 SQL 编写请求中的显式表 / 列限制，但完整模式仍在场。因此仅凭保留模式上下文不能确立链接子集被忽略。这些暴露候选检查把响应接口失败与可观察的候选偏差区分开；它们不取代独立校准，也不提供修订后的基准结果。

统一接口与测量前参考审查。 Gate-v4 把来源指派的响应接口与五个未变的 Gate-v3 机制探针结合。另写的 32 控制集（gpt-5.6-sol）在执行前接受盲测来源审查。作

Arm	K_{cand}	K_{total}	Bare (%)	Best (%)	Oracle (%)	H (pp)
A	5.78	6.78	63.25	66.00	74.51	8.51
B	6.11	7.11	63.25	66.12	74.39	8.26
C	5.61	6.61	63.25	65.64	75.01	9.38
D	3.83	4.83	63.25	65.65	73.90	8.25

表 11: 同核心提升空间分解。所有臂使用相同 400 题与相同 bare 结果。 K_{cand} 排除 bare, $K_{\text{total}} = K_{\text{cand}} + 1$; 数量与准确率为单元均值。提升空间为 oracle 减最佳固定准确率, 不是已实现路由增益。

者熟悉更早的控制失败; 此来源审查中发现的模式响应与声明投票参数不匹配在保留初版的同时被修正。修订参考在每机制有两个一致符合与两个一致不符合控制。冻结其来源、配置与依赖后, 一次测量覆盖 124 个场景, 无执行异常。结构结果为 4 通过、6 失败、22 需审阅。

一个新的审查上下文 (gpt-5.5) 收到全部来源与实际轨迹, 但没有参考标签、来源审查决定或自动判定。其首次判定为 18 符合、14 不符合。在预先指定的混合规则中保留结构失败会接受全部 16 个符合参考, 但也接受一个不符合的提示控制, 故有限零错误标准未满足。该控制正确重述已有提示, 却在未提供提示时虚构了强制排序。一次记录在案的、有针对性的证据澄清纠正了这一疏漏, 也纠正了一个把同一请求的两个样本当作独立表述的双视图判定。后一控制本已被结构拒绝。澄清后的判定与全部 32 个参考一致, 但这次跟进不取代首次盲测结果, 也不构成新的独立校准通过。此检查中未执行任何仪器重跑、提供方生成或基准评估。

声明词表的范围。 这些控制覆盖八个策略强制合同, 不覆盖自由臂的四种声明 (repair、vote、twostage、plain)。在原自由提示中, vote 指定多次采样与选择但未指定三票多数投票; twostage 指定产物消费但无特定响应接口。plain 声明还指定无控制流机制, 而自由提示要求控制流变更。因此把八策略门控应用于这些声明需要另行固定语义规则与不确定政策, 而不是静默把 vote 当作 vote3 或在观察其结果后选择兼容配置。这一来源级范围缺口不估计生成候选的错误拒绝率。

G.1 同核心提升空间分解

H 诊断流程与验证 (本次修订)

五个问题类。 对一个 harness 种群与一个 bare 参考, 诊断流程在显式执行矩阵 $Y[h, x, r, c]$ (成员、任务、重复、执行条件) 上评估五类命题: **(A)** 测量充分性 (清单一致性、带显式已执行 / 未执行状态的评分器重放、同一性唯一性; 未运行的检查被报告为未运行, 且永远不能把该类渲染为 SUPPORTED); **(B)** 单次覆盖 (oracle 减最佳固定, 开发固定单独报告); **(C)** 稳定性, 分两个分开的估计目标; **(D)** 执行前可选择性 (冻结的一次调用选择政策对照开发固定); **(E)** 冻结 1 次调用预算、 $\lambda=1$ 损害加权下的预算匹配政策效用 (离线、一次调用; 除非逐任务调用预算由逐

记录证据验证或属于生成设计的一部分，否则 E 留作 INSUFFICIENT_EVIDENCE)。每类返回 SUPPORTED、REFUTED_WITHIN_SCOPE、INSUFFICIENT_EVIDENCE 或 NOT_APPLICABLE，附范围与最小缺失证据；各类绝不合并为单一分数。

两个稳定性估计目标。 *C-rank*：成对同条件准确率差，配共享题目重采样 bootstrap 与所有 $M(M-1)/2$ 个规范成员对上的 max-T 同时 95% 区间（族系错误控制；v3 之前的逐对区间未对 36 个同时比较调整），外加跨重复符号一致性；对的方向由成员身份固定，故种群结论对成员排序不变。种群状态意味着多重性调整后至少一对不同，而非完整排序稳定。 *C-comp*：一般群体的稳定互补性是 $H_{\text{stable}} = \mathbb{E} \max_h q_h(x) - \max_h \mathbb{E} q_h(x)$ ，恰在某成员在每题上都是期望最佳时为零；对两个成员它退化为式 (2) 的半绝对值形式（正文只展示该形式）。执行条件字段不同或成员来源哈希不同的重复被拒绝作为匹配重复并强制 INSUFFICIENT_EVIDENCE；逐字节相同的结果矩阵被拒绝，除非两次重复都带有不同的、显式独立的执行来源（合法的近确定性程序可以复现相同矩阵，故同一性相等触发的是来源验证而非自动拒绝）。未知单元的对级插补界与记录成功率一并报告。

v3 C-comp 判定（2026-09-19 审查之后）。 H_{stable} 的重复平均 plug-in 仅作为描述性字段保留；它从不决定科学状态。审查中的两个已知真值反例被编码为回归测试： $M=9, T=400, R=3$ 下全部 $q = 0.9$ 给出 plug-in $\hat{H} = 8.69$ pp（300 个哈希绑定模拟数据集上的均值），密封同代码克隆臂打印 2.67 pp——两者真实 $H_{\text{stable}} = 0$ 。校准统计量是 §3 所述交叉拟合冻结选择增益 G ；判定使用真实减克隆差 D 。

什么在总体层面成立、什么是经验检查的。令 $\theta^* = G$ 为冻结选择协议 S 下的种群增益。每题上被选成员的概率至多为 $\max_h q_h(x)$ ，故 $\theta^* \leq H_{\text{stable}}$ 。零假设 $H_{\text{stable}} = 0$ 是全局支配锥：存在某 h_0 对所有 h 与几乎每个 x 满足 $q_{h_0}(x) \geq q_h(x)$ 。在支配下，总体最优的冻结映射路由到支配成员，因此整个锥上总体增益 $\theta^* \leq 0$ ，不只在等能力处。这是关于总体选择器的陈述，而非有限 (R, T) 统计量：发现 argmax 是从含噪重复中选出的，较弱成员可能在有限样本中因与含噪发现分数并列而被选中（密封克隆臂打印的 $G_{\text{clone}} = 0.55$ pp 正来自这一选择噪声），所以 $\theta^* \leq 0$ 本身并不界定有限样本拒绝概率。双臂 Monte Carlo 随机化参考在等能力边界处是精确的——在该处置换标签可交换，重算统计量（配合 +1 校正）是同一条件分布的一次抽样。在支配锥的其余部分，错误支持是在下面校准网格的每个零假设 DGP 上经验验证——包括异质难度、异质支配、0.5/0.9 配置、缺失性以及两臂间匹配的黏性题内潜在状态——而不是解析地断言为有限样本结果。水平 .05 的程序在有限网格上可以以 .05 的水平错误支持；可辩护的陈述是观测到的最差比率及其 Wilson 区间，而非“不可能”。

并列处理。冻结 argmax 中的成员标签并列处理使用 iid $U(0, 10^{-9})$ 抖动，在真实数据报告上对十个冻结并列实现取平均（每个校准数据集用一次抽样：零假设下并列偏差均值为零）；确定性字典序规则不是标签不变的，被模拟拒绝。标签对称性由一个置换不变性回归测试直接断言：当成员顺序在两臂中以相同方式置换时，10 次抽样并列平均的 G 、 D 与状态在 Monte Carlo 容差内一致。

随机化机制。 标签在每个题目且每个重复内独立置换（跨重复的单一联合置换会保留真正的交叉映射，不会使统计量归零：开发中已验证），每次抽取重算两个 G 、它们的差及两个选择；+1 Monte Carlo 校正给出精确离散水平。配对题目 bootstrap 提供抽样区间；一个 $\leq 10\%$ 不完整题目覆盖门控、极值未知单元界与正 G_{real} 符号守卫补全规则，没有克隆臂时不发出 SUPPORTED 状态。

已知真值模拟校准。 二元张量从指定的 $M \times T$ 概率矩阵抽取 (experiment/diagnostics/calibration_sim.py)：常数 q 与共享题目难度的 iid 等能力；带干净支配固定成员、审查者 0.5/0.9 配置及异质支配的全局支配；以及两类潜在任务类型上强度递增的交叉备择，外加难度相关的部分交叉。网格覆盖 $M \in \{3, 9, 20\}$ 、 $T \in \{100, 400, 1000\}$ 、 $R \in \{3, 5, 10, 20\}$ 、完整数据、5% MCAR 与 3% 难度相关缺失；论文表聚焦 (9, 400, ·) 获取设计，每格 300 个 Monte Carlo 数据集（扫描中 150 个）。每格报告四种程序（plug-in；单切分冻结增益；重复交叉拟合增益；克隆校准 v3 判定）的支持、否证、弃答与错误率，对真实参数的区间覆盖，以及平均估计。结果（产物在 artifacts/diagnostics/calibration_v3/）：plug-in 在所有网格点的每个零假设上以约 1 的比率错误支持；v3 在 100 个模拟零假设单元上的零假设支持率至多 2%（最差单元 Wilson 上界 5.71%，零错误），覆盖所列零假设族、 $M/T/R$ 点、完整数据、5% MCAR 与 3% 难度相关缺失；其在备择上的功效随 R 增长（小 / 中等交互在 $R=3$ 下仍未解决，这作为弃答性质报告而非隐藏）。更早的八个机制派生类与四个基于重复的类（C9–C12，其中 C9/C10 现与注册的同代码克隆臂配对）继续匹配其哈希冻结期望状态；不变量测试还直接断言置换不变性、支配 $\neq$ 互补性、同一性拒绝及两个审查反例。

有限重复偏差与克隆零假设校准。 把 $\hat{q}_h(x)$ 记为重复平均估计，由 Jensen，对每题 $\mathbb{E} \max_h \hat{q}_h(x) \geq \max_h \mathbb{E} \hat{q}_h(x)$ ，当有限 R 噪声能改变逐题 argmax 时严格不等。plug-in 提升空间是两个此类最大值之差；Jensen 分别界定每一项，因此一般而言并不确立该差向上偏——在一个两成员两任务交叉例子中 plug-in 可能向下偏（真实 $H=0.40$ ，三次重复的期望 plug-in 约为 0.34）。被确立的是更强也更窄的命题：在同代码可交换性下，真实 H_{stable} 为零，而 plug-in 以趋近一的概率为正（逐题 argmax 上的选择噪声； $q=0.9$ 、 $M=9$ 、 $T=400$ 、 $R=3$ 的已知真值模拟中 $\hat{H}=8.69$ pp，密封克隆臂的 383 个完整任务上描述性为 2.67 pp（真实面板在另一个 350 题完整集合上打印 2.54 pp；二者不是配对比较））。因此校准程序从不凭 plug-in 判定：发现 / 验证交叉拟合在发现重复上冻结逐题成员映射，在留出重复上对照最佳固定成员评分（使全局支配成员总是被冻结选中），真实减克隆差用双臂 Monte Carlo 随机化参考移除残余的有限 (R, T) 选择噪声成分（+1 校正；在等能力边界精确，在整个支配网格上经验检查而非解析断言；附录 H）。同一性门控通过要求来源验证的独立执行直接处理退化情形；没有不同来源的相同矩阵被拒绝。

D 类与 E 类形式定义。 D 类评估一个冻结的确定性政策 $\pi_Z : Z(x) \mapsto h$ ——执行前特征（题目文本、冻结机制标签、训练折开发准确率），仅在开发任务上拟合——按

$D(\pi_Z) = \mathbb{E}_x[Y(x, \pi_Z(x)) - Y(x, h_{\text{dev-fixed}})]$ ，并带弃答规则：当 top-2 选择概率差距低于冻结边界时回退到 bare。E 类在均匀逐任务调用预算 b 、 $\lambda=1$ 损害加权（一次回归抵消一次修复）下评估 $U_b(\pi) = \mathbb{E}_x[\Delta(x, \pi(x))]$ ；仅当逐记录证据在每个被评估成员一任务对上验证预算时它才可受理，否则弃答。

在人工构建已知真值控制上的验证。冻结包有两层：原八个机制派生类 $\times 2$ 实例（16 个控制，期望不变），加四个基于重复的类 $\times 2$ 实例，演练单次控制无法到达的稳定性路径——全局支配（C-rank SUPPORTED，C-comp REFUTED）、等均值交叉技能（C-rank INSUFFICIENT，C-comp 在克隆校准下 SUPPORTED，可见层使 D/E SUPPORTED）、条件混合陷阱与克隆重复陷阱（后两者必须弃答）；C9/C10 按 v3 判定要求携带注册的同代码克隆臂。期望状态在任何盲测运行之前冻结于哈希清单，并由生成机制导出。不变量测试还断言置换不变性、支配 $\neq$ 互补性、同一性拒绝、两个 2026-09-19 审查反例（iid 噪声与 0.5/0.9 支配不得支持；交叉在重复充足时必须支持），以及判定从不在无克隆臂时支持。校准在所有状态单元上匹配；盲测集（12 个控制加 2 个审核者挑战，在当前代码下从预提交、哈希绑定的规格重新执行）在全部 14×6 单元上匹配：零错误支持，正控制被识别，弃答上限成立。这些离散控制补充但不取代 §3 的 Monte Carlo 错误支持 / 功效校准——后者才是确立 v3 检验统计规模的东西。更早存储的、其 CH2 数字与自身规格矛盾的挑战结果（生成规则强制 0.79 时最佳固定 0.94 不可达）仅作为来源保留；忠实于规格的重新执行在每个单元上匹配审核者预提交期望。

在存档上的应用。应用于 MATH-500 存档（36 成员 $\times$ 400 题）与 18 单元 BIRD Phase-II 存档。在 BIRD 上，完整性类（A）对每个单元为 REFUTED_WITHIN_SCOPE：冻结输入清单包含重叠的采集文件，其行在 canonical 键上重复（由存档的先写先得策略解决，并记录判定冲突计数），因此下述覆盖数字在该去重视图上计算，而非在无冲突存档上；评分器重放在此路径上不执行，被报告为未运行而非通过。在此范围内，所有单元显示单次覆盖（B SUPPORTED）；稳定性、可选择性与可部署性按冻结规则为 INSUFFICIENT_EVIDENCE，因为存档不含匹配重复也没有供政策训练的开发 / 评估划分——不是因为成本缺失：逐记录逻辑调用已存档，并在与其余重分析相同的规范化去重视图上读取（153,600 条候选-题核心子集记录上共 259,304 次调用，表 7），但 token / 美元成本仍不可恢复。在 MATH 上，冻结选择政策在 400 道评估题的前 80 道上训练（这 80 道从所有 D/E 命题中留出；存档不含开发集执行：附录 J 的 100 题开发划分仅用于生成冒烟测试，故政策划分从评估侧切出，留下 320 道计分题），在每道评估题上与开发固定（bare）持平，因此可选择性与可部署性为 INSUFFICIENT_EVIDENCE 而非被否定。三个已发表数字被修正（结果向量计数的成员口径，现为计入 bare 的 33/36 成员与 32/35 生成 harness；生成 harness 准确率范围 0.6825–0.915，此前印为 0.68–0.87；最佳固定 = bare 的提升空间分解明确写出），两个过载的指标名被消歧（并集全败对任一候选失败），一个保留判定控制在显式定义下确认了报告的一对数字（联合修复 76.0% / 并集全败 0.8%）。对全部 14,400 条 MATH 判定的版本化端点敏感评分器的一次哈希绑定重执行改变了其中 14 条——全是单一任务（math500_split#103）上 v1 对区间端点答案的错误拒绝；v1 重放本身内部一致，而更早存储的零翻转产物无法从提

交代码复现，已被取代。因此新评分器旨在捕获的括号合并缺陷确实在此存档中触发，且恰在一个任务上。

I WP-1R/WP-2R 新采集：协议与执行记录

冻结协议。 获取协议 (`review-stage/REAL_EVIDENCE_PROTOCOL_V1.md`, v1.0 于 2026-09-15 冻结，带日期修订：v1.1 (统计与预算修复) 与 v1.2 (操作性测试规格) 先于任何验证性结果；v1.3 (尝试上限 45,000→60,000，与任务授权匹配) 与并发修订 (2→6) 为吞吐而在采集中途作出，作为条件相关历史披露) 固定了：面板抽取 (以冻结的重复 0 平均逻辑调用 ≤ 3.05 为资格——这是一个预算可行性筛选，已披露为使面板偏向低调用机制，而非 35 个生成成员的均匀抽样；然后是加盐哈希抽取，每个构建器一个分层席位加两个自由席位，盐 `wplr-panel-v1-20260915`，记录于 `WPLR_PANEL_DRAW.json`)；每臂 $R=3$ 次新重复；九个槽位的同代码克隆臂 (`clone-cl...c9`，与 `bare` 来源逐字节相同) 作为可交换的等能力参考；冻结 MATH-500 划分的 400 评估与 100 开发任务 (SHA256 已记录)；评估任务此前在单次小型审核中分析过，故结果标注为回顾性任务 / 前瞻性执行，而非未见任务验证。

统计程序 (v3, 2026-09-19 审查之后)。 主要互补性统计量是 §3 的交叉拟合冻结选择增益 G ：三折中的每一折，用两次重复冻结逐题成员映射与最佳固定成员，第三次重复把冻结映射对照该固定成员评分； G 是逐题均值在折上的平均。并列处理是标签对称的：由于 $R=2$ 发现分数落在 $\{0, \frac{1}{2}, 1\}$ 上且高准确率下并列占主导，确定性字典序规则会使选择偏向列表中第一个成员，因此按 (折、题) 抽取 iid $U(0, 10^{-9})$ 抖动并对十个冻结并列实现取平均；一个关于支配成员位置的模拟验证该统计量与顺序无关。判定统计量是两臂都完整的任务交集上的真实减克隆差 $D = G_{\text{real}} - G_{\text{clone}}$ 。其参考分布使用 10,000 次双臂随机化：在每题每重复内，每臂独立置换成员标签并重算 D (开发中否决了跨重复的单一联合置换，因为它保留真正的交叉映射、不会使其归零)。配对题目 bootstrap (2,000 次抽取，种子 20260915) 给出 95% 区间。冻结规则仅在以下条件全部满足时发出 SUPPORTED：覆盖门控通过 (任一臂不完整题目 $\leq 10\%$ ；配对任务 ≥ 30)、随机化 $p < 0.05$ 、bootstrap 下界为正、 $D > 1.0$ pp、且 G_{real} 自身下界为正；REFUTED 要求 D 上界在界线内且等效 p 很小；否则 INSUFFICIENT。任一状态即终止研究、不再重跑的接纳规则保留。更早的 v2 程序——在重复 2-3 上对照 `bare` 评分的发现重复 `argmax (A8.6)`——作为有标签的次要统计量保留，不是互补性检验 (在 `bare` 为 0.5、其他成员为 0.9 的纯全局支配下，其期望约为 $0.5(1 - 0.1^8) \cdot 0.4 \approx 0.20$)。两个冻结敏感性分支伴随它 (题内可用重复均值插补；排除双重执行冲突单元)。

执行记录与续跑合并。 采集在 60,000 尝试全局预算与逐单元原子预留下于 2026-09-15 至 2026-09-19 进行。两次提供方超时停止 (2026-09-17、2026-09-18) 把真实臂拆到三个续跑账本、克隆臂拆到两个；每个续跑在合并时逐字段重新绑定相同的冻结求解器条件。合并规则是确定性的：已完成观察胜过 `unknown_remote` 标记；同一单元的已完成记录中最早账本胜出。在真实臂的 19,318 行中，它合并

了 8,418 个迁移副本、有 14 次优先取已完成记录而非 `unknown-remote` 标记、有 9 次补全了更早的 `unknown` 标记，并发现 5 个单元有两次已完成但不一致的执行（保留先完成者；一个冻结敏感性分支改为排除它们）。克隆臂的 14,967 行合并为 10,800 个唯一单元（4,160 个副本，0 个冲突）。72 个单元在所有账本中保持 `unknown-remote`，在结果矩阵中保持 NaN——绝不插补——故 v3 覆盖门控排除其题目（点估计 G 是完整案例统计量，在纳入题目上为精确值），并报告在对被排除题目的未知结果作全 0 与全 1 填充时 G 的情景范围（紧致填充极值，每次都重算包括选择变化在内的完整交叉拟合），记为 `missing_extremal_G_bounds`。合并后的臂经哈希密封（`SEALED_eval_real.json`、`SEALED_eval_clone.json`、`SEALED_dev_real.json`）。三个采集器来源版本跨续跑服务真实臂（并发 2/2/6）；每个密封记录该臂绑定的采集器哈希，同一性门控排除运行身份字段（获取 `id`），同时本附录披露并发与修订历史。分析代码、校准模拟及其单元测试在 `experiment/diagnostics/ccomp_v3.py`、`experiment/diagnostics/calibration_sim.py` 与 `experiment/revision/wplr_analysis.py`。

预算语义与已实现账目（E4）。 报告三种不同的比较且绝不混淆。(i) 等槽位采集：两臂都执行九个成员 / 槽位、三次重复；这是随机化设计，不意味着匹配花费。(ii) 共同逐任务执行预算 (§4.3)：在 $b \in \{3, 9, 15, 27\}$ 次逐任务执行下，离线比较开发排序面板组合与 27 次同代码执行中的 b 次，仅采用执行后 *oracle* 聚合；面板减同代码的 *oracle* 差为 +0.37, +0.03, -0.11, -0.25 pp。由于两臂输出格式不兼容（带框数字对自由散文）、模态答案键不公平，不报告跨臂多数投票准确率。(iii) 已实现花费：逐请求账目分层为实验运行 > harness 执行 > 逻辑调用 > 提供方尝试；迁移副本排除。真实臂作出 22,192 次逻辑调用（32,097 次提供方尝试；54.17 M 已知 token；每评估题 54.5 次调用），而克隆臂为 10,800 次逻辑调用（10,804 次尝试；14.51 M token；每题恰好 27 次）——由多调用面板成员驱动的 $2.05\times$ 调用比与 $3.73\times$ token 比；在冻结盈亏平衡价下的保守上限为 1,803.82 对 483.15 元人民币（定价不可独立验证；报告为 token 数乘以冻结的每 1M token 33.3 元，绝不作为计费金额）。全部臂的总计：38,458 逻辑调用、50,817 尝试、79.8 M 已知 token、2,656.22 元上限。因此我们不作已实现成本匹配主张；共同预算表才是成本受控的比较。

选择器规格（E3）。 π_Z 是在 TF-IDF 题目特征（最多 300）与仅在训练折内计算的逐成员开发准确率上的多项 logistic 回归；在 100 道开发题上作 5 折题目级 CV，问题重复绝不跨折拆分；折模型平均；并列以成员 `id` 打破；当 top-2 概率差距低于 0.15 时弃答至 bare。重复聚合使用逐成员一题的可用重复均值（问题重复留在一折）。比较器：bare、开发固定、预先固定随机成员（带种子）、M1b（缺失单元上带 bare 回退的开发固定）。 E_1 （预算按构造满足）不适用，因为面板成员发起不止一次调用； $b=3$ 次逐题调用的 E_b 作为单独命名的估计目标报告。泄漏控制：不使用答案、正确性、评估派生难度、执行后轨迹或评分器特征。

Policy	Eval acc. (%)	Δ vs dev-fixed (pp) [95% CI]
bare (fixed)	94.96	0.00 [0.00, 0.00]
dev-fixed	94.96	—
random (pre-fixed)	85.14	-10.12 [-13.27, -7.22]
M1b (dev-fixed + bare fallback)	94.96	0.00 [0.00, 0.00]
π_Z (frozen selector)	94.96	0.00 [0.00, 0.00]

表 12: 400 道 MATH-500 评估题上的 WP-2R 冻结比较器集（三次新重复的重复均值正确性；回顾性任务、前瞻性执行——不作未见任务主张）。配对差为逐题对照开发固定，配题目级 bootstrap CI。

J 跨领域重复：MATH-500 小型审核

为检验 Phase-II 干净协议的发现（无门控自由生成产生不同的单次正确性向量）是否为文本转 SQL 所特有，我们在竞赛数学上重复了自由臂协议。

协议。 六个构建器（与 Phase II 相同模型），一个种子，各八个槽位，每槽位 $R=3$ 次原始尝试上限，中性有效性门控（机制盲：在两道开发题上检查解析、导入、接口与非空答案）。冻结目标 GLM-5.3-Flash（与 SQL 研究相同），温度 0。MATH-500 (Lightman et al., 2023): 500 道题在生成前冻结（100 开发 / 400 评估，种子 20260908）。100 道开发题仅用于生成侧冒烟测试，从不在评估存档中执行；因此附录 H 的选择政策实验从评估侧切出其训练划分（80 道题），留下 320 道计分题供 D/E 命题。评分器：两侧均解析为数字时取数值相等（含 a/b 、 $\frac{a}{b}$ 、小数），否则取归一化 LaTeX 字符串相等（去除单位、进制下标、°；保留 X 内容； $\text{pmatrix} \rightarrow$ 元组）。评分器自洽性：400/400 标准答案与自身比较均判对。匹配答案格式指令下 bare 准确率为 0.9375。产出：48 槽位接纳 35 个（ R_{artifact} 0.10–1.00；两个重推理构建器 GLM-5.3 与 Qwen3.8-Max 在多数槽位于发出代码前即耗尽 32k token 生成预算——按实际情况报告）。这一约束实际上把六个构建器中的两个移出了被评估池，因此自由臂种群对重推理构建器风格代表性不足；我们不在事后调整预算，该限制是所报告协议的一部分。这是重复探查，不是析因研究：无策略强制、无一致性门控。

结果（35 个 harness，400 道评估题）。 平均成对结果分歧 10.6%（最大 33.0%）；计入 bare 时 36 个成员中 33 个有唯一结果向量（35 个生成 harness 中为 32 个）；结果相同的对占 0.7%——没有 Phase-I 式坍塌的迹象。对 bare 错题的联合修复为 76.0%；全部生成候选的并集在 0.8% 的 bare 答对题上失败（这是并集全败率，不是任一候选或路由器损害）。观测 oracle 覆盖超出 bare 4.75 pp，而最佳固定成员就是 bare 自身（0.9375；生成 harness 为 0.6825–0.915）：每个生成成员单独都更差。单次小型审核最初未采集重复执行或同代码克隆控制；这一缺口由同一 MATH-500 题集上新的预注册 WP-1R 采集补上（§4.3），它对一个八成员面板与九个同代码克隆槽执行三次独立重复，因此确实跨领域评估了稳定性估计目标。对全部 14,400 条存档判定的版本化端点敏感重评分的一次哈希绑定重执行改变了其中 14 条（0.097%）：全部是单一任务上 v1 对区间端点答

领域 / 分析	n_H	n_{eval}	分歧	Oracle	最佳固定	H (pp)
BIRD, A / D	18 单元	1,169	—	76.14 / 75.70%	67.58 / 67.30%	8.56 / 8.40
BIRD, D—A	18 配对	1,169	—	—	—	—0.16
MATH-500, 自由	35	400	10.6%	98.50%	93.75% (bare)	4.75

表 13: 同一测量问题的平行领域证据。BIRD 是存档析因分析；MATH-500 是单种子探索性自由臂探查。两种设计不合并。提升空间是单次诊断量，不是选择器准确率或稳定互补性。

案的错误拒绝，因此逐成员准确率至多上升一道题，任何定性结论都不变（附录 H）。一个更早的、报告零翻转的已存储产物无法从提交代码复现，仅作为来源保留。

两项失败侧观察。 第一，干净协议的多样性结果在第二个领域、不同输出空间上得到重复。第二，一个被隔离的试运行轮次（在 `PROTOCOL_CHANGELOG.md` 的 G1 条目中披露）提供了一项探索性比较：当相同六个构建器（被错误地）收到数值答案格式与 MATH-500 不匹配的 GSM8K 风格任务描述时，生成种群仍保持行为多样（16.2% 分歧，19 个唯一结果向量），但其联合修复坍缩至 18%——对灾难性成员的代码级检查逐字复现了 Phase-I 轨迹分类（一个先生成后验证的 harness，其验证器拒绝几乎所有答案，其回退返回过时的循环变量或“0”）。有多多样性而无效用，由代码级检查不可见的提示侧协议错误诱发：检测到它的是测量任务本身，而非任何代码级审核。

范围。 一个种子、一个目标、无析因、探索性；造成 Phase-I 坍缩的 SQL 协议未在数学领域重跑，因此本重复只说明干净协议的结果，不涉及坍缩的边界。

J.1 测量边界的平行领域证据

表 13 把两个领域就同一诊断问题并列呈现，但不合并。MATH-500 复现了该边界：单次分歧与 4.75 pp 提升空间与 bare 作为最佳固定成员（93.75%）并存。单次探查本身没有修复门控控制；克隆、重复与选择器控制来自单独的新 WP-1R 采集（§4.3）。