

诊断 AI 生成 HARNESS 群体中的表观互补性 (中文参考译本)

Anonymous authors

Paper under double-blind review

ABSTRACT

自动生成的 LLM harness 提供了丰富的设计空间，但其源代码、执行与结果多样性必须分别测量。我们定义五类分别报告的命题——测量充分性、单次覆盖、稳定排序、稳定互补性、执行前可选择性，以及预算匹配效用——并为两项稳定性命题给出控制规模的检验。互补性检验在发现阶段重复上冻结逐题成员映射，在留出重复上对照最佳固定成员评分（此时全局支配不可能被看成互补性），再用同代码克隆臂与 Monte Carlo 随机化检验进行校准。已知真值模拟在不同成员数、题目数和重复数下确立其错误支持率与功效：旧的重复平均估计量在我们测试的每个零假设情形下都对纯执行噪声给出错误支持，而校准检验把错误支持率保持在名义水平，并且只有在重复数足以支撑可靠映射时才检出交互。应用于一项新的预注册 MATH-500 采集（八个生成 harness 与九个逐字节相同的 bare 克隆槽，各三次独立重复），面板呈现稳定的成员排序，但克隆校准的选择增益为 -0.10 pp (95% CI $[-1.55, 1.46]$ ；随机化 $p = .7742$)：证据既未确立其在声明的 1 pp 界线上超过同一固定程序的独立执行，也未确立等效；冻结的覆盖门控使判定保持为 INSUFFICIENT EVIDENCE（证据不足）。在 BIRD 文本转 SQL 上，轨迹检查与版本化析因重分析（ -0.16 pp, 95% CI $[-0.83, +0.87]$ ）记录了单次运行数字无法确立的内容。该框架把表观多样性转化为可审计的证据，并且按构造不会制造它所寻找的互补性。

1 引言

LLM harness 是包裹冻结模型的一组提示、工具与控制流程程序。自动生成大量这类程序带来一个评估问题：什么证据能够说明一个新程序提供了新能力？不同代码可能执行相同路径；不同路径可能给出相同答案；而一次运行中不同的答案可能反映执行随机性，并非可重复的优势。

我们在 BIRD 文本转 SQL 任务上研究这一问题 (Li et al., 2023)。在 Phase-I 发现种群中，66 对生成候选中有 21 对的正确性向量完全相同（计入 react 与 bare 后，91 对中为 36 对），而代码相似度与结果分歧没有秩关联 ($\rho = -0.01$)。轨迹检查发现三种情

形：宣称的机制不在控制流中、机制存在但未触发、多轮实现失效。这些观察促使我们审核测量流程；它们并不证明生成的 harness 普遍坍塌。

后续一项预先指定的析因研究在六个构建器、三个种子上交叉设置策略强制与一致性门控。其主评估使用协议开发之外九个数据库的 1,169 道题，另有一项已披露的 18 题冒烟测试例外。在这一修订后的设置下，无门控自由生成已产生 8.6 pp 的观测 oracle 提升空间；Phase-I 的模式没有重现，但生成方式、评分器、数据与执行均发生变化，缺少受控桥接实验时不能归因于任一协议组件。门控还改变了可接纳的策略空间：两种允许的单次调用提示变换无法通过其机制检查。我们保留该实验并报告版本化的审后重分析；主对比仍为 -0.16 pp (95% CI $[-0.83, +0.87]$)，既未证明改善，也未确立等效性。

我们在当前阶段的贡献是一种带有校准统计保证的测量方法，加上两个实证案例研究：

1. **代码、轨迹与结果多样性各不相同。**发现阶段的例子说明，为何未激活的分支与缺失的机制需要不同的检验。
2. **准入与推断定义了比较的含义。**一项析因研究及其数据与统计链条的明确修正，说明实际被评估的是哪项干预、其估计支持什么。
3. **观测 oracle 价值不是稳定或可用价值。**重复不稳定性要求分别报告 oracle 准确率、最佳固定准确率、重复运行优势与实际选择器表现。
4. **规模校准的诊断区分各类命题。**互补性判定把冻结选择器与最佳固定成员交叉拟合，并以同代码克隆随机化零假设校准；模拟显示旧的 plug-in 对纯噪声错误支持，而校准规则保持名义水平，并按重复数如实报告功效 (§6)。

决定性问题是：不同的生成程序能否在相同执行次数花在同一固定程序上之外，带来冻结选择收益，且这种优势能在独立重复中保留。一项新的预注册 MATH-500 采集恰好提供这一控制 (§5.4)。在该面板上，增益位于声明的 1 pp 界线之内，但由于覆盖缺口，形式上是 INSUFFICIENT EVIDENCE（证据不足）而非强否定：克隆校准差为 -0.10 pp (CI $[-1.55, 1.46]$)。因此，稳定互补性仍是一个需在其他面板与领域上以更多重复检验的估计目标，而不是本面板已发现的性质。

这一边界为群体构造指出了一个更锐利的对象：有用的路由取决于分离执行噪声之后稳定的任务—harness 交互——这正是我们的诊断所要检验的估计目标。

2 相关工作

2.1 面向 LLM 的 HARNESS 生成

一系列工作围绕冻结模型生成任务专用的外围程序。TTHE 通过 LLM 提议者 / 评判者循环演化文本转 SQL harness (Nie et al., 2026)；Self-Harness (Zhang et al., 2026b) 展示模型可以改进自己的 harness；JIT-Agent (Zhang et al., 2026a) 训练模型在推理时为每道任务生成一个 harness；Task-CoEvolve (Miyai et al., 2026) 联合演化任务与外围程序。2026 年的一组同期工作从验证侧使 harness 演化具备行为意识：HarnessLens (Xu

	本研究	HarnessLens	HarnessBank
研究单位	种群结果矩阵	演化循环	多样性库
测量种群坍塌	是	否	仅搜索坍塌
门控定义	反事实轨迹	可归因证据	语义筛选
门控校准	正 / 负控制	—	—
门控比较	析因, 混合筛选	门控消融 (单因素)	无
验证性划分	九个隔离数据库	—	—

表 1: 最接近的同期系统。演化系统内部的行为感知验证属于同期独立工作; 我们的贡献是种群级结果测量、仪器校准与生成策略对比。当前门控包含结构性筛选; 数据库划分存在一项已披露的 18 题冒烟测试例外。

et al., 2026) 在演化过程中以行为级检查分配 rollout 预算; HarnessFix (Chen et al., 2026a) 根据有轨迹依据的诊断修复 harness; AHE (Lin et al., 2026) 按每次提议编辑自述的行为预测加以验证; 带门控的语义质量—多样性搜索 (Luo et al., 2026) 按 LLM 指派的病理描述符演化种群; Harness Handbook (Wang et al., 2026) 攻行为定位与外层搜索; HarnessForge (Chen et al., 2026b) 将外部 harness 与内部策略作为一对联合演化。演化整个执行结构带来两项成本, 正是我们诊断的动因: 逐候选算力, 以及脆弱的准入验证。我们在任何部署主张之前, 离线地剪去冗余变体并拒斥虚幻的单次运行 oracle 增益。

我们的工作互补, 但分析单位与问题不同。表 1 对比两个最接近的系统。HarnessLens 将行为用作演化循环内部分配算力的信号; 我们追问所得种群作为一种结果性质是否行为多样, 以及它在生成侧干预下如何变化。HarnessBank (Luo et al., 2026) 记录搜索空间坍塌, 并以带门控的筛选维护语义多样性库; 我们的一致性门控完全不做语义评分——它通过反事实轨迹探针机械地验证声明机制确实执行——并且我们的设计通过析因对比比较准入策略。由于实际门控也排除了允许的提示变换, 当前实验并未分离验证的因果贡献。

2.2 HARNESS 的条件效用与路由

Harness 质量是以实例为条件的: Gupta et al. (2026) 与 Cho (2026) 记录了不存在跨实例占优的单一 harness。HELIX 评估完整的同源 harness 结果矩阵及超过最佳固定候选的组合互补性, 并把路由器列为未来工作 (Fan & Huang, 2026)。STS 在六种固定的人工设计外围程序间路由 (Zhou et al., 2026); GRASP 把技能编辑经门控纳入开发期库 (Moll et al., 2026); Kim (2026) 在 {不搜索、搜索、弃答} 上学习实例级路由; Liu et al. (2026) 在 harness 内部路由模型。经典算法选择 (Rice, 1976) 与 SATzilla 等组合求解器 (Xu et al., 2008; Kotthoff, 2014) 根据实例特征选择被枚举的算法。

这里的决策边界就是定量交互与定性 (交叉) 交互之间的经典边界: 仅效应大小的变化未必改变首选动作 (Gail & Simon, 1985)。集成选择同样是在模型库上优化一个验证目标, 其信息集与执行前选择单个成员不同 (Caruana et al., 2004)。类似地, 自治性增

益来自运行多条采样轨迹并聚合，因此其成本与采样后信息不同于执行前单成员路由 (Wang et al., 2022)。

我们的候选是完整的自动生成 harness。我们测量选择器将继承的种群结果结构 (§C.1)，而非构建选择器。Kwok et al. (2026) 将执行后验证形式化为生成一选择瓶颈；他们对已完成的轨迹评分，而我们的 D 类估计目标 (§6) 在执行前选择 harness，信息集不同。我们诊断执行路径，并通过一项处理包含结构性筛选的析因研究比较生成策略；本研究并未确立稳定的可选择价值。

2.3 LLM 种群的行为多样性

LLM 输出的多样性大多在样本层面（自洽性、多样化解码）或智能体策略层面得到研究。从固定生成器重复采样本身就会产生多样结果 (pass@k; Chen et al., 2021)；我们的克隆控制是其执行层面的对应物——同一固定程序的一组同槽位独立执行。语法不同的程序表现出相同行为，与经典的程序等价 (Budd & Angluin, 1982) 和等价变异体 (Papadakis et al., 2019) 结果相邻；我们把该问题具体化到 AI 生成的 harness 种群上。

3 PHASE I: 坍缩的测量与诊断（发现研究）

Phase I 是一项发现研究：其作用是确立现象、分类与题目侧提升空间的存在，并为验证性设计提供动机。其任何结果都不是验证性的：151 个评估项中有 24 个与协议开发测量重叠，人工控制是在检查开发轨迹后设计的，其评分器是一个保守代理（附录 A）。我们在明确这些限制的前提下报告它。

3.1 HARNESS、结果与三项指标

Harness H 包裹一个冻结的目标模型 M ：它接收自然语言任务 x ，对 M 发起一次或多次调用，可选地执行中间产物（如 SQL），并返回以程序化方式评分的最终答案。以 H_0 为单次调用的 bare 基线、 $Y \in \{0, 1\}$ 为正确性，**harness 边际价值**为 $\Delta(x, H, M) = Y(x, H, M) - Y(x, H_0, M) \in \{-1, 0, +1\}$ （+1 为修复，-1 为 harness 引入的损害）。

我们建议 harness 生成与 harness 路由流程在留出集上报告三项前提指标，它们都可从任何评估本就产生的结果矩阵计算：**(i) 成对结果分歧**——在所有 harness 对上，正确性不同的题目比例；**(ii) 联合修复率**——bare 错题中被某个种群成员修复的比例；**(iii) 包含 bare 的 oracle 提升空间**——在留出题目 $x_1, \dots, x_n$ 上，

$$H(P) = \frac{1}{n} \sum_{i=1}^n \max_{H \in P \cup \{H_0\}} Y(x_i, H) - \max_{H \in P \cup \{H_0\}} \frac{1}{n} \sum_{i=1}^n Y(x_i, H).$$

正的观测提升空间记录的是该执行矩阵中依题目而异的成功；要确立稳定的路由信号需要独立重复。有分歧而无修复，不增加超出 bare 的观测覆盖；有修复而无提升空间，不增加超出最佳固定成员的观测 oracle 优势。

3.2 坍缩的量化

领域为 BIRD 文本转 SQL (SQLite; 执行准确率评分), 整个 Phase I 目标冻结为 **GLM-5.3-Flash** (温度 0)。在首日种群——14 个 harness (**bare**、**react** 与 12 个演化候选) $\times$ 60 道题——上, 平均成对结果分歧为 **3.3%**, 且 **91 对中有 36 对在每道题上都相同**; 仅看 12 个生成候选 (66 个候选对; 原代码差异检查的归一化字符指标下平均成对代码相似度 0.143), 分歧为 3.8%, 21 对完全相同。每个候选都通过了代码差异检查 (“所有文件互不相同, 差异非平凡”)。对 **bare** 错题的联合修复率为 7.7%, **oracle** 提升空间为 3.3pp; **react** 与 **bare** 在零道题上有差异。

图 2 (附录 A) 把核心关系定量化: 在全部 91 对上, 该图 token 序列指标下的源代码相似度与结果分歧的 Spearman $\rho = -0.010$ ——代码相似度在此与行为相似度没有观测到秩关联。(各对相互重叠; ρ 是描述性的, 不是推断性的。)

3.3 轨迹分类: 代码多样性为何未能成为行为多样性

审核执行轨迹把 “不同代码” 分解为三类失败: **T1——机制被描述但未执行 (6/12 个候选)**: 一次调用, 不执行任何产物 (与 **bare** 路径相同; 文档字符串宣称的检索或自检并不存在); **T2——机制存在但未触发 (react, 10/10 道题)**: 第一条 SQL 即成功, 因此错误修复从不触发, 最终 SQL 与 **bare** 相同 (这并不表明修复路径在失败时缺乏因果作用); **T3——多轮路径失效 (1/12)**: 自然语言散文被当作最终 SQL 返回, 把 **bare** 答对的题变成 harness 答错。T1 需要执行路径准入门控, T2 需要受控故障, T3 需要可执行输出验证。

3.4 人工正控制: 提升空间确实存在

四个手写 harness 具有强制区分的执行路径 (执行后修复; 三票投票; 模式链接; 提示前置重排), 使用相同的冻结目标与评分器, 在 60 道题上给出 **6.67 pp** 的 **oracle** 提升空间, 在 151 题集合上为 **7.28 pp** [3.3, 10.0], 且每个机制都修复了其他机制漏掉的题。该控制是在检查首日轨迹后设计的, 因此其提升空间是描述性的, 不是盲测的; **bare** 自身在两次温度 0 的首日运行之间翻转了 60 题中的 3 题。

4 PHASE II: 验证性生成研究 (设计)

Phase II 是验证性研究。其协议在观察到任何验证性结果之前即冻结并提交 (一个例外: 18 题流水线冒烟测试, 其聚合准确率曾被观察且题目被保留, 在协议变更日志中作为偏差 D1 披露); 偏差均记录于协议变更日志 (附录 B)。以下概述冻结的估计目标、划分、仪器与分析计划。

4.1 设计

实验组。 两个交叉因素: 策略强制 ($S=1$: 构建器被指派固定八种机制中的一种具名机制; $S=0$: 构建器在不指定机制的情况下自行发明改进) 与一致性门控 ($G=1$: harness

必须通过冻结的一致性套件； $G=0$ ：仅中性有效性）。这给出四个析因组，记为 **II-A**（自由 / 无门控）、**II-B**（自由 / 有门控）、**II-C**（强制 / 无门控）、**II-D**（强制 / 有门控）。第五个预先指定的次要组 **II-E**（开放机制发现：构建器在通用轨迹原语上发出自行指定的行为合同，按其自身声明门控）检验机制多样性是否根本需要作者供给的词汇；它被有意置于析因之外。每个单元有八个槽位：强制组中为八个被指派机制，自由组中为同一自由提示的八次独立生成。在有门控自由组（**II-B**）中，构建器从固定的四词词表（`repair`、`vote`、`twostage`、`plain`）发出自行声明的机制；门控对照轨迹验证声明的场景。这些声明比强制合同窄，且该映射是操作性的、未经独立校准（附录 G），因此 B 组种群不是 A 组的嵌套子集，产出也不必有序。这些组名专用于 Phase II；§A.1 中的 Phase-I 条件一律以其描述性名称指代。

实际实施的处理；共同尝试上限。 原门控把 `hint_guard` 与 `format_guard` 都映射为返回 `NO_MECHANISM_declared` 的普通场景；准入要求 `PASS`。因此八个强制策略槽位中的两个即使中性有效也无法通过，并且两个强制组中都没有 `format_guard` 候选通过中性有效性（一项提取审计发现内嵌 SQL 围栏会截断本属有效的 Python，附录 B）。我们把 G 解释为非平凡机制筛选加一致性验证；存档结果不能识别纯验证。每个槽位至多有 $R=3$ 次原始构建尝试（同一模型，温度 0.7，16,384 token 上限），首次接纳即停；A/B/C/D 记录的原始尝试总数为 269/255/273/324，token 成本未完整恢复。槽位失败即终局（不补足），因此生成可靠性是处理的一部分，并通过三个比率单独报告（附录 B）。

构建器与种子。 六个来自独立实验室的构建器（GLM-5.3、Qwen3.8-Max、DeepSeek-V4-Pro、Kimi-K3、MiniMax-M3、ERNIE-5.0-Thinking-Preview），各三个种子：18 个配对（构建器 $\times$ 种子）单元——即项目单一 API 网关上最强的模型；当时无法访问 Anthropic 或 OpenAI 家族的构建器，因此前沿能力依赖性未经检验。每个单元都进入主对比，无论接纳种群大小如何，包括 $K=0$ ；排除低产出单元会以处理后结果为条件。

数据隔离。 一个失败即关闭的污染寄存器扫描每个项目产物中曾被观察的 BIRD 题目。开发期间接触过的两个数据库被整体禁用；验证性评估使用来自九个开发期间从未打开过的数据库的 1,169 道题，另有一个在结果出现前抽取的分层 400 题核心集（跨九库按比例分配，种子 20260904；未使用任何结果变量；不声称预训练时段隔离；18 题冒烟接触是已披露的例外）。析因次要分析在全部四组上使用相同核心题。

评分器。 主评分器：官方 BIRD 执行评分器（原始结果行的集合相等，30s 墙钟超时）。次要评分器：Phase-I 旧评分器，经测量一致地保守（在 Phase-I 矩阵上它从不把官方评分器判错的答案判对）。

仪器。 一致性套件以脚本场景驱动每个 harness，并对记录的执行轨迹断言，从不针对任务表现，因此门控不会泄漏结果监督。每个机制都用成对反事实变体探针探测，这些变体的正确答案不同——包括第一个查询成功的变体，以把条件修复与无条件第二次调用区分开。仪器以手写正 / 负控制校准，并在每批生成前重跑（图 3，附录 B）。

Metric	II-A	II-D
Candidate count	5.78	3.83
Oracle accuracy (%)	76.14	75.70
Best-fixed accuracy (%)	67.58	67.30
Headroom (pp)	8.56	8.40
D-A headroom (pp)	-0.16	
Unadjusted bootstrap 95% CI	[-0.83, +0.87]	
One-sided sign-flip p	0.647	

表 2: 原干预的修正主分析。1,169 道题上 18 个构建器一种子单元的均值。oracle 与最佳固定比较器均包含 bare。CI 纳入题目与生成种子变异, 以六个固定构建器及存档执行记录为条件。符号翻转参考检验以观察到的题目为条件, 并假设单元对比对称。

4.2 冻结分析计划

主估计目标是完整 1,169 题集合、官方评分器下, (构建器 $\times$ 种子) 单元上包含 bare 的 oracle 提升空间的配对差 $H(\text{II-D}) - H(\text{II-A})$ ——一个连续效应, 配双侧 95% CI 与配对置换检验, 绝不设通过 / 失败阈值。对角对比是主要的, 因为两个因素在生成流程中是一起部署的; 主效应与交互作为次要项将其分解。Phase-I 阈值仅作为描述性清单保留。验证性次要项 (Holm 校正, 全部四组在相同 core-400 题上): 门控主效应 $[(B-A) + (D-C)]/2$ 、策略主效应 $[(C-A) + (D-B)]/2$, 以及二者交互 $(D-C) - (B-A)$ ——即策略差异化是否需要执行保真才能实现。原计划与修正后的推断: 原代码漏掉了库内题目重采样, 只重采样单元摘要。版本化的审后分析在全部组与单元间使用 10,000 次共享的数据库 / 库内题目抽取, 构建器保持固定, 在构建器内部重采样生成种子; 它不加入执行重复方差, 而每个构建器只有三个种子, 种子成分可能低估真实生成变异 (一项已报告的数据限制)。精确符号翻转参考检验以观察到的题目为条件、以单元对比的符号对称性为条件 (主检验单侧; 次要检验双侧并作 Holm 调整)——不是随机化因果检验。 $H(P)$ 对 K 不单调——加入一个全对的 harness 会把提升空间驱向零——因此是匹配 K 比较、而非单调性, 许可跨种群主张。 K 匹配敏感性、完整估计目标定义与稳健性审核 (双评分器、关缓存复现、重复稳定性) 连同协议偏差日志在附录 B 中规定。

5 PHASE II: 结果

5.1 原门控实验的修正重分析

以下表格报告的是存档结果的审后重分析, 而非用修复后的门控做的新实验。原分析文件仍可获取。所有修订表格使用同一 canonical 输入顺序下的全精度结果; 四组分析在相同 400 题上复用相同的 bare 记录。修订区间在全部组与单元间使用共享的数据库与库内题目抽取, 并在六个固定构建器内部重采样生成种子。




图 1: 版本化修正重分析。左: 完整集 D-A 单元对比与合并的未校正 95% 区间。右: 相同 core-400 题上以共享 bare 为基线的四组提升空间。两轴均为百分点。不使用显著性星号; 原始与校正后 p 值见表 3。

Contrast	Effect (pp)	95% CI (pp)	Raw p	Holm p
Gate	-0.69	[-1.56, +0.20]	0.026	0.079
Strategy	+0.42	[-0.32, +1.51]	0.263	0.428
Interaction	-0.87	[-2.83, +0.65]	0.214	0.428

表 3: 修正的 core-400 析因重分析。门控为 $[(B - A) + (D - C)]/2$, 策略为 $[(C - A) + (D - B)]/2$, 交互为 $(D - C) - (B - A)$ 。CI 为未校正的数据库 / 题目 / 种子 bootstrap 区间。原始 p 值使用双侧单元符号翻转; Holm 对三项次要检验校正。两类程序处理不同的变异来源。对比由全精度单元级数据计算; 从表 11 的舍入单元均值重算可能相差至多 0.1 pp。

配对估计为 -0.16 pp, 未校正 95% CI 为 [-0.83, +0.87], 单侧符号翻转 $p = 0.647$: 没有明确改善, 区间也未确立等效性。单元对比范围为 -4.36 to +2.74 pp。这些是实际实施的筛选政策的估计, 不是纯验证干预。

5.2 析因效应与绝对表现

门控估计为 -0.69 pp; 其 Holm 校正后 $p = 0.079$ 未达到 0.05, 因此无法把有益验证与门控对提示变换的结构排除区分开。固定 K 敏感性为 -0.31 pp (CI [-1.07, +0.40]); 提升空间对种群规模不单调 (附录 B)。D-A 使 oracle 准确率变化 -0.44 pp、最佳固定变化 -0.28 pp (表 11, 附录 G.1)。

预先指定的次要组 II-E。 开放机制组仅在开发侧运行过一次, 从未在验证性划分上评估, 因此它没有提升空间估计目标 (附录 B)。

5.3 执行变异性与稳定互补性问题

独立执行使单次运行比较失稳: canonical R2 重放发现 2391/28,000 次同 harness 判定翻转 (8.54%), R3 审核发现 14.5% 的题目至少发生一次 bare 正确性变化 (附录 B);

budget b (exec./task)	panel oracle (%)	same-code oracle (%)
3	98.00	97.63
9	98.25	98.22
15	98.25	98.36
27	98.25	98.50

表 4: 共同逐任务执行预算, 对密封 **MATH-500** 重复的离线重放。开发排序面板组合与 27 次同代码 **bare** 执行中的 b 次的执行后 oracle 覆盖 (最佳官方判定结果, 是需要事后验证器的上界) (1,000 个带种子子集; 95% 范围在 0.3 pp 内)。不报告跨臂多数投票准确率, 因为两臂使用互不兼容的答案格式 (附录 I)。

把三次 **bare** 执行当作三个“成员”会给出描述性的 6.50 pp 单次 oracle 差距——单次提升空间可以来自执行采样, 而非新能力。稳定提升空间对同代码克隆池以及在全局支配下均消失 (式 1); 其有限重复 **plug-in** 未经校准 (§6), 因此下面是使用规模控制程序的、新的克隆控制采集 (§5.4)。

5.4 MATH-500 上新的克隆控制证据

存档缺少匹配重复与同代码控制, 因此无法把稳定互补性与单次运行的采样运气分开。一项预注册采集 (2026-09-15 冻结; 附录 I) 在 400 道 MATH-500 任务上对一个冻结的八 harness 面板加 **bare** 执行三次重复, 并对九个等槽位、逐字节相同的 **bare** 克隆槽执行相同重复; 我们把“等预算”保留给下文共同执行预算比较。

估计目标与结果。 我们把三个量分开: (i) 描述性的重复平均 **plug-in** $\hat{H}$ (此处为 2.54 pp, 在克隆臂上也为正的 2.67 pp——已知真值模拟显示它在纯噪声下错误支持); (ii) 交叉拟合的、对照最佳固定成员 (绝不对照 **bare**) 的冻结选择增益 G ($G_{\text{real}} = 0.17$ pp, CI $[-0.82, 1.31]$; $G_{\text{clone}} = 0.55$ pp, 因此有限 (R, T) 选择噪声与面板增益同阶); (iii) 在 342 个配对完整题目上校准的真实减克隆差 $D = -0.10$ pp (CI $[-1.55, 1.46]$, 随机化 $p = .7742$)。C-rank 在多重性校正区间下为 SUPPORTED。覆盖门控未通过 (真实臂 12.5% 的题目被排除, 高于冻结的 10%), 因此 C-comp 为 INSUFFICIENT_EVIDENCE: 这不是不存在性的证明, 区间上端也未在 1 pp 上确立等效; 未知单元极值把 G 界定在 $[0.33, 0.75]$ pp。

共同执行预算。 槽位不决定花费。表 4 在密封重复上离线比较开发排序的面板组合与 $b = 3, 6, \dots, 27$ 时 27 次同代码执行中的 b 次: 执行后 oracle 覆盖在每个预算上均持平 (-0.25 到 $+0.37$ pp)。我们不报告跨臂多数投票准确率: 两臂发出互不兼容的答案格式 (盒装数字 vs 自由形式散文), 因此不存在对各格式公平的模态答案键; 臂内重放保留在产物中。面板使用了克隆臂 $3.7\times$ 的 token, 因此不作已实现成本匹配主张 (附录 I)。

选择器效用 (E3)。 冻结政策 π_Z 在每道评估题上都弃答至 **bare**, 并在 94.96% 上与开发固定持平 (配对 0.00 pp, CI $[0.00, 0.00]$); 一个预先固定的随机成员明显更差

(−10.12 pp, CI [−13.27, −7.22]; 表 12)。D 类没有给出可用的可选择性，且对每个冻结政策， $b=3$ 效用 U_b 均为 yes 增益。

6 表观互补性的校准诊断

上述边界结果是关于单次运行数字无法确立什么的陈述。我们把一个离线诊断打包在执行矩阵 $Y[h, x, r, c]$ (成员、任务、重复、条件) 上，每类命题返回四种状态之一——SUPPORTED、REFUTED_WITHIN_SCOPE、INSUFFICIENT_EVIDENCE、NOT_APPLICABLE——并附范围与最小缺失证据，绝不合并为一个分数：(A) 测量充分性；(B) 单次覆盖；(C) 两种估计目标下的稳定性；(D) 执行前可选择性 (冻结 π_Z 对照开发固定)；(E) 预算匹配的政策效用 ($\lambda=1$ ，以已验证的调用证据为门控)。

两项稳定性命题。 C -rank 追问是否存在某对成员在同时区间 (所有规范对上取 max-T, 族系 95%) 下、以符号一致的重复相区别；对的方向由成员身份而非列表位置固定。 C -comp 追问是否存在稳定的任务—harness 交互。令 $\Delta(x) = p_1(x) - p_0(x)$ 、 $(u)_+ = \max(u, 0)$,

$$H_{\text{stable}} = \mathbb{E} \Delta(x)_+ - (\mathbb{E} \Delta(x))_+ = \frac{1}{2} (\mathbb{E} |\Delta(x)| - |\mathbb{E} \Delta(x)|), \quad (1)$$

因此一个处处更好的成员给出 $H_{\text{stable}}=0$ 的稳定排序差异：全局支配否定互补性。交互要求优势在任务间交叉，而任何执行前选择差距都以 H_{stable} 为上界。同一性门控要求条件字段相等、来源哈希恒定，并在矩阵重合时要求有区别的独立执行来源。

为何 plug-in 无法判定，以及校准检验。把 R 次重复平均代入 H_{stable} 会对含噪的逐题估计取最大值；重采样题目无法消除该选择噪声 (表 5: 在 $M=9, T=400, R=3$ 下，plug-in 在每个零假设上的错误支持率都约为 1，包括 $q \equiv 0.9$ 以及密封克隆臂的 2.67 pp)。我们交叉拟合一个冻结选择增益：折 v 在其余重复上同时冻结逐题映射 $h_v(x) = \arg \max_h \bar{q}_h(x)$ 与最佳固定成员 $\bar{h}_v = \arg \max_h \mathbb{E}_x \bar{q}_h(x)$ ，然后在留出重复上对 $g_v(x) = Y_{h_v(x), x, v} - Y_{\bar{h}_v, x, v}$ 评分， $G = \mathbb{E}_{x, v} g_v(x)$ 。在支配下冻结映射就是最佳固定成员 ($G \leq 0$)，且 $0 \leq G \leq H_{\text{stable}}$ 。判定统计量为相同题目上的 $D = G_{\text{real}} - G_{\text{clone}}$ ，配双臂 Monte Carlo 随机化检验 (+1；两臂中按题目和重复独立置换标签) 与配对题目 bootstrap。该参考在等能力处是精确的；在支配锥其余部分上的有限样本错误支持由下面的网格经验验证，而非解析断言。没有克隆臂时 G 仅为描述性，不发出 SUPPORTED；一个 $\leq 10\%$ 不完整题目覆盖门控与极值未知单元界补全了规则。

已知真值验证。我们从指定的 $M \times T$ 概率矩阵模拟二元张量：iid 等能力 (常数及异质难度)、全局支配 (包括旧的对照 bare 统计量在其下虚假拒绝的 0.5/0.9 配置) 与交叉备择，覆盖 $M \in \{3, 9, 20\}$ 、 $T \in \{100, 400, 1000\}$ 、 $R \in \{3, 5, 10, 20\}$ 以及 MCAR 与难度相关缺失。表 5: v3 在每个零假设上保持名义水平，而 plug-in 几乎总是错误支持；干净的双专家交叉 ($H=17.5$ pp) 在 $R=3/5$ 时功效为 0/1%，在 $R=10, 20$ 时为 100%，而 1–4 pp 的现实循环交互仍未解决——这是三次重复下诚实的弃答。12 个人工控制与两个审核者挑战与其哈希冻结状态一致，并配有置换不变性及支配 $\neq$ 互补性的不变量

测试，旧规则仅作为描述性 plug-in 保留。一次哈希绑定重执行还修正了一项含 14 次翻转的验证主张（附录 H）；在存档上 C/D/E 按构造弃答。

regime	$R=3$		$R=10$		$R=20$		abst.
	plug	v3	plug	v3	plug	v3	$R=3$
equal $q=0.9^\dagger$	100	0	100	0	100	1	100
equal + difficulty [†]	100	0	100	1	100	1	100
0.5/0.9 dominance [†]	100	0	100	0	13	0	100
dominance [†]	100	0	100	0	100	0	100
cross $H \approx 0.9$ pp	100	1	100	0	100	0	99
cross $H \approx 1.8$ pp	100	1	100	1	100	0	99
cross $H \approx 4.2$ pp	100	0	100	0	100	0	100
two strong specialists, $H=17.5$ pp	100	0	100	100	100	100	100

[†]Null ($H=0$): false-support %, nominal 5%; else power %. $M=9$, $T=400$, $B=300$ at $R=3$ (150 sweeps), 300 randomizations. Wilson intervals and the full M , T , R , missingness grid in Appendix H.

表 5: $M=9, T=400$ 下的已知真值校准。零假设：错误支持%（名义 5%）；备择：功效；完整网格见附录 H。

7 讨论与结论

核心洞见与证据。群体效用是分离噪声之后稳定的任务—harness 交互：oracle 追问谁当时答对了；路由器在事先选择。诊断区分了数字所许可的内容：排序不是互补性，弃答不是否认，plug-in 不是校准证据。在 MATH-500 上，克隆校准增益为 -0.10 pp (CI $[-1.55, 1.46]$)：在 1 pp 界线上没有超出同代码重执行的增益，并伴随覆盖门控弃答；模拟 (§6) 显示了 $R=3$ 能分辨什么。

局限。一个 SQL 目标、六个构建器、三个种子 (W1/W3 为描述性)；低调用面板筛选与此前分析过的题目——不作未见任务主张。匹配预算的选择增益未被发现，而所用工具本身不会制造互补性。

致谢

占位：经费、算力与基础设施致谢由作者在 camera-ready 前定稿（投稿阶段匿名）。

伦理声明

全部实验使用公开的 BIRD 与 MATH-500 基准数据及生成的程序产物；不涉及人类被试、私人记录或个人身份信息。模型调用作为实验来源的一部分报告，论文不发布凭据或会暴露私人数据的提供方响应。主要伦理风险是夸大单次运行 oracle 增益对部署路由的含义；因此我们把未解决的选择与成本命题明确报告为 INSUFFICIENT EVIDENCE（证据不足）。

可复现性声明

补充材料包含冻结的诊断实现、控制清单与哈希绑定的结果记录。`REPRODUCE.md` 给出单元测试、校准、盲测控制、存档诊断与 LaTeX 构建的确切离线命令。所报告的依赖提供方的存档连同其来源与哈希保留；任何命题都不需要访问在线模型 API 即可重跑诊断本身。

AI 使用声明

本研究按构造就是一个借助 AI 研究 AI 生成产物的项目，以下精确披露 AI 协助的范围。

必要披露。生成式 AI 工具用于：(i) 编写和修改实验代码（生成流程、评估采集器、统计分析脚本）；(ii) 运行涉及模型 API 调用的实验流程；(iii) 分析实验数据并制作表格和图；(iv) 起草和修改论文文字。修订后的主分析表、析因表和结果图由共同的版本化重分析产物生成。历史探索性分析保留各自原始来源与所述局限。审后修正与原协议分开记录。验证记录分别说明各产物的自动测试、开发控制与审核范围。审后修订也使用了同模型子代理审核；这些属于机械检查，不构成跨模型独立科学验证。开发控制和本机运行测试不能确立独立门控校准或提供方层面的执行独立性。

研究构思与方向。核心研究问题、因果设计决策（估计目标、对比、排除规则）、解释标准及拟议的继续 / 停止准则在 AI 协助下形成。人类作者确定总体研究方向并要求按审稿意见修订；AI 工具也提出分析与实验设计、识别反例并实施修订。最终科学决策及投稿批准仍由作者负责。本声明不表示每项 AI 提议的决策均已获得作者逐项批准。

责任。作者对本研究最终内容承担责任，包括借助生成式 AI 产出的文字、主张和产物。本节中的事实陈述供作者核实；其准确性的最终责任在作者。

REFERENCES

- Timothy A. Budd and Dana Angluin. Two notions of correctness and their relation to testing. *Acta Informatica*, 18(1):31–45, 1982.
- Rich Caruana, Alexandru Niculescu-Mizil, Geoff Crew, and Alex Ksikes. Ensemble selection from libraries of models. In *Proceedings of the 21st International Conference on Machine Learning*, 2004.
- Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*, 2021.
- Mengzhuo Chen, Junjie Wang, Zhe Liu, Yawen Wang, Haiming Zheng, and Qing Wang. From failed trajectories to reliable LLM agents: Diagnosing and repairing harness flaws. *arXiv preprint arXiv:2606.06324*, 2026a.

- Mingju Chen, Can Lv, Guibin Zhang, Heng Chang, and Shiji Zhou. HarnessForge: Joint harness and policy evolution for adaptive agent systems. *arXiv preprint arXiv:2606.01779*, 2026b.
- Yong-eun Cho. It’s not the capability: Harness sensitivity is non-monotone across LLM agent tiers. *arXiv preprint arXiv:2605.26731*, 2026.
- Tianyu Fan and Chao Huang. HELIX: Model-harness co-evolution for recursive self-improvement. *arXiv preprint arXiv:2608.13951*, 2026.
- Mitchell H. Gail and Richard Simon. Testing for qualitative interactions between treatment effects and patient subsets. *Biometrics*, 41(2):361–372, 1985. doi: 10.2307/2530862.
- Akshat Gupta, Jermaine Lei, Alexander Lu, Gopala Anumanchipalli, and Leshem Choshen. Automated discovery has no universally superior harness. *arXiv preprint arXiv:2607.18235*, 2026.
- Minho Kim. When should LLMs search? counterfactual supervision for search routing. *arXiv preprint arXiv:2607.05752*, 2026.
- Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(2):48–60, 2014.
- Jacky Kwok, Shulu Li, Pranav Atreya, Yuejiang Liu, Yixing Jiang, Chelsea Finn, Marco Pavone, Ion Stoica, and Azalia Mirhoseini. LLM-as-a-verifier: A general-purpose verification framework. *arXiv preprint arXiv:2607.05391*, 2026.
- Jinyang Li, Binyuan Hui, Ge Qu, Jiaxi Yang, Binhua Li, Bowen Li, Bailin Wang, Bowen Qin, Ruiying Geng, Nan Huo, et al. Can LLM already serve as a database interface? a BIRD’s eye view. In *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, 2023.
- Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Lightman et al. let’s verify step by step appendix: Math-500 subset. *arXiv preprint arXiv:2305.20050*, 2023.
- Jiahang Lin, Shichun Liu, Chengjun Pan, Lizhi Lin, Shihan Dou, Zhiheng Xi, Xuanjing Huang, and Hang Yan. Agentic harness engineering: Observability-driven automatic evolution of coding-agent harnesses. *arXiv preprint arXiv:2604.25850*, 2026.
- Xinchen Liu, Hang Zhou, Yingjie Zong, Yuchuan Tian, Liuyang Song, and Shuo Zhang. Agentic routing: The harness-native data flywheel. *arXiv preprint arXiv:2607.11399*, 2026.

- Xiaotian Luo, Dizhan Xue, Fengxingyu Wang, Chuanrui Hu, and Yafeng Deng. HarnessBank: Semantic gene-bank search with gated verification for agent-harness self-evolution. *arXiv preprint arXiv:2607.13683*, 2026.
- Atsuyuki Miyai, Kiyoharu Aizawa, and Toshihiko Yamasaki. Task-CoEvolve: Efficient harness optimization via adaptive validation task selection. *arXiv preprint arXiv:2608.20169*, 2026.
- Johannes Moll, Jean-Philippe Corbeil, Jiazhen Pan, Martin Hadamitzky, Daniel Rueckert, and Lisa Adams. GRASP: Gated regression-aware skill proposer for self-improving LLM agents. *arXiv preprint arXiv:2605.29668*, 2026.
- Jun Nie, Yonggang Zhang, Jun Song, Qianshu Cai, Dahai Yu, Xinmei Tian, Bo Han, Yike Guo, et al. TTHE: Test-time harness evolution. *arXiv preprint arXiv:2607.08124*, 2026.
- Mike Papadakis, Marinos Kintis, Jie Zhang, Yue Jia, Yves Le Traon, and Mark Harman. Mutation testing advances: an analysis and survey. *Advances in Computers*, 112:275–378, 2019.
- John R. Rice. *The Algorithm Selection Problem*. Elsevier, 1976.
- Ruhan Wang, Yucheng Shi, Zongxia Li, Zhongzhi Li, Yue Yu, and Junyao Yang. Harness handbook: Making evolving agent harnesses readable, navigable, and editable. *arXiv preprint arXiv:2607.13285*, 2026.
- Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc V. Le, Ed H. Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. Self-consistency improves chain of thought reasoning in language models. *arXiv preprint arXiv:2203.11171*, 2022. doi: 10.48550/arXiv.2203.11171.
- Jinghan Xu, Yikai Zhang, Aili Chen, Weiyuan Li, Jiaqing Liang, and Deqing Yang. Verify smarter, evolve further: Efficient harness evolution through behavior-aware verification. *arXiv preprint arXiv:2608.27311*, 2026.
- Lin Xu, Frank Hutter, Holger H. Hoos, and Kevin Leyton-Brown. SATzilla: Portfolio-based algorithm selection for SAT. *Journal of Artificial Intelligence Research*, 32: 565–606, 2008.
- Guibin Zhang, Leo Lu, Fangzhou Xie, Kang Zhu, Junhao Wang, and Zhifei Xie. JIT-Agent: Scaling harness intelligence via just-in-time harness evolution. *arXiv preprint arXiv:2608.25593*, 2026a.
- Hangfan Zhang, Shao Zhang, Kangcong Li, Chen Zhang, Yang Chen, and Yiqun Zhang. Self-harness: Harnesses that improve themselves. *arXiv preprint arXiv:2606.09498*, 2026b.

Heng Zhou, Zelin Tan, Zhemeng Zhang, Yutao Fan, Yibing Lin, and Li Kang. Select-then-solve: Paradigm routing as inference-time optimization for LLM agents. *arXiv preprint arXiv:2604.06753*, 2026.

A PHASE-I 来源与条件详述

发现研究状态。 Phase I (§3 与 §C.1) 是发现研究。其 151 个评估项中有 24 个与首日协议开发测量重叠；人工控制是在检查首日轨迹后设计的（其观测提升空间是描述性的，不是稳定互补性的盲估计）；仓库历史为事后初始化，决策日志变更记录是权威的排序记录。Phase-I 准入阈值（联合修复率 $\geq 15\%$ 、提升空间 ≥ 5 pp、 ≥ 3 个成对不同的非空修复集合）在 151 题评估之前已于内部决策日志冻结；v6→v7 的阈值变更（20%→15%）已披露，两种读数接纳相同种群。这是内部评估前冻结，不是外部预注册。

数据卫生。 bare 基线在两次首日运行之间翻转了 60 题中的 3 题（温度 0 下的 API 非确定性），因此 60 题列以略有不同的 bare 错题集合为条件。Phase-I 评分使用行集合相等代理，我们后来测得它相对官方 BIRD 评分器一致保守（在两个记录了最终 SQL 的 Phase-I 矩阵上，它从不把官方评分器判错的答案判对；一致率 0.97–0.99）。

Phase-I 种群。 种子基线：bare（单次调用）与 react（执行反馈循环，随 TTHE 提供）。旧提议者协议：从 TTHE 优化循环输出中选出的六个候选（GLM-5.3-Flash 构建器），仅使用与评估集不相交的 36 道题、按评估前冻结的规则为行为多样性而选择。策略强制自由形式：GLM-5.3-Flash、Qwen3.8-Flash、DeepSeek-V4-Flash-Vision-Exp 构建器，各八个指派机制；GLM 种群是有日志的重跑（ $K=3$ ；原 09-01 运行记录为零接纳，但其工具未保存，该观察无法审核）。Harness IR：从声明式机制规格确定性编译的六个 harness（上下文 $\in \{\text{plain, schema_link, hint_guard, link+hint}\}$ ，带温度的候选生成、逐候选执行、修复轮次、选择规则），因此声明机制按构造存在于控制流中。人工正控制：§3.4 的四个手写 harness。

生成来源缺口。 09-01 自由形式种群在会话中产出；其生成工具未保存，也不存在逐尝试日志——因此这些运行的预算相等无法审核，我们也不作此主张。它们的准入是评估时的导入 / 冒烟检查，不是 Phase-II 的反事实一致性门控。自 2026-09-03 起的在案工具（builder_generate3.py）记录每次尝试（3 次重试、16,384 token 预算、逐尝试阶段与结束原因）；完整的逐策略网格与构建器接纳排序（3/8、7/8、8/8）来自该有日志工具，相对冻结的准入决定属于事后。

A.1 PHASE-I 协议探查及其局限

Phase I 还探查了生成侧修复——策略强制自由形式协议（指派机制，导入 / 冒烟准入）与编译式 Harness IR。在策略强制协议下，三个构建器中有两个产生的种群点估计超过预先指定阈值（Qwen3.8-Flash 5.96、DeepSeek-V4-Flash-Vision-Exp 7.95 pp；旧协议臂为 4.64 pp 未达标），且逐策略接纳随构建器身份排序（在有日志工具下 GLM-5.3-Flash




图 2: 语法多样性与行为坍缩 (Phase I, 发现研究: 首日种群: 14 个 harness $\times$ 60 道题, 计入 `bare` 与 `react` 基线共 91 对)。每个点是一个 harness 对; x = token 序列代码相似度, y = 正确性不同的题目比例。代码相似度不能预测结果分歧 ($\rho = -0.01$); 91 对中 36 对在全部 60 题上相同。原始点对: 代码材料中的 `fig1_phenomenon_data.json`。

3/8、Qwen3.8-Flash 7/8、DeepSeek-V4-Flash-Vision-Exp 8/8)。这些观察为 Phase II 提供动机, 但不是验证性的, 原因有三并已披露: 设计是两个嵌套对比, 无法把协议主效应与构建器主效应分开; 早期运行缺少逐尝试日志, 预算相等无法审核; 准入是导入 / 冒烟检查, 不是 §4 的反事实一致性门控。完整条件见附录 A。

生成空结果失败 (M0)。 用 Qwen3.8-Flash 与 DeepSeek-V4-Flash-Vision-Exp 构建器重跑原优化循环, 产生 40 个与 `bare` 基线源码逐字节相同的候选。代码同一并不意味着随机执行也相同。这次运行没有提供不同代码的种群; 它作为另一种更原始的失败模式报告——流水线根本没有产生不同种群。上述坍缩主张完全基于来源确实不同的首日种群。

B PHASE-II 协议摘要与偏差日志

权威协议 (估计目标、划分、仪器、排除规则与历史偏差变更日志) 是代码材料中的 `PHASE2_PROTOCOL.md`, 冻结于 `PROTOCOL_FREEZE.txt` 记录的提交。摘要: 2×2 析因加开放机制臂; 六构建器 $\times$ 三种子; 每槽位至多 $R=3$ 次尝试, 首次接纳即停, 不补足; 污染登记器 (失败即关闭, 两个开发数据库整体禁用); 来自九个开发期间从未打开数据库的 1,169 题验证集加预抽取 400 题核心; 官方 BIRD 评分器强制 30s 超时; 以模型身份为键、跨进程加锁的响应缓存 (偏差 D13 记录并修复了采集中发现的一个缓存并发缺陷); 主对比为配对 (构建器 $\times$ 种子) 单元上的 D-A, 配分层 bootstrap 与置换推断; 共同核心上 Holm 校正的析因次要项; 仅 K 匹配敏感性。偏差 D1-D13 包括已披露的 18 题流水线冒烟测试、在观察任何验证性结果之前所作的仪器校准修复、凭据处理事件及其补救、以及产物分歧隔离——每项在变更日志中均有理由与日期。审后修正记录于 `review-stage/REVISION_20260910.md`; 修订结果不替代历史冻结。特别

地，实际门控在结构上拒绝两种允许的提示层策略，且各组实际生成成本不同。如正文所述，修正表格使用共享基线记录与数据库 / 题目重采样。

Phase-II confirmatory design: database-level isolation, 2x2 factorial + open-mechanism arm, three-layer admission




图 3: Phase-II 验证性设计（冻结协议）。左：数据库级污染隔离。中：2x2 析因与共同尝试上限，加开放机制臂 II-E。右：三层准入流程。

上游代码提取审计。 在 36 个强制 C/D 单元中，全部 108 次 `format_guard` 尝试均未通过中性有效性：71 条日志报告 Python 字符串未终止，36 条报告无 Python 围栏，1 条报告提供方超时。存档生成器的非贪婪 Python 围栏提取器在随后第一个三反引号处终止，包括 Python 字符串内部的三反引号。三个合成的、语法有效、在普通字符串、文档字符串或正则中包含 SQL 围栏的文件变成了无效前缀；而提取器仍把其截断标志设为 `false`。该提取器与审稿锁定提交相比未变，但历史尝试日志未绑定其执行时来源哈希。完整构建器消息未被该生成器保存。因此失败模式与提取损坏相容，但不证明所有历史失败都由此造成，也不证明修复后的候选会通过准入。我们找到 74 个已保存的提取文件，全部语法无效；其中三个与无围栏日志并存，作为来源冲突保留，不归属于那些尝试。这些发现把一个生成接口失败置于门控显式策略排除之旁。

修正的 K 匹配与 R2 重放。 两次重放都使用与修正主分析相同的 `manifest` 排序 `canonical` 加载器与共享数据库 / 库内题目抽取，在固定构建器内重采样种子（10,000 次重复）。K 匹配中，每个 A/B 与 C/D 对使用较小候选数；每个均匀候选子集被精确枚举一次。`bare` 留在每个子集中，最佳固定在每次题目抽取的每个子集内部重算。这是规模敏感性分析，不是因果中介分解。保留全部 18 个单元（包括两个 A 子集为单成员的单元）使子集 D-A 从 +0.42 变为 +0.81 pp（变化 +0.39 pp, 95% CI [-0.95, +1.63]）。R2 子集提升空间排除 `bare`，因为 R2 未获得匹配的 `bare` 运行，故它不同于包含 `bare` 的主估计目标；旧的 16 单元比较在此对账。这些是不稳定性测量，不是标准误，也不是平均处理效应的可检出下限；它们不证明每个对比都不变，也不识别 `harness` 间分歧中有多大部分是噪声。

R2 在 400 题上获得 70 个 `harness`，在可用时为每个 A/D 单元选择前两个可调用的已接纳候选。两个关缓存获取文件即使都存储 `repeat=0` 也保留各自身份；来源哈希

Sensitivity estimand	Estimate (pp)	95% CI (pp)
K-matched B-A headroom	-0.55	[-1.53, +0.63]
K-matched D-C headroom	-0.08	[-1.26, +0.80]
K-matched gate mean	-0.31	[-1.07, +0.40]
R2 subset D-A (cached)	+0.42	[-0.61, +1.48]
R2 subset D-A (cache-off)	+0.81	[-0.35, +1.84]
R2 change in subset D-A	+0.39	[-0.95, +1.63]

表 6: core-400、18 单元上的修正敏感性。CI 未校正。K 匹配比较始终保留 bare；R2 比较排除 bare，并以观察到的获取组为条件。

与缓存运行核对。未获得匹配 bare，因此 R2 提升空间在两种条件下都排除 bare。修正分析保留单成员单元（其子集提升空间为零），得到全部 18 个配对单元。对缓存结果有 2391/28,000 次判定翻转（8.54%），两次 D 关缓存轮次之间有 1245/14,400 次翻转（8.65%）。仅为对账，限制到两臂都至少有两个成员的 16 个单元，缓存下 D-A 为 -0.11 pp、关缓存下为 +0.36 pp。这解释了与全单元估计的差别；两种分析都不识别未来执行方差、单独缓存的效应、或相对克隆的稳定互补优势。获取时间与缓存条件未被分离。

R3 仅 bare 重复审核。 R3 是一项单独的、更小的不稳定性审核：仅 bare 基线（无生成 harness）在相同 core-400 题、相同冻结目标（GLM-5.3-Flash，温度 0）上的三次独立关缓存执行。400 题中 58 题（14.5%）在三次重复中至少一次改变 bare 正确性；重复对之间的成对翻转率为 39/400、40/400、37/400（9.75%、10.0%、9.25%）。因此 R3 测量的是温度 0 API 非确定性下基线自身的观测不稳定率。这不是任何对比的标准误或效应大小下限，但它设定了重复控制成为解释必要项的尺度：没有它们，这个量级的 harness 对 bare 差异不能归因于能力。存档记录为 `artifacts/phase2/r3_flip_rate.json`，生成脚本为 `experiment/phase2/run_r2r3.py`。

记录成本与缺失账单数据。 相同 canonical 核心记录在 153,600 条候选一题目记录中包含 259,304 次记录的逻辑 solver 调用（表 7）。这些调用包括缓存服务的请求，不是提供方计费的 API 请求。所检查的记录均无 token 用量字段；我们不从调用数推算 token 或货币支出。因此实际生成尝试数、接纳候选数与这些执行计数保持为不同测量。种群成本均值对每个构建器一种子单元等权且排除 bare；零候选种群贡献零次 solver 调用。

B.1 审后提供方获取状态

审后的提供方获取尝试未形成完整共同池：传输中断把已完成响应、未闭合请求与未启动尝试留在不同的可审计状态中。这些记录为来源与缺失性核算保留，但被排除于关于种群表现、成本或稳定互补性的主张之外。因此，稿件不把提供方可用性或部分获取用作未解决的克隆控制问题的证据。

Arm	Candidate-task records	Logged solver calls	Calls/task/population
A	41,600	67,258	9.34
B	44,000	64,399	8.94
C	40,400	75,604	10.50
D	27,600	52,043	7.23

表 7: core-400 上的描述性 canonical 成本审核，每组 18 单元。记录的逻辑调用不是计费请求或 token 计数。末列为各单元逐题候选种群调用的平均值。

C 探索性指纹与选择分析

两项分析都是对存档验证性单元（18 个构建器 $\times$ 种子单元、384 个接纳候选、core-400 结果）的事后分析。版本化的 `experiment/revision/` 脚本现在使用与主重分析相同的 canonical 加载器、冻结题目列表、成员关系与来源检查。它们仍是描述性的：这些题目此前已被分析过，这不是独立迁移验证。

丰富指纹。 为隔离加载器变更，W3 重分析保留旧的有损 SQL 文本变换：删除分号、替换反引号、即使在单引号分段后仍整体小写化、合并空白。这不是 SQL 解析器或语义归一化；它可能改变字面量与带引号标识符。在 364,428 个两条变换后 SQL 相同且非空的对一题观察中，有 0 个判定不同。这是观测到的一致性检查，不是按构造保证的性质。

对级 SQL 不相似度仅在判定一致且两条 SQL 非空的题目上平均 (1-token-Jaccard)。它与整体结果分歧的 Spearman 相关在 4,386 个单元内对上为 0.597，在 1,010 个组内对上为 0.588。各对共享候选与题目，且 SQL 指标以判定一致为条件；这些相关没有基于独立性的显著性或因果解释。

在 R2 的 70-harness 首次关缓存获取中，调用数在 506/28000 次比较中变化，判定在 2391/28000 次中变化。变换后 SQL 在 19569/27936 次比较中变化 (70.05%)；64 次比较缺少两条非空 SQL，仅从 SQL 分母中排除。变化 SQL 对的平均 token Jaccard 为 0.619。这些通道特定比率不定义效应大小噪声地板。canonical 逻辑调用成本在表 7 中单独报告。

多样性感知选择。 每个单元合并跨臂的全部接纳候选。重分析保留旧种子、100 次随机数据库对半划分、每划分每单元 200 次随机子集抽取及候选选择规则。它记录一个新的确定性调度：历史的集合派生单元顺序未存档，因此仅凭种子无法恢复相同的历史划分与抽取。选择使用开发数据库；评估使用互补数据库。重叠划分不是 1,800 个独立实验。方法为开发准确率 top- k 、均匀随机子集、贪心开发 oracle 覆盖、以及贪心平均准确率加 λ 倍 oracle 覆盖 ($\lambda \in \{0.25, 0.5, 1, 2\}$)。所有候选选择都在划分的评估之前于划分内冻结。

表 8 在每个被评估子集中保留共同的 AD bare; k 只计候选。JSON 还记录仅候选值以区分历史估计目标。Oracle 与最佳固定使用留出结果作为描述性上界。开发固定改为

k	Selection	Oracle (%)	Best (%)	H (pp)	Dev-fixed (%)
4	top-acc	73.98	66.64	7.34	65.10
4	random	73.90	66.03	7.87	64.66
4	div-only	74.22	66.18	8.04	65.13
8	top-acc	76.03	67.11	8.93	65.10
8	random	76.15	66.76	9.39	64.95
8	div-only	76.39	66.68	9.70	65.10

表 8: canonical 描述性 W1 重分析。每个池含 k 个选定候选加共同 bare。18 单元与 100 个重叠数据库划分上的均值；无置信区间。开发固定仅在开发数据上选择；最佳固定使用留出结果。

用开发准确率选一个成员，成员名并列时升序、bare 优先。确定性方法本就保留一个全局开发最佳候选；该比较器的差异可能来自哪些并列最大值存活，而非开发最大准确率提高。

在 $k = 8$ 时，仅多样性相对 top-acc 使 oracle 变化 +0.35 pp、最佳固定变化 -0.42 pp、提升空间变化 +0.78 pp。开发固定变化 -0.001 pp。这些是不同的量，没有一个是独立验证的路由增益。我们撤回旧的仅单元置信区间；当前表是描述性的，涵盖数据库 / 题目采样与重选择的推断仍待完成。更早的归一化提升空间比率仅保留在历史产物中，不进入修订主张。

重选择不确立区间覆盖。 一个精确反例排除了我们提出的正权重重选择百分位区间的普遍 95% 覆盖保证。令九个独立数据库各含一个 $\text{Bernoulli}(p)$ 任务状态。16 个固定候选由八个状态 0 专家后接八个状态 1 专家组成；bare 恒错。把 canonical $k = 8$ 规则应用于四个开发库与五个留出库。在记录的并列规则下，仅多样性减 top-acc 提升空间统计量的期望为 $(1 - p^4) \mathbb{E}[\min(B, 5 - B)/5] > 0$ ，其中 $B \sim \text{Binomial}(5, p)$ 。在全部九个状态恰好相同的事件上，每种正加权都给两种方法产生零提升空间，故百分位区间为 $[0, 0]$ 。因此覆盖率至多为 $1 - p^9 - (1 - p)^9$ ，在 $p = 0.1$ 时为 61.26%。对相同单元或重叠固定划分取平均不能移除该事件。此界限针对所述构造与区间，不涉及 BIRD 特定覆盖率，也不涉及其他推断方法的不可能性。

C.1 路由与探索性选择

Phase-I 留一 harness 预测器未在所测 DeepSeek 种群中超过最佳固定 harness (-3.4 pp)；Qwen 估计为 +0.9 pp (CI [-5.2, +6.9])，题目留出的修复 AUROC 为 0.512。这些预测器与划分特定结果不确立价值预测。canonical W1 分析同样是描述性的：在 $k = 8$ 时，多样性相对 top-准确率选择使 oracle 变化 +0.35 pp、最佳固定变化 -0.42 pp、提升空间变化 +0.78 pp；开发选定固定成员变化 -0.001 pp。没有一个是经验验证的路由增益（附录 C）。

D PHASE-I 补充结果

逐 harness 准确率、逐折 LOHO 表、bootstrap 区间、修复集审核、 K 子采样曲线、题目留出控制与第二目标重复（Qwen3.8-Flash 作冻结目标：坍塌重复；策略强制种群保留提升空间；提示侧人工控制未整体迁移）均连同其生成脚本包含在匿名代码材料中。

E 模型与版本

表 9 列出本文使用的每个模型及其发送给 API 的确切版本字符串。所有模型均通过单一商业 OpenAI 兼容 API 聚合器访问（每个角色都用同一提供方）；BIRD 数据采集窗口为 2026-08-30 至 2026-09-08。冻结目标始终在温度 0 调用。Phase-II harness 生成使用温度 0.7、16,384 token 预算；Phase-I 生成设置按工具记录于代码材料。Phase I 使用代理执行评分器；Phase II 使用官方 BIRD 评分器（30s 超时），旧评分器作为次要审核。MATH-500 探查使用附录 J 的答案比较器；报告的准确率无一由 LLM 评分器产生。

角色	模型（确切版本字符串）	用于
冻结目标求解器	GLM-5.3-Flash（温度 0）	Phase I-II
第二冻结目标（重复）	Qwen3.8-Flash	Phase I
Phase-I 构建器	GLM-5.3-Flash, Qwen3.8-Flash, DeepSeek-V4-Flash-Vision-Exp	§A.1
Phase-II 构建器	GLM-5.3, Qwen3.8-Max, DeepSeek-V4-Pro, Kimi-K3, MiniMax-M3, ERNIE-5.0-Thinking-Preview	Phase II
门控仪器开发	GPT-6	附录 G
控制编写	gpt-5.5（v2/v3 集）, gpt-5.6-sol（v4 集）	附录 G
盲测控制审核 / 裁决	gpt-5.6-sol（v2/v3）, gpt-5.5（v4, 语义裁决）	附录 G
评分器	代理 / 官方 BIRD 执行评分器；MATH 答案比较器	见正文

表 9: 完整模型清单。目标在每个阶段内保持冻结；Phase-II 构建器来自六个独立实验室。

F PHASE-I 轨迹审核的工作样例

为使 §3.3 的失败分类具体化，本节把一项 BIRD 任务在被审 harness 中走一遍。产物逐字取自首日轨迹审核（5 个 harness $\times$ 10 道题）；其日志器把存储的 SQL 摘录上限设为 120 字符，故截断以 *[trunc.]* 标记。完整 harness 来源与轨迹在代码材料中。

任务。 BIRD 开发集问题 352（card_games 数据库；题目文本逐字，拼写错误为数据集原有）：

```

1134         Calculate the percentage of the cards available in Chinese
1135         Simplified.
1136

```

其 BIRD 提示:

```

1140         'Chinese Simplified' is the language; percentage = Divide(Sum(id
1141         where language = 'Chinese Simplified'), Count(id)) *100
1142

```

Gold SQL (在发布数据库上执行两者分别得 8.7734 与 8.7728——官方评分器将其区分):

```

1147         SELECT CAST(SUM(CASE WHEN T2.language = 'Chinese Simplified' THEN
1148         1 ELSE 0 END) AS REAL) * 100 / COUNT(T1.id) FROM cards AS T1 INNER
1149         JOIN foreign_data AS T2 ON T1.uuid = T2.uuid
1150

```

bare harness 回答:

```

1152         SELECT SUM(CASE WHEN language = 'Chinese Simplified' THEN 1 ELSE 0
1153         END) * 100.0 / COUNT(id) AS percentage FROM foreign_data;
1154

```

被官方评分器判错: 它直接在 `foreign_data` 上计数, 而 gold 查询在连接 `cards` 之后计数; 提示没有写明该连接。

react (T2: 机制存在但未触发)。 `react` 的控制流确实执行 SQL 并在数据库错误时重试。但其第一次调用与 `bare` 的提示逐字节相同, 而此处生成的 SQL 执行无错误, 因此错误触发的重试从不发生, 最终 SQL 与 `bare` 相同。在全部 10 道被审任务上模式都成立: 有 SQL 执行, 10/10 最终 SQL 与 `bare` 逐字节相同——反馈循环是真实代码, 但其修复分支在这些题上未激活。需要受控故障注入来检验反馈是否改变输出。

cand_bird_g1_b0r0_g0 (T1: 机制被描述但未执行)。 该候选的文档字符串宣称一种“保守修复”: 限制求解器最大输出 token 并要求仅答案块。其 `solve()` 在结构上就是 `bare`: 一次 LLM 调用, 然后 `extract_sql.token` 上限仅作为 `os.environ.setdefault` 默认值存在 (2,048 对运行时的 32,000)——没有任何 harness 控制流实现它, 且在这些题上它从不生效, 因为 SQL 答案比上限低几个数量级。在工作样例题上它恰好发起一次调用、什么都不执行, 并返回与 `bare` 相同的错误查询 (忽略空白差异; 直接在 `foreign_data` 上计数而无连接)。在全部 10 道被审任务上它记录的 SQL 执行数为零, 且最终 SQL 有 6 个与 `bare` 逐字节相同 (其余差异可追溯到改写的系统提示, 而非任何机制)。因此最常见的 Phase-I 失败类不是机械损坏而是机械缺失: 声明的机制只存在于散文中。

cand_bird_g1_b0r1_g0 (代码级多样性, 行为同一性)。 该候选是一个真正不同的程序: 它把单次 coder 调用包在守护线程看门狗中, 若调用停滞超过 40s 就发出一次对冲重复追问。机制存在于控制流中——但其触发器 (停滞的 API 调用) 在审核中从未

出现：零次 SQL 执行，且全部 10 道被审题的最终 SQL 都等于 `bare`。即使新增机制是真实的，代码不同而行为相同仍可存活：它只是从不触发。

`cand_bird_g1_b1r1_g1` (T3: 损坏的多轮路径)。唯一一个实现了真正执行—检查—修复的被审候选把模型的散文当作最终 SQL 返回。在一道 `bare` 答对的题 (“State the alternative languages available for card named Annul numbered 29.”) 上，其记录的最后 SQL 逐字开头为：

```
with "only a single read-only SELECT is allowed". The previous
"query" was actually just prose text (the model wrote rea[trunc.]
```

修复再提示招致了失败：被要求修复一个“实际上只是散文”的查询时，冻结目标以更多散文推理回应，找不到 SQL 块，推理文本便被当作查询提交。该题从 `bare` 正确翻转为 `harness` 错误。

G 仪器控制的独立构造

我们用 32 个新编写的控制测试审后 Gate-v2 开发仪器，与开发其探针所用的控制分开。仪器先固定，之后另一个模型 (`gpt-5.5`; 表 9) 只收到公开合同与可调用接口，不接触其实现或早期控制。作者为八类机制各提供两个意图符合与两个意图不符合的实现。控制来源、作者参考标签、仪器、测量代码与执行顺序在首次评估前哈希。未运行任何基准或提供方生成，首次测量原样保留。

声明机制	结构通过	结构失败	需审阅
修复	2	2	0
执行结果投票	2	2	0
模式链接	0	4	0
提示守卫	0	0	4
双视图	0	3	1
分解	1	3	0
错误分类	0	4	0
格式守卫	0	0	4
合计	5	18	9

表 10: 固定开发仪器对 32 个独立编写控制的首次评估。无一例发生执行失败。这些是仪器状态，不是正确性标签或种群错误率；作者意图的正 / 负标签需另行审查。

九个需审阅案例全部保留。第三个模型 (`gpt-5.6-sol`) 收到完整控制来源与轨迹，但没有作者参考标签或自动判定，用于对全部 32 个控制作来源—合同审查并对四类指定机制作语义裁决。独立来源审查支持一个分解控制与两个错误分类控制符合，而仪器拒绝了它们。分解 `stub` 返回其文本在请求中出现的第一个计划步骤的载荷；因此在下一请求的上下文中保留较早步骤会再次取回较早载荷。分类检查移除了确切错误文本，但仍把普通 `Schema`: 标题计为一个类别，使提取的类别集与预期错误类不一致。这些是

仪器在这些控制上的失败，不是目标模型的观测失败。三个作者意图正控制被争议：两个模式链接控制保留了无关表，一个双视图控制批量处理其请求并错误处理空结果。其原始标签与审查分歧分别保留。在作者标签与来源审查一致的 29 个控制中，仪器拒绝了 13 个符合控制中的 3 个；全部 16 个不符合控制在指定语义审查后都被拒绝。因此仪器未通过这项有限控制检查。这些计数不估计生成种群中的错误率。指定 16 个控制的语义裁决产生 7 个符合、8 个不符合、1 个不确定。不确定案例本就有结构失败，保留该失败而不解决其语义。这个小型、刻意平衡的控制集不是生成 harness 的随机样本。通过它并不能验证生产接口或取代准入政策的共同原始池比较。来源、冻结输入、完整轨迹与裁决保留在配套修订产物中。

修订仪器与新的独立控制集。 Gate-v3 修正了解析请求归属，并把类别关键词与共享请求模板当作审阅线索而非自动拒绝。我们在新的模型上下文（gpt-5.5 编写、gpt-5.6-sol 审查）编写并审查新的 32 控制集之前固定此版本，仍为每机制两个意图正、两个意图负控制。审查包隐去作者标签、自动判定与仪器派生的归属元数据。全部 32 个控制接受来源审查；四个提示 / 表述组加分解中的 20 个控制还接受语义或数据流审查。结构结果为 8 通过、10 失败、14 需审阅，无执行失败。经一次记录在案的证据澄清，来源审查把 15 个控制分类为符合、17 个不符合；语义审查分类为 8 符合、11 不符合、1 不确定。

不确定的分类控制请求一个中间错误类别，但合成接口返回 SQL 文本。其回退随后选择了语义修复动作。这确立的是 fixture 中的响应类型不匹配，不是真实求解器的分类错误。第二个分类控制受到参考争议：其来源把提供的模式失败消息映射到语义动作。在 31 个无争议参考中，15 个符合控制有 14 个被接受、1 个仍未解决；全部 16 个不符合控制被拒绝。因此预先指定的有限检查因未决案例及错误分类缺乏足够一致的正覆盖而仍未满足。一个投票控制的符合性仅适用于结果仲裁；它未确立以任务为条件的候选生成。这些有限机制检查不验证完整 harness 运行，也不取代计划中的共同池政策比较。

运行时响应合同。 我们随后测试了七个存档的无门控、策略强制候选，按策略选择第一个可用文件名而非按表现；没有可用的格式守卫候选（附录 B）。27 个合成场景同时暴露了候选与仪器的局限。双视图候选在第一个结果非空时跳过第二次执行，与其原本“两者都执行”的声明相反。相比之下，模式链接候选请求 JSON 却收到纯文本，分解请求中的完整计划使冻结探针无法唯一归属当前目标。我们保留这些观察，并在另外 11 个开发场景中测试来源指派的响应配置。专用子问题字段识别了当前目标，可执行 SQL 载荷到达最终装配，内存 SQLite 数据库产生的四个错误引出相应的语法或模式修复指令。模式链接 JSON 改变了 SQL 编写请求中的显式表 / 列限制，但完整模式仍在场。因此仅凭保留模式上下文不能确立链接子集被忽略。这些暴露候选检查把响应接口失败与可观察的候选偏差区分开；它们不取代独立校准，也不提供修订后的基准结果。

统一接口与测量前参考审查。 Gate-v4 把来源指派的响应接口与五个未变的 Gate-v3 机制探针结合。另写的 32 控制集（gpt-5.6-sol）在执行前接受盲测来源审查。作者

Arm	K_{cand}	K_{total}	Bare (%)	Best (%)	Oracle (%)	H (pp)
A	5.78	6.78	63.25	66.00	74.51	8.51
B	6.11	7.11	63.25	66.12	74.39	8.26
C	5.61	6.61	63.25	65.64	75.01	9.38
D	3.83	4.83	63.25	65.65	73.90	8.25

表 11: 同核心提升空间分解。所有臂使用相同 400 题与相同 bare 结果。 K_{cand} 排除 bare, $K_{\text{total}} = K_{\text{cand}} + 1$; 数量与准确率为单元均值。提升空间为 oracle 减最佳固定准确率, 不是已实现路由增益。

熟悉更早的控制失败; 此来源审查中发现的模式响应与声明投票参数不匹配在保留初版的同时被修正。修订参考在每机制有两个一致符合与两个一致不符合控制。冻结其来源、配置与依赖后, 一次测量覆盖 124 个场景, 无执行异常。结构结果为 4 通过、6 失败、22 需审阅。

一个新的审查上下文 (gpt-5.5) 收到全部来源与实际轨迹, 但没有参考标签、来源审查决定或自动判定。其首次判定为 18 符合、14 不符合。在预先指定的混合规则中保留结构失败会接受全部 16 个符合参考, 但也接受一个不符合的提示控制, 故有限零错误标准未满足。该控制正确重述已有提示, 却在未提供提示时虚构了强制排序。一次记录在案的、有针对性的证据澄清纠正了这一疏漏, 也纠正了一个把同一请求的两个样本当作独立表述的双视图判定。后一控制本已被结构拒绝。澄清后的判定与全部 32 个参考一致, 但这次跟进不取代首次盲测结果, 也不构成新的独立校准通过。此检查中未执行任何仪器重跑、提供方生成或基准评估。

声明词表的范围。 这些控制覆盖八个策略强制合同, 不覆盖自由臂的四种声明 (repair、vote、twostage、plain)。在原自由提示中, vote 指定多次采样与选择但未指定三票多数投票; twostage 指定产物消费但无特定响应接口。plain 声明还指定无控制流机制, 而自由提示要求控制流变更。因此把八策略门控应用于这些声明需要另行固定语义规则与不确定政策, 而不是静默把 vote 当作 vote3 或在观察其结果后选择兼容配置。这一来源级范围缺口不估计生成候选的错误拒绝率。

G.1 同核心提升空间分解

H 诊断流程与验证 (本次修订)

五个问题类。 对一个 harness 种群与一个 bare 参考, 诊断流程在显式执行矩阵 $Y[h, x, r, c]$ (成员、任务、重复、执行条件) 上评估五类命题: **(A)** 测量充分性 (清单一致性、带显式已执行 / 未执行状态的评分器重放、同一性唯一性; 未运行的检查被报告为未运行, 且永远不能把该类渲染为 SUPPORTED); **(B)** 单次覆盖 (oracle 减最佳固定, 开发固定单独报告); **(C)** 稳定性, 分两个分开的估计目标; **(D)** 执行前可选择性 (冻结的一次调用选择政策对照开发固定); **(E)** 冻结 1 次调用预算、 $\lambda=1$ 损害加权下的预算匹配政策效用 (离线、一次调用; 除非逐任务调用预算由逐记录证据

验证或属于生成设计的一部分，否则 E 留作 INSUFFICIENT_EVIDENCE)。每类返回 SUPPORTED、REFUTED_WITHIN_SCOPE、INSUFFICIENT_EVIDENCE 或 NOT_APPLICABLE，附范围与最小缺失证据；各类绝不合并为单一分数。

两个稳定性估计目标。 *C-rank*: 成对同条件准确率差，配共享题目重采样 bootstrap 与所有 $M(M-1)/2$ 个规范成员对上的 max-T 同时 95% 区间（族系错误控制；v3 之前的逐对区间未对 36 个同时比较调整），外加跨重复符号一致性；对的方向由成员身份固定，故种群结论对成员排序不变。种群状态意味着多重性调整后至少一对不同，而非完整排序稳定。*C-comp*: 稳定互补性 $H_{\text{stable}} = \mathbb{E} \max_h q_h(x) - \max_h \mathbb{E} q_h(x)$ 满足式 (1)，且恰在某成员在每题上都是期望最佳时为零。执行条件字段不同或成员来源哈希不同的重复被拒绝作为匹配重复并强制 INSUFFICIENT_EVIDENCE；逐字节相同的结果矩阵被拒绝，除非两次重复都带有不同的、显式独立的执行来源（合法的近确定性程序可以复现相同矩阵，故同一性相等触发的是来源验证而非自动拒绝）。未知单元的对级插补界与记录成功率一并报告。

v3 C-comp 判定（2026-09-19 审查之后）。 H_{stable} 的重复平均 plug-in 仅作为描述性字段保留；它从不决定科学状态。审查中的两个已知真值反例被编码为回归测试： $M=9, T=400, R=3$ 下全部 $q = 0.9$ 给出 plug-in $\hat{H} = 8.83$ pp 且 bootstrap 区间排除零，密封同代码克隆臂打印 2.67 pp——两者真实 $H_{\text{stable}} = 0$ 。校准统计量是 §6 所述交叉拟合冻结选择增益 G ；判定使用真实减克隆差 D 。

为何该规则在整个零假设族上有规模保证。令 $\theta^* = G$ 为冻结选择协议 S 下的种群增益。每题上被选成员的概率至多为 $\max_h q_h(x)$ ，故 $\theta^* \leq H_{\text{stable}}$ 。零假设 $H_{\text{stable}} = 0$ 是全局支配锥：存在某 h_0 对所有 h 与几乎每个 x 满足 $q_{h_0}(x) \geq q_h(x)$ 。在支配下，冻结映射只能路由到支配成员，或当较弱成员与含噪发现分数并列时偏离它路由；因此被评分的留出期望为 $E[q_{g_S(x)}(x)] \leq E[q_{h_0}(x)] = \max_h \mu_h$ ，从而在整个锥上 $\theta^* \leq 0$ ，不只在等能力处。双臂随机化参考在等能力边界处是精确的（置换标签可交换，重算统计量是同一条件分布的一次抽样），并且由于真实臂上的种群参数在锥其余部分 ≤ 0 而克隆臂保持以零为中心，针对等能力包络的单侧拒绝事件 $D > 0$ 在支配下不可能获得概率：参考在那里是保守的。这些是关于种群参数的结构性陈述；名义水平的有限样本有效性随后在下面校准网格的每个零假设 DGP 上经验检查，包括异质难度、异质支配、0.5/0.9 配置、缺失性以及两臂间匹配的黏性题内潜在状态。

并列处理。冻结 argmax 中的成员标签并列处理使用 iid $U(0, 10^{-9})$ 抖动，在真实数据报告上对十个冻结并列实现取平均（每个校准数据集用一次抽样：零假设下并列偏差均值为零）；确定性字典序规则不是标签不变的，被模拟拒绝。标签对称性由一个置换不变性回归测试直接断言：当成员顺序在两臂中以相同方式置换时，10 次抽样并列平均的 G 、 D 与状态在 Monte Carlo 容差内一致。

随机化机制。 标签在每个题目且每个重复内独立置换（跨重复的单一联合置换会保留真正的交叉映射，不会使统计量归零：开发中已验证），每次抽取重算两个 G 、它们的差及两个选择；+1 Monte Carlo 校正给出精确离散水平。配对题目 bootstrap 提供抽

样区间；一个 $\leq 10\%$ 不完整题目覆盖门控、极值未知单元界与正 G_{real} 符号守卫补全规则，没有克隆臂时不发出 SUPPORTED 状态。

已知真值模拟校准。 二元张量从指定的 $M \times T$ 概率矩阵抽取 (experiment/diagnostics/calibration_sim.py)：常数 q 与共享题目难度的 iid 等能力；带干净支配固定成员、审查者 0.5/0.9 配置及异质支配的全局支配；以及两类潜在任务类型上强度递增的交叉备择，外加难度相关的部分交叉。网格覆盖 $M \in \{3, 9, 20\}$ 、 $T \in \{100, 400, 1000\}$ 、 $R \in \{3, 5, 10\}$ 、完整数据、5% MCAR 与 3% 难度相关缺失；论文表聚焦 (9, 400, ·) 获取设计，每格 300 个 Monte Carlo 数据集（扫描中 150 个）。每格报告四种程序（plug-in；单切分冻结增益；重复交叉拟合增益；克隆校准 v3 判定）的支持、否证、弃答与错误率，对真实参数的区间覆盖，以及平均估计。结果（产物在 artifacts/diagnostics/calibration_v3/）：plug-in 在所有网格点的每个零假设上以约 1 的比率错误支持；v3 在各零假设与缺失性情形下把零假设支持率保持在名义水平或以下，其在备择上的功效随 R 增长（小 / 中等交互在 $R=3$ 下仍未解决，这作为弃答性质报告而非隐藏）。更早的八个机制派生类与四个基于重复的类（C9–C12，其中 C9/C10 现与注册的同代码克隆臂配对）继续匹配其哈希冻结期望状态；不变量测试还直接断言置换不变性、支配 $\neq$ 互补性、同一性拒绝及两个审查反例。

有限重复偏差与克隆零假设校准。 把 $\hat{q}_h(x)$ 记为重复平均估计，由 Jensen，对每题 $\mathbb{E} \max_h \hat{q}_h(x) \geq \max_h \mathbb{E} \hat{q}_h(x)$ ，当有限 R 噪声能改变逐题 argmax 时严格不等。plug-in 提升空间是两个此类最大值之差；Jensen 分别界定每一项，因此一般而言并不确立该差向上偏——在一个两成员两任务交叉例子中 plug-in 可能向下偏（真实 $H=0.40$ ，三次重复的期望 plug-in 约为 0.34）。被确立的是更强也更窄的命题：在同代码可交换性下，真实 H_{stable} 为零，而 plug-in 以趋近一的概率为正（逐题 argmax 上的选择噪声； $q=0.9$ 、 $M=9$ 、 $T=400$ 、 $R=3$ 的已知真值模拟中 $\hat{H}=8.83$ pp，密封克隆臂上描述性为 2.54 pp）。因此校准程序从不凭 plug-in 判定：发现 / 验证交叉拟合在发现重复上冻结逐题成员映射，在留出重复上对照最佳固定成员评分（使全局支配成员总是被冻结选中），真实减克隆差用双臂 Monte Carlo 随机化参考移除残余的有限 (R, T) 选择噪声成分（+1 校正；在等能力边界精确，在整个支配网格上经验检查而非解析断言；附录 H）。同一性门控通过要求来源验证的独立执行直接处理退化情形；没有不同来源的相同矩阵被拒绝。

D 类与 E 类形式定义。 D 类评估一个冻结的确定性政策 $\pi_Z : Z(x) \mapsto h$ ——执行前特征（题目文本、冻结机制标签、训练折开准确率），仅在开发任务上拟合——按 $D(\pi_Z) = \mathbb{E}_x[Y(x, \pi_Z(x)) - Y(x, h_{\text{dev-fixed}})]$ ，并带弃答规则：当 top-2 选择概率差距低于冻结边界时回退到 bare。E 类在均匀逐任务调用预算 b 、 $\lambda=1$ 损害加权（一次回归抵消一次修复）下评估 $U_b(\pi) = \mathbb{E}_x[\Delta(x, \pi(x))]$ ；仅当逐记录证据在每个被评估成员一任务对上验证预算时它才可受理，否则弃答。

在人工构建已知真值控制上的验证。 冻结包有两层：原八个机制派生类 $\times 2$ 实例（16 个控制，期望不变），加四个基于重复的类 $\times 2$ 实例，演练单次控制无法到达的稳定

性路径——全局支配 (C-rank SUPPORTED, C-comp REFUTED)、等均值交叉技能 (C-rank INSUFFICIENT, C-comp 在克隆校准下 SUPPORTED, 可见层使 D/E SUPPORTED)、条件混合陷阱与克隆重复陷阱 (后两者必须弃答); C9/C10 按 v3 判定要求携带注册的同代码克隆臂。期望状态在任何盲测运行之前冻结于哈希清单, 并由生成机制导出。不变量测试还断言置换不变性、支配 $\neq$ 互补性、同一性拒绝、两个 2026-09-19 审查反例 (iid 噪声与 0.5/0.9 支配不得支持; 交叉在重复充足时必须支持), 以及判定从不在无克隆臂时支持。校准在所有状态单元上匹配; 盲测集 (12 个控制加 2 个审核者挑战, 在当前代码下从预提交、哈希绑定的规格重新执行) 在全部 14×6 单元上匹配: 零错误支持, 正控制被识别, 弃答上限成立。这些离散控制补充但不取代 §6 的 Monte Carlo 错误支持 / 功效校准——后者才是确立 v3 检验统计规模的东西。更早存储的、其 CH2 数字与自身规格矛盾的挑战结果 (生成规则强制 0.79 时最佳固定 0.94 不可达) 仅作为来源保留; 忠实于规格的重新执行在每个单元上匹配审核者预提交期望。

在存档上的应用。 应用于 MATH-500 存档 (36 成员 $\times$ 400 题) 与 18 单元 BIRD Phase-II 存档。在 BIRD 上, 完整性类 (A) 对每个单元为 REFUTED_WITHIN_SCOPE: 冻结输入清单包含重叠的采集文件, 其行在 canonical 键上重复 (由存档的先写先得策略解决, 并记录判定冲突计数), 因此下述覆盖数字在该去重视图上计算, 而非在无冲突存档上; 评分器重放在此路径上不执行, 被报告为未运行而非通过。在此范围内, 所有单元显示单次覆盖 (B SUPPORTED); 稳定性、可选择性与可部署性按冻结规则为 INSUFFICIENT_EVIDENCE, 因为存档不含匹配重复也没有供政策训练的开发 / 评估划分——不是因为成本缺失: 逐记录逻辑调用已存档且现已读取 (核心子集单元共 288,104 次调用), 但 token / 美元成本仍不可恢复。在 MATH 上, 冻结选择政策在 400 道评估题的前 80 道上训练 (这 80 道从所有 D/E 命题中留出; 存档不含开发集执行: 附录 J 的 100 题开发划分仅用于生成冒烟测试, 故政策划分从评估侧切出, 留下 320 道计分题), 在每道评估题上与开发固定 (bare) 持平, 因此可选择性与可部署性为 INSUFFICIENT_EVIDENCE 而非被否认。三个已发表数字被修正 (结果向量计数的成员口径, 现为计入 bare 的 33/36 成员与 32/35 生成 harness; 生成 harness 准确率范围 0.6825–0.915, 此前印为 0.68–0.87; 最佳固定 = bare 的提升空间分解明确写出), 两个过载的指标名被消歧 (并集全败对任一候选失败), 一个保留判定控制在显式定义下确认了报告的一对数字 (联合修复 76.0% / 并集全败 0.8%)。对全部 14,400 条 MATH 判定的版本化端点敏感评分器的一次哈希绑定重执行改变了其中 14 条——全是单一任务 (math500_split#103) 上 v1 对区间端点答案的错误拒绝; v1 重放本身内部一致, 而更早存储的零翻转产物无法从提交代码复现, 已被取代。因此新评分器旨在捕获的括号合并缺陷确实在此存档中触发, 且恰在一个任务上。

I WP-1R/WP-2R 新采集: 协议与执行记录

冻结协议。 获取协议 (review-stage/REAL_EVIDENCE_PROTOCOL_V1.md, v1.0 于 2026-09-15 冻结, 带日期修订: v1.1 (统计与预算修复) 与 v1.2 (操作性测试规格) 先于任

何验证性结果：v1.3（尝试上限 45,000→60,000，与任务授权匹配）与并发修订（2→6）为吞吐而在采集中途作出，作为条件相关历史披露）固定了：面板抽取（以冻结的重复 0 平均逻辑调用 ≤ 3.05 为资格——这是一个预算可行性筛选，已披露为使面板偏向低调用机制，而非 35 个生成成员的均匀抽样；然后是加盐哈希抽取，每个构建器一个分层席位加两个自由席位，盐 `wp1r-panel-v1-20260915`，记录于 `WP1R_PANEL_DRAW.json`）；每臂 $R=3$ 次新重复；九个槽位的同代码克隆臂（`clone-c1..c9`，与 `bare` 来源逐字节相同）作为可交换的等能力参考；冻结 MATH-500 划分的 400 评估与 100 开发任务（SHA256 已记录）；评估任务此前在单次小型审核中分析过，故结果标注为回顾性任务 / 前瞻性执行，而非未见任务验证。

统计程序（v3，2026-09-19 审查之后）。 主要互补性统计量是 §6 的交叉拟合冻结选择增益 G ：三折中的每一折，用两次重复冻结逐题成员映射与最佳固定成员，第三次重复把冻结映射对照该固定成员评分； G 是逐题均值在折上的平均。并列处理是标签对称的：由于 $R=2$ 发现分数落在 $\{0, \frac{1}{2}, 1\}$ 上且高准确率下并列占主导，确定性字典序规则会使选择偏向列表中第一个成员，因此按（折、题）抽取 iid $U(0, 10^{-9})$ 抖动并对十个冻结并列实现取平均；一个关于支配成员位置的模拟验证该统计量与顺序无关。判定统计量是两臂都完整的任务交集上的真实减克隆差 $D = G_{\text{real}} - G_{\text{clone}}$ 。其参考分布使用 4,000 次双臂随机化：在每题每重复内，每臂独立置换成员标签并重算 D （开发中否决了跨重复的单一联合置换，因为它保留真正的交叉映射、不会使其归零）。配对题目 bootstrap（2,000 次抽取，种子 20260915）给出 95% 区间。冻结规则仅在以下条件全部满足时发出 SUPPORTED：覆盖门控通过（任一臂不完整题目 $\leq 10\%$ ；配对任务 ≥ 30 ）、随机化 $p < 0.05$ 、bootstrap 下界为正、 $D > 1.0$ pp、且 G_{real} 自身下界为正；REFUTED 要求 D 上界在界线内且等效 p 很小；否则 INSUFFICIENT。任一状态即终止研究、不再重跑的接纳规则保留。更早的 v2 程序——在重复 2-3 上对照 `bare` 评分的发现重复 `argmax`（A8.6）——作为有标签的次要统计量保留，不是互补性检验（在 `bare` 为 0.5、其他成员为 0.9 的纯全局支配下，其期望约为 $0.5(1 - 0.1^8) \cdot 0.4 \approx 0.20$ ）。两个冻结敏感性分支伴随它（题内可用重复均值插补；排除双重执行冲突单元）。

执行记录与续跑合并。 采集在 60,000 尝试全局预算与逐单元原子预留于 2026-09-15 至 2026-09-19 进行。两次提供方超时停止（2026-09-17、2026-09-18）把真实臂拆到三个续跑账本、克隆臂拆到两个；每个续跑在合并时逐字段重新绑定相同的冻结求解器条件。合并规则是确定性的：已完成观察胜过 `unknown_remote` 标记；同一单元的已完成记录中最早账本胜出。在真实臂的 19,318 行中，它合并了 8,418 个迁移副本、有 14 次优先取已完成记录而非 `unknown-remote` 标记、有 9 次补全了更早的 `unknown` 标记，并发现 5 个单元有两次已完成但不一致的执行（保留先完成者；一个冻结敏感性分支改为排除它们）。克隆臂的 14,967 行合并为 10,800 个唯一单元（4,160 个副本，0 个冲突）。72 个单元在所有账本中保持 `unknown_remote`，在结果矩阵中保持 NaN——绝不插补——故 v3 覆盖门控排除其题目，并报告极值未知单元界。合并后的臂经哈希密封（`SEALED_eval_real.json`、`SEALED_eval_clone.json`、`SEALED_dev_real.json`）。三个采集器来源版本跨续跑服务真实臂（并发 2/2/6）；每个密封记录该臂绑定的

采集器哈希，同一性门控排除运行身份字段（获取 id），同时本附录披露并发与修订历史。分析代码、校准模拟及其单元测试在 `experiment/diagnostics/ccomp_v3.py`、`experiment/diagnostics/calibration_sim.py` 与 `experiment/revision/wp1r_analysis.py`。

预算语义与已实现账目（E4）。 报告三种不同的比较且绝不混淆。(i) 等槽位采集：两臂都执行九个成员 / 槽位、三次重复；这是随机化设计，不意味着匹配花费。(ii) 共同任务执行预算（表 4, §5.4）：在 $b = 3, \dots, 27$ 次逐任务执行下，离线比较开发排序面板组合与 27 次同代码执行中的 b 次，采用 oracle 与多数聚合。(iii) 已实现花费：逐请求账目分层为实验运行 > harness 执行 > 逻辑调用 > 提供方尝试；迁移副本排除。真实臂作出 22,192 次逻辑调用（32,097 次提供方尝试；54.17 M 已知 token；每评估题 54.5 次调用），而克隆臂为 10,800 次逻辑调用（10,804 次尝试；14.51 M token；每题恰好 27 次）——由多调用面板成员驱动的 $2.05\times$ 调用比与 $3.73\times$ token 比；在冻结盈亏平衡价下的保守上限为 1,803.82 对 483.15 元人民币（定价不可独立验证；报告为 token 数乘以冻结的每 1M token 33.3 元，绝不作为计费金额）。全部臂的总计：38,458 逻辑调用、50,817 尝试、79.8 M 已知 token、2,656.22 元上限。因此我们不作已实现成本匹配主张；共同预算表才是成本受控的比较。

选择器规格（E3）。 π_Z 是在 TF-IDF 题目特征（最多 300）与仅在训练折内计算的逐成员开发准确率上的多项 logistic 回归；在 100 道开发题上作 5 折题目级 CV，同题重复绝不跨折拆分；折模型平均；并列以成员 id 打破；当 top-2 概率差距低于 0.15 时弃答至 **bare**。重复聚合使用逐成员一题的可用重复均值（同题重复留在一折）。比较器：**bare**、开发固定、预先固定随机成员（带种子）、M1b（缺失单元上带 bare 回退的开发固定）。 E_1 （预算按构造满足）不适用，因为面板成员发起不止一次调用； $b=3$ 次逐题调用的 E_b 作为单独命名的估计目标报告。泄漏控制：不使用答案、正确性、评估派生难度、执行后轨迹或评分器特征。

Policy	Eval acc. (%)	Δ vs dev-fixed (pp) [95% CI]
bare (fixed)	94.96	0.00 [0.00, 0.00]
dev-fixed	94.96	—
random (pre-fixed)	85.14	-10.12 [-13.27, -7.22]
M1b (dev-fixed + bare fallback)	94.96	0.00 [0.00, 0.00]
π_Z (frozen selector)	94.96	0.00 [0.00, 0.00]

表 12: 400 道 MATH-500 评估题上的 **WP-2R** 冻结比较器集（三次新重复的重复均值正确性；回顾性任务、前瞻性执行——不作未见任务主张）。配对差为逐题对照开发固定，配题目级 bootstrap CI。

J 跨领域重复：MATH-500 小型审核

为检验 Phase-II 干净协议的发现（无门控自由生成产生不同的单次正确性向量）是否为文本转 SQL 所特有，我们在竞赛数学上重复了自由臂协议。

协议。 六个构建器（与 Phase II 相同模型），一个种子，各八个槽位，每槽位 $R=3$ 次原始尝试上限，中性有效性门控（机制盲：在两道开发题上检查解析、导入、接口与非空答案）。冻结目标 GLM-5.3-Flash（与 SQL 研究相同），温度 0。MATH-500 (Lightman et al., 2023)：500 道题在生成前冻结（100 开发 / 400 评估，种子 20260908）。100 道开发题仅用于生成侧冒烟测试，从不在评估存档中执行；因此附录 H 的选择政策实验从评估侧切出其训练划分（80 道题），留下 320 道计分题供 D/E 命题。评分器：两侧均解析为数字时取数值相等（含 a/b 、 $\frac{a}{b}$ 、小数），否则取归一化 LaTeX 字符串相等（去除单位、进制下标、°；保留 `\text{X}` 内容；`pmatrix` $\rightarrow$ 元组）。评分器自洽性：400/400 标准答案与自身比较均判对。匹配答案格式指令下 bare 准确率为 0.9375。产出：48 槽位接纳 35 个（ R_{artifact} 0.10–1.00；两个重推理构建器 GLM-5.3 与 Qwen3.8-Max 在多数槽位于发出代码前即耗尽 32k token 生成预算——按实际情况报告）。这一约束实际上把六个构建器中的两个移出了被评估池，因此自由臂种群对重推理构建器风格代表性不足；我们不在事后调整预算，该限制是所报告协议的一部分。这是重复探查，不是析因研究：无策略强制、无一致性门控。

结果（35 个 harness，400 道评估题）。 平均成对结果分歧 10.6%（最大 33.0%）；计入 bare 时 36 个成员中 33 个有唯一结果向量（35 个生成 harness 中为 32 个）；结果相同的对占 0.7%——没有 Phase-I 式坍塌的迹象。对 bare 错题的联合修复为 76.0%；全部生成候选的并集在 0.8% 的 bare 答对题上失败（这是并集全败率，不是任一候选或路由器损害）。观测 oracle 覆盖超出 bare 4.75 pp，而最佳固定成员就是 bare 自身（0.9375；生成 harness 为 0.6825–0.915）：每个生成成员单独都更差。单次小型审核最初未采集重复执行或同代码克隆控制；这一缺口由同一 MATH-500 题集上新的预注册 WP-1R 采集补上 (§5.4)，它对一个八成员面板与九个同代码克隆槽执行三次独立重复，因此确实跨领域评估了稳定性估计目标。对全部 14,400 条存档判定的版本化端点敏感重评分的一次哈希绑定重执行改变了其中 14 条（0.097%）：全部是单一任务上 v1 对区间端点答案的错误拒绝，因此逐成员准确率至多上升一道题，任何定性结论都不变（附录 H）。一个更早的、报告零翻转的已存储产物无法从提交代码复现，仅作为来源保留。

两项失败侧观察。 第一，干净协议的多样性结果在第二个领域、不同输出空间上得到重复。第二，一个被隔离的试运行轮次（在 PROTOCOL_CHANGELOG.md 的 G1 条目中披露）提供了一项探索性比较：当相同六个构建器（被错误地）收到数值答案格式与 MATH-500 不匹配的 GSM8K 风格任务描述时，生成种群仍保持行为多样（16.2% 分歧，19 个唯一结果向量），但其联合修复坍塌至 18%——对灾难性成员的代码级检查逐字复现了 Phase-I 轨迹分类（一个先生成后验证的 harness，其验证器拒绝几乎所有答案，其回退返回过时的循环变量或“0”）。有多样性而无效用，由代码级检查不可见的提示侧协议错误诱发：检测到它的是测量任务本身，而非任何代码级审核。

范围。 一个种子、一个目标、无析因、探索性；造成 Phase-I 坍塌的 SQL 协议未在数学领域重跑，因此本重复只说明干净协议的结果，不涉及坍塌的边界。

领域 / 分析	n_H	n_{eval}	分歧	Oracle	最佳固定	H (pp)
BIRD, A / D	18 单元	1,169	—	76.14 / 75.70%	67.58 / 67.30%	8.56 / 8.40
BIRD, D-A	18 配对	1,169	—	—	—	-0.16
MATH-500, 自由	35	400	10.6%	98.50%	93.75% (bare)	4.75

表 13: 同一测量问题的平行领域证据。BIRD 是存档析因分析；MATH-500 是单种子探索性自由臂探查。两种设计不合并。提升空间是单次诊断量，不是选择器准确率或稳定互补性。

J.1 测量边界的平行领域证据

表 13 把两个领域就同一诊断问题并列呈现，但不合并。MATH-500 复现了该边界：单次分歧与 4.75 pp 提升空间与 bare 作为最佳固定成员（93.75%）并存。单次探查本身没有修复门控控制；克隆、重复与选择器控制来自单独的新 WP-1R 采集 (§5.4)。